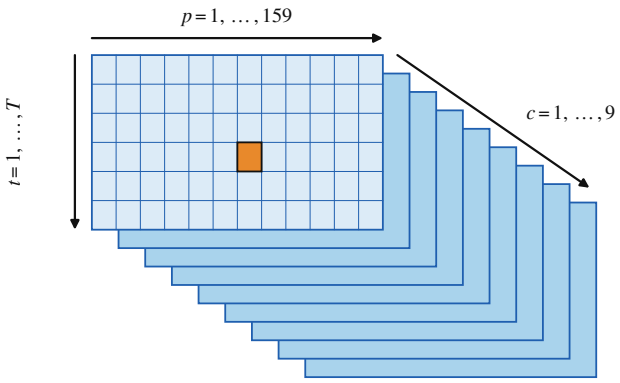
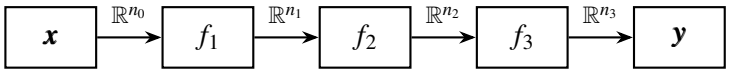
Rysunek 1.1 (plik: rozdzial-01.tex)



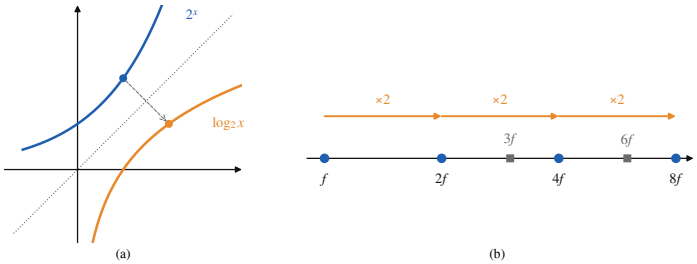
Tensor $X \in \mathbb{R}^{T \times 9 \times 159}$ jako stos dziewięciu macierzy (kanałów); przedni płat ($c = 1$) ma narysowaną siatkę: T wierszy (oś t, w dół) i 159 kolumn (oś p, poziomo), a kolejne kanały leżą za nim (oś c). Pomarańczowa kratka to jeden element $X_{t,c,p}$; trzy indeksy jednoznacznie wskazują jedną liczbę.

Rysunek 1.2 (plik: rozdzial-01.tex)



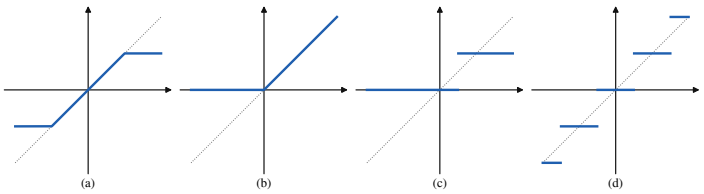
Złożenie trzech funkcji $\boldsymbol{y} = f_3(f_2(f_1(\boldsymbol{x})))$. Nad strzałkami stoją przestrzenie, w których żyje wynik każdego kroku; wyjście jednej funkcji musi mieć kształt wejścia następnej.

Rysunek 1.3 (plik: rozdzial-01.tex)



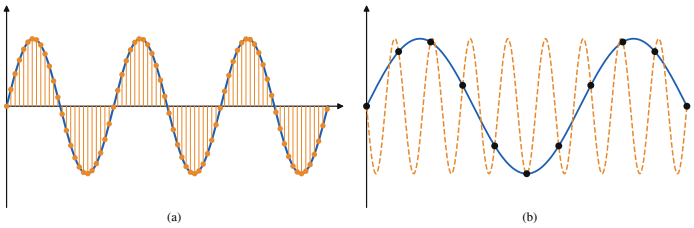
(a) Funkcje 2^x (niebieska) i $\log_2 x$ (pomarańczowa) są swoimi lustrzanymi odbiciami względem prostej $y = x$ (kropkowana): odbicie punktu $(2,4)$ to $(4,2)$. (b) Na osi logarytmicznej kolejne podwojenia $f, 2f, 4f, 8f$ leżą w równych odstępach (pomarańczowe strzałki mają tę samą długość); punkty $3f$ i $6f$ też dzieli dokładnie jeden taki krok, bo $\log_2 6 - \log_2 3 = 1$.

Rysunek 1.4 (plik: rozdzial-01.tex)



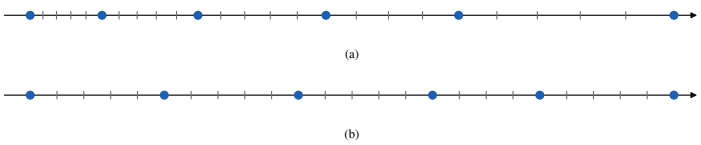
Cztery proste funkcje jednej zmiennej na tle prostej $y = x$ (kropkowana). (a) $\mathrm{clip}(x, -1, 1)$ przycina wartości do przedziału. (b) $\max(0, x)$, czyli ReLU, zeruje wartości ujemne. (c) Wskaźnik $\mathbb{1}\left[x \geq \frac{1}{2}\right]$ jest równy 1 albo 0. (d) $\mathrm{round}(x)$ zaokrągla do najbliższej całkowitej. Funkcje (c) i (d) mają skoki, więc nie da się ich używać w uczeniu przez gradient; dlatego dekoder w rozdziale **??** jest poza siecią.

Rysunek 2.1 (plik: rozdzial-02.tex)



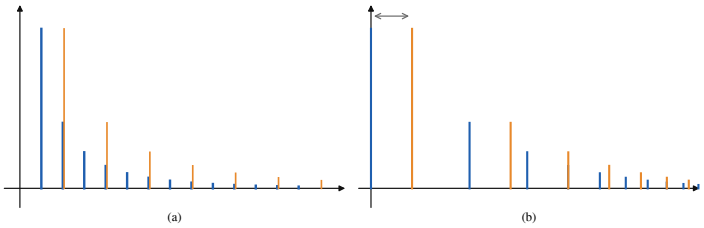
(a) Sinusoida 440 Hz (niebieska) i jej próbki przy $f_s = 11\,025$ Hz (pomarańczowe kropki): około 25 próbek na okres. (b) Aliasing: niebieska sinusoida $0{,}15 f_s$ i pomarańczowa przerywana $-\sin$ o częstotliwości $0{,}85 f_s$ przechodzą przez te same punkty (czarne kropki), więc po spróbkowaniu nie da się ich rozróżnić.

Rysunek 2.2 (plik: rozdzial-02.tex)



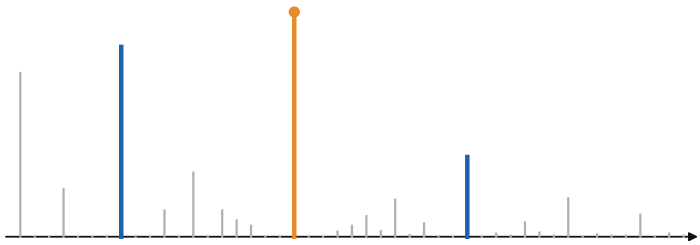
Nuty od E2 do E4 (kreski) i sześć strun (niebieskie kropki). (a) Na osi liniowej częstotliwości odstępy między półtonami rosną: ostatni jest ok. 3,8 raza większy niż pierwszy ($2^{23/12}$), więc niskie nuty tłoczą się przy zerze. (b) Na osi $\log_2 f$ wszystkie półtony są równo oddalone o $1/12$ (z tw. **??**). Dlatego model liczy bliskość nut w półtonach, a nie w hercach.

Rysunek 3.1 (plik: rozdzial-03.tex)



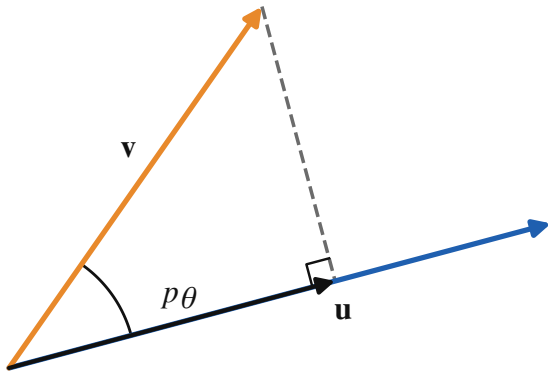
Widma szarpniętych strun liczone FFT. (a) Oś liniowa: prążki E2 (niebieskie) i E3 (pomarańczowe, nieco przesunięte w prawo, żeby były widoczne). Każdy prążek E3 pada na parzysty prążek E2 (tw. **??**). (b) Oś w półtonach $12\log_2(f/f_{E2})$: wzorzec prążków E2 (niebieskie) i A2 (pomarańczowe) to ta sama figura przesunięta o 5 półtonów (strzałka); kształt zależy tylko od numeru alikwotu, nie od wysokości.

Rysunek 3.2 (plik: rozdzial-03.tex)



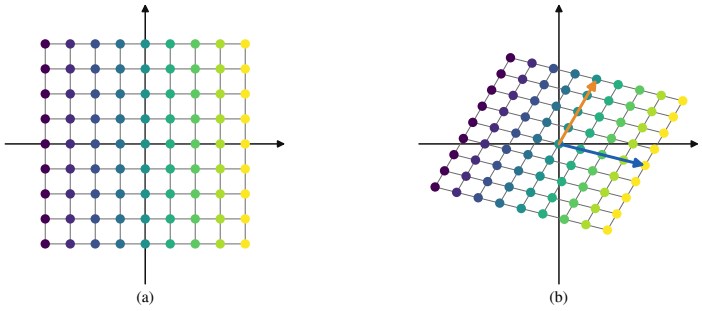
Salience (suma energii sześciu pierwszych alikwotów) dla szarpniętej struny E3 ($m = 52$) w funkcji numeru kandydata m. Prawdziwa nuta (pomarańczowa) ma najwyższy słupek, ale kandydat o oktawę niżej ($m = 40$, niebieski) jest niewiele niższy, a ten o oktawę wyżej ($m = 64$) też wyraźnie się wyróżnia. Wszystkie wartości liczone z widma FFT jednej nuty.

Rysunek 4.1 (plik: rozdzial-04.tex)



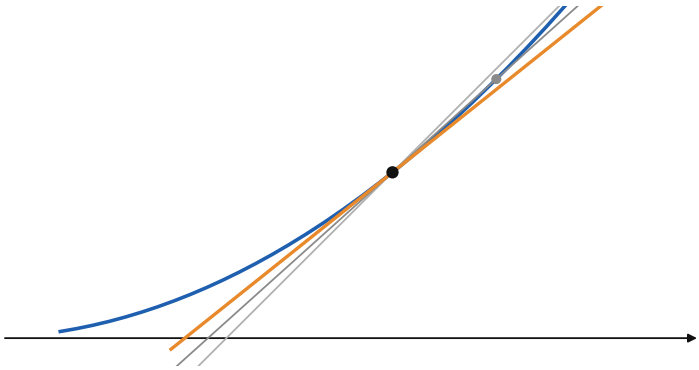
Rozkład z dowodu tw. **??**. Wektor $\boldsymbol{v}$ (pomarańczowy) rzutujemy na kierunek $\boldsymbol{u}$ (niebieski): rzut p (czarny) jest równoległy do $\boldsymbol{u}$, a odcinek kreskowany $\boldsymbol{r} = \boldsymbol{v} - \boldsymbol{p}$ jest do niego prostopadły (kąt prosty). Długość rzutu to $\|\boldsymbol{v}\| \cos\theta$, więc $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = \|\boldsymbol{u}\| \, \|\boldsymbol{v}\| \cos\theta$.

Rysunek 4.2 (plik: rozdzial-04.tex)



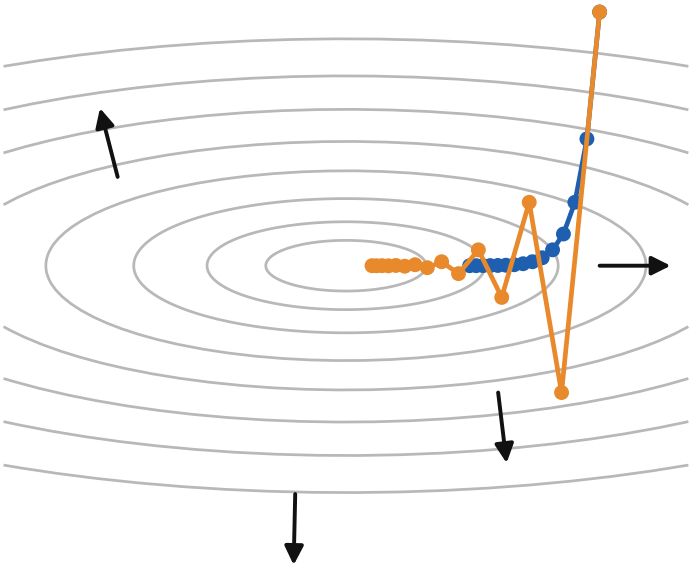
(a) Siatka punktów 9×9 w kwadracie $[-1,1]^2$, pokolorowana według współrzędnej x (od fioletu do żółci). (b) Obraz tej siatki po przekształceniu $\boldsymbol{x} \mapsto A\boldsymbol{x}$ z kolumnami $A\boldsymbol{e}_1$ (niebieska strzałka) i $A\boldsymbol{e}_2$ (pomarańczowa). Kolory pozwalają śledzić każdy punkt: proste zostają prostymi, a pole kwadratu rośnie $|\det A| = 1{,}2 \cdot 1{,}6 + 0{,}7 \cdot 0{,}4 = 2{,}2$ razy.

Rysunek 5.1 (plik: rozdzial-05.tex)



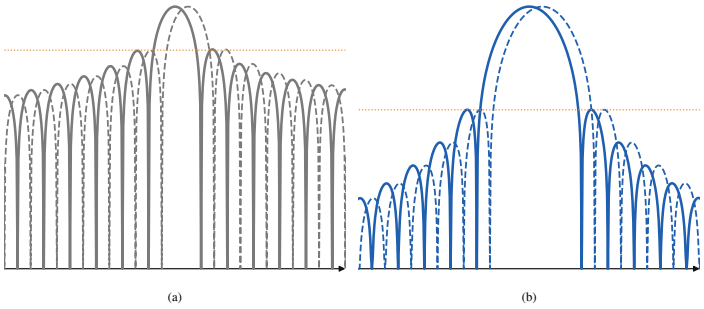
Pochodna jako granica nachyleń. Funkcja x^2 (niebieska) i sieczne (szare) przez punkt $(3,9)$ (czarny) i punkty oddalone o $h = 1{,}5$ oraz $0{,}75$. Gdy $h \to 0$, sieczna dąży do stycznej (pomarańczowa) o nachyleniu $f'(3) = 6$.

Rysunek 5.2 (plik: rozdzial-05.tex)



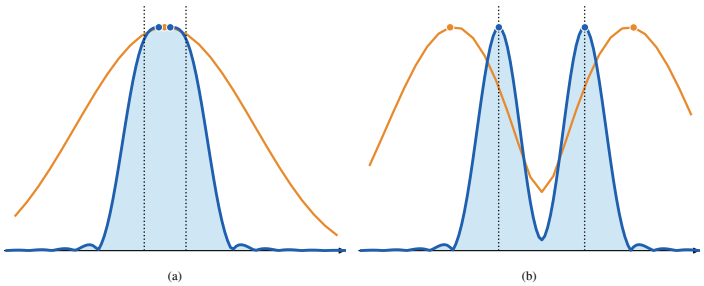
Spadek gradientu dla $L = \frac{1}{2}(x^2 + 10y^2)$ (szare warstwice) z punktu $(1,1)$. Czarne strzałki to gradient w kilku punktach: zawsze prostopadły do warstwicy i skierowany pod górę, więc krok idzie w przeciwną stronę. Niebieska ścieżka ($\eta = 0{,}05$, 14 kroków) schodzi gładko, ale wolno; pomarańczowa ($\eta = 0{,}15$) przeskakuje przez dolinę i zygzakuje. Obie obliczone programem.

Rysunek 6.1 (plik: rozdzial-06.tex)



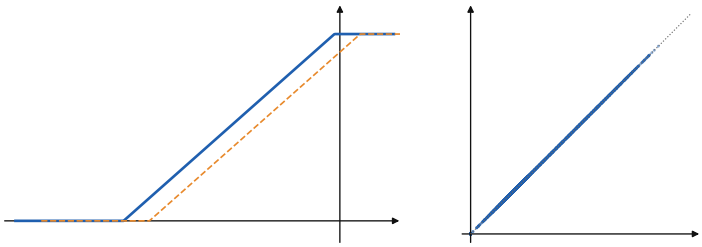
Widmo tonu z $N = 128$ próbek w decybelach (skala od -80 do $0\,\mathrm{dB}$, wspólna). Ton dokładnie w prążku (linia ciągła) i w połowie między prążkami (przerywana). (a) Okno prostokątne (szare): wąski pik, ale listki boczne opadają wolno; pierwszy ma $-13\,\mathrm{dB}$ (pomarańczowa kropkowana). (b) Okno Hanna (niebieskie): pik dwa razy szerszy, ale pierwszy listek tylko $-31\,\mathrm{dB}$ (pomarańczowa kropkowana), a dalsze opadają szybko. Ton między prążkami ma niższy pik w obu oknach.

Rysunek 6.2 (plik: rozdzial-06.tex)



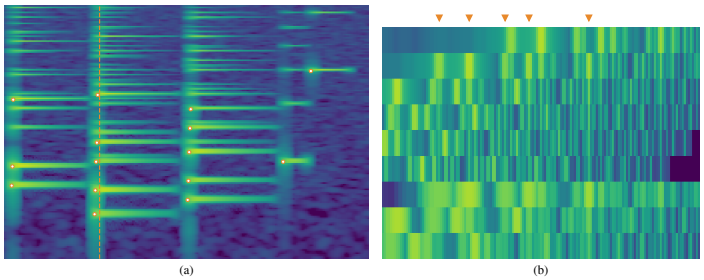
Widmo (okno Hanna) sumy dwóch sinusoid; czarne kropkowane pionowe linie to prawdziwe częstotliwości, kropki to znalezione piki. Niebieskie z wypełnieniem: okno $N = 4096$; pomarańczowe: $N = 1024$. (a) E2 i F2 (półton, 4,9 Hz): długie okno daje dwa bliskie piki w złych miejscach (interferencja), krótkie jeden szeroki pagórek. (b) E2 i F#2 (10,1 Hz): długie okno rozdziela tony prawie bez błędu położenia, krótkie daje dwa piki odsunięte od prawdy o kilka herców. Dlatego model dostaje dwa okna — długie dla wysokości, krótkie dla czasu — i uczy się łączyć wskazówki z wielu klatek.

Rysunek 7.1 (plik: rozdzial-07.tex)



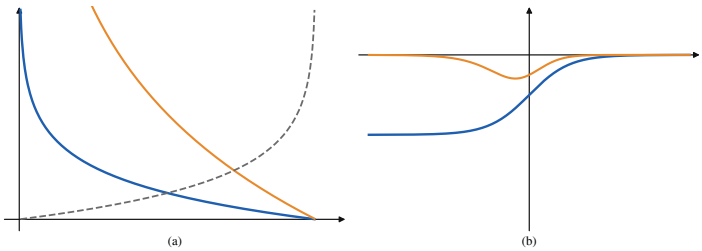
(a) Cecha jako funkcja $\log_{10} A$ (niebieska): płaski początek (cisza poniżej 60 dB od referencji), liniowy wzrost i przycięcie na 1,3. Nagranie 3 razy głośniejsze (pomarańczowa przerywana) ma tę samą krzywą, bo referencja przesuwa się razem z poziomami (tw. **??**). (b) Wartości cech tego samego nagrania (poziomo) i nagrania 10 razy cichszego (pion): wszystkie punkty leżą na przekątnej (kropkowana).

Rysunek 7.2 (plik: rozdzial-07.tex)



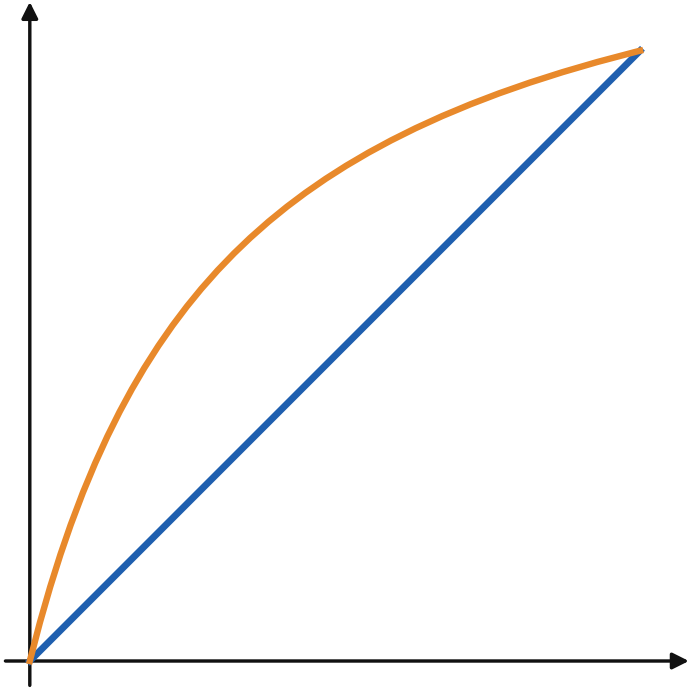
HCQT syntetycznego, 6-sekundowego nagrania gitary. (a) Kanał $h = 1$: czas poziomo (243 klatki), wysokość pionowo (159 binów); jasne ślady to alikwoty grających nut, kółka z pomarańczowym brzegiem to początki prawdziwych nut, przerywana linia to klatka pokazana w (b). (b) Cała jedna klatka: 9 kanałów (wiersze) $\times$ 159 binów (kolumny). Pomarańczowe trójkąty wskazują prawdziwe nuty: pod każdym z nich w kolumnie pojawiają się jasne plamy w wielu kanałach naraz, bo alikwoty kandydata ustawiono w jednej kolumnie.

Rysunek 8.1 (plik: rozdzial-08.tex)



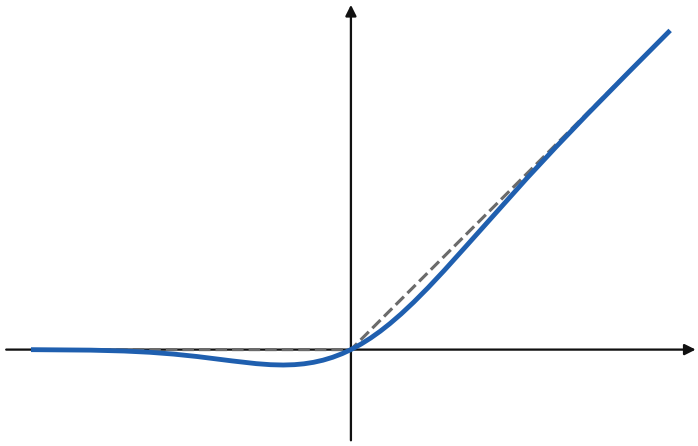
(a) Strata BCE w funkcji p: dla $y = 1$ ($-\ln p$, niebieska) i z wagą $\alpha = 4$ (pomarańczowa) rośnie do nieskończoności, gdy $p \to 0$; dla $y = 0$ ($-\ln(1-p)$, szara przerywana) rośnie, gdy $p \to 1$. (b) Gradient po logicie dla $y = 1$: BCE (niebieska, $\sigma - 1$) pozostaje blisko -1 przy dużym błędzie; gradient błędu kwadratowego (pomarańczowa) zanika w nasyceniu.

Rysunek 8.2 (plik: rozdzial-08.tex)



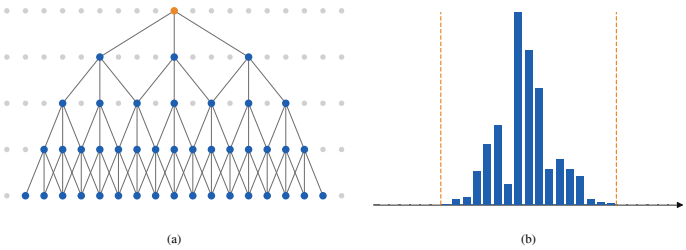
Optymalne prawdopodobieństwo p^* (pion) w zależności od prawdziwej częstości q (poziom) dla wagi $\alpha = 1$ (niebieska, leży na przekątnej) i $\alpha = 4$ (pomarańczowa, nad przekątną). Waga klasy dodatniej przesuwa wyjścia sieci w górę; dekoder (rozdział **??**) musi to uwzględnić przez progi dobrane na walidacji.

Rysunek 9.1 (plik: rozdzial-09.tex)



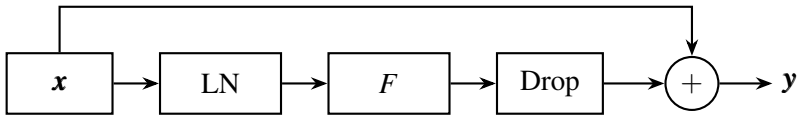
GELU (niebieska) i ReLU (szara przerywana). GELU jest gładką wersją ReLU: w odróżnieniu od niego ma niewielką ujemną „zatokę” (minimum ok. $-0{,}17$) i nie ma ostrego załamania w zerze, więc ma pochodną wszędzie.

Rysunek 9.2 (plik: rozdzial-09.tex)



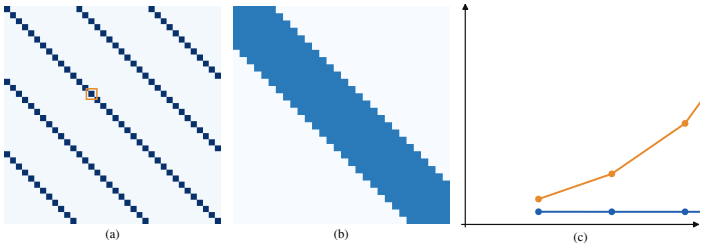
(a) Schemat czterech konwolucji czasowych z jądrem 3 i dylatacjami 1 (trzon), $1, 2, 4$ (od wejścia na dole do wyjścia na górze): pomarańczowa kropka to jedna klatka wyjścia, niebieskie to klatki wejścia, od których zależy (zasięg $\pm 8 = 1 + 1 + 2 + 4$). Z dylatacją pole widzenia rośnie wykładniczo, a nie liniowo, przy tej samej liczbie parametrów. (b) Pomiar: moduł gradientu jednej wartości wyjścia po wejściu w funkcji odległości w klatkach dla stosu z trzonem 3×7 i trzema blokami z dylatacjami $1, 2, 4$ (losowe wagi, PyTorch): gradient jest niezerowy dokładnie dla $|t| \leq 8 = 1 + (1 + 2 + 4)$ (niebieskie) i zerowy poza (szare).

Rysunek 9.3 (plik: rozdzial-09.tex)



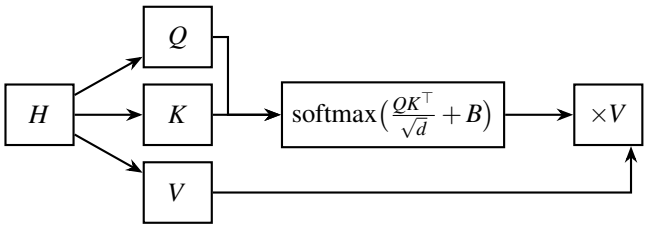
Blok resztkowy typu „pre-norm”, jak w warstwach Gen 6: wejście $\boldsymbol{x}$ jest normalizowane (LN), przechodzi przez F (konwolucja albo uwaga) i dropout, a następnie dodawane do niezmienionego $\boldsymbol{x}$ (górna ścieżka). Wynik: $\boldsymbol{y} = \boldsymbol{x} + \mathrm{Drop}(F(\mathrm{LN}(\boldsymbol{x})))$.

Rysunek 10.1 (plik: rozdzial-10.tex)



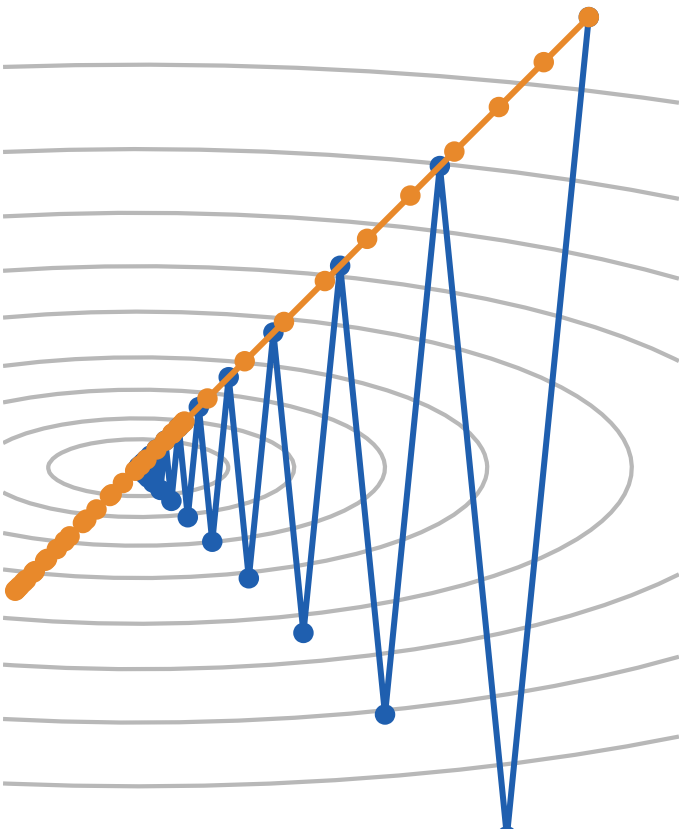
(a) Zabawka: 36 półtonów, a zapytanie i klucz to wskazanie klasy wysokości $(i \bmod 12)$. Każdy wiersz macierzy wag α ma ciemne pola tylko dla tej samej klasy, czyli co 12 półtonów: wysokość 14 (pomarańczowa ramka) patrzy na 2, 14 i 26 — uwaga potrafi „zobaczyć” oktawy. (b) Maska okna $|t-u| \le 5$ dla 30 klatek: tylko pasmo wokół przekątnej ma niezerowe wagi. (c) Odchylenie standardowe $\langle \boldsymbol{q}, \boldsymbol{k} \rangle$ dla wymiarów $d = 4, 16, 64, 256$ (oś pozioma $\log_2 d$): bez skalowania (pomarańczowa) rośnie jak $\sqrt{d}$, po podzieleniu przez $\sqrt{d}$ (niebieska) jest równe 1. Obliczone z 10^5 losowych par.

Rysunek 10.2 (plik: rozdzial-10.tex)



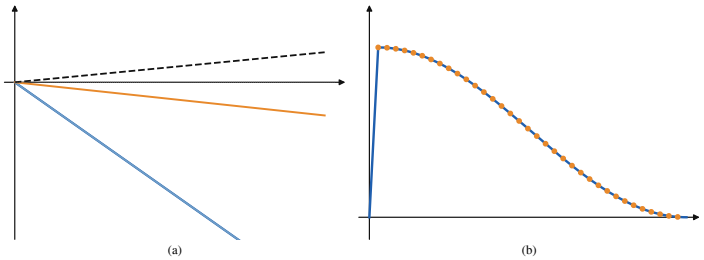
Przepływ danych jednej głowicy uwagi. Wektory cech $H \in \mathbb{R}^{n\times D}$ są rzutowane na $Q, K, V \in \mathbb{R}^{n\times d_h}$; iloczyny $QK^\top \in \mathbb{R}^{n\times n}$ (wyniki dopasowania), dzielone przez $\sqrt{d}$ i powiększone o premie B, przechodzą przez softmax wiersz po wierszu; powstałe wagi mnożą V i dają wyjście $n \times d_h$.

Rysunek 11.1 (plik: rozdzial-11.tex)



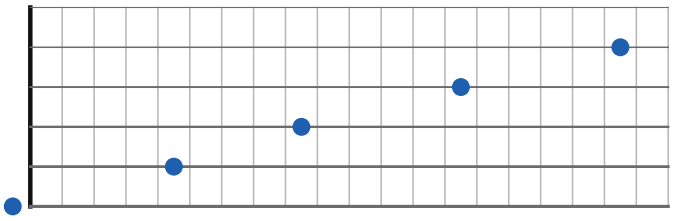
Ta sama dolina $L = \frac{1}{2}(x^2 + 10y^2)$ co w rozdziale **??**, start $(1,1)$, 40 kroków. Niebieska: spadek gradientu z optymalnym krokiem $2/11$ (strata końcowa $6 \cdot 10^{-7}$). Pomarańczowa: Adam z $\eta = 0{,}1$ (strata końcowa 0,056: długie kroki w obu osiach, ale potem drży wokół minimum). Szare warstwice to poziomy strat. Na tej prostej paraboli, przy idealnie dobranym kroku, wygrywa zwykły spadek gradientu. Obie ścieżki obliczone programem.

Rysunek 11.2 (plik: rozdzial-11.tex)



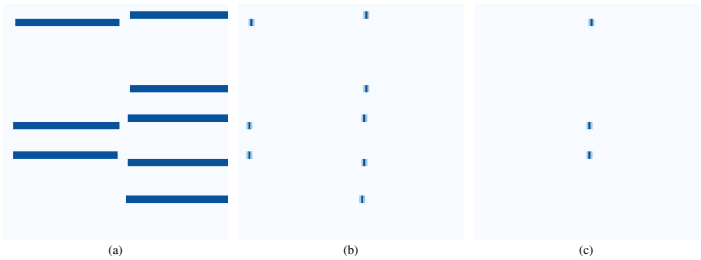
(a) Spadek gradientu dla $\lambda = 10$ ($\log_{10}|x|$ w kolejnych krokach): $\eta = 0{,}05$ (niebieska) i 0,15 (jasnoniebieska) zbiegają; $\eta = 0{,}19$ (pomarańczowa) zbiega z wolno gasnącym drżeniem; $\eta = 0{,}21 > 2/\lambda$ (czarna przerywana) rozbiega się. Szara kropkowana to poziom początkowy. (b) Harmonogram kroku z rozgrzewką i spadkiem kosinusowym (niebieska) oraz wartości zapisane w dzienniku prawdziwego uczenia Gen 6 po każdej epoce (pomarańczowe kropki): leżą dokładnie na krzywej.

Rysunek 12.1 (plik: rozdzial-12.tex)



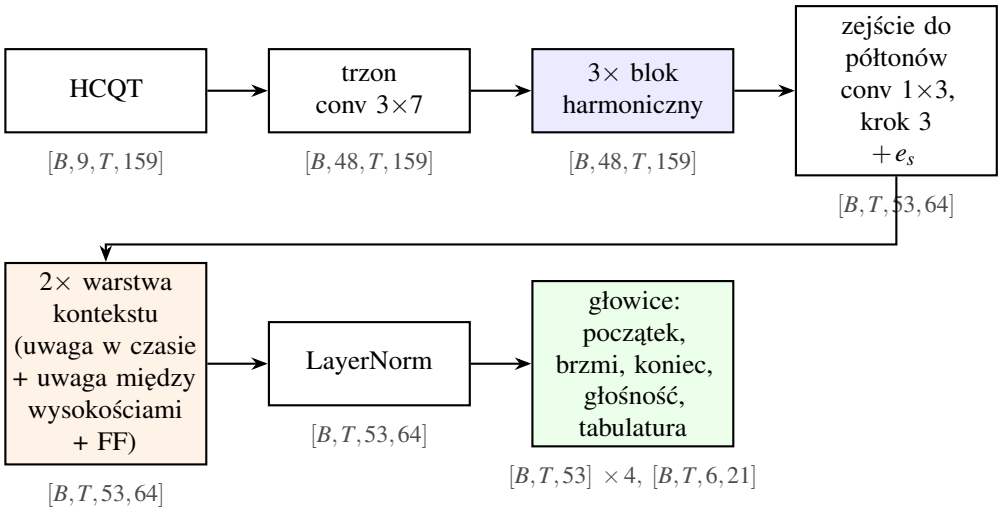
Gryf z 20 progami; struny od najcieńszej (góra) do najgrubszej (dół). Niebieskie kropki to wszystkie pięć pozycji nuty E4: próg 0 (struna pusta, kropka przed siodełkiem), 5, 9, 14 i 19. Wysokość nie wystarcza do ustalenia pozycji; o strunie decyduje barwa dźwięku (struny o różnej grubości mają inny rozkład alikwotów) i kontekst muzyczny.

Rysunek 12.2 (plik: rozdzial-12.tex)



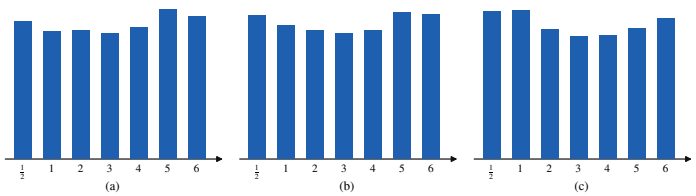
Mapy celów syntetycznego nagrania z 15 nutami (fragment: 110 klatek, półtony 4–35): (a) „brzmi” — poziome kreski trwających nut, (b) początki — pojedyncze kropki (jasne punkty to 1, ich pionowe sąsiedztwo w czasie to miękkie 0,4), (c) końce. Mapy początków i końców są rzadkie: tylko 0,12% komórek początków jest równa 1 (rozdział **??**). Mapy zbudowane kodem z repozytorium.

Rysunek 13.1 (plik: rozdzial-13.tex)



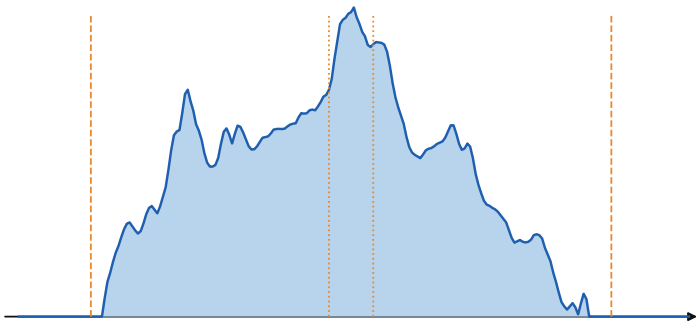
Przepływ tensorów w Gen 6 (B — liczba nagrań w paczce, T — liczba klatek). Pierwsza połowa (rozdz. **??**, niebieskie pole): cechy HCQT przechodzą przez trzon i trzy bloki harmoniczne, a potem „schodzą” z 159 binów do 53 półtonów (64 liczby opisu na każdą parę klatka–półton). Druga połowa (rozdz. **??**): dwie warstwy kontekstu (pomarańczowe pole), normalizacja i pięć głowic (zielone pole). Łącznie 249 219 parametrów.

Rysunek 13.2 (plik: rozdzial-13.tex)



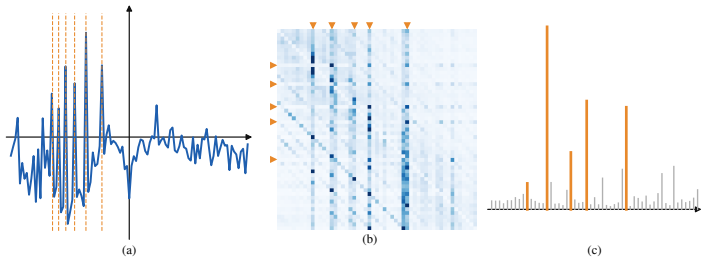
Średnie wartości bezwzględne wag W_h w grupach wejść odpowiadających alikwotom $h = \frac{1}{2}, 1, 2, 3, 4, 5, 6$ (pod słupkami) dla trzech bloków (a), (b), (c) prawdziwego, wytrenowanego modelu Gen 6 (skala pionowa wspólna, od zera). Wszystkie siedem miejsc ma wagi podobnej wielkości (0,088–0,107): żadne nie zostało „wyłączone". Wielkość wag nie dowodzi jednak ważności (brak badania ablacyjnego, zob. rozdział **??**).

Rysunek 14.1 (plik: rozdzial-14.tex)



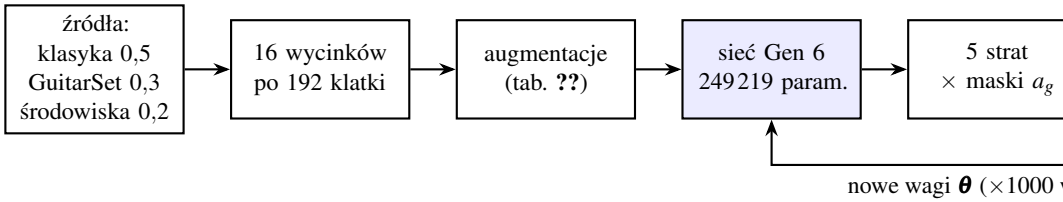
Pomiar pola widzenia prawdziwego modelu Gen 6: $\log_{10}$ modułu gradientu logitu początku w klatce t (jeden półton) po cechach wejściowych w klatce $t + \Delta t$, od -125 do 125 klatek (pomarańczowe pionowe: kropkowane ± 8 — zasięg samej części konwolucyjnej, przerywane ± 94 — zasięg całej sieci). Poza ± 94 zależności nie ma (wypełnienie opada do dna skali); wewnątrz maleje o kilka rzędów wielkości.

Rysunek 14.2 (plik: rozdzial-14.tex)



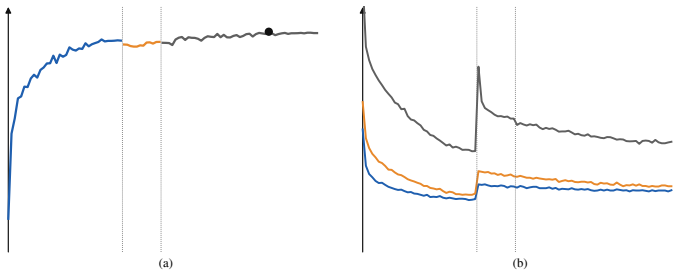
Uwaga między wysokościami w prawdziwym modelu Gen 6 (warstwa kontekstu 0). (a) Wyuczona premia r_d głowicy 2: niebieska krzywa, pomarańczowe przerywane linie to odległości $-12\log_2 h$ dla $h = 2,\dots,7$ ($-12, -19, -24, -28, -31, -34$). Dokładnie siedem odległości ma premię powyżej 0,6: sześć z nich to te interwały alikwotów, a siódma to $+12$. (b) Macierz wag uwagi (średnia z czterech głowic; wiersz — zapytanie, kolumna — klucz) w klatce nagrania, w której gra 5 nut (pomarańczowe znaczniki przy osiach to ich półtony). (c) Wiersz najniższej nuty ($m = 45$): pomarańczowe słupki to pozostałe nuty akordu; trafia w nie 45% całej wagi, podczas gdy równomierny rozkład dałby $4/53 = 7{,}5\%$.

Rysunek 15.1 (plik: rozdzial-15.tex)



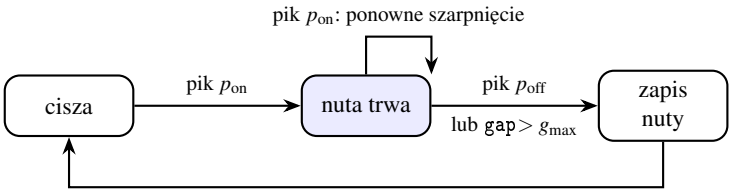
Jeden krok uczenia Gen 6. Z trzech źródeł (wagi losowania w ramce) losuje się 16 wycinków po 4,46 s, zniekształca je augmentacjami, przepuszcza przez sieć, liczy pięć strat z maskami dostępności etykiet, sumuje je do $\mathscr{L}$, przycina gradient do normy 1 i aktualizuje wagi optymalizatorem AdamW; po 1000 takich krokach kończy się epoka.

Rysunek 15.2 (plik: rozdzial-15.tex)



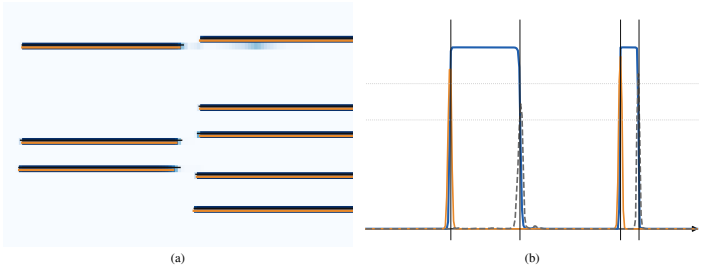
Prawdziwy przebieg uczenia Gen 6 (dziennik `docs/wyniki/epoki.csv`, 97 epok). (a) F1 nut na stałej próbie walidacyjnej 180 nagrań (skala od 66 do 93%): sesja 1 niebieska, sesja 3 pomarańczowa, sesja 4 ciemnoszara; czarna kropka to wybrana epoka 81 (90,27%). Pionowe linie rozdzielają sesje. (b) $\log_{10}$ strat uczących: początki (niebieska), brzmi (pomarańczowa), tabulatura (ciemnoszara). Skok strat na początku sesji 3 i 4 to efekt restartu kroku i nowych, trudniejszych danych.

Rysunek 16.1 (plik: rozdzial-16.tex)



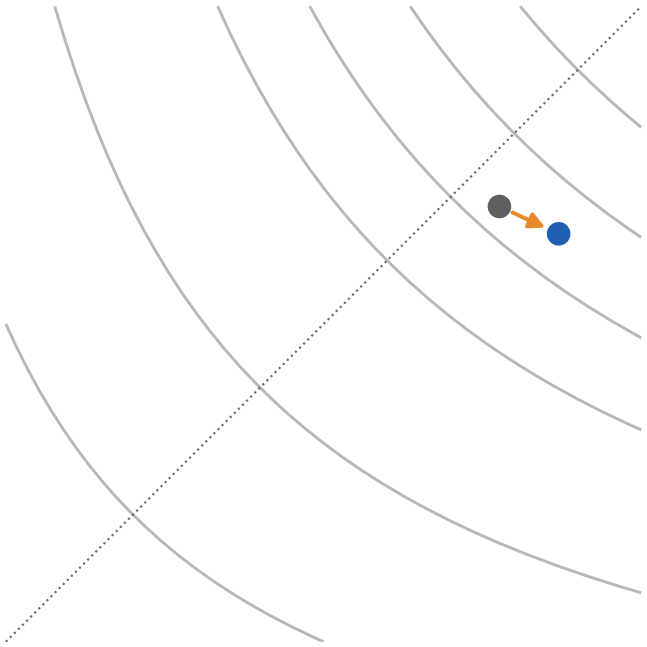
Maszyna stanów dekodera dla jednego półtonu. Z ciszy wychodzi się na piku początku; nuta trwa, dopóki $p_{\text{fr}} \geq \theta_{\text{fr}}$; kończy ją pik końca albo przerwa dłuższa niż $g_{\max}$ klatek; nowy pik początku w trakcie nuty kończy ją i zaczyna następną.

Rysunek 16.2 (plik: rozdzial-16.tex)



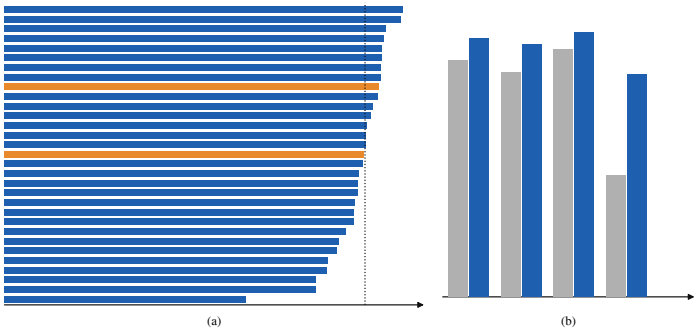
Dekoder na wyjściach prawdziwego modelu Gen 6 (syntetyczne nagranie z 15 nutami). (a) Mapa p_{fr} (jasność), fragment 110 klatek i półtony 4–39; czarne kreski — prawdziwe nuty, pomarańczowe — nuty z dekodera (każda para blisko siebie; największy błąd początku 18,7 ms). (b) Trzy głowice dla jednego półtonu z dwiema nutami: p_{fr} (niebieska), p_{on} (pomarańczowa), p_{off} (szara przerywana) i progi $\theta_{\mathrm{on}} = 0{,}6$, $\theta_{\mathrm{off}} = 0{,}8$ (kropkowane poziome); czarne pionowe kreski to początki i końce nut z dekodera.

Rysunek 17.1 (plik: rozdzial-17.tex)



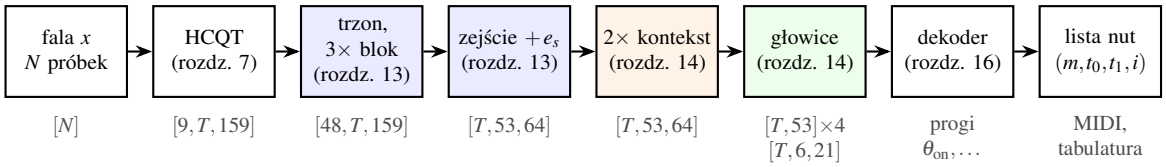
Płaszczyzna precyzja (poziom) – czułość (pion), od 0,5 do 1, z poziomicami F1 (szare linie, od 0,6 do 0,95; kropkowana to $P = R$). Szara kropka: dekoder domyślny ($P = 88{,}8\%$, $R = 84{,}2\%$), niebieska: dostrojony (93,5%, 82,1%); strzałka pokazuje zmianę. Precyzja rośnie o 4,7 punktu, czułość spada o 2,1, a punkt przechodzi na wyższą poziomicę (F1 ze średnich P,R: 86,5% $\rightarrow$ 87,4%); F1 jest tym większe, im bliżej górnego prawego rogu i im bliżej przekątnej. Raportowane makro-F1 (85,9% $\rightarrow$ 86,6%) jest liczone inaczej (przykład **??**).

Rysunek 17.2 (plik: rozdzial-17.tex)



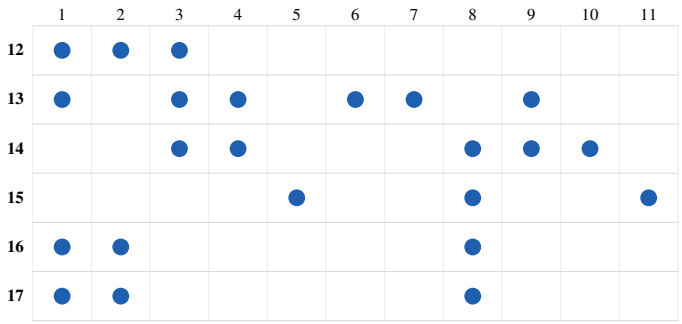
(a) F1 nut (makro) dla każdej z 31 grup testowych modelu końcowego (dekoder domyślny), od najlepszej do najgorszej; pomarańczowe słupki to prawdziwa gitara (GuitarSet), niebieskie — syntetyczne nagrania klasyki; kropkowana pionowa to wynik ogólny 85,94%. Najlepsze: pizzicato (95,0%), ukulele (94,5%), gitara klasyczna (90,9%, $n = 74$); najsłabsze: chór (57,5%), wiolonczela (74,3%), syntezator (74,3%). (b) Gen 5 (szare) i Gen 6 (niebieskie) na GuitarSet: F1 nut razem, akompaniament, melodie, nuty z końcem (od lewej).

Rysunek 18.1 (plik: rozdzial-18.tex)



Cała droga od fali do listy nut z kształtami tensorów (liczby zmierzone na prawdziwym modelu dla $T = 243$ w tab. **??**). Pola niebieskie to część konwolucyjna, pomarańczowe — kontekst z uwagą, zielone — głowice; dekoder nie ma parametrów uczonych gradientem.

Rysunek 18.2 (plik: rozdzial-18.tex)



Macierz zależności książki. Poziomo — rozdziały matematyki i narzędzi (1–11), pionowo — rozdziały o modelu (12–17); niebieska kropka oznacza, że rozdział o modelu wymaga danego rozdziału matematyki. Np. blok harmoniczny (rozdz. 13) wymaga alikwotów (3), widma i HCQT (6, 7), macierzy (4) i konwolucji (9); uczenie (rozdz. 15) — pochodnych (5), straty (8) i optymalizacji (11).