Jak słyszy Gen 6

Matematyka od zera i model transkrypcji gitary: od fali dźwiękowej do listy nut

Projekt Gutar

Przedmowa

Ta książka tłumaczy, jak działa model **Gen 6** z projektu *Gutar*: sieć neuronowa, która z nagrania gitary robi listę nut (wysokość, początek, koniec, a także strunę i próg). Nie zakłada niczego poza szkolną matematyką. Każde pojęcie, którego model używa — logarytm, widmo Fouriera, iloczyn skalarny, gradient, konwolucja, uwaga, entropia krzyżowa — jest najpierw wyjaśnione *od zera*, z obrazem, dowodem i przykładem policzonym do końca. Dopiero potem składamy z nich model, a na końcu zapisujemy go w całości jako jeden opis matematyczny.

Układ.. Część I (rozdziały 1–11) to matematyka. Część II (rozdziały 12–17) to model: dane i etykiety, architektura, uczenie, dekoder, wyniki. Część III (rozdział 18) to pełny opis matematyczny Gen 6 w jednym miejscu. Dodatki zawierają rozbicie liczby parametrów, ściągę wzorów i opis, jak odtworzyć wyniki.

Co tu jest prawdziwe.. Rysunki z rozdziałów o modelu powstały z *prawdziwego, wytrenowanego modelu* (plik `best.pt`, epoka 81, 249 219 parametrów): wagi, wyuczone premie uwagi, mapy uwagi, pole widzenia mierzone gradientem, wyjścia dekodera. Krzywe uczenia i wyniki testu pochodzą z zapisów projektu. Każda liczba z przykładów i rozwiązań ćwiczeń została sprawdzona programem (`weryfikacja.py`); w trakcie pisania kontrola wychwyciła kilka pomyłek, które poprawiono.

Czego tu nie ma.. Książka nie ukrywa ograniczeń modelu: większość danych uczących to synteza, nie badano wpływu poszczególnych elementów (brak ablacji), wynik pochodzi z jednego uczenia, a zachowanie na gitarze nagranej w innych warunkach jest niezmierzone (rozdział 17). Tam, gdzie coś jest obserwacją z wag modelu, a nie dowodem, napisano to wprost.

Oznaczenia.. Wektory piszemy pogrubioną kursywą ($\boldsymbol{x}$), przecinek dziesiętny zapisujemy jako 1,5. Hasła na marginesie to nowe pojęcia; podpisy rysunków mówią, co widać i co z tego wynika. Rysunki nie zawierają napisów: cały opis jest w podpisie. Uwagi zakończone znakiem $\diamondsuit$ to intuicje, pułapki i komentarze; szare pola to przykłady policzone na konkretnych liczbach.

Spis treści

Przedmowa **ii**

I Matematyka od zera **1**

1 Zapis, tensory i logarytm **2**
1.1 Po co ten rozdział? 2
1.2 Sumy i indeksy 2
1.3 Wektory, macierze i tensory 3
1.4 Funkcje i ich składanie 4
1.5 Potęgi i logarytm 4
1.6 Funkcje pomocnicze 5

2 Dźwięk, próbkowanie i wysokość **8**
2.1 Od drgania do liczb 8
2.2 Sinusoida 8
2.3 Próbkowanie 8
2.4 Półtony, MIDI i centy 10
2.5 Klatki czasu 11

3 Struna gitary i alikwoty **13**
3.1 Dlaczego nuta to nie jedna sinusoida? 13
3.2 Drgania własne struny 13
3.3 Wspólne alikwoty: skąd błąd oktawowy 14
3.4 Oś logarytmiczna: wzorzec, który się nie zmienia 15
3.5 Salience: jak wygląda błąd oktawowy w liczbach 16

4 Wektory i macierze **18**
4.1 Dlaczego algebra liniowa? 18
4.2 Wektor i iloczyn skalarny 18
4.3 Macierz jako przekształcenie 20
4.4 Ile parametrów ma warstwa? 21

5 Pochodne, gradient i propagacja wsteczna **23**
5.1 Jak poprawić model, który się myli? 23
5.2 Pochodna funkcji jednej zmiennej 23
5.3 Gradient i spadek gradientu 25
5.4 Propagacja wsteczna na jednym neuronie 26

6 Transformata Fouriera: z drgań do widma **29**
6.1 Co jest w tym nagraniu? 29
6.2 Liczby zespolone w dwóch zdaniach 29
6.3 Dyskretna transformata Fouriera 29

6.4 Przeciek i okno 30
6.5 Rozdzielczość: kiedy dwa dźwięki są jednym 32

7 HCQT: widmo ułożone harmonicznie **35**
7.1 Pomysł: niech każdy kandydat widzi swoje alikwoty w jednym miejscu 35
7.2 Biny logarytmiczne i alikwoty 35
7.3 Decybele i normalizacja 36
7.4 Kanały to przesunięte kopie jednego widma 37
7.5 Co dokładnie dostaje sieć 38

8 Prawdopodobieństwo i funkcje straty **40**
8.1 Jak powiedzieć modelowi, że się myli? 40
8.2 Sigmoida i softmax 40
8.3 Entropia krzyżowa 41
8.4 Dlaczego rzadkie etykiety są trudne 43
8.5 Softmax i tabulatura 44

9 Sieć neuronowa: warstwy, konwolucja i normalizacja **45**
9.1 Z czego zbudowana jest sieć? 45
9.2 Nieliniowość: po co i jaka 45
9.3 Konwolucja 45
9.4 Normalizacja warstwy i połączenia resztkowe 48

10 Uwaga (attention) **51**
10.1 Czemu konwolucja nie wystarcza? 51
10.2 Uwaga pojedynczego zapytania 51
10.3 Dlaczego dzielimy przez $\sqrt{d}$ 52
10.4 Uwaga dla całej sekwencji i premie położenia 52
10.5 Wiele głowic i liczba parametrów 54

11 Optymalizacja: jak sieć się uczy **56**
11.1 Od gradientu do działającego uczenia 56
11.2 Kiedy spadek gradientu się zbiega? 56
11.3 SGD i jego szum 57
11.4 Adam i AdamW 58
11.5 Harmonogram kroku 59

II Model Gen 6 **62**

12 Zadanie, dane i etykiety **63**
12.1 Co dokładnie ma zrobić model? 63
12.2 Niejednoznaczność tabulatury 63
12.3 Dane uczące 64
12.4 Mapy celów 64
12.5 Dostępność etykiet 66

13 Architektura I: trzon i blok harmoniczny **68**
13.1 Przegląd całości 68
13.2 Trzon 68
13.3 Blok harmoniczny 69

13.4 Zejście do półtonów 70

14 Architektura II: uwaga, kontekst i głowice 73
14.1 Co jeszcze potrafi poprawić wektor opisu? 73
14.2 Warstwa kontekstu 73
14.3 Uwaga w czasie 73
14.4 Uwaga między wysokościami 74
14.4.1 Co się nauczyła uwaga: obserwacja, nie dowód 75
14.5 Głowice 76

15 Strata całkowita i uczenie 78
15.1 Jak z pięciu głowic zrobić jedną liczbę? 78
15.2 Strata całkowita 78
15.3 Jak dobierano dane i zniekształcano 79
15.4 Przebieg uczenia 80

16 Dekoder: od map prawdopodobieństw do listy nut 82
16.1 Sieć nie zwraca nut 82
16.2 Algorytm dla jednego półtonu 82
16.3 Wybór struny 83
16.4 Strojenie progów 83

17 Ewaluacja, wyniki i ograniczenia 87
17.1 Jak uczciwie zmierzyć, czy model działa? 87
17.2 Poprawna nuta, precyzja, czułość, F1 87
17.3 Niepewność: bootstrap 89
17.4 Wyniki Gen 6 90
17.5 Co ten pomiar *nie* pokazuje 90

III Opis matematyczny modelu 93

18 Gen 6 w jednym miejscu: pełny opis matematyczny 94
18.1 Po co jeszcze jeden rozdział? 94
18.2 Oznaczenia 94
18.3 Model jako złożenie 94
18.4 Liczba parametrów dla dowolnych hiperparametrów 95
18.5 Mapa: skąd się bierze każdy element 97

A Skąd bierze się 249 219 parametrów 99

B Ściąga wzorów 100

C Jak odtworzyć wyniki z tej książki 101

Część I

Matematyka od zera

suma

1 Zapis, tensory i logarytm

1.1 Po co ten rozdział?

Model, któremu poświęcona jest ta książka, bierze nagranie gitary i zwraca listę nut. W środku nie dzieje się nic magicznego: to ciąg operacji na tablicach liczb. Zanim opiszemy te operacje, musimy się umówić, jak zapisywać tablice, sumy i funkcje. Ten rozdział jest krótką umową o języku. Kto zna sumy, indeksy i logarytmy, może go przejrzeć i przejść do rozdziału 2; wszystko, co tu zdefiniujemy, jest używane do końca książki.

Po tym rozdziale umiesz: (i) odczytać kształt tensora i policzyć, ile ma liczb, (ii) zapisać złożenie funkcji jako ciąg kroków, (iii) uzasadnić, dlaczego logarytm zamienia mnożenie na dodawanie.

1.2 Sumy i indeksy

Definicja 1.1 (Suma). Dla liczb $a_1, a_2, \ldots, a_n$ zapis

$$\sum_{i=1}^{n} a_i \;=\; a_1 + a_2 + \cdots + a_n \tag{1.1}$$

oznacza ich sumę. Literę i nazywamy *indeksem*; może być dowolna, bo znika po rozpisaniu sumy. Gdy $n = 0$, suma jest pusta i wynosi 0.

Przykład 1.1. $\sum_{i=1}^{4} i^2 = 1+4+9+16 = 30$. Ta sama suma zapisana z indeksem k od 0 do 3 wygląda $\sum_{k=0}^{3} (k+1)^2$ i też daje 30. Zmiana nazwy indeksu ani jego zakresu (z odpowiednim przesunięciem we wzorze) nie zmienia wyniku.

Intuicja. Znak $\sum$ to pętla `for`, która dodaje: `s=0; for i in range(1,n+1): s+=a[i]`. W kodzie indeksy zaczynają się od 0, w matematyce od 1; w tej książce zawsze powiemy, od czego. ♢

Sumy będą nam potrzebne wszędzie: iloczyn skalarny to suma iloczynów, średnia to suma podzielona przez liczbę elementów, a strata modelu to średnia po tysiącach klatek.

Twierdzenie 1.2 (Liniowość sumy). *Dla dowolnych liczb a_i, b_i i stałej c zachodzi*

$$\sum_{i=1}^{n} (c\,a_i + b_i) = c \sum_{i=1}^{n} a_i + \sum_{i=1}^{n} b_i. \tag{1.2}$$

Pomysł dowodu. Rozpisujemy sumę na składniki i korzystamy z przemienności oraz rozdzielności dodawania.

Dowód.

$$\begin{aligned}
\sum_{i=1}^{n}(c\,a_i+b_i) &= (c\,a_1+b_1)+(c\,a_2+b_2)+\cdots+(c\,a_n+b_n) && \text{(def. sumy)}\\
&= (c\,a_1+\cdots+c\,a_n)+(b_1+\cdots+b_n) && \text{(zmiana kolejności)}\\
&= c\,(a_1+\cdots+a_n)+(b_1+\cdots+b_n) && \text{(rozdzielność)}\\
&= c\sum_{i=1}^{n}a_i+\sum_{i=1}^{n}b_i. && \text{(def. sumy)}
\end{aligned}$$

Każdy krok zmienia tylko zapis albo kolejność dodawania, więc równość zachodzi. ■

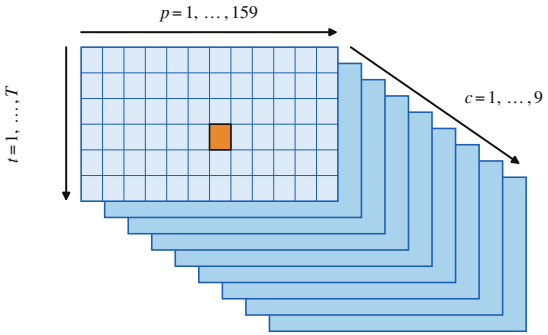
W zwykłym języku: stałą wolno wyciągnąć przed sumę, a sumę sum wolno rozbić. Użyjemy tego, gdy będziemy liczyć pochodną straty (rozdział 5).

1.3 Wektory, macierze i tensory

tensor

Definicja 1.3 (Tensor i jego kształt). *Tensorem* nazywamy tablicę liczb rzeczywistych indeksowaną jedną lub kilkoma liczbami całkowitymi. Liczba indeksów to *rząd* tensora. Ciąg długości zakresów indeksów to *kształt*. Tensor rzędu 1 to *wektor*, rzędu 2 to *macierz*. Zapis $X \in \mathbb{R}^{n_1\times n_2\times\cdots\times n_r}$ oznacza tensor kształtu $(n_1,\ldots,n_r)$; ma on $n_1 n_2\cdots n_r$ liczb.

Przykład 1.2 (Cechy jednego nagrania). Model Gen 6 zamienia nagranie na tensor $X \in \mathbb{R}^{T\times 9\times 159}$ (rozdział 7): T klatek czasu, 9 kanałów i 159 binów częstotliwości. Nagranie trwające 6 sekund daje $T = 243$ klatek, więc X ma $243\cdot 9\cdot 159 = 347\,733$ liczb. Element $X_{t,c,p}$ to liczba z klatki t, kanału c i binu p.



Rysunek 1.1: Tensor $X \in \mathbb{R}^{T\times 9\times 159}$ jako stos dziewięciu macierzy (kanałów); przedni płat ($c = 1$) ma narysowaną siatkę: T wierszy (oś t, w dół) i 159 kolumn (oś p, poziomo), a kolejne kanały leżą za nim (oś c). Pomarańczowa kratka to jeden element $X_{t,c,p}$; trzy indeksy jednoznacznie wskazują jedną liczbę.

Pułapka. Kształt (T,C,P) i kształt (C,T,P) to dwa różne tensory, nawet gdy mają tyle samo liczb. W kodzie PyTorch sieć dostaje tensor $[B,C,T,P]$ (paczka, kanały, czas, biny), a cechy zapisujemy jako $[T,C,P]$. Zawsze sprawdzaj kształt przed operacją; błąd w kolejności osi daje poprawnie działający program z bezsensownym wynikiem. ♢

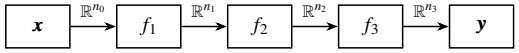
1.4 Funkcje i ich składanie

złożenie funkcji

Definicja 1.4 (Funkcja i złożenie). *Funkcja* $f\colon A\to B$ przypisuje każdemu elementowi zbioru A dokładnie jeden element zbioru B. *Złożeniem* funkcji $f\colon A\to B$ i $g\colon B\to C$ jest funkcja $g\circ f\colon A\to C$, $(g\circ f)(x) = g(f(x))$.

Przykład 1.3. Niech $f(x) = 2x$ i $g(x) = x+3$. Wtedy $(g\circ f)(5) = g(10) = 13$, a $(f\circ g)(5) = f(8) = 16$. Kolejność ma znaczenie: złożenie nie jest przemienne.

Intuicja. Cały model Gen 6 to jedno długie złożenie model $= f_n\circ\cdots\circ f_2\circ f_1$: cechy wchodzą do pierwszej warstwy, jej wynik do drugiej itd. W rozdziale 18 rozpiszemy je w całości. Dlatego ważne jest, by każda warstwa miała jasno określone wejście i wyjście: ich kształty muszą do siebie pasować. ♢



Rysunek 1.2: Złożenie trzech funkcji $\boldsymbol{y} = f_3(f_2(f_1(\boldsymbol{x})))$. Nad strzałkami stoją przestrzenie, w których żyje wynik każdego kroku; wyjście jednej funkcji musi mieć kształt wejścia następnej.

1.5 Potęgi i logarytm

logarytm

Wysokość dźwięku, głośność w decybelach i położenie binu na osi częstotliwości są w tej książce mierzone *logarytmicznie*. Powód zobaczymy w rozdziale 2; tu przypominamy narzędzie.

Definicja 1.5 (Logarytm). Dla $b > 0$, $b \neq 1$ i $x > 0$ *logarytmem* $\log_b x$ nazywamy jedyną liczbę y, dla której $b^y = x$. Logarytm przy podstawie e oznaczamy $\ln x$, a przy podstawie 10 po prostu $\log_{10} x$.

Przykład 1.4. $\log_2 8 = 3$, bo $2^3 = 8$. $\log_2 \frac{1}{2} = -1$, bo $2^{-1} = \frac{1}{2}$. $\log_2 3 \approx 1{,}585$, bo $2^{1{,}585} \approx 3$. Logarytmu z liczby niedodatniej nie ma, bo żadna potęga liczby dodatniej nie jest ujemna ani zerowa.

Twierdzenie 1.6 (Logarytm iloczynu). *Dla $x,y > 0$ zachodzi $\log_b(xy) = \log_b x + \log_b y$ oraz $\log_b(x^k) = k\log_b x$ dla każdej liczby rzeczywistej k.*

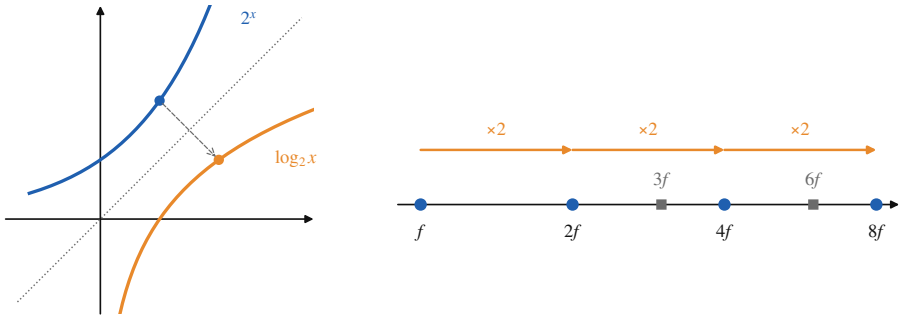
Pomysł dowodu. Zamieniamy x i y na potęgi podstawy b i dodajemy wykładniki.

Dowód. Niech $u = \log_b x$ i $v = \log_b y$, czyli $x = b^u$ i $y = b^v$. Wtedy

$$\begin{aligned}
xy &= b^u b^v = b^{u+v} && \text{(wykładniki się dodają)}\\
\log_b(xy) &= u+v = \log_b x+\log_b y && \text{(def. 1.5)}
\end{aligned}$$

Dla potęgi: $x^k = (b^u)^k = b^{uk}$, więc $\log_b(x^k) = uk = k\log_b x$. ■

Zdanie ludzkim językiem: logarytm zamienia *mnożenie* na *dodawanie*. Mnożenie częstotliwości przez 2 (oktawa wyżej) staje się dodaniem stałej 1 do $\log_2 f$, bez względu na to, od jakiej częstotliwości zaczynamy (rys. 1.3b). To jest sedno całej książki.



(a) (b)

Rysunek 1.3: (a) Funkcje 2^x (niebieska) i $\log_2 x$ (pomarańczowa) są swoimi lustrzanymi odbiciami względem prostej $y = x$ (kropkowana): odbicie punktu $(2,4)$ to $(4,2)$. (b) Na osi logarytmicznej kolejne podwojenia $f, 2f, 4f, 8f$ leżą w równych odstępach (pomarańczowe strzałki mają tę samą długość); punkty $3f$ i $6f$ też dzieli dokładnie jeden taki krok, bo $\log_2 6 - \log_2 3 = 1$.

Na konkretnych liczbach. Ile wynosi $\log_2 12$? Zapisujemy $12 = 3 \cdot 2^2$ i stosujemy twierdzenie 1.6: $\log_2 12 = \log_2 3 + 2\log_2 2 = 1{,}585 + 2 = 3{,}585$. Sprawdzenie: $2^{3{,}585} \approx 12{,}0$. Ta sztuczka (rozbicie na iloczyn znanych czynników) pozwoli nam w rozdziale 3 policzyć, ile półtonów leży nad daną nutą jej trzeci alikwot.

Twierdzenie 1.7 (Zmiana podstawy). *Dla $a, b > 0$, $a, b \neq 1$ i $x > 0$ zachodzi* $\log_b x = \dfrac{\log_a x}{\log_a b}$.

Pomysł dowodu. Logarytmujemy obie strony równości $x = b^{\log_b x}$ przy podstawie a.

Dowód. Niech $y = \log_b x$, czyli $x = b^y$. Stosujemy $\log_a$ do obu stron:

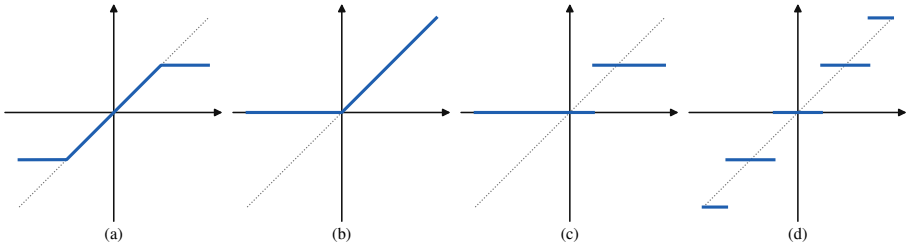
$$\begin{aligned} \log_a x &= \log_a\left(b^y\right) && \text{(podstawienie)} \\ &= y \log_a b && \text{(tw. 1.6)} \\ \Rightarrow\ y &= \frac{\log_a x}{\log_a b}. && \text{(dzielimy przez } \log_a b \neq 0\text{)} \end{aligned}$$

Ponieważ $y = \log_b x$, to jest dokładnie dowodzony wzór. ■

W praktyce: kalkulator ma zwykle tylko ln i $\log_{10}$, więc $\log_2 x = \ln x / \ln 2$. W programie `np.log2(x)` daje to samo.

1.6 Funkcje pomocnicze

W modelu pojawi się kilka prostych funkcji, które warto poznać od razu.



(a) (b) (c) (d)

Rysunek 1.4: Cztery proste funkcje jednej zmiennej na tle prostej $y = x$ (kropkowana). (a) $\mathrm{clip}(x, -1, 1)$ przycina wartości do przedziału. (b) $\max(0, x)$, czyli ReLU, zeruje wartości ujemne. (c) Wskaźnik $\mathbb{1}[x \geq \frac{1}{2}]$ jest równy 1 albo 0. (d) $\mathrm{round}(x)$ zaokrągla do najbliższej całkowitej. Funkcje (c) i (d) mają skoki, więc nie da się ich używać w uczeniu przez gradient; dlatego dekoder w rozdziale 16 jest poza siecią.

zapis	znaczenie	przykład
$\mathrm{clip}(x, a, b)$	$\min(\max(x, a), b)$	$\mathrm{clip}(1{,}7; 0; 1{,}3) = 1{,}3$
$\max_i a_i$	największa z liczb	$\max(2, 5, 3) = 5$
$\arg\max_i a_i$	*numer* największej	$\arg\max(2, 5, 3) = 2$ (od 1)
$\mathbb{1}$[warunek]	1, gdy prawda, inaczej 0	$\mathbb{1}[3 > 2] = 1$
$\mathrm{round}(x)$	najbliższa całkowita	$\mathrm{round}(35{,}07) = 35$
$\lfloor x \rceil$	część całkowita w dół	$\lfloor 2{,}9 \rfloor = 2$

Pułapka. arg max zwraca *miejsce*, a max *wartość*. Pomylenie ich jest tak częste, że w kodzie dekodera (rozdział 16) wybór struny to arg max po strunach, a pewność nuty to max. ♢

Podsumowanie

- Suma $\sum$ to pętla dodająca; stałą wolno wyciągnąć przed sumę (tw. 1.2).
- Tensor to tablica liczb o kształcie $(n_1, \ldots, n_r)$; cechy modelu to $X \in \mathbb{R}^{T \times 9 \times 159}$.
- Model to złożenie funkcji; kształty wyjść i wejść muszą do siebie pasować.
- Logarytm zamienia mnożenie na dodawanie, a podwojenie częstotliwości na stały krok (tw. 1.6).
- clip, max, arg max, wskaźnik i zaokrąglenie to cegiełki dekodera i normalizacji cech.

Ćwiczenia

1. Policz $\sum_{i=1}^{5}(2i-1)$ i podaj wynik w prostszej postaci. (Wskazówka: tw. 1.2 oraz $\sum i = n(n+1)/2$.)
2. Ile liczb ma tensor kształtu $[16, 9, 192, 159]$ (paczka 16 wycinków po 192 klatki)? Ile to megabajtów w formacie `float16` (2 bajty na liczbę)?
3. Policz $\log_2 48$ i $\log_2 \sqrt{2}$ bez kalkulatora, znając $\log_2 3 \approx 1{,}585$.
4. Czy $\log_b(x+y) = \log_b x + \log_b y$? Podaj kontrprzykład liczbowy.

Rozwiązania

1. $\sum_{i=1}^{5}(2i-1) = 2\cdot 15 - 5 = 25$ (suma pierwszych n nieparzystych to n^2); sprawdzenie: $1+3+5+7+9 = 25$.
2. $16\cdot 9\cdot 192\cdot 159 = 4\,396\,032$ liczb, czyli $\approx 8{,}8$ MB w `float16`.
3. $48 = 3\cdot 2^4$, więc $\log_2 48 = 1{,}585 + 4 = 5{,}585$; $\log_2 \sqrt{2} = \frac{1}{2}$.
4. Nie. Dla $b = 2$ i $x = y = 4$ mamy $\log_2(4+4) = \log_2 8 = 3$, a $\log_2 4 + \log_2 4 = 2+2 = 4$. Prawdziwy jest wzór na *iloczyn*: $\log_2(4\cdot 4) = \log_2 16 = 4$.

2 Dźwięk, próbkowanie i wysokość

2.1 Od drgania do liczb

Struna gitary drga, pudło przekazuje drgania powietrzu, mikrofon zamienia zmiany ciśnienia na napięcie, a komputer zapisuje to napięcie jako ciąg liczb. Cała wiedza, jaką model ma o nagraniu, to ten ciąg liczb. Żeby ją wydobyć, trzeba najpierw zrozumieć dwie rzeczy: czym jest wysokość dźwięku i co się traci przy zamianie fali ciągłej na liczby.

Po tym rozdziale umiesz: (i) policzyć częstotliwość dowolnej nuty z jej numeru MIDI, (ii) zmierzyć odstęp dwóch dźwięków w centach, (iii) uzasadnić, dlaczego model pracuje przy 11 025 Hz i nie widzi wyższych częstotliwości niż 5512,5 Hz, (iv) policzyć, ile klatek ma nagranie.

2.2 Sinusoida

częstotliwość

Definicja 2.1 (Sinusoida, częstotliwość, okres). *Sinusoidą* nazywamy sygnał $x(t) = A\sin(2\pi f t + \varphi)$ zmiennej t (czas w sekundach). Liczba $A \geq 0$ to *amplituda*, f to *częstotliwość* w hercach (1 Hz = jeden pełny obieg na sekundę), a φ to *faza*. Sygnał powtarza się co $T = 1/f$ sekund; T nazywamy *okresem*.

Przykład 2.1. Strojowe A (nuta A4) ma $f = 440$ Hz, więc okres $T = 1/440 \approx 2{,}27$ ms. W ciągu jednej sekundy powietrze wykonuje 440 pełnych drgań. Dla sinusoidy $x(t) = 0{,}5\sin(2\pi\cdot 440 t)$ największe wychylenie wynosi 0,5 i powtarza się co 2,27 ms.

Intuicja. Sinusoida to ruch punktu po okręgu oglądany z boku: faza mówi, skąd zaczynamy, a częstotliwość, ile obiegów robimy na sekundę. Każdy dźwięk muzyczny to suma sinusoid; w rozdziale 3 zobaczymy, że nuta gitary to sinusoida f_0 i jej całkowite wielokrotności. ♢

2.3 Próbkowanie

Komputer nie widzi sygnału w każdej chwili, tylko co ułamek sekundy.

próbkowanie

Definicja 2.2 (Próbkowanie). Dla sygnału $x(t)$ i *częstotliwości próbkowania* f_s ciąg próbek to $x[n] = x(n/f_s)$ dla $n = 0, 1, 2, \ldots$. Jedna próbka to jedna liczba; nagranie trwające τ sekund ma $N = \tau f_s$ próbek.

Przykład 2.2. Płyta CD ma $f_s = 44\,100$ Hz, więc minuta dźwięku to $60 \cdot 44\,100 = 2\,646\,000$ liczb. Model Gen 6 zmienia próbkowanie nagrania na $f_s = 11\,025$ Hz (dokładnie ćwierć 44 100): 6 sekund to $N = 66\,150$ próbek.

Pojawia się pytanie: ile informacji tracimy? Okazuje się, że dwie różne sinusoidy mogą dać *identyczne* próbki.

Twierdzenie 2.3 (Aliasing). *Niech $f_s > 0$. Dla każdej liczby całkowitej k sinusoidy o częstotliwościach f i $f + kf_s$ mają te same próbki. Ponadto sinusoidy $\sin(2\pi ft)$ i $-\sin(2\pi(f_s - f)t)$ mają te same próbki. W szczególności sygnały o częstotliwościach powyżej $f_s/2$ są nierozróżnialne od sygnałów o częstotliwościach poniżej $f_s/2$.*

Pomysł dowodu. Wstawiamy $t = n/f_s$ i korzystamy z tego, że sinus ma okres 2π, a n jest całkowite.

Dowód. Dla $t = n/f_s$ i $k \in \mathbb{Z}$:

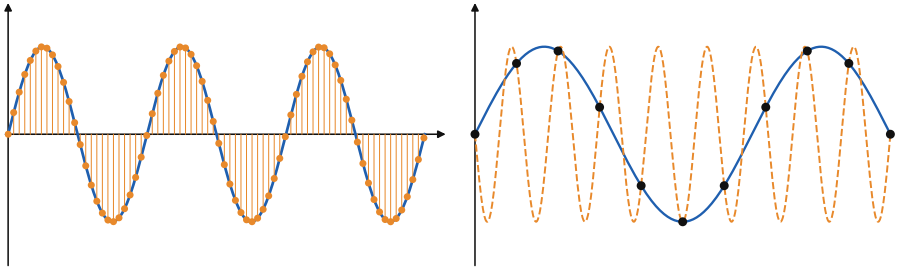
$$\begin{aligned} \sin\big(2\pi(f + kf_s)\tfrac{n}{f_s}\big) &= \sin\big(2\pi f\tfrac{n}{f_s} + 2\pi kn\big) && \text{(rozdzielność)} \\ &= \sin\big(2\pi f\tfrac{n}{f_s}\big) && (kn \in \mathbb{Z}\text{, okres } 2\pi) \end{aligned}$$

To jest pierwsza część. Dla drugiej częstotliwość $f_s - f$ daje

$$\begin{aligned} \sin\big(2\pi(f_s - f)\tfrac{n}{f_s}\big) &= \sin\big(2\pi n - 2\pi f\tfrac{n}{f_s}\big) && \text{(wymnożenie)} \\ &= -\sin\big(2\pi f\tfrac{n}{f_s}\big) && \text{(nieparzystość sinusa, okres)} \end{aligned}$$

Zatem $-\sin(2\pi(f_s - f)n/f_s) = \sin(2\pi fn/f_s)$. Skoro każda częstotliwość większa niż $f_s/2$ ma postać $f_s - f$ z $f < f_s/2$ (po odjęciu odpowiedniej wielokrotności f_s), jej próbki zgadzają się z próbkami niższej częstotliwości. To kończy dowód. ■

W zwykłym języku: przy próbkowaniu f_s da się odróżnić tylko częstotliwości z przedziału $[0, f_s/2]$; wyższe „zawijają się” w niższe (rys. 2.1b). Liczbę $f_s/2$ nazywamy *częstotliwością Nyquista*.



(a) (b)

Rysunek 2.1: (a) Sinusoida 440 Hz (niebieska) i jej próbki przy $f_s = 11\,025$ Hz (pomarańczowe kropki): około 25 próbek na okres. (b) Aliasing: niebieska sinusoida $0{,}15 f_s$ i pomarańczowa przerywana $-\sin$ o częstotliwości $0{,}85 f_s$ przechodzą przez te same punkty (czarne kropki), więc po spróbkowaniu nie da się ich rozróżnić.

Na konkretnych liczbach. Przy $f_s = 11\,025$ Hz częstotliwość Nyquista wynosi 5512,5 Hz. Najwyższa nuta, którą obsługuje Gen 6, to MIDI 88 (1318,5 Hz). Jej trzeci alikwot (3955,5 Hz) jest jeszcze poniżej Nyquista, ale szósty (7911 Hz) już nie. Dlatego HCQT (rozdział 7) zeruje kanały, w których alikwot wypada powyżej $0{,}46 f_s = 5071{,}5$ Hz: tam i tak nie ma wiarygodnej informacji.

Pułapka. Nie można „odzyskać” wysokich częstotliwości po zmniejszeniu f_s. Przy zmianie próbkowania nagrania z 44 100 na 11 025 Hz trzeba najpierw odfiltrować wszystko powyżej 5512,5 Hz; inaczej aliasing wmiesza wysokie dźwięki w niskie i sieć zobaczy „duchy”, których w nagraniu nie było. ♢

2.4 Półtony, MIDI i centy

Ucho nie słyszy różnicy częstotliwości, tylko ich *stosunek*: oktawa to zawsze podwojenie. Dlatego muzycy dzielą oktawę na 12 równych *stosunkowo* kroków (półtonów).

półton

Definicja 2.4 (Skala równomiernie temperowana i numer MIDI). Nutom przypisujemy numery $m \in \mathbb{Z}$ (*numer MIDI*) tak, że $m = 69$ to A4 o częstotliwości 440 Hz, a kolejne numery różnią się o jeden półton: stosunek częstotliwości sąsiednich nut jest stały, a po 12 krokach częstotliwość się podwaja. Częstotliwość nuty m oznaczamy $f(m)$.

Twierdzenie 2.5 (Wzór na częstotliwość nuty). *Stosunek częstotliwości sąsiednich półtonów wynosi $2^{1/12} \approx 1{,}0595$ oraz*

$$f(m) = 440 \cdot 2^{(m-69)/12}. \tag{2.1}$$

Pomysł dowodu. Stały stosunek r i podwojenie po 12 krokach dają $r^{12} = 2$; reszta to kolejne mnożenie przez r.

Dowód. Niech $r = f(m+1)/f(m)$ będzie stałe dla każdego m. Z definicji 2.4 po dwunastu krokach częstotliwość się podwaja:

$$\begin{aligned} f(m+12) &= r^{12} f(m) && \text{(12 mnożeń przez } r\text{)} \\ &= 2f(m) && \text{(oktawa)} \end{aligned}$$

Stąd $r^{12} = 2$, czyli $r = 2^{1/12}$ (jedyne dodatnie rozwiązanie). Kolejne mnożenie przez r od $m = 69$ daje $f(m) = f(69)\, r^{m-69} = 440 \cdot 2^{(m-69)/12}$, także dla $m < 69$ (dzielenie przez r). To kończy dowód. ■

struna	6	5	4	3	2	1
nuta	E2	A2	D3	G3	B3	E4
numer MIDI m	40	45	50	55	59	64
$f(m)$ [Hz]	82,41	110,00	146,83	196,00	246,94	329,63

Tabela 2.1: Struny gitary w stroju standardowym i ich częstotliwości z wzoru (2.1).

Przykład 2.3 (Częstotliwość najniższej struny). Struna E2 ma $m = 40$, więc $f(40) = 440 \cdot 2^{(40-69)/12} = 440 \cdot 2^{-29/12} \approx 82{,}41\,\text{Hz}$. Sprawdzenie: E2 leży dwie oktawy ($64 - 40 = 24 = 2 \cdot 12$ półtonów) pod E4, więc $f = 329{,}63/2^2 = 82{,}41\,\text{Hz}$.

Odstępy mniejsze niż półton mierzymy w *centach*: półton ma 100 centów.

cent

Definicja 2.6 (Cent). Odstęp dwóch dźwięków o częstotliwościach f_1 i f_2 wynosi

$$c = 1200 \log_2 \frac{f_2}{f_1} \quad \text{centów.} \tag{2.2}$$

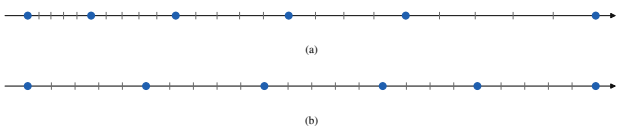
Przykład 2.4. Czysta kwinta ($f_2/f_1 = 3/2$) to $1200 \log_2 1{,}5 = 701{,}96$ centa, czyli prawie dokładnie 7 półtonów (700). Struna rozstrojona z 440 do 445 Hz jest podwyższona o $1200 \log_2(445/440) \approx 19{,}6$ centa.

Wniosek 2.7 (Centy się dodają). *Jeśli c_{12} to odstęp od f_1 do f_2, a c_{23} od f_2 do f_3, to odstęp od f_1 do f_3 wynosi $c_{12} + c_{23}$. Odstęp jednego półtonu to* 100 *centów.*

Dowód.

$$\begin{aligned} c_{12} + c_{23} &= 1200 \log_2 \frac{f_2}{f_1} + 1200 \log_2 \frac{f_3}{f_2} && \text{(def. 2.6)} \\ &= 1200 \log_2 \left(\frac{f_2}{f_1} \cdot \frac{f_3}{f_2} \right) && \text{(tw. 1.6)} \\ &= 1200 \log_2 \frac{f_3}{f_1}. && \text{(skrócenie } f_2\text{)} \end{aligned}$$

Dla półtonu $f_2/f_1 = 2^{1/12}$, więc $c = 1200 \cdot \frac{1}{12} \log_2 2 = 100$. Odstępy dodają się jak długości odcinków na osi $\log_2 f$. ∎



Rysunek 2.2: Nuty od E2 do E4 (kreski) i sześć strun (niebieskie kropki). (a) Na osi liniowej częstotliwości odstępy między półtonami rosną: ostatni jest ok. 3,8 raza większy niż pierwszy ($2^{23/12}$), więc niskie nuty tłoczą się przy zerze. (b) Na osi $\log_2 f$ wszystkie półtony są równo oddalone o $1/12$ (z tw. 1.6). Dlatego model liczy bliskość nut w półtonach, a nie w hercach.

W modelu Gen 6 jedna nuta ma 3 biny na półton, czyli bin to $100/3 \approx 33{,}3$ centa. Ewaluacja uznaje wysokość za poprawną, jeśli różni się od wzorca o mniej niż 50 centów (ćwierć tonu) — to ok. półtora biną.

2.5 Klatki czasu

Model nie analizuje całego nagrania naraz, tylko *klatkami*: co h próbek (krok, ang. *hop*) bierze okno długości N_w próbek i liczy z niego widmo (rozdział 6).

Przykład 2.5 (Liczba klatek). Gen 6 używa okna $N_w = 4096$ próbek (371,5 ms) i kroku $h = 256$ próbek (23,2 ms). Okno mieści się w nagraniu o N próbkach dla $t = 0, \ldots, \lfloor (N - N_w)/h \rfloor$, więc $T = \lfloor (N - N_w)/h \rfloor + 1$. Dla $N = 66\,150$ (6 s): $T = \lfloor 62\,054/256 \rfloor + 1 = 242 + 1 = 243$ klatki.

Ćwiczenia

1. Oblicz częstotliwość nuty $m = 52$ (E3) i nuty $m = 76$. Ile półtonów i ile centów dzieli E3 od E2?
2. Nuta ma częstotliwość $f_1 = 200\,\text{Hz}$, a druga $f_2 = 206\,\text{Hz}$. Ile centów je dzieli? Czy mieści się w tolerancji 50 centów?
3. Sinusoida 7000 Hz jest próbkowana przy $f_s = 11\,025\,\text{Hz}$. Jaką częstotliwość zobaczy komputer? Skorzystaj z tw. 2.3.
4. Nagranie ma $N = 11\,025 \cdot 30$ próbek. Ile klatek T daje okno 4096 z krokiem 256?

Rozwiązania

1. $f(52) = 440 \cdot 2^{-17/12} = 164{,}81\,\text{Hz}$ oraz $f(76) = 440 \cdot 2^{7/12} = 659{,}26\,\text{Hz}$. E3 jest 12 półtonów, czyli 1200 centów, nad E2 (stosunek $164{,}81/82{,}41 = 2$).
2. $c = 1200 \log_2(206/200) = 1200 \cdot 0{,}0426 = 51{,}2$ centa, czyli o włos powyżej tolerancji 50.
3. $f_s - 7000 = 4025\,\text{Hz}$ (z drugiej części twierdzenia; znak jest przeciwny). Komputer zobaczy ton 4025 Hz w przeciwnej fazie.
4. $N = 330\,750$ i $(330\,750 - 4096)/256 = 1275{,}99\ldots$, więc $T = 1275 + 1 = 1276$ klatek.

3 Struna gitary i alikwoty

3.1 Dlaczego nuta to nie jedna sinusoida?

Gdy zagramy na gitarze nutę A2, w nagraniu nie ma jednej sinusoidy 110 Hz. Jest cały szereg sinusoid: 110, 220, 330, 440… Hz. Te dodatkowe składowe nazywamy *alikwotami* (harmonicznymi). To one nadają instrumentowi barwę, ale też sprawiają największy kłopot w transkrypcji: alikwoty jednej nuty lądują dokładnie tam, gdzie leżą *inne* nuty. Ten rozdział wyjaśnia, skąd się biorą i dlaczego na osi logarytmicznej wyglądają jak niezmienny wzorzec — na tym wzorcu opiera się pierwszy blok sieci Gen 6.

Po tym rozdziale umiesz: (i) uzasadnić, że struna drga z częstotliwościami kf_0, (ii) wskazać, które nuty dzielą alikwoty, (iii) policzyć położenie h-tego alikwotu w półtonach i binach, (iv) wyjaśnić, skąd bierze się błąd oktawowy.

3.2 Drgania własne struny

Struna o długości L jest zamocowana na obu końcach. Jej wychylenie $u(x,t)$ w punkcie $x \in [0,L]$ i chwili t spełnia równanie falowe $u_{tt} = v^2 u_{xx}$, gdzie v to prędkość fali na strunie (zależy od naciągu i masy), oraz warunki brzegowe $u(0,t) = u(L,t) = 0$.

fala stojąca

Definicja 3.1 (Fala stojąca (tryb własny)). *Falą stojącą* nazywamy rozwiązanie równania falowego postaci $u(x,t) = \phi(x)\cos(2\pi f t)$, w którym kształt $\phi(x)$ nie zmienia się w czasie, tylko jego wychylenie pulsuje z częstotliwością f.

Twierdzenie 3.2 (Częstotliwości własne struny). *Funkcje*

$$u_k(x,t) = \sin\Big(\frac{k\pi x}{L}\Big)\cos(2\pi f_k t), \qquad k = 1,2,3,\dots,$$

są falami stojącymi spełniającymi równanie falowe i warunki brzegowe wtedy i tylko wtedy, gdy

$$f_k = k\,\frac{v}{2L} = k f_1. \tag{3.1}$$

Pomysł dowodu. Wstawiamy u_k do równania $u_{tt} = v^2 u_{xx}$, policzymy obie drugie pochodne i porównamy współczynniki.

Dowód. Warunki brzegowe są spełnione, bo $\sin(0) = 0$ oraz $\sin(k\pi) = 0$ dla całkowitego k. Liczymy pochodne (wzory $(\sin ax)'' = -a^2 \sin ax$ i $(\cos bt)'' = -b^2\cos bt$ są znane ze szkoły):

$$u_{tt} = -(2\pi f_k)^2 u_k, \qquad \text{(po czasie)}$$
$$u_{xx} = -\big(\tfrac{k\pi}{L}\big)^2 u_k. \qquad \text{(po położeniu)}$$

Równanie $u_{tt} = v^2 u_{xx}$ jest więc równoważne $(2\pi f_k)^2 = v^2(k\pi/L)^2$, czyli $2\pi f_k = vk\pi/L$, skąd $f_k = kv/(2L)$ (bierzemy dodatni pierwiastek, bo $f_k > 0$). Dla dowolnego innego f równość nie zachodzi, więc $f = f_k$ jest warunkiem koniecznym i wystarczającym. Struna może więc drgać z częstotliwościami będącymi całkowitymi wielokrotnościami najniższej z nich. To kończy dowód. ∎

Że *każde* drganie struny jest sumą takich fal, orzekł Daniel Bernoulli (rozwinięcie w szereg Fouriera; dowód wykracza poza zakres tej książki). Dlatego nuta gitary to suma sinusoid:

$$x(t) = \sum_{h=1}^{H} A_h \sin\big(2\pi h f_0 t + \varphi_h\big), \qquad f_0 = f_1, \tag{3.2}$$

gdzie f_0 nazywamy *częstotliwością podstawową*, a składową $h = 2,3,\dots$ *alikwotem* (dokładnie: h-tą *harmoniczną*). Amplitudy A_h zwykle maleją z h, ale nie znikają.

Przykład 3.1 (Najniższa struna). Struna E2 ($f_0 = 82{,}41$ Hz) ma długość drgającą $L \approx 0{,}65$ m. Z tw. 3.2 prędkość fali to $v = 2Lf_0 \approx 2 \cdot 0{,}65 \cdot 82{,}41 = 107{,}1$ m/s. Alikwoty $h = 1,\dots,6$ mają częstotliwości 82,4; 164,8; 247,2; 329,6; 412,0; 494,4 Hz. Alikwot $h = 4$ (329,6 Hz) to dokładnie częstotliwość nuty E4 — najwyższej, otwartej struny.

Intuicja. Struna może drgać jako całość ($k = 1$), w dwóch połowach ($k = 2$), w trzech trzecich ($k = 3$) itd. Każdy sposób ma swoją częstotliwość i wszystkie występują naraz. Szarpnięcie w środku wzbudza głównie nieparzyste, przy końcu struny — bogatszy zestaw. ♢

Pułapka. Prawdziwa struna jest sztywna, więc jej alikwoty są *nieco wyższe* niż hf_0: $f_h \approx hf_0\sqrt{1+Bh^2}$, gdzie $B \geq 0$ to współczynnik nieharmoniczności. Dla $B = 10^{-4}$ szósty alikwot jest za wysoki o $1200\log_2\sqrt{1+36\cdot 10^{-4}} \approx 3{,}1$ centa, a dla $B = 10^{-3}$ o 30,6 centa, prawie cały bin. Dlatego blok harmoniczny w rozdziale 13 ma dodatkowy filtr po sąsiednich binach. ♢

3.3 Wspólne alikwoty: skąd błąd oktawowy

Twierdzenie 3.3 (Alikwoty oktawy). *Niech nuta A ma częstotliwość podstawową f_0, a nuta B częstotliwość $2f_0$ (oktawa wyżej). Wtedy każdy alikwot nuty B jest alikwotem nuty A: $h \cdot 2f_0 = (2h)\,f_0$. Odwrotnie nie: nieparzyste alikwoty A nie są alikwotami B.*

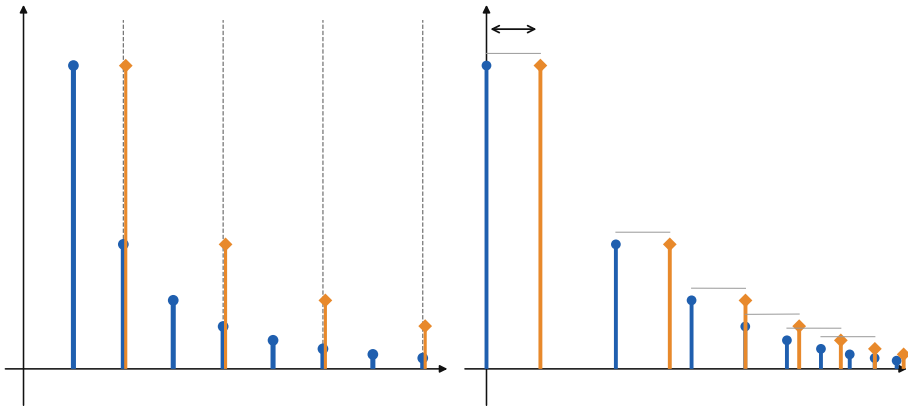
Pomysł dowodu. Wystarczy przepisać $h \cdot 2f_0$ jako $(2h)f_0$ i zauważyć, że $2h$ jest całkowite i parzyste.

Dowód. Niech $h \in \{1,2,\dots\}$.

$$h \cdot (2f_0) = (2h) \cdot f_0 \qquad \text{(łączność mnożenia)}$$

Liczba $2h$ jest całkowita, więc $(2h)f_0$ to $2h$-ty alikwot nuty A. Natomiast $3f_0$ ($h = 3$ dla A) byłoby alikwotem B tylko dla h' spełniającego $h' \cdot 2f_0 = 3f_0$, czyli $h' = 1{,}5 \notin \mathbb{N}$. Zatem parzyste alikwoty A pokrywają się z alikwotami B, a nieparzyste nie. To kończy dowód. ∎

W zwykłym języku: gdy gra E3, w widmie jest wszystko, co zgłosiłoby E2 — z wyjątkiem co drugiego prążka. A skoro wyższe alikwoty bywają słabe, E3 do złudzenia przypomina E2 z wyciszonym podstawowym tonem. To jest *błąd oktawowy*: najtrudniejsza pomyłka w transkrypcji gitary (w naszych pomiarach ok. 24% fałszywych alarmów klatkowych leży dokładnie oktawę od prawdziwej nuty).



(a) (b)

Rysunek 3.1: Widma szarpniętych strun liczone FFT (wysokość słupka — amplituda względem prążka podstawowego). (a) Oś liniowa: prążki E2 (niebieskie kółka) i pierwsze cztery prążki E3 (pomarańczowe romby, przesunięte nieco w prawo, żeby były widoczne). Szare przerywane pionowe prowadnice stoją na parzystych prążkach E2: każdy prążek E3 trafia dokładnie w jedną z nich (tw. 3.3). (b) Oś w półtonach $12\log_2(f/f_{E2})$: wzorzec prążków E2 (niebieskie) i A2 (pomarańczowe) to ta sama figura przesunięta o 5 półtonów (strzałka u góry); cienkie szare łączniki spinają te same numery alikwotów. Kształt zależy tylko od numeru alikwotu, nie od wysokości.

3.4 Oś logarytmiczna: wzorzec, który się nie zmienia

Teraz najważniejsze twierdzenie rozdziału. Zmierzmy położenie na osi w półtonach względem ustalonej nuty odniesienia (np. $f_{\text{ref}} = 440\,\text{Hz}$): $u(f) = 12\log_2(f/f_{\text{ref}})$.

Twierdzenie 3.4 (Niezmienniczość wzorca alikwotów). *Jeśli nuta ma częstotliwość podstawową f_0 i położenie $u_0 = u(f_0)$, to jej h-ty alikwot leży w punkcie*

$$u(hf_0) = u_0 + 12\log_2 h. \tag{3.3}$$

Przesunięcie $12\log_2 h$ zależy od h, ale nie *zależy od f_0.*

Pomysł dowodu. Logarytm iloczynu jest sumą logarytmów (tw. 1.6): mnożenie przez h staje się dodaniem stałej.

Dowód.

$$\begin{aligned} u(hf_0) &= 12\log_2 \frac{hf_0}{f_{\text{ref}}} && \text{(definicja } u\text{)} \\ &= 12\log_2 h + 12\log_2 \frac{f_0}{f_{\text{ref}}} && \text{(tw. 1.6)} \\ &= 12\log_2 h + u_0. && \text{(definicja } u_0\text{)} \end{aligned}$$

Stała $12\log_2 h$ nie zawiera f_0, więc wzorzec alikwotów ma na tej osi ten sam kształt dla każdej nuty (rys. 3.1b). To kończy dowód. ■

Wniosek 3.5 (Biny alikwotów). *Przy 3 binach na półton alikwot h leży o $k_h = 36\log_2 h$ binów od podstawy. Zaokrąglone wartości dla alikwotów używanych w Gen 6:*

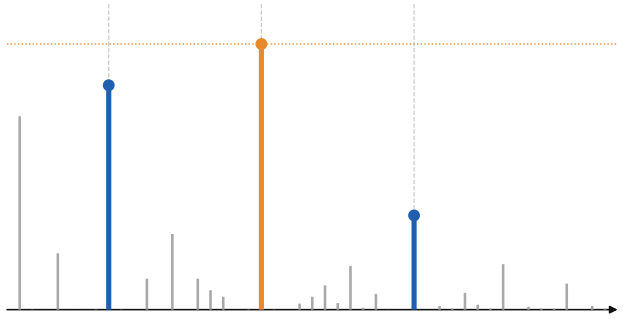
h	0,5	1	2	3	4	5	6
$12\log_2 h$ *[półtony]*	−12	0	12	19,02	24	27,86	31,02
$k_h = \text{round}(36\log_2 h)$ *[biny]*	−36	0	36	57	72	84	93

Dowód. Z tw. 3.4 odstęp w półtonach to $12\log_2 h$; przy 3 binach na półton mnożymy przez 3: $k_h = 36\log_2 h$. Wartości w tabeli to $36\log_2 h$: 36, 57,06, 72, 83,59, 93,06 zaokrąglone do najbliższej liczby całkowitej; np. $\text{round}(83{,}59) = 84$, a 84 biny to dokładnie 28 półtonów, czyli nuta temperowana. Zaokrąglenie przesuwa więc piąty alikwot o 0,41 bina (13,7 centa), czyli dokładnie o tyle, o ile ten alikwot jest za niski względem skali temperowanej. ■

Na konkretnych liczbach. Struna A2 (110 Hz) ma piąty alikwot 550 Hz. Leży on $12\log_2 5 = 27{,}86$ półtonów nad A2, czyli blisko nuty o numerze $45 + 28 = 73$ (cis^3, 554,4 Hz), ale o $1200\log_2(550/554{,}4) = -13{,}7$ centa niżej. To nie błąd modelu, tylko fizyka: trzeci i piąty alikwot nigdy nie trafiają dokładnie w temperowaną skalę.

3.5 Salience: jak wygląda błąd oktawowy w liczbach

Najprostszy detektor wysokości sumuje energię widma w miejscach, gdzie leżałyby alikwoty kandydata: $\text{sal}(f) = \frac{1}{H}\sum_{h=1}^{H} S(hf)$, gdzie S to amplituda widma. Dla prawdziwej nuty wszystkie składniki są duże. Ale dla kandydata o oktawę niżej, $f/2$, składniki o parzystym h trafiają w alikwoty prawdziwej nuty, więc salience też jest wysoka (rys. 3.2).



Rysunek 3.2: Salience (suma energii sześciu pierwszych alikwotów, względem największej) dla szarpniętej struny E3 ($m = 52$) w funkcji numeru kandydata m. Prawdziwa nuta (pomarańczowa) ma najwyższy słupek; pomarańczowa kropkowana pozioma to jej poziom. Kandydat o oktawę niżej ($m = 40$, niebieski) jest niewiele niższy, a ten o oktawę wyżej ($m = 64$) też się wyróżnia. Szare przerywane pionowe linie to $m = 40, 52, 64$. Wartości liczone z

Wniosek praktyczny: samo sumowanie nie wystarcza i trzeba, by sieć porównywała kandydatów *ze sobą*. Do tego służy uwaga między wysokościami (rozdział 14).

Podsumowanie

- Struna drga z częstotliwościami kf_1 (tw. 3.2); nuta to suma alikwotów hf_0.
- Prawdziwe struny są lekko nieharmoniczne: $f_h \approx hf_0\sqrt{1+Bh^2}$.
- Alikwoty nuty o oktawę wyższej zawierają się w alikwotach niższej (tw. 3.3): źródło błędu oktawowego.
- Na osi półtonów alikwot h leży o $12\log_2 h$ nad podstawą, niezależnie od f_0 (tw. 3.4).
- Przy 3 binach na półton przesunięcia to $-36, 0, 36, 57, 72, 84, 93$ (wn. 3.5); na nich opiera się blok harmoniczny.

Ćwiczenia

1. Wypisz częstotliwości alikwotów $h = 1, \dots, 8$ struny A2 (110 Hz). Które z nich są częstotliwościami podstawowymi nut A3 i E4?
2. Oblicz $12\log_2 7$ i $36\log_2 7$. O ile centów siódmy alikwot odbiega od najbliższej nuty temperowanej?
3. Pokaż, że alikwoty nuty o częstotliwości $3f_0$ (dwunasta wyżej) są alikwotami nuty f_0. Które z nich się pokrywają?
4. Struna ma $B = 10^{-3}$. O ile centów podwyższony jest alikwot $h = 4$? Czy mieści się w jednym binie (33,3 centa)?

Rozwiązania

1. 110, 220, 330, 440, 550, 660, 770, 880 Hz. A3 to 220 Hz ($h = 2$); E4 to 329,6 Hz, a 330 Hz ($h = 3$) jest blisko, ale to E_4 temperowane (329,63) tylko w przybliżeniu (o 2 centy).
2. $12\log_2 7 = 33{,}69$ półtonów, $36\log_2 7 = 101{,}06$ binów. Najbliższa nuta jest 34 półtony wyżej, więc alikwot jest za niski o 0,31 półtonu, czyli 31 centów.
3. $h \cdot 3f_0 = (3h)f_0$; pokrywają się alikwoty $h' = 3, 6, 9, \dots$ nuty f_0 (co trzeci).
4. $1200\log_2\sqrt{1+16\cdot 10^{-3}} = 600\log_2(1{,}016) = 600\cdot 0{,}02289 = 13{,}7$ centa, więc mieści się w jednym binie ($< 33{,}3$).

4 Wektory i macierze

4.1 Dlaczego algebra liniowa?

Prawie każda warstwa modelu Gen 6 to mnożenie przez macierz. Macierz zamienia jeden wektor cech na inny, a iloczyn skalarny mierzy, jak bardzo dwa wektory są do siebie podobne; uwaga (rozdział 10) to nic więcej niż iloczyny skalarne wstawione do softmaksa. Wystarczy nam kilka pojęć, ale musimy je rozumieć geometrycznie.

Po tym rozdziale umiesz: (i) policzyć iloczyn skalarny, normę i kąt, (ii) uzasadnić nierówność Cauchy'ego–Schwarza, (iii) pomnożyć macierz przez wektor i dwie macierze przez siebie, (iv) policzyć liczbę parametrów warstwy liniowej.

4.2 Wektor i iloczyn skalarny

iloczyn skalarny

Definicja 4.1 (Iloczyn skalarny i norma). Dla wektorów $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$ ich *iloczynem skalarnym* jest liczba

$$\langle \boldsymbol{u}, \boldsymbol{v} \rangle = \sum_{i=1}^{n} u_i v_i = \boldsymbol{u}^\top \boldsymbol{v}, \tag{4.1}$$

a *normą* (długością) wektora $\|\boldsymbol{u}\| = \sqrt{\langle \boldsymbol{u}, \boldsymbol{u} \rangle}$.

Przykład 4.1. Dla $\boldsymbol{u} = (2, 1, -1)$ i $\boldsymbol{v} = (1, 3, 2)$: $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = 2\cdot 1 + 1\cdot 3 + (-1)\cdot 2 = 3$, $\|\boldsymbol{u}\| = \sqrt{6} \approx 2{,}449$, $\|\boldsymbol{v}\| = \sqrt{14} \approx 3{,}742$. Iloczyn skalarny wektora z samym sobą to kwadrat jego długości: $\langle \boldsymbol{u}, \boldsymbol{u} \rangle = 4 + 1 + 1 = 6$.

Intuicja. Iloczyn skalarny pyta: „w ile wektor $\boldsymbol{u}$ jest skierowany tak jak $\boldsymbol{v}$?". Wynik jest duży i dodatni, gdy wskazują ten sam kierunek, zero, gdy są prostopadłe, ujemny, gdy przeciwne. W modelu wektor $\boldsymbol{q}$ („czego szukam") i wektor $\boldsymbol{k}$ („co mam") są porównywane właśnie tak. ♢

Twierdzenie 4.2 (Cauchy'ego–Schwarza). *Dla dowolnych $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$ zachodzi $|\langle \boldsymbol{u}, \boldsymbol{v} \rangle| \le \|\boldsymbol{u}\|\,\|\boldsymbol{v}\|$, przy czym równość jest równoważna temu, że wektory są równoległe (jeden jest wielokrotnością drugiego).*

Pomysł dowodu. Rozkładamy $\boldsymbol{v}$ na część równoległą do $\boldsymbol{u}$ i prostopadłą do niej. Część prostopadła ma nieujemną długość.

Dowód. Jeśli $\boldsymbol{u} = \boldsymbol{0}$, obie strony są zerem. Niech $\boldsymbol{u} \neq \boldsymbol{0}$ i niech $\boldsymbol{p} = \dfrac{\langle \boldsymbol{u}, \boldsymbol{v} \rangle}{\|\boldsymbol{u}\|^2}\boldsymbol{u}$

oraz $\boldsymbol{r} = \boldsymbol{v} - \boldsymbol{p}$. Sprawdzamy, że $\boldsymbol{r} \perp \boldsymbol{u}$:

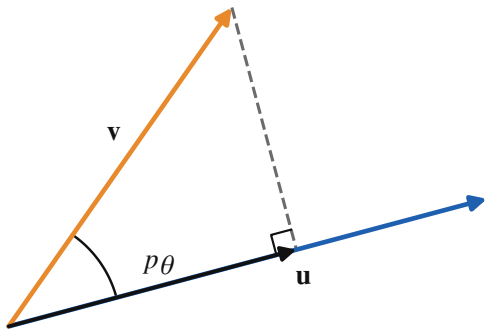
$$\begin{aligned}\langle \boldsymbol{r}, \boldsymbol{u}\rangle &= \langle \boldsymbol{v}, \boldsymbol{u}\rangle - \frac{\langle \boldsymbol{u}, \boldsymbol{v}\rangle}{\|\boldsymbol{u}\|^2}\langle \boldsymbol{u}, \boldsymbol{u}\rangle && \text{(liniowość)}\\ &= \langle \boldsymbol{u}, \boldsymbol{v}\rangle - \langle \boldsymbol{u}, \boldsymbol{v}\rangle = 0. && (\langle \boldsymbol{u}, \boldsymbol{u}\rangle = \|\boldsymbol{u}\|^2)\end{aligned}$$

Skoro $\boldsymbol{v} = \boldsymbol{p} + \boldsymbol{r}$ z $\boldsymbol{p} \perp \boldsymbol{r}$, to $\|\boldsymbol{v}\|^2 = \|\boldsymbol{p}\|^2 + \|\boldsymbol{r}\|^2 \geq \|\boldsymbol{p}\|^2$ (Pitagoras). A $\|\boldsymbol{p}\|^2 = \dfrac{\langle \boldsymbol{u}, \boldsymbol{v}\rangle^2}{\|\boldsymbol{u}\|^2}$, więc

$$\|\boldsymbol{v}\|^2 \geq \frac{\langle \boldsymbol{u}, \boldsymbol{v}\rangle^2}{\|\boldsymbol{u}\|^2} \quad \Longrightarrow \quad \langle \boldsymbol{u}, \boldsymbol{v}\rangle^2 \leq \|\boldsymbol{u}\|^2 \|\boldsymbol{v}\|^2.$$

Równość zachodzi dokładnie wtedy, gdy $\boldsymbol{r} = \boldsymbol{0}$, czyli $\boldsymbol{v} = \boldsymbol{p}$ jest wielokrotnością $\boldsymbol{u}$. Pierwiastkowanie obu stron daje tezę. ■

W zwykłym języku: iloczyn skalarny nigdy nie jest większy niż iloczyn długości, a największy jest dla wektorów równoległych. Stąd wynika, że liczba $\cos\theta := \langle \boldsymbol{u}, \boldsymbol{v}\rangle / (\|\boldsymbol{u}\|\,\|\boldsymbol{v}\|)$ leży w $[-1, 1]$ i można ją nazwać cosinusem kąta θ między wektorami (rys. 4.1). Tę samą nierówność wykorzystamy w rozdziale 5, by pokazać, w którą stronę gradient rośnie najszybciej.



Rysunek 4.1: Rozkład z dowodu tw. 4.2. Wektor $\boldsymbol{v}$ (pomarańczowy) rzutujemy na kierunek $\boldsymbol{u}$ (niebieski): rzut p (czarny) jest równoległy do $\boldsymbol{u}$, a odcinek kreskowany $\boldsymbol{r} = \boldsymbol{v} - \boldsymbol{p}$ jest do niego prostopadły (kąt prosty). Długość rzutu to $\|\boldsymbol{v}\|\cos\theta$, więc $\langle \boldsymbol{u}, \boldsymbol{v}\rangle = \|\boldsymbol{u}\|\,\|\boldsymbol{v}\|\cos\theta$.

Na konkretnych liczbach. Dla wektorów z przykładu 4.1: $\cos\theta = 3/\sqrt{6\cdot 14} = 3/9{,}165 = 0{,}327$, czyli $\theta \approx 70{,}9°$. Rzut $\boldsymbol{v}$ na $\boldsymbol{u}$ to $\boldsymbol{p} = \frac{3}{6}\boldsymbol{u} = (1; 0{,}5; -0{,}5)$, a reszta $\boldsymbol{r} = \boldsymbol{v} - \boldsymbol{p} = (0; 2{,}5; 2{,}5)$. Sprawdzenie prostopadłości: $\langle \boldsymbol{r}, \boldsymbol{u}\rangle = 0\cdot 2 + 2{,}5\cdot 1 + 2{,}5\cdot(-1) = 0$. ✓

Pułapka. Iloczyn skalarny rośnie wraz z długością wektorów, nie tylko z podobieństwem kierunków. Dwa długie, słabo podobne wektory mogą mieć większy iloczyn niż dwa krótkie, równoległe. Dlatego w uwadze dzielimy iloczyn przez $\sqrt{d_h}$ (rozdział 10), a w sieci normalizujemy cechy (rozdział 9). ♢

4.3 Macierz jako przekształcenie

macierz

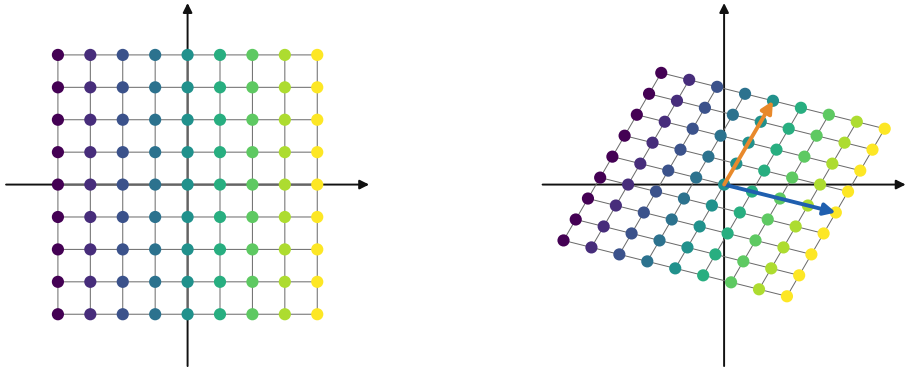
Definicja 4.3 (Iloczyn macierzy i wektora). Dla macierzy $W \in \mathbb{R}^{m\times n}$ i wektora $\boldsymbol{x} \in \mathbb{R}^n$ wektor $W\boldsymbol{x} \in \mathbb{R}^m$ ma współrzędne

$$(W\boldsymbol{x})_i = \sum_{j=1}^{n} W_{ij}x_j = \langle \boldsymbol{w}_i, \boldsymbol{x}\rangle\,, \tag{4.2}$$

gdzie $\boldsymbol{w}_i$ to i-ty wiersz W. Każda współrzędna wyniku to iloczyn skalarny wiersza z wektorem.

Przykład 4.2. Niech $W = \begin{pmatrix} 1 & 2\\ 0 & 1\\ -1 & 1\end{pmatrix} \in \mathbb{R}^{3\times 2}$ i $\boldsymbol{x} = (2, 1)$. Wtedy $W\boldsymbol{x} = (1\cdot 2 + 2\cdot 1,\ 0\cdot 2 + 1\cdot 1,\ -1\cdot 2 + 1\cdot 1) = (4, 1, -1)$: wektor z $\mathbb{R}^2$ trafił do $\mathbb{R}^3$. Dodając wektor obciążenia (ang. *bias*) $\boldsymbol{b} = (0{,}5; 0; 1)$ dostajemy *warstwę liniową* $W\boldsymbol{x} + \boldsymbol{b} = (4{,}5; 1; 0)$.

Intuicja. Macierz 2×2 działa na całą płaszczyznę naraz: prosta zostaje prostą, początek układu zostaje na miejscu, a siatka kwadratów zamienia się w siatkę równoległoboków. Kolumny W to obrazy wektorów bazowych (rys. 4.2). ♢



(a) (b)

Rysunek 4.2: (a) Siatka punktów 9×9 w kwadracie $[-1, 1]^2$, pokolorowana według współrzędnej x (od fioletu do żółci). (b) Obraz tej siatki po przekształceniu $\boldsymbol{x} \mapsto A\boldsymbol{x}$ z kolumnami $A\boldsymbol{e}_1$ (niebieska strzałka) i $A\boldsymbol{e}_2$ (pomarańczowa). Kolory pozwalają śledzić każdy punkt: proste zostają prostymi, a pole kwadratu rośnie $|\det A| = 1{,}2\cdot 1{,}6 + 0{,}7\cdot 0{,}4 = 2{,}2$ razy.

Twierdzenie 4.4 (Mnożenie macierzy to składanie przekształceń). *Dla $A \in \mathbb{R}^{m\times n}$ i $B \in \mathbb{R}^{n\times p}$ macierz $AB \in \mathbb{R}^{m\times p}$ o elementach $(AB)_{ik} = \sum_j A_{ij}B_{jk}$ spełnia $(AB)\boldsymbol{x} = A(B\boldsymbol{x})$ dla każdego $\boldsymbol{x} \in \mathbb{R}^p$.*

Pomysł dowodu. Rozpisujemy obie strony na współrzędne i zamieniamy kolejność sumowania.

Dowód.

$$\begin{aligned}
\big(A(B\boldsymbol{x})\big)_i &= \sum_{j=1}^{n} A_{ij}\,(B\boldsymbol{x})_j && \text{(def. 4.3)}\\
&= \sum_{j=1}^{n} A_{ij} \sum_{k=1}^{p} B_{jk} x_k && \text{(def. 4.3)}\\
&= \sum_{k=1}^{p} \Big(\sum_{j=1}^{n} A_{ij} B_{jk} \Big) x_k && \text{(zmiana kolejności sum)}\\
&= \sum_{k=1}^{p} (AB)_{ik}\, x_k = \big((AB)\boldsymbol{x}\big)_i. && \text{(def. } AB\text{)}
\end{aligned}$$

Obie strony mają te same współrzędne, więc są równe. Wymiary zgadzają się, bo $B\boldsymbol{x} \in \mathbb{R}^n$, a A przyjmuje wektory z $\mathbb{R}^n$. ∎

W zwykłym języku: dwie warstwy liniowe pod rząd to jedna warstwa liniowa o macierzy AB. Dlatego sieci wstawiają między warstwy funkcje nieliniowe (rozdział 9); bez nich głębokość nic by nie dała.

Przykład 4.3 (Kolejność ma znaczenie). Dla $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ i $B = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix}$ mamy $AB = \begin{pmatrix} 3 & 1 \\ 1 & 1 \end{pmatrix}$, ale $BA = \begin{pmatrix} 2 & 2 \\ 1 & 2 \end{pmatrix}$. Mnożenie macierzy nie jest przemienne.

4.4 Ile parametrów ma warstwa?

Warstwa liniowa $\boldsymbol{x} \mapsto W\boldsymbol{x} + \boldsymbol{b}$ z n wejściami i m wyjściami ma $mn + m$ parametrów (W ma mn liczb, $\boldsymbol{b}$ ma m). To najprostszy rachunek, który będziemy powtarzać w dodatku A.

Na konkretnych liczbach. Warstwa $64 \to 256$ (pierwsza w bloku feed-forward modelu Gen 6): $256 \cdot 64 + 256 = 16\,640$ parametrów. Warstwa $256 \to 64$: $64 \cdot 256 + 64 = 16\,448$. Razem blok ma $33\,088$ parametrów.

Podsumowanie

- $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = \sum u_i v_i = \|\boldsymbol{u}\|\,\|\boldsymbol{v}\| \cos\theta$ mierzy zgodność kierunków (tw. 4.2).
- Rzut $\boldsymbol{v}$ na $\boldsymbol{u}$ to $\frac{\langle \boldsymbol{u}, \boldsymbol{v} \rangle}{\|\boldsymbol{u}\|^2}\boldsymbol{u}$; reszta jest prostopadła do $\boldsymbol{u}$.
- $W\boldsymbol{x}$: każda współrzędna to iloczyn skalarny wiersza z wektorem; $m \times n$ to $n \to m$.
- $(AB)\boldsymbol{x} = A(B\boldsymbol{x})$; mnożenie macierzy nie jest przemienne.
- Warstwa liniowa $n \to m$ ma $mn + m$ parametrów.

Ćwiczenia

1. Dla $\boldsymbol{u} = (1, 2, 2)$ i $\boldsymbol{v} = (2, 0, 1)$ policz $\langle \boldsymbol{u}, \boldsymbol{v} \rangle$, obie normy i $\cos\theta$. Czy wektory są prostopadłe?
2. Znajdź wektor $\boldsymbol{w}$ prostopadły do $\boldsymbol{u} = (1, 2, 2)$, taki że $\boldsymbol{w} = (a, 1, 0)$.

3. Policz AB dla $A = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix}$, $B = \begin{pmatrix} 1 & 3 \\ 0 & 2 \end{pmatrix}$ i sprawdź tw. 4.4 dla $\boldsymbol{x} = (1, 1)$.
4. Ile parametrów ma warstwa $159 \to 48$? A konwolucja 1×1 z 336 kanałów do 48 (zob. rozdz. 9)?

Rozwiązania

1. $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = 2 + 0 + 2 = 4$, $\|\boldsymbol{u}\| = 3$, $\|\boldsymbol{v}\| = \sqrt{5}$, $\cos\theta = 4/(3\sqrt{5}) = 0{,}596$. Nie są prostopadłe (iloczyn $\neq 0$).
2. $\langle \boldsymbol{u}, \boldsymbol{w} \rangle = a + 2 = 0$, więc $a = -2$ i $\boldsymbol{w} = (-2, 1, 0)$.
3. $AB = \begin{pmatrix} 2 & 6 \\ 1 & 5 \end{pmatrix}$. $AB\boldsymbol{x} = (8, 6)$; $B\boldsymbol{x} = (4, 2)$, $A(B\boldsymbol{x}) = (8, 4+2) = (8, 6)$. ✓
4. $159 \cdot 48 + 48 = 7680$. Konwolucja 1×1 to warstwa liniowa w każdym punkcie: $336 \cdot 48 + 48 = 16\,176$ parametrów.

5 Pochodne, gradient i propagacja wsteczna

5.1 Jak poprawić model, który się myli?

Model ma miliony pokręteł, czyli parametrów. Po każdej pomyłce chcemy wiedzieć: *w którą stronę i jak mocno przekręcić każde pokrętło, żeby błąd zmalał?* Odpowiedzią jest gradient, a narzędziem do jego liczenia reguła łańcuchowa. Ten rozdział wyprowadza obie rzeczy od początku i pokazuje na malutkiej sieci (jeden neuron), jak wygląda propagacja wsteczna.

Po tym rozdziale umiesz: (i) policzyć pochodną złożenia funkcji, (ii) uzasadnić, że gradient wskazuje kierunek najszybszego wzrostu, (iii) zrobić krok spadku gradientu, (iv) policzyć ręcznie gradient strat dla jednego neuronu i sprawdzić go numerycznie.

5.2 Pochodna funkcji jednej zmiennej

pochodna

Definicja 5.1 (Pochodna). *Pochodną* funkcji f w punkcie x nazywamy granicę (o ile istnieje)

$$f'(x) = \lim_{h\to 0} \frac{f(x+h)-f(x)}{h}. \tag{5.1}$$

Liczba $f'(x)$ to nachylenie stycznej do wykresu w punkcie x.

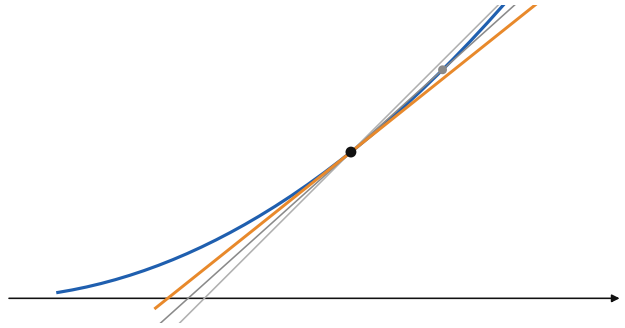
Przykład 5.1. Dla $f(x)=x^2$: $\dfrac{(x+h)^2-x^2}{h} = \dfrac{2xh+h^2}{h} = 2x+h \to 2x$. W punkcie $x=3$ nachylenie wynosi 6. Nachylenia siecznych przez $(3,9)$ i $(3+h,(3+h)^2)$ to 7, 6,5, 6,1, 6,01 dla $h = 1;\,0{,}5;\,0{,}1;\,0{,}01$: zbliżają się do 6 (rys. 5.1).

Intuicja. Pochodna odpowiada na pytanie: „o ile zmieni się wynik, jeśli wejście poruszę o drobinę?”. Zmiana wyniku $\approx f'(x)\cdot$ zmiana wejścia. To przybliżenie liniowe jest sercem uczenia: nie trzeba znać całej funkcji, wystarczy jej lokalne nachylenie. ♢

Zbierzmy reguły, których użyjemy (pierwsze dwie wynikają wprost z def. 5.1): $(af+bg)' = af'+bg'$, $(fg)' = f'g+fg'$. Najważniejsza jest trzecia.

Twierdzenie 5.2 (Reguła łańcuchowa). *Jeśli g jest różniczkowalna w x, a f w $u=g(x)$, to $(f\circ g)'(x) = f'(g(x))\cdot g'(x)$.*

Pomysł dowodu. Przybliżamy g prostą o nachyleniu $g'(x)$, a potem f prostą o nachyleniu $f'(u)$. Nachylenia mnożą się.



Rysunek 5.1: Pochodna jako granica nachyleń. Funkcja x^2 (niebieska) i sieczne (szare) przez punkt $(3,9)$ (czarny) i punkty oddalone o $h = 1{,}5$ oraz $0{,}75$. Gdy $h\to 0$, sieczna dąży do stycznej (pomarańczowa) o nachyleniu $f'(3)=6$.

Dowód. Różniczkowalność g w x oznacza $g(x+h)-g(x) = g'(x)h+\varepsilon_1(h)h$, gdzie $\varepsilon_1(h)\to 0$ przy $h\to 0$. Podobnie dla f w $u=g(x)$ i $k=g(x+h)-g(x)$: $f(u+k)-f(u) = f'(u)k+\varepsilon_2(k)k$, $\varepsilon_2(k)\to 0$ przy $k\to 0$ (ustalamy $\varepsilon_2(0)=0$). Zatem

$$\begin{aligned}
\frac{f(g(x+h))-f(g(x))}{h} &= \frac{f'(u)\,k+\varepsilon_2(k)\,k}{h} && \text{(rozwinięcie } f\text{)}\\
&= \big(f'(u)+\varepsilon_2(k)\big)\cdot\frac{k}{h} && \text{(wyłączenie } k\text{)}\\
&= \big(f'(u)+\varepsilon_2(k)\big)\big(g'(x)+\varepsilon_1(h)\big). && (k/h \text{ z rozwinięcia } g)
\end{aligned}$$

Gdy $h\to 0$, to $k\to 0$ (bo g jest ciągła), więc $\varepsilon_1,\varepsilon_2\to 0$ i całość dąży do $f'(u)g'(x)$. To kończy dowód. ■

W zwykłym języku: pochodna złożenia to iloczyn pochodnych kolejnych etapów. Sieć neuronowa to długie złożenie, więc jej pochodna to długi iloczyn.

Twierdzenie 5.3 (Pochodna sigmoidy). *Funkcja $\sigma(z) = \dfrac{1}{1+e^{-z}}$ spełnia $\sigma'(z) = \sigma(z)\big(1-\sigma(z)\big)$.*

Pomysł dowodu. Zapisujemy $\sigma = (1+e^{-z})^{-1}$ i stosujemy regułę łańcuchową.

Dowód. Niech $u = 1+e^{-z}$, więc $\sigma = u^{-1}$, $\dfrac{d\sigma}{du} = -u^{-2}$ i $\dfrac{du}{dz} = -e^{-z}$. Z tw. 5.2:

$$\begin{aligned}
\sigma'(z) &= -u^{-2}\cdot(-e^{-z}) = \frac{e^{-z}}{(1+e^{-z})^2} && \text{(reguła łańcuchowa)}\\
&= \frac{1}{1+e^{-z}}\cdot\frac{e^{-z}}{1+e^{-z}} && \text{(rozbicie)}\\
&= \sigma(z)\Big(1-\frac{1}{1+e^{-z}}\Big) = \sigma(z)\big(1-\sigma(z)\big). && \big(\tfrac{e^{-z}}{1+e^{-z}} = 1-\sigma\big)
\end{aligned}$$

Pochodną można więc policzyć z samej wartości σ, bez ponownego liczenia wykładnika. To kończy dowód. ■

Największa pochodna wynosi $\sigma'(0) = \frac{1}{2}\cdot\frac{1}{2} = \frac{1}{4}$; dla $|z|$ dużego pochodna dąży do zera (*nasycenie*) — to jedna z przyczyn, dla których głębokie sieci z samymi sigmoidami uczą się wolno.

5.3 Gradient i spadek gradientu

gradient

Definicja 5.4 (Pochodna cząstkowa i gradient). Dla $f\colon \mathbb{R}^n \to \mathbb{R}$ *pochodna cząstkowa* $\partial f/\partial x_i$ to pochodna po x_i przy pozostałych współrzędnych traktowanych jak stałe. *Gradient* to wektor tych pochodnych: $\nabla f(\boldsymbol{x}) = \left(\frac{\partial f}{\partial x_1}, \ldots, \frac{\partial f}{\partial x_n}\right)$.

Przykład 5.2. Dla $f(x,y) = x^2 + 3xy$: $\partial f/\partial x = 2x + 3y$, $\partial f/\partial y = 3x$. W punkcie $(1,2)$ gradient to $(8,3)$ o długości $\sqrt{73} \approx 8{,}54$. Zwiększenie x o 0,01 zwiększa f o ok. 0,08, zwiększenie y o 0,01 o ok. 0,03.

Twierdzenie 5.5 (Gradient wskazuje kierunek najszybszego wzrostu). *Niech f będzie różniczkowalna w $\boldsymbol{x}$ i $\nabla f(\boldsymbol{x}) \neq \boldsymbol{0}$. Wśród wektorów jednostkowych $\boldsymbol{d}$ pochodna kierunkowa $\frac{d}{dt} f(\boldsymbol{x} + t\boldsymbol{d})\big|_{t=0}$ jest największa dla $\boldsymbol{d} = \nabla f / \|\nabla f\|$ i wynosi wtedy $\|\nabla f\|$.*

Pomysł dowodu. Reguła łańcuchowa zamienia pochodną kierunkową na iloczyn skalarny $\langle \nabla f, \boldsymbol{d}\rangle$, a tu działa nierówność Cauchy'ego–Schwarza (tw. 4.2).

Dowód. Niech $\phi(t) = f(\boldsymbol{x} + t\boldsymbol{d})$. Z reguły łańcuchowej dla wielu zmiennych (każda współrzędna zależy od t z pochodną d_i):

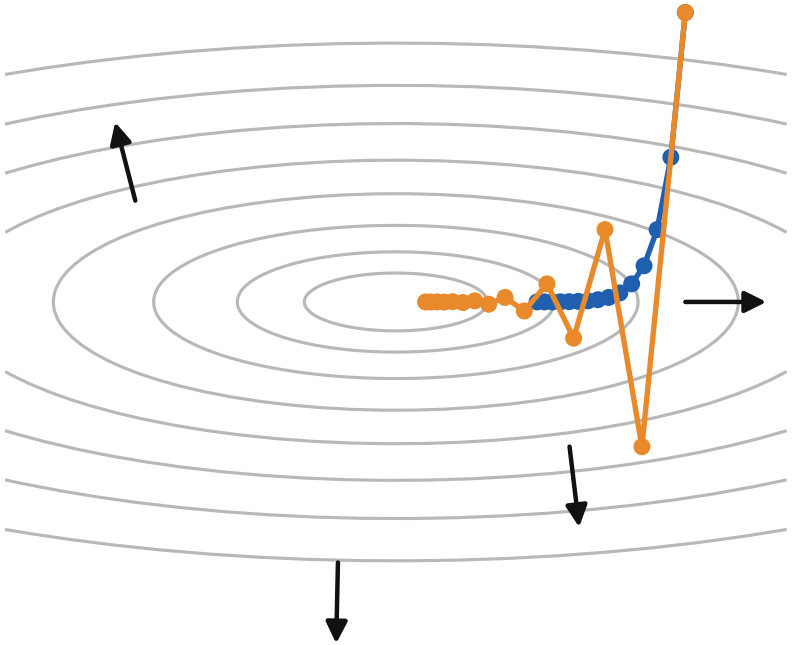
$$\begin{aligned} \phi'(0) &= \sum_{i=1}^{n} \frac{\partial f}{\partial x_i} d_i && \text{(reguła łańcuchowa)} \\ &= \langle \nabla f(\boldsymbol{x}), \boldsymbol{d}\rangle \le \|\nabla f\|\,\|\boldsymbol{d}\| = \|\nabla f\|\,. && \text{(tw. 4.2, } \|\boldsymbol{d}\| = 1\text{)} \end{aligned}$$

Równość w Cauchy'ego–Schwarza zachodzi, gdy $\boldsymbol{d}$ jest równoległy do ∇f, czyli $\boldsymbol{d} = \nabla f / \|\nabla f\|$ (dodatnia wielokrotność, żeby wynik był dodatni). Wtedy $\phi'(0) = \langle \nabla f, \nabla f\rangle / \|\nabla f\| = \|\nabla f\|$. To kończy dowód. ∎

W zwykłym języku: stoisz na zboczu i chcesz iść w górę jak najszybciej — idź wzdłuż gradientu. Chcemy *zmniejszać* stratę, więc idziemy *przeciwnie*.

Definicja 5.6 (Spadek gradientu). Dla funkcji straty $L(\boldsymbol{\theta})$ i *kroku uczenia* $\eta > 0$ kolejne przybliżenia to $\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \eta\,\nabla L(\boldsymbol{\theta}_k)$.

Na konkretnych liczbach. Weźmy $L(x,y) = \frac{1}{2}(x^2 + 10y^2)$, $\nabla L = (x, 10y)$ i start $(1,1)$. Dla $\eta = 0{,}05$ kolejne punkty to $(0{,}95; 0{,}5)$, $(0{,}902; 0{,}25)$, $(0{,}857; 0{,}125)$: schodzimy gładko, ale wolno wzdłuż x. Dla $\eta = 0{,}15$: $(0{,}85; -0{,}5)$, $(0{,}722; 0{,}25)$, $(0{,}614; -0{,}125)$: współrzędna y zmienia znak w każdym kroku (zygzak) i jest dwa razy mniejsza w kolejnych krokach. Dla $\eta = 0{,}21$ zygzak rośnie i metoda się rozbiega (dlaczego, wyjaśnia tw. 11.1 w rozdziale 11).



Rysunek 5.2: Spadek gradientu dla $L = \frac{1}{2}(x^2 + 10y^2)$ (szare warstwice) z punktu $(1,1)$. Czarne strzałki to gradient w kilku punktach: zawsze prostopadły do warstwicy i skierowany pod górę, więc krok idzie w przeciwną stronę. Niebieska ścieżka ($\eta = 0{,}05$, 14 kroków) schodzi gładko, ale wolno; pomarańczowa ($\eta = 0{,}15$) przeskakuje przez dolinę i zygzakuje. Obie obliczone programem.

5.4 Propagacja wsteczna na jednym neuronie

Przykład 5.3 (Gradient strat dla neuronu). Neuron: $z = wx + b$, $\hat{y} = \sigma(z)$, strata $L = (\hat{y} - y)^2$. Dane: $x = 2$, $w = 0{,}5$, $b = -0{,}3$, cel $y = 1$. *Przód:* $z = 0{,}7$, $\hat{y} = \sigma(0{,}7) = 0{,}6682$, $L = (0{,}6682 - 1)^2 = 0{,}1101$. *Tył*

(reguła łańcuchowa, od wyniku ku wejściu):

$$\frac{\partial L}{\partial \hat{y}} = 2(\hat{y}-y) = -0{,}6636,$$
$$\frac{\partial \hat{y}}{\partial z} = \hat{y}(1-\hat{y}) = 0{,}2217 \qquad \text{(tw. 5.3)}$$
$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial w} = (-0{,}6636)(0{,}2217)(2) = -0{,}2943,$$
$$\frac{\partial L}{\partial b} = (-0{,}6636)(0{,}2217)(1) = -0{,}1471.$$

Sprawdzenie numeryczne: $\big(L(w+10^{-6}) - L(w-10^{-6})\big)/(2\cdot 10^{-6}) = -0{,}2943$. ✓Ujemny gradient oznacza, że *zwiększenie* w zmniejsza stratę: neuron powinien być bardziej pewny odpowiedzi 1.

Intuicja. Propagacja wsteczna to reguła łańcuchowa wykonana od końca: zaczynamy od „jak strata zależy od wyniku” i cofając się przez każdą operację, mnożymy przez jej lokalną pochodną. Każda warstwa musi znać tylko własną pochodną i gradient przychodzący z góry; dzięki temu da się to zautomatyzować dla dowolnej sieci (PyTorch robi dokładnie to). ♢

Pułapka. Gradient policzony ręcznie warto *zawsze* porównać z ilorazem różnicowym (jak wyżej). Błąd znaku albo brakującego czynnika nie powoduje awarii, tylko powolne, dziwne uczenie, które trudno zdiagnozować. Granice stosowalności: różnica 10^{-6} w `float64` jest dobra; w `float32` zbyt mały krok tonie w błędach zaokrągleń. ♢

Podsumowanie

- Pochodna to nachylenie stycznej; zmiana wyniku $\approx f'(x)\cdot$ zmiana wejścia.
- Reguła łańcuchowa: pochodna złożenia to iloczyn pochodnych (tw. 5.2); $\sigma' = \sigma(1-\sigma)$.
- Gradient to wektor pochodnych cząstkowych i wskazuje kierunek najszybszego wzrostu (tw. 5.5).
- Spadek gradientu: $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla L$; za duży krok powoduje zygzak i rozbieżność.
- Propagacja wsteczna to reguła łańcuchowa liczona od wyniku w stronę wejść; wynik sprawdzamy ilorazem różnicowym.

Ćwiczenia

1. Policz pochodną $f(x) = \sigma(3x-1)$ w $x=0$. (Wskazówka: tw. 5.2 i 5.3.)
2. Dla $f(x,y) = x^2 + 3xy$ w punkcie $(1,2)$ podaj kierunek jednostkowy najszybszego wzrostu i wartość pochodnej kierunkowej w tym kierunku.
3. Wykonaj jeden krok spadku gradientu z $(1,2)$ dla $L = x^2+3xy$ i $\eta = 0{,}01$. O ile (w przybliżeniu) zmieni się L?
4. Neuron z przykładu 5.3 ma $y=0$ zamiast 1. Jaki jest teraz $\partial L/\partial w$?

Rozwiązania

1. $\sigma(-1) = 0{,}2689$, więc $f'(0) = 3\sigma(-1)(1-\sigma(-1)) = 3\cdot 0{,}2689\cdot 0{,}7311 = 0{,}590$.
2. $\nabla f = (8,3)$, kierunek $(8,3)/8{,}544 = (0{,}936;\, 0{,}351)$, pochodna kierunkowa $\|\nabla f\| = 8{,}544$.
3. Krok: $(1,2) - 0{,}01(8,3) = (0{,}92;\, 1{,}97)$. $L(1,2) = 1+6 = 7$; $L(0{,}92;1{,}97) = 0{,}8464 + 5{,}4372 = 6{,}2836$. Zmiana $\approx -0{,}716$ (przybliżenie liniowe: $-\eta\,\|\nabla f\|^2 = -0{,}01\cdot 73 = -0{,}73$).
4. $\partial L/\partial \hat{y} = 2(0{,}6682 - 0) = 1{,}3364$, więc $\partial L/\partial w = 1{,}3364\cdot 0{,}2217\cdot 2 = 0{,}5926$ (dodatni: w należy *zmniejszyć*).

6 Transformata Fouriera: z drgań do widma

6.1 Co jest w tym nagraniu?

Nagranie to ciąg liczb zmieniających się w czasie. Nas interesuje coś innego: *jakie częstotliwości w nim grają?* Odpowiada na to transformata Fouriera, która rozkłada sygnał na sinusoidy. Dla krótkiego okna dźwięku zamienia N próbek w N liczb mówiących, ile energii niesie każda częstotliwość. To jest pierwszy krok liczenia cech Gen 6 (rozdział 7). Poznamy jej własności i, co ważne, *ograniczenia*: przeciek i skończoną rozdzielczość.

Po tym rozdziale umiesz: (i) policzyć DFT małego sygnału ręcznie, (ii) uzasadnić, że wiąże ona sinusoidy z pojedynczymi prążkami, (iii) wyjaśnić, czemu stosuje się okno Hanna, (iv) policzyć rozdzielczość f_s/N i ocenić, czy dwa dźwięki da się rozdzielić.

6.2 Liczby zespolone w dwóch zdaniach

wzór Eulera

Definicja 6.1 (Jednostka urojona i wzór Eulera). Liczba i spełnia $i^2 = -1$. Dla rzeczywistego θ definiujemy $e^{i\theta} = \cos\theta + i\sin\theta$ — punkt na okręgu jednostkowym o kącie θ. Moduł $|a+ib| = \sqrt{a^2+b^2}$. Zachodzi $e^{i\alpha}e^{i\beta} = e^{i(\alpha+\beta)}$ oraz $\left|e^{i\theta}\right| = 1$.

Przykład 6.1. $e^{i\pi} = \cos\pi + i\sin\pi = -1$, $e^{i\pi/2} = i$, $e^{-i\pi/2} = -i$. Zatem $\cos\theta = \frac{1}{2}(e^{i\theta}+e^{-i\theta})$ i $\sin\theta = \frac{1}{2i}(e^{i\theta}-e^{-i\theta})$ — sinus i cosinus to „składowe" punktu na okręgu.

6.3 Dyskretna transformata Fouriera

DFT

Definicja 6.2 (DFT). Dla ciągu $x[0],\dots,x[N-1]$ jego *dyskretna transformata Fouriera* to ciąg liczb zespolonych

$$X[k] = \sum_{n=0}^{N-1} x[n]\, e^{-2\pi i k n/N}, \qquad k = 0,1,\dots,N-1. \tag{6.1}$$

Numer k odpowiada częstotliwości $f_k = k\,f_s/N$; $|X[k]|$ nazywamy *widmem amplitudowym*. Odstęp $\Delta f = f_s/N$ między sąsiednimi k to *rozdzielczość* (szerokość binu) DFT.

Przykład 6.2 ($N=4$ ręcznie). Niech $x = (1,0,-1,0)$, czyli jeden okres cosinusa w 4 próbkach. Ponieważ $e^{-2\pi i k n/4} = (-i)^{kn}$: $X[0] = 1+0-1+0 = 0$; $X[1] = 1+(-1)(-i)^2 = 1+1 = 2$; $X[2] = 1+(-1)(-i)^4 = 1-1 = 0$; $X[3] = 1+(-1)(-i)^6 = 1+1 = 2$. Widmo $|X| = (0,2,0,2)$: cosinus daje dwa prążki, w $k=1$ i lustrzany $k = 3 = N-1$. Przy $f_s = 4\,\mathrm{Hz}$ prążek $k=1$ to $1\,\mathrm{Hz}$.

Intuicja. $X[k]$ mierzy, jak bardzo sygnał „zgadza się" z sinusoidą o k obiegach na okno: mnożymy sygnał przez tę sinusoidę i sumujemy (to iloczyn skalarny z rozdziału 4!). Gdy sygnał ją zawiera, wszystkie składniki sumy dodają się; gdy nie, wzajemnie się znoszą. ♢

Twierdzenie 6.3 (Ortogonalność sinusoid). *Dla całkowitych k,l:*

$$\sum_{n=0}^{N-1} e^{2\pi i(k-l)n/N} = \begin{cases} N, & k \equiv l \pmod N, \\ 0, & \text{w przeciwnym razie.} \end{cases} \tag{6.2}$$

Pomysł dowodu. To suma wyrazów ciągu geometrycznego o ilorazie $q = e^{2\pi i(k-l)/N}$, a $q^N = 1$.

Dowód. Niech $q = e^{2\pi i(k-l)/N}$. Gdy $k \equiv l \pmod N$, to $q = 1$ i suma ma N składników równych 1, czyli wynosi N. W przeciwnym razie $q \neq 1$ i ze wzoru na sumę ciągu geometrycznego

$$\begin{aligned} \sum_{n=0}^{N-1} q^n &= \frac{1-q^N}{1-q} && \text{(suma geometryczna)} \\ &= \frac{1-e^{2\pi i(k-l)}}{1-q} = \frac{1-1}{1-q} = 0. && (q^N = e^{2\pi i(k-l)} = 1) \end{aligned}$$

Sinusoidy o różnych numerach są więc wzajemnie prostopadłe (iloczyn skalarny zero), a o tym samym mają „długość" $\sqrt{N}$. To kończy dowód. ■

Wniosek 6.4 (DFT sinusoidy o całkowitej liczbie okresów). *Jeśli $x[n] = A\cos(2\pi k_0 n/N)$ dla całkowitego $0 < k_0 < N/2$, to $X[k_0] = X[N-k_0] = AN/2$, a pozostałe $X[k] = 0$.*

Dowód. Z przykładu 6.1: $x[n] = \frac{A}{2}\left(e^{2\pi i k_0 n/N} + e^{-2\pi i k_0 n/N}\right)$. Wstawiamy do (6.1):

$$\begin{aligned} X[k] &= \frac{A}{2}\sum_n e^{2\pi i(k_0-k)n/N} + \frac{A}{2}\sum_n e^{-2\pi i(k_0+k)n/N} && \text{(rozdzielność)} \\ &= \frac{A}{2}N\mathbb{1}[k=k_0] + \frac{A}{2}N\mathbb{1}[k=N-k_0]\,. && \text{(tw. 6.3)} \end{aligned}$$

Dla $N=4$, $k_0=1$, $A=1$ daje to $X[1]=X[3]=2$, zgodnie z przykładem 6.2. Czysty ton daje więc dokładnie jeden prążek (i jego lustro). ■

6.4 Przeciek i okno

Jest haczyk: wniosek 6.4 wymaga, by ton miał *całkowitą* liczbę okresów w oknie. Częstotliwości nut tego nie spełniają. Co się dzieje, gdy k_0 nie jest całkowite?

Twierdzenie 6.5 (Przeciek). *Niech $x[n] = e^{2\pi i \kappa n/N}$ z dowolnym rzeczywistym κ i niech $\delta = \kappa - k$. Wtedy*

$$|X[k]| = \left| \frac{\sin(\pi\delta)}{\sin(\pi\delta/N)} \right|. \tag{6.3}$$

Jest to N dla $\delta = 0$, zero dla niezerowych całkowitych δ i ok. $\frac{2}{\pi}N \approx 0{,}64N$ dla $\delta = \frac{1}{2}$ (dla dużych N).

Pomysł dowodu. To znów suma geometryczna, tym razem z ilorazem $e^{2\pi i\delta/N} \neq 1$; moduł licznika i mianownika daje sinusy.

Dowód. Z (6.1) i definicji δ:

$$\begin{aligned} X[k] &= \sum_{n=0}^{N-1} e^{2\pi i\delta n/N} = \frac{1-e^{2\pi i\delta}}{1-e^{2\pi i\delta/N}} && \text{(suma geometryczna)} \\ &= \frac{e^{i\pi\delta}\left(e^{-i\pi\delta} - e^{i\pi\delta}\right)}{e^{i\pi\delta/N}\left(e^{-i\pi\delta/N} - e^{i\pi\delta/N}\right)} && \text{(wyłączenie połówek kątów)} \\ &= e^{i\pi\delta(1-1/N)}\,\frac{\sin(\pi\delta)}{\sin(\pi\delta/N)}. && \text{(wzór Eulera na sinus)} \end{aligned}$$

Moduł czynnika $e^{i\cdots}$ wynosi 1, więc zostaje podany wzór. Dla $\delta = 0$ granica to N; dla całkowitego $\delta \neq 0$ licznik jest zerem; dla $\delta = \frac{1}{2}$ mianownik $\sin(\pi/2N) \approx \pi/2N$, a licznik 1, czyli $\approx 2N/\pi$. To kończy dowód. ■

W zwykłym języku: ton między binami „rozlewa się" na sąsiednie prążki i traci w najgorszym miejscu ok. 3,9 dB głośności ($20\log_{10}(2/\pi) = -3{,}9$ dB). Poza tym ogony przecieku opadają wolno: pierwszy listek boczny okna prostokątnego to tylko -13 dB. Silny ton zasłoni więc słabe składowe daleko od siebie. Rozwiązaniem jest okno.

okno Hanna

Definicja 6.6 (Okno Hanna). *Oknem Hanna* nazywamy $w[n] = \frac{1}{2}\big(1 - \cos(2\pi n/N)\big)$, $n = 0, \ldots, N-1$. Przed liczeniem DFT mnożymy próbki przez $w[n]$.

Przykład 6.3. Dla $N = 8$: $w = (0;\, 0{,}146;\, 0{,}5;\, 0{,}854;\, 1;\, 0{,}854;\, 0{,}5;\, 0{,}146)$: okno łagodnie zaczyna się od zera, osiąga 1 w środku i znów opada. Brzegi okna nie są więc ucinane gwałtownie, a to właśnie nagła krawędź powoduje długi ogon przecieku.

Twierdzenie 6.7 (Widmo okna Hanna). *Jeśli $Y[k]$ jest DFT sygnału $y[n]$ z oknem prostokątnym, to DFT sygnału $y[n]w[n]$ z oknem Hanna wynosi $\frac{1}{2}Y[k] - \frac{1}{4}Y[k-1] - \frac{1}{4}Y[k+1]$.*

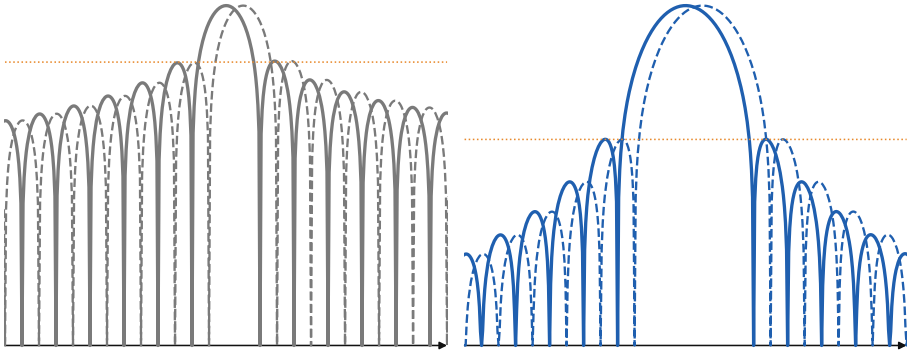
Pomysł dowodu. Zapisujemy $w[n] = \frac{1}{2} - \frac{1}{4}e^{2\pi in/N} - \frac{1}{4}e^{-2\pi in/N}$ i zauważamy, że mnożenie przez $e^{2\pi in/N}$ przesuwa widmo o jeden bin.

Dowód. Z wzoru Eulera $\cos(2\pi n/N) = \frac{1}{2}\big(e^{2\pi in/N} + e^{-2\pi in/N}\big)$, więc $w[n] = \frac{1}{2} - \frac{1}{4}e^{2\pi in/N} - \frac{1}{4}e^{-2\pi in/N}$. Dla składnika z $e^{2\pi in/N}$:

$$\sum_n y[n]e^{2\pi in/N}e^{-2\pi ikn/N} = \sum_n y[n]e^{-2\pi i(k-1)n/N} = Y[k-1]. \quad \text{(złączenie wykładników)}$$

Analogicznie $e^{-2\pi in/N}$ daje $Y[k+1]$. Z liniowości DFT otrzymujemy podany wzór. To kończy dowód. ■

Skutki (to już obserwacja liczbowa, rys. 6.1, a nie część dowodu): kopie z $k \pm 1$ mają znak przeciwny niż środkowa, więc kasują ogon przecieku, a główny listek robi się szerszy (4 biny między zerami zamiast 2). Pierwszy listek boczny spada z $-13{,}3$ dB (okno prostokątne) do $-31{,}5$ dB.



(a) (b)

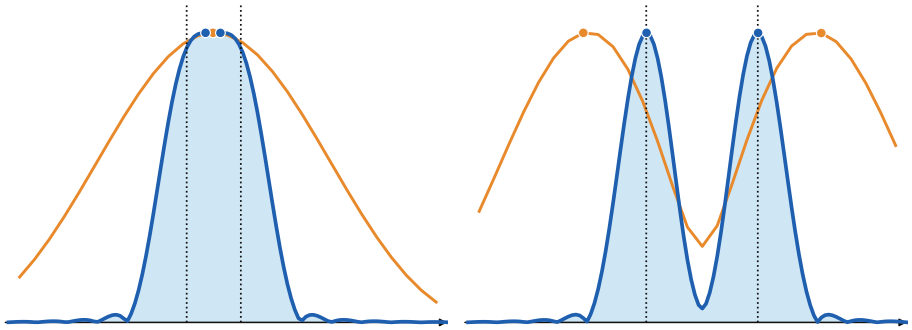
Rysunek 6.1: Widmo tonu z $N = 128$ próbek w decybelach (skala od -80 do 0 dB, wspólna). Ton dokładnie w prążku (linia ciągła) i w połowie między prążkami (przerywana). (a) Okno prostokątne (szare): wąski pik, ale listki boczne opadają wolno; pierwszy ma -13 dB (pomarańczowa kropkowana). (b) Okno Hanna (niebieskie): pik dwa razy szerszy, ale pierwszy listek tylko -31 dB (pomarańczowa kropkowana), a dalsze opadają szybko. Ton między prążkami ma niższy pik w obu oknach.

Pułapka. Okno Hanna nie jest za darmo: rozszerza główny listek dwukrotnie, więc *pogarsza rozdzielczość*. Zyskujemy czystość widma (brak „duchów" od silnych tonów), tracimy zdolność do rozdzielania dwóch bliskich dźwięków. Wybór okna to zawsze kompromis. ♢

6.5 Rozdzielczość: kiedy dwa dźwięki są jednym

Gen 6 liczy FFT dla okna $N = 4096$ przy $f_s = 11\,025$ Hz (czas 372 ms), więc $\Delta f = 2{,}69$ Hz; główny listek Hanna ma $\pm 2\Delta f = \pm 5{,}4$ Hz. Zero-padding (dopisanie zer, rozdział 7) dzieli siatkę na 0,67 Hz, ale *nie zwiększa rozdzielczości* — tylko interpoluje ten sam kształt.

Na konkretnych liczbach. Najniższe nuty gitary leżą blisko siebie: E2 (82,41 Hz) i F2 (87,31 Hz) dzieli 4,9 Hz, mniej niż 5,4 Hz połowy głównego listka. Numerycznie (rys. 6.2a) widmo sumy z oknem 4096 ma dwa „piki" w 84,1 i 85,5 Hz: to artefakt interferencji, nie prawdziwe położenia nut. Dla E2 i F#2 (10,1 Hz różnicy) piki są już rozdzielone i leżą w 82,8 i 92,2 Hz, czyli mniej niż 0,4 Hz od prawdy (b). Okno $N = 1024$ ($\Delta f = 10{,}8$ Hz) daje dla pary (b) dwa piki w błędnych miejscach (78,1 i 96,9 Hz).



(a) (b)

Rysunek 6.2: Widmo (okno Hanna) sumy dwóch sinusoid; czarne kropkowane pionowe linie to prawdziwe częstotliwości, kropki to znalezione piki. Niebieskie z wypełnieniem: okno $N = 4096$; pomarańczowe: $N = 1024$. (a) E2 i F2 (półton, 4,9 Hz): długie okno daje dwa bliskie piki w złych miejscach (interferencja), krótkie jeden szeroki pagórek. (b) E2 i F#2 (10,1 Hz): długie okno rozdziela tony prawie bez błędu położenia, krótkie daje dwa piki odsunięte od prawdy o kilka herców. Dlatego model dostaje dwa okna — długie dla wysokości, krótkie dla czasu — i uczy się łączyć wskazówki z wielu klatek.

Wniosek jest uczciwy i ważny: z samego widma jednej klatki nie da się wiarygodnie odróżnić sąsiednich niskich półtonów. Dlatego dalsze rozdziały dodają kontekst w czasie (uwaga między klatkami) i szereg alikwotów (wyższe alikwoty są szerzej rozstawione w hercach, więc łatwiej je rozdzielić).

Podsumowanie

- DFT $X[k] = \sum x[n] e^{-2\pi i k n/N}$; bin k to $k f_s/N$ Hz; rozdzielczość $\Delta f = f_s/N$.
- Sinusoidy o różnych k są ortogonalne (tw. 6.3); ton o całkowitej liczbie okresów daje jeden prążek.
- Ton między binami „przecieka” (tw. 6.5); okno prostokątne ma listki -13 dB.
- Okno Hanna to trzy przesunięte kopie okna prostokątnego (tw. 6.7): listki -31 dB, ale główny listek dwa razy szerszy.
- Dla $N = 4096$ rozdzielczość to 2,7 Hz, a sąsiednie niskie półtony (odstęp 4,9 Hz) nie rozdzielają się czysto.

Ćwiczenia

1. Policz ręcznie DFT dla $x = (1, 1, 0, 0)$ ($N = 4$) i podaj widmo amplitudowe.
2. Ile wynosi Δf dla $N = 1024$ i $N = 16384$ przy $f_s = 11025$ Hz? Który z nich ma większą *rozdzielczość* i dlaczego $N = 16384$ z zero-paddingiem z 4096 nie jest dokładniejszy niż 4096?
3. Ton $A\cos(2\pi \cdot 10n/64)$ ma $N = 64$. Które k mają niezerowe $X[k]$ i ile wynosi $|X|$ dla $A = 2$?

4. Pokaż, że $\sum_{n=0}^{N-1} w[n] = N/2$ dla okna Hanna (wskazówka: tw. 6.3 z $k = l \pm 1$).

Rozwiązania

1. $X[k] = 1 + e^{-2\pi i k/4} = 1 + (-i)^k$: $X[0] = 2$, $X[1] = 1 - i$, $X[2] = 0$, $X[3] = 1 + i$. $|X| = (2, \sqrt{2}, 0, \sqrt{2})$.
2. $\Delta f = 10{,}77$ Hz i 0,673 Hz. Zero-padding z 4096 do 16384 daje siatkę 0,673 Hz, ale okno nadal trwa 372 ms, więc rozdzielczość pozostaje 2,69 Hz (główny listek tak samo szeroki). Prawdziwe $N = 16384$ próbek (1,5 s) miałoby $\Delta f = 0{,}673$ Hz *prawdziwej* rozdzielczości.
3. $k = 10$ i $k = 54$; $|X| = AN/2 = 2 \cdot 64/2 = 64$.
4. $\sum w = \frac{1}{2}N - \frac{1}{4}\sum e^{2\pi i n/N} - \frac{1}{4}\sum e^{-2\pi i n/N} = \frac{N}{2} - 0 - 0 = \frac{N}{2}$, bo sumy z $k - l = \pm 1$ są zerami.

7 HCQT: widmo ułożone harmonicznie

7.1 Pomysł: niech każdy kandydat widzi swoje alikwoty w jednym miejscu

Mamy widmo $|X[k]|$ okna dźwięku (rozdział 6) i wiemy, że nuta to szereg alikwotów (rozdział 3). Chcemy, żeby sieć uczyła się „wzorca nuty". Gdyby ułożyć widmo tak, by dla *każdego kandydata na wysokość* wszystkie jego alikwoty leżały w tym samym miejscu tensora, zwykła konwolucja (rozdział 9) mogłaby je porównywać bez żadnej kombinatoryki. Tak działa HCQT (ang. *harmonic constant-Q transform*): to stos kopii widma, z których h-ta jest „ściśnięta" h-krotnie. Nasz opis opiera się na pomyśle Bittnera i in. (2017).

Po tym rozdziale umiesz: (i) zdefiniować wartość HCQT w binie p kanału h, (ii) policzyć decybele i normalizację, (iii) udowodnić, że cechy nie zależą od głośności nagrania, (iv) udowodnić, że kanały to przesunięte kopie jednego widma, (v) odczytać kształt $X \in \mathbb{R}^{T\times 9\times 159}$.

7.2 Biny logarytmiczne i alikwoty

Zamiast równych odstępów w hercach (jak w DFT) używamy równych odstępów w *półtonach*: wprost z rozdziału 3 wiemy, że wtedy wzorzec alikwotów jest niezmienniczy względem przesunięcia.

bin logarytmiczny

Definicja 7.1 (Bin wysokości i jego częstotliwość). Niech $b = 3$ (liczba binów na półton) i $m_{\min} = 36$. Bin o numerze $p = 0, 1, \ldots, 158$ ma wysokość $m_p = m_{\min} + \dfrac{p-1}{3}$ (w skali MIDI) i częstotliwość środkową $f(p) = 440 \cdot 2^{(m_p-69)/12}$. Bin $p = 3s+1$ jest środkiem półtonu $s = 0, \ldots, 52$ (nuta MIDI $36+s$); biny $3s$ i $3s+2$ leżą 33,3 centa niżej i wyżej.

Przykład 7.1. Nuta E2 ($m = 40$, $s = 4$) leży w binie $p = 3\cdot 4+1 = 13$: $m_{13} = 36+12/3 = 40$ i $f = 82{,}41$ Hz. Biny 12 i 14 to $m = 39{,}67$ i $40{,}33$, czyli ∓ 33 centy od E2. Zakres wszystkich 159 binów to $m = 35{,}67$ do $88{,}33$.

HCQT

Definicja 7.2 (Wartość HCQT). Niech $S_t[k]$ będzie widmem amplitudowym okna o środku w klatce t (okno Hanna, FFT z zero-paddingiem $\times 4$). Dla *numeru alikwotu* $h \in \{0{,}5; 1; 2; 3; 4; 5\}$ definiujemy amplitudę w binie p:

$$A_h[t,p] = \max\Big\{ S_t[k] \;:\; hf(p)\,2^{-1/72} \le f_k \le hf(p)\,2^{1/72} \Big\}. \tag{7.1}$$

Przedział to $\pm\frac{1}{6}$ półtonu (czyli $\frac{1}{72}$ oktawy) wokół częstotliwości $hf(p)$. Zakres jest pusty ($A_h := 0$), gdy $hf(p) > 0{,}46 f_s$ (ponad Nyquistem).

Przykład 7.2. Dla $p = 13$ (E2, $f = 82{,}41$ Hz) i $h = 2$ szukamy maksimum widma w przedziale $[2\cdot 82{,}41\cdot 2^{-1/72},\, 2\cdot 82{,}41\cdot 2^{1/72}] = [163{,}3;\ 166{,}4]$ Hz wokół drugiego alikwotu (164,8 Hz). Przy zero-paddingu $\times 4$ bin FFT ma 0,67 Hz, więc przedział zawiera ok. 5 binów FFT, a $A_2[t, 13]$ to największa z ich amplitud.

Intuicja. $A_h[t,p]$ odpowiada na pytanie: „gdyby w binie p grała nuta, a ja podsłuchałbym jej h-ty alikwot — ile energii bym tam usłyszał?". Kanał $h = 1$ to zwykłe widmo, kanał $h = 2$ pokazuje, ile energii jest o oktawę wyżej niż każdy kandydat, itd. ♢

7.3 Decybele i normalizacja

Ucho ocenia głośność logarytmicznie (rozdział 1), więc amplitudy zamieniamy na decybele.

decybel

Definicja 7.3 (Decybel i cecha). Poziom amplitudy $A > 0$ w decybelach to $L = 20\log_{10} A$ dB. Dla ustalonej *referencji* L_{ref} definiujemy *cechę*

$$\varphi = \operatorname{clip}\Big(\frac{L - L_{\text{ref}}}{60} + 1,\ 0,\ 1{,}3\Big). \tag{7.2}$$

Referencją jest 99,5. percentyl wszystkich poziomów L nagrania (osobno dla okna długiego i krótkiego).

Na konkretnych liczbach. Niech $L_{\text{ref}} = -20$ dB (czyli $A_{\text{ref}} = 0{,}1$). Piksel o $A = 0{,}1$ ma $\varphi = 1$. Piksel o $A = 10^{-3}$ ($L = -60$ dB): $\varphi = (-60+20)/60 + 1 = 0{,}333$. Piksel o $A = 0{,}12$ ($L = -18{,}4$ dB): $\varphi = 1{,}026$ (cecha bywa > 1, bo A może przewyższać percentyl). Piksel o $A = 10^{-5}$ ($L = -100$ dB): $\varphi = -0{,}333$, po przycięciu 0. Zakres 60 dB znaczy: wszystko cichsze niż 60 dB poniżej referencji to dla sieci cisza.

Twierdzenie 7.4 (Niezależność od głośności nagrania). *Niech nagranie x zostanie pomnożone przez stałą $g > 0$. Pomijając wpływ stałej 10^{-9} w logarytmie, cechy φ obliczone dla gx i dla x są identyczne.*

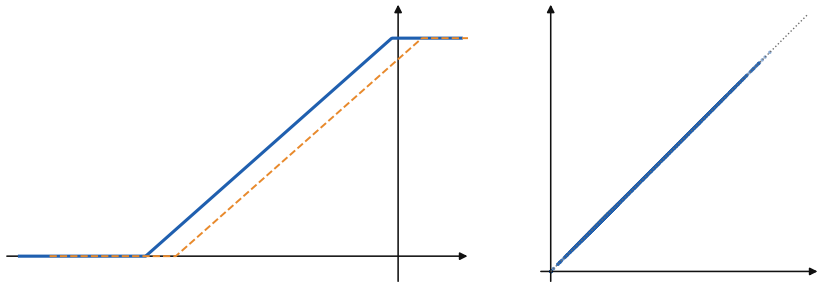
Pomysł dowodu. Skalowanie sygnału dodaje stałą do wszystkich decybeli, a percentyl przesuwa się o tę samą stałą; różnica $L - L_{\text{ref}}$ się nie zmienia.

Dowód. Widmo jest liniowe w sygnale, więc $S_t[k] \mapsto gS_t[k]$, a maksimum z dodatnich liczb też się skaluje: $A \mapsto gA$ (maksimum jest jednorodne). Zatem

$$\begin{aligned} L' &= 20\log_{10}(gA) = L + 20\log_{10} g && \text{(tw. 1.6)}\\ L'_{\text{ref}} &= \operatorname{perc}_{99{,}5}\{L+c\} = L_{\text{ref}} + c, \quad c = 20\log_{10} g && \text{(percentyl przesuwa się o } c\text{)}\\ L' - L'_{\text{ref}} &= L - L_{\text{ref}}. && \text{(} c \text{ się skraca)} \end{aligned}$$

Cecha zależy tylko od $L - L_{\text{ref}}$, więc jest taka sama. Percentyl przesuwa się o c, bo dodanie stałej nie zmienia kolejności elementów. ■

W zwykłym języku: czy nagranie jest ciche, czy głośne, sieć dostaje te same liczby. Jeżeli $g = 3$, wszystkie poziomy rosną o $20\log_{10} 3 = 9{,}54\,\text{dB}$, a referencja o tyle samo. Numerycznie (rys. 7.1b) dla nagrania i nagrania 10 razy cichszego największa różnica cech to $4 \cdot 10^{-5}$, czyli błąd zaokrągleń `float32`.



(a) (b)

Rysunek 7.1: (a) Cecha jako funkcja $\log_{10} A$ (niebieska): płaski początek (cisza poniżej 60 dB od referencji), liniowy wzrost i przycięcie na 1,3. Nagranie 3 razy głośniejsze (pomarańczowa przerywana) ma tę samą krzywą, bo referencja przesuwa się razem z poziomami (tw. 7.4). (b) Wartości cech tego samego nagrania (poziomo) i nagrania 10 razy cichszego (pion): wszystkie punkty leżą na przekątnej (kropkowana).

Pułapka. Niezależność od głośności dotyczy *stałego* przeskalowania całego nagrania. Nie obejmuje szumu: jeśli głośniejsza jest tylko jedna część, albo tło ma stały poziom, normalizacja nie pomoże. Stała 10^{-9} w logarytmie psuje twierdzenie tylko dla amplitud tak małych, że i tak są obcięte do zera. ♢

7.4 Kanały to przesunięte kopie jednego widma

Twierdzenie 7.5 (Przesunięcie kanałów). *Jeśli $k_h = 36\log_2 h$ jest liczbą całkowitą, to dla każdej klatki i każdego binu p zachodzi $A_h[t,p] = A_1[t, p+k_h]$.*

Pomysł dowodu. Bin $p+k_h$ ma częstotliwość środkową dokładnie h razy większą niż bin p, więc obie amplitudy to maksimum z tego samego przedziału widma.

Dowód. Z def. 7.1 mamy $m_{p+k_h} = m_p + k_h/3$. Zatem

$$\begin{aligned} f(p+k_h) &= 440 \cdot 2^{(m_p+k_h/3-69)/12} = f(p)\cdot 2^{k_h/36} && \text{(dodanie wykładników)} \\ &= f(p)\cdot 2^{\log_2 h} = h\,f(p). && (k_h = 36\log_2 h) \end{aligned}$$

Przedział w def. 7.2 dla $A_h[t,p]$ to $[hf(p)2^{-1/72}, hf(p)2^{1/72}]$, a dla $A_1[t,p+k_h]$ to $[f(p+k_h)2^{-1/72}, f(p+k_h)2^{1/72}]$; są identyczne. Maksimum z tego samego zbioru jest to samo. (Rozważamy tylko p, dla których $p+k_h$ mieści się w $0,\ldots,158$.) To kończy dowód. ■

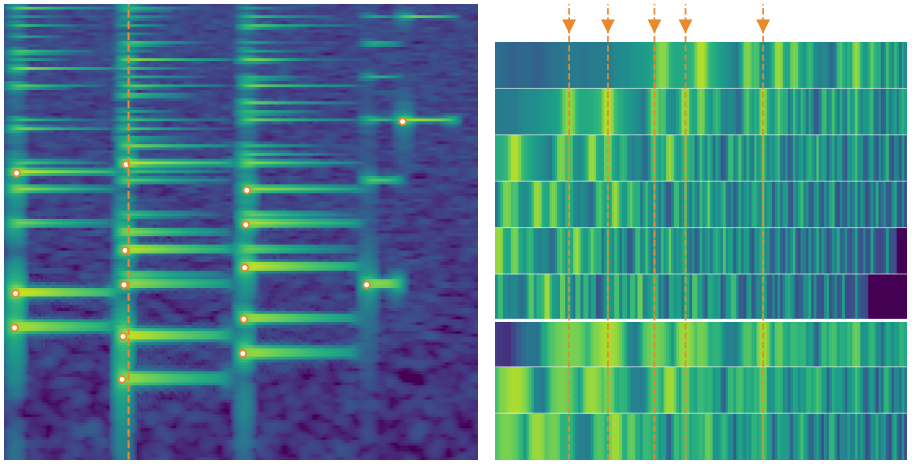
Dla $h = 0{,}5;2;4$ mamy $k_h = -36;36;72$, więc równość jest dokładna; dla $h = 3$ i 5 ($k_h = 57{,}06$ i $83{,}59$) przesunięcie całkowite jest tylko przybliżeniem, a błąd to poniżej pół bina. Sprawdziliśmy to na prawdziwym

kodzie: dla kanałów $h = 0{,}5;2;4$ różnica $A_h[t,p] - A_1[t,p+k_h]$ wynosi dokładnie 0 w całym nagraniu, a dla $h = 3$ średnio 0,007 (maksymalnie 0,18). Ta własność uzasadnia blok harmoniczny sieci (rozdział 13): sieć sama może „doprzesunąć” własne cechy o k_h binów i uzyskać alikwoty także wyższe niż 5.

7.5 Co dokładnie dostaje sieć

parametr	wartość	znaczenie
f_s	11 025 Hz	po zmianie próbkowania
okna	4096 i 1024 próbek	długie (wysokość), krótkie (czas)
krok	256 próbek = 23,2 ms	odstęp klatek
zero-padding	×4	gładsze położenie pików
alikwoty długie	0,5; 1; 2; 3; 4; 5	kanały 1–6
alikwoty krótkie	1; 2; 3	kanały 7–9
biny	$3 \times 53 = 159$	MIDI 36–88
normalizacja	99,5 perc., 60 dB, clip 1,3	def. 7.3

Tabela 7.1: Parametry HCQT w modelu Gen 6. Wynik: $X \in \mathbb{R}^{T\times 9\times 159}$.



(a) (b)

Rysunek 7.2: HCQT syntetycznego, 6-sekundowego nagrania gitary. (a) Kanał $h = 1$: czas poziomo (243 klatki), wysokość pionowo (159 binów); jasne ślady to alikwoty grających nut, kółka z pomarańczowym brzegiem to początki prawdziwych nut, pomarańczowa przerywana linia to klatka pokazana w (b). (b) Cała jedna klatka: 9 kanałów (wiersze; gruba biała linia oddziela 6 kanałów okna długiego od 3 okna krótkiego) × 159 binów (kolumny). Pomarańczowe trójkąty i przerywane pionowe linie wskazują kolumny prawdziwych nut: w każdej z nich jasne plamy pojawiają się w wielu kanałach naraz, bo alikwoty kandydata ustawiono w jednej kolumnie.

W obu oknach analizujemy tę samą klatkę t (środek wspólny). Dla nagrania 6-sekundowego $T = 243$ i X ma $243 \cdot 9 \cdot 159 = 347\,733$ liczby (przykład 1.2). Rysunek 7.2b to najważniejszy obrazek książki: siatka nut jako kolumny, siedem „pięter” alikwotów jako wiersze. Zadaniem sieci jest rozpoznać w tej siatce wzorzec „ta kolumna jest zajęta przez nutę” i odróżnić go od kolumn, które tylko udają nutę, bo leżą oktawę niżej.

Podsumowanie

- Bin wysokości ma $\frac{1}{3}$ półtonu; $p = 3s+1$ jest środkiem półtonu s.
- $A_h[t,p]$ to maksimum widma wokół $hf(p)$ ($\pm\frac{1}{6}$ półtonu); $h = 0{,}5\ldots5$ (okno długie), $1,2,3$ (krótkie): razem 9 kanałów.
- Cecha $= \text{clip}((L-L_{\text{ref}})/60+1,0,1{,}3)$ jest niezależna od głośności nagrania (tw. 7.4).
- Jeśli $36\log_2 h$ jest całkowite, kanał h to kanał 1 przesunięty o tyle binów (tw. 7.5).
- Wejście sieci to $X \in \mathbb{R}^{T\times 9\times 159}$ ze krokiem 23,2 ms.

Ćwiczenia

1. O ile decybeli rośnie poziom, gdy amplituda podwaja się? A gdy rośnie 10 razy?
2. Dla $L_{\text{ref}} = -30$ dB policz cechę piksela o $A = 0{,}005$. (Wskazówka: $L = 20\log_{10} A$.)
3. Który bin odpowiada nucie A2 ($m = 45$)? Jaki jest numer binu jej trzeciego alikwotu ($h = 3$), w przybliżeniu całkowitym?
4. Od jakiej wysokości kanał $h = 5$ jest zerowy? Użyj progu $0{,}46 f_s$ i podaj najniższy bin p, dla którego tak jest.

Rozwiązania

1. $20\log_{10} 2 = 6{,}02$ dB, a $20\log_{10} 10 = 20$ dB.
2. $L = 20\log_{10} 0{,}005 = -46{,}02$ dB, $\varphi = (-46{,}02+30)/60+1 = 0{,}733$.
3. $p = 3\cdot(45-36)+1 = 28$. Trzeci alikwot: $k_3 = \text{round}(36\log_2 3) = 57$, czyli bin $28+57 = 85$ ($m_{85} = 36+84/3 = 64$, to E4; dokładnie oczekiwane $45+19{,}02 = 64{,}02$).
4. Zero, gdy $5f(p) > 5071{,}5$ Hz, czyli $f(p) > 1014{,}3$ Hz, czyli $m_p > 69 + 12\log_2(1014{,}3/440) = 83{,}48$. Z $m_p = 36+(p-1)/3$ dostajemy $p-1 > 142{,}4$, więc najniższy zerowy bin to $p = 144$. Zerowych jest więc $159-144 = 15$ binów (najwyższe 5 półtonów: ok. 83,5–88,3).

8 Prawdopodobieństwo i funkcje straty

8.1 Jak powiedzieć modelowi, że się myli?

Wyjściem sieci jest, dla każdej klatki i półtonu, liczba z przedziału $(0,1)$: „z jakim prawdopodobieństwem w tej klatce gra ta nuta?”. Żeby uczyć sieć gradientem (rozdział 5), potrzebujemy funkcji straty: jednej liczby, która jest mała, gdy odpowiedzi są dobre, i duża, gdy złe. Tu wyprowadzimy dwie funkcje używane w Gen 6 (sigmoidę z entropią krzyżową dla początków, ramek i końców; softmax dla tabulatury) i pokażemy, *dlaczego* akurat takie.

Po tym rozdziale umiesz: (i) zamienić liczbę rzeczywistą na prawdopodobieństwo sigmoidą i softmaksem, (ii) policzyć stratę BCE i jej gradient, (iii) uzasadnić, że BCE jest najmniejsza dla prawdziwego prawdopodobieństwa, (iv) powiedzieć, co robi waga klasy dodatniej.

8.2 Sigmoida i softmax

sigmoida

Definicja 8.1 (Sigmoida). Funkcja $\sigma(z) = \dfrac{1}{1+e^{-z}}$ przekształca dowolną liczbę $z \in \mathbb{R}$ (zwaną *logitem*) w liczbę z przedziału $(0,1)$. Zachodzi $\sigma(-z) = 1-\sigma(z)$ i $\sigma(0) = \frac{1}{2}$.

Przykład 8.1. $\sigma(0) = 0{,}5$; $\sigma(2) = 0{,}881$; $\sigma(-2) = 0{,}119$; $\sigma(-3) = 0{,}0474$. Duży dodatni logit oznacza „prawie na pewno tak”, duży ujemny „prawie na pewno nie”. Odwrotność: $z = \ln\frac{p}{1-p}$ (logarytm szans).

softmax

Definicja 8.2 (Softmax). Dla wektora logitów $\boldsymbol{z} \in \mathbb{R}^K$ (K klas) *softmaksem* nazywamy wektor o współrzędnych $\text{softmax}(\boldsymbol{z})_i = \dfrac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$.

Przykład 8.2. Dla $\boldsymbol{z} = (2;1;0{,}1)$ mamy $e^z = (7{,}389;\ 2{,}718;\ 1{,}105)$, suma 11,212, więc softmax to $(0{,}659;\ 0{,}242;\ 0{,}099)$. Największy logit dostaje największe prawdopodobieństwo, ale mniejsze też nie giną.

Twierdzenie 8.3 (Własności softmaksa). *Dla każdego $\boldsymbol{z}$: (a)* $\text{softmax}(\boldsymbol{z})_i > 0$ *i* $\sum_i \text{softmax}(\boldsymbol{z})_i = 1$*; (b)* $\text{softmax}(\boldsymbol{z}+c\mathbf{1}) = \text{softmax}(\boldsymbol{z})$ *dla dowolnej stałej c.*

Pomysł dowodu. (a) wynika z dodatniości wykładnika i z tego, że dzielimy przez sumę; (b): czynnik e^c skraca się w liczniku i mianowniku.

Dowód. (a) $e^{z_i} > 0$ dla każdego z_i, a mianownik jest sumą takich liczb, więc wynik jest dodatni; suma ułamków o wspólnym mianowniku $\sum_j e^{z_j}$ daje 1. (b)

$$\frac{e^{z_i+c}}{\sum_j e^{z_j+c}} = \frac{e^c e^{z_i}}{e^c \sum_j e^{z_j}} \qquad (e^{a+b} = e^a e^b)$$
$$= \frac{e^{z_i}}{\sum_j e^{z_j}}. \qquad \text{(skrócenie } e^c\text{)}$$

W praktyce odejmujemy od logitów ich maksimum ($c = -\max z$), żeby uniknąć przepełnienia e^z dla dużych z — wynik się nie zmienia. To kończy dowód. ■

Sigmoida to softmax dwóch klas $(z, 0)$: $\mathrm{softmax}(z,0)_1 = e^z/(e^z+1) = \sigma(z)$. Używamy sigmoidy, gdy klasy nie wykluczają się (w jednej klatce może grać wiele półtonów naraz), a softmaksu, gdy dokładnie jedna odpowiedź jest prawdziwa (na strunie dokładnie jedna z 21 klas: milczy albo któryś próg).

8.3 Entropia krzyżowa

entropia krzyżowa

Definicja 8.4 (Strata BCE). Dla prawdopodobieństwa $p \in (0,1)$ i etykiety $y \in [0,1]$ (zwykle 0 lub 1) *binarna entropia krzyżowa* wynosi

$$\ell(p,y) = -\big[y \ln p + (1-y)\ln(1-p)\big]. \tag{8.1}$$

Z *wagą klasy dodatniej* $\alpha > 0$: $\ell_\alpha(p,y) = -\big[\alpha y \ln p + (1-y)\ln(1-p)\big]$.

Przykład 8.3. Dla $y=1$ i $p=0{,}9$: $\ell = -\ln 0{,}9 = 0{,}105$. Dla $p=0{,}2$: $\ell = -\ln 0{,}2 = 1{,}609$; z wagą $\alpha = 4$ strata wynosi 6,44. Dla $y=0$ i $p=0{,}2$: $\ell = -\ln 0{,}8 = 0{,}223$. Pewność w złą stronę ($p \to 0$ przy $y=1$) jest karana nieograniczenie: $-\ln p \to \infty$ (rys. 8.1a).

Intuicja. Strata BCE to „zaskoczenie" modelu: $-\ln p$ to ile bitów (nat) informacji niesie zdarzenie, któremu przypisaliśmy p. Model, który był pewien złej odpowiedzi, jest bardzo zaskoczony, więc ponosi dużą karę. ♢

Twierdzenie 8.5 (Gradient BCE po logicie). *Dla* $p = \sigma(z)$: $\dfrac{\partial \ell}{\partial z} = \sigma(z) - y$.

Z wagą α: $\dfrac{\partial \ell_\alpha}{\partial z} = (\alpha y + 1 - y)\,\sigma(z) - \alpha y$.

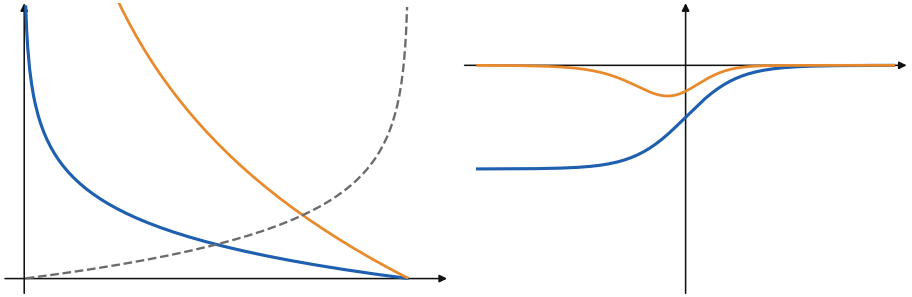
Pomysł dowodu. Regułą łańcuchową przez $p = \sigma(z)$ i pochodną sigmoidy $\sigma' = \sigma(1-\sigma)$ (tw. 5.3); czynniki $p(1-p)$ się skracają.

Dowód. Niech $p = \sigma(z)$, więc $\partial p/\partial z = p(1-p)$. Dla ℓ_α:

$$\frac{\partial \ell_\alpha}{\partial p} = -\frac{\alpha y}{p} + \frac{1-y}{1-p} \qquad \text{(pochodna ln)}$$
$$\frac{\partial \ell_\alpha}{\partial z} = \Big(-\frac{\alpha y}{p} + \frac{1-y}{1-p}\Big) p(1-p) \qquad \text{(reguła łańcuchowa)}$$
$$= -\alpha y(1-p) + (1-y)p \qquad \text{(skrócenie)}$$
$$= (\alpha y + 1 - y)\,p - \alpha y. \qquad \text{(wyłączenie } p\text{)}$$

Dla $\alpha = 1$ to $p - y$. Dla $y = 1$ gradient to $-\alpha(1-p)$, dla $y = 0$ to p. To kończy dowód. ■

W zwykłym języku: gradient po logicie to po prostu „odpowiedź modelu minus prawda". Gdy $y = 1$ i model mówi $p \approx 0$ (bardzo się myli), gradient jest bliski -1 — silny sygnał do poprawy. Dla błędu kwadratowego $(p-y)^2$ ten sam gradient to $2(p-y)p(1-p)$, który *znika*, gdy sigmoida jest nasycona (rys. 8.1b): np. dla $z = -5$ i $y = 1$ gradient BCE wynosi $-0{,}993$, a błędu kwadratowego tylko $-0{,}013$. Dlatego do klasyfikacji używamy BCE.



(a) (b)

Rysunek 8.1: (a) Strata BCE w funkcji p: dla $y=1$ ($-\ln p$, niebieska) i z wagą $\alpha = 4$ (pomarańczowa) rośnie do nieskończoności, gdy $p \to 0$; dla $y=0$ ($-\ln(1-p)$, szara przerywana) rośnie, gdy $p \to 1$. (b) Gradient po logicie dla $y=1$: BCE (niebieska, $\sigma - 1$) pozostaje blisko -1 przy dużym błędzie; gradient błędu kwadratowego (pomarańczowa) zanika w nasyceniu.

Twierdzenie 8.6 (BCE uczy prawdziwego prawdopodobieństwa). *Niech etykieta* $y \in \{0,1\}$ *wypada* 1 *z prawdopodobieństwem* $q \in (0,1)$. *Średnia strata* $\mathbb{E}[\ell_\alpha(p,y)] = -\alpha q \ln p - (1-q)\ln(1-p)$ *jest najmniejsza dla*

$$p^* = \frac{\alpha q}{\alpha q + 1 - q}. \tag{8.2}$$

W szczególności dla $\alpha = 1$ *jest to* $p^* = q$.

Pomysł dowodu. Różniczkujemy średnią stratę po p, przyrównujemy do zera i sprawdzamy, że to minimum.

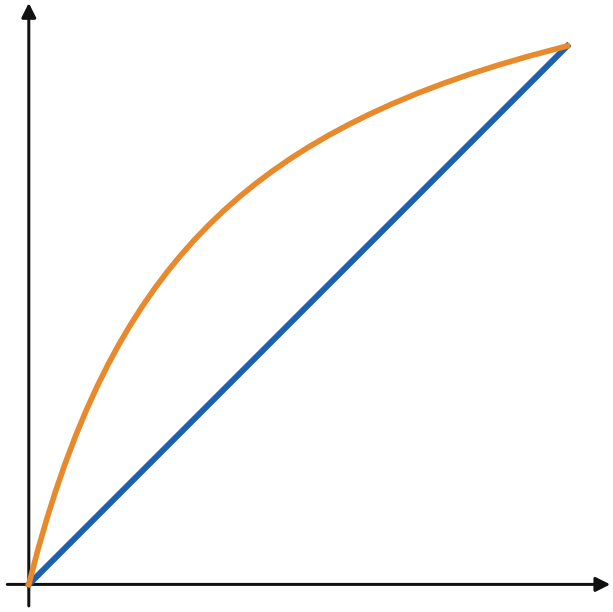
Dowód. Niech $J(p) = -\alpha q \ln p - (1-q)\ln(1-p)$ dla $p \in (0,1)$.

$$J'(p) = -\frac{\alpha q}{p} + \frac{1-q}{1-p} = 0 \qquad \text{(warunek konieczny)}$$
$$\Rightarrow\ \alpha q(1-p) = (1-q)p \ \Rightarrow\ p^* = \frac{\alpha q}{\alpha q + 1 - q}. \qquad \text{(rozwiązanie względem } p\text{)}$$

Druga pochodna $J''(p) = \alpha q/p^2 + (1-q)/(1-p)^2 > 0$, więc to jedyne minimum. To kończy dowód. ■

Na konkretnych liczbach. Jeśli w danym półtonie początek nuty występuje w $q = 10\%$ przypadków, a waga to $\alpha = 4$, model uczony BCE nauczy się mówić $p^* = 0{,}4/(0{,}4+0{,}9) = 0{,}308$, a nie 0,1. Waga za-

wyża więc prawdopodobieństwa (rys. 8.2). Podobnie miękka etykieta $y = 0{,}4$ (sąsiednie klatki wokół początku w Gen 6) przy $\alpha = 1$ i q interpretowanym jako średnia etykieta daje $p^* = 0{,}4$: model nie jest karany za niepewność o jedną klatkę.



Rysunek 8.2: Optymalne prawdopodobieństwo p^* (pion) w zależności od prawdziwej częstości q (poziom) dla wagi $\alpha = 1$ (niebieska, leży na przekątnej) i $\alpha = 4$ (pomarańczowa, nad przekątną). Waga klasy dodatniej przesuwa wyjścia sieci w górę; dekoder (rozdział 16) musi to uwzględnić przez progi dobrane na walidacji.

Pułapka. Wyjścia sieci uczonej z wagą $\alpha > 1$ *nie są* prawdziwymi prawdopodobieństwami. Próg 0,5 w dekoderze nie ma wtedy żadnego szczególnego znaczenia; dlatego progi dekodera Gen 6 stroimy osobno (rozdział 16). ♢

8.4 Dlaczego rzadkie etykiety są trudne

Weźmy prawdziwy przykład: nagranie z rozdziału 7 ($T = 243$ klatek, 53 półtony, 12 879 komórek) ma 15 nut. Mapa początków ma więc tylko 15 komórek równych 1 (i 30 równych 0,4): to 0,12% wszystkich. Sieć, która zawsze odpowiada „zero”, ma niemal idealną dokładność, a zupełnie nie nadaje się do niczego. Dwa środki zaradcze używane w Gen 6: waga $\alpha = 4$ dla początków ($\alpha = 2$ dla końców) oraz *inicjalizacja obciążenia* ostatniej warstwy na -3 dla początków (i -2 dla ramek). Na starcie $\sigma(-3) = 0{,}047$, więc strata na komórkę to $-\big[0{,}0012 \ln 0{,}047 + 0{,}9988 \ln 0{,}953\big] = 0{,}052$, a przy $\sigma(0) = 0{,}5$ byłoby 0,693: sieć nie musi tracić pierwszych kroków na samo „nauczenie się, że nut jest mało”.

8.5 Softmax i tabulatura

Dla jednej struny w jednej klatce sieć zwraca 21 logitów (klasa 0: struna milczy, klasy $1 + f$ dla progów $f = 0, \ldots, 19$). Strata to ujemny logarytm prawdopodobieństwa klasy prawdziwej: $\ell = -\ln \mathrm{softmax}(\boldsymbol{z})_c = -z_c + \ln \sum_j e^{z_j}$. Jej gradient po logitach to $\mathrm{softmax}(\boldsymbol{z}) - \boldsymbol{e}_c$ (analogicznie do tw. 8.5).

Na konkretnych liczbach. Dla trzech klas $\boldsymbol{z} = (2; 1; 0{,}1)$ i prawdziwej klasy $c = 1$ (pierwszej): softmax $= (0{,}659;\ 0{,}242;\ 0{,}099)$, strata $-\ln 0{,}659 = 0{,}417$, gradient po logitach $(0{,}659 - 1;\ 0{,}242;\ 0{,}099) = (-0{,}341;\ 0{,}242;\ 0{,}099)$. Zwróćmy uwagę: suma gradientu to zero, bo suma softmaksu to 1 — podnoszenie jednego logitu odbywa się kosztem pozostałych.

Podsumowanie

- σ zamienia logit na prawdopodobieństwo; softmax robi to dla wielu wykluczających się klas i jest niezmienniczy względem dodania stałej.
- BCE $= -[y \ln p + (1 - y) \ln(1 - p)]$; jej gradient po logicie to $\sigma(z) - y$ (tw. 8.5).
- BCE jest najmniejsza dla prawdziwej częstości; waga α zawyża wyjścia do $\frac{\alpha q}{\alpha q + 1 - q}$ (tw. 8.6).
- Etykiety początków są rzadkie (0,12% komórek), więc używamy wagi i obciążenia początkowego -3.
- Tabulatura: softmax po 21 klasach na strunę i strata $-\ln p_{\text{klasa}}$.

Ćwiczenia

1. Policz $\sigma(1)$, $\sigma(-1)$ i sprawdź, że sumują się do 1.
2. Dla $y = 1$ policz stratę BCE z $\alpha = 1$ oraz $\alpha = 2$ przy $p = 0{,}3$, a także gradient po logicie w obu przypadkach.
3. Pokaż, że $\mathrm{softmax}(z, 0)_1 = \sigma(z)$.
4. Przy $q = 0{,}05$ i $\alpha = 2$ ile wynosi p^*? Jaką wagę α trzeba wziąć, by $p^* = 0{,}5$ przy $q = 0{,}05$?

Rozwiązania

1. $\sigma(1) = 0{,}7311$, $\sigma(-1) = 0{,}2689$, suma 1,0000.
2. $\alpha = 1$: $-\ln 0{,}3 = 1{,}204$, gradient $0{,}3 - 1 = -0{,}7$. $\alpha = 2$: strata 2,408, gradient $-2(1 - 0{,}3) = -1{,}4$.
3. $\mathrm{softmax}(z, 0)_1 = e^z/(e^z + e^0) = e^z/(e^z + 1) = 1/(1 + e^{-z}) = \sigma(z)$ (dzielimy licznik i mianownik przez e^z).
4. $p^* = 2 \cdot 0{,}05/(0{,}1 + 0{,}95) = 0{,}095$. Z równania $\alpha q = 1 - q$: $\alpha = (1 - q)/q = 19$ daje $p^* = 0{,}5$.

9 Sieć neuronowa: warstwy, konwolucja i normalizacja

9.1 Z czego zbudowana jest sieć?

Sieć neuronowa to złożenie prostych funkcji (rozdział 1); każda z nich ma kilka parametrów, które dobieramy gradientem (rozdział 5). Model Gen 6 używa pięciu rodzajów cegiełek: warstwy liniowej (rozdział 4), funkcji nieliniowej GELU, konwolucji, normalizacji warstwy i połączeń resztkowych. Poznajmy je po kolei, ze sprawdzeniem na małych liczbach.

Po tym rozdziale umiesz: (i) policzyć GELU i konwolucję jednowymiarową ręcznie, (ii) policzyć liczbę parametrów konwolucji, (iii) wyznaczyć pole widzenia stosu konwolucji z dylatacją, (iv) uzasadnić własności LayerNorm i połączenia resztkowego.

9.2 Nieliniowość: po co i jaka

Z twierdzenia 4.4 wiemy, że dwie warstwy liniowe to jedna warstwa liniowa. Żeby głębokość coś dawała, między warstwami wstawiamy funkcję nieliniową działającą na każdą liczbę osobno.

GELU

Definicja 9.1 (GELU). Niech $\Phi(z) = \frac{1}{2}\big(1+\operatorname{erf}(z/\sqrt{2})\big)$ będzie dystrybuantą rozkładu normalnego $N(0,1)$. Funkcja $\mathrm{GELU}(z) = z\Phi(z)$ „bramkuje" wejście: mnoży je przez prawdopodobieństwo, że losowa liczba $N(0,1)$ jest mniejsza od z. Dla porównania $\mathrm{ReLU}(z) = \max(0,z)$.

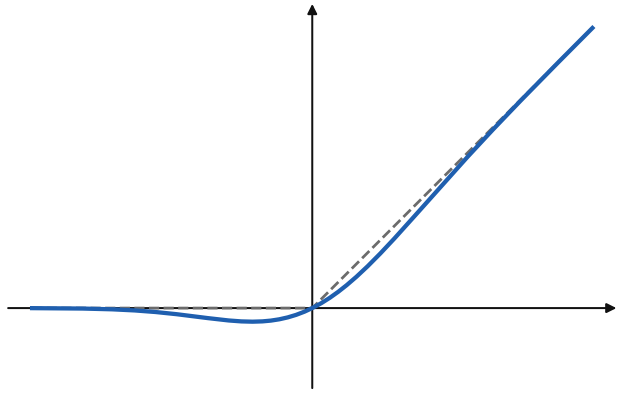
Przykład 9.1. $\mathrm{GELU}(2) = 2\cdot 0{,}9772 = 1{,}9545$, $\mathrm{GELU}(1) = 0{,}8413$, $\mathrm{GELU}(0) = 0$, $\mathrm{GELU}(-1) = -0{,}1587$, $\mathrm{GELU}(-3) = -0{,}0040$. Dla dużych dodatnich z funkcja zachowuje się jak z, dla dużych ujemnych dąży do zera; w okolicy zera jest gładka (rys. 9.1).

Intuicja. ReLU wycina wszystko ujemne. GELU robi to łagodnie: małe ujemne wartości są tylko osłabiane. Przez to pochodna zmienia się płynnie i sieć uczy się stabilniej. Sam kształt nie jest świętością — ważne jest, by funkcja była nieliniowa. ♢

9.3 Konwolucja

Warstwa liniowa łączy każde wejście z każdym wyjściem. Dla sygnałów, w których ten sam wzorzec może wystąpić w różnych miejscach (nuta w dowolnej klatce, wzorzec alikwotów w dowolnej wysokości), lepsza jest warstwa, która *używa tych samych wag w każdym miejscu*.

konwolucja



Rysunek 9.1: GELU (niebieska) i ReLU (szara przerywana). GELU jest gładką wersją ReLU: w odróżnieniu od niego ma niewielką ujemną „zatokę" (minimum ok. −0,17) i nie ma ostrego załamania w zerze, więc ma pochodną wszędzie.

Definicja 9.2 (Konwolucja jednowymiarowa). Dla sygnału $x[t]$ i *jądra* $w[-r],\dots,w[r]$ (długość $k = 2r+1$) wynik konwolucji z krokiem 1 i dopełnieniem zerami to

$$y[t] = b + \sum_{j=-r}^{r} w[j]\,x[t+j], \tag{9.1}$$

przy czym $x[s] = 0$ poza zakresem. *Dylatacja* d rozstawia próbki jądra co d: $y[t] = b + \sum_j w[j]\,x[t+d\,j]$. *Krok* (stride) s oblicza wynik tylko co s-te t.

Przykład 9.2. Sygnał $x = (1,2,3,4,5,6)$, jądro $w = (1,0,-1)$ (dla $j = -1,0,1$), $b = 0$: $y[t] = x[t-1] - x[t+1]$. Wynik: $y = (-2,-2,-2,-2,-2,5)$. Różnica „poprzedni minus następny" wynosi -2 wszędzie, gdzie sygnał rośnie liniowo; ostatnia wartość $5 = x[5] - 0$ pochodzi z dopełnienia zerem, które udaje, że za końcem jest $x = 0$. Takie jądro wykrywa nachylenie sygnału, czyli działa jak pochodna.

W obrazach i widmach (dwa wymiary: czas i bin) jądro ma kształt $k_t \times k_p$ i przesuwa się w obu osiach. Jeśli każde z C_{we} kanałów wejściowych ma osobne jądro, a wyniki sumujemy do C_{wy} kanałów:

Twierdzenie 9.3 (Liczba parametrów konwolucji). *Konwolucja $k_t \times k_p$ z C_{we} kanałów do C_{wy} kanałów ma $C_{\text{we}}C_{\text{wy}}k_tk_p + C_{\text{wy}}$ parametrów, a konwolucja* głębokościowa *(osobne jądro dla każdego kanału, $C_{\text{we}} = C_{\text{wy}} = C$) ma $Ck_tk_p + C$ parametrów. Liczba ta* nie zależy *od długości sygnału.*

Pomysł dowodu. Każdy z C_{wy} kanałów wyjściowych ma po jednym jądrze $k_t \times k_p$ dla każdego kanału wejściowego i jedno obciążenie.

Dowód. Jedno jądro ma k_tk_p liczb. Kanał wyjściowy sumuje wkłady wszystkich kanałów wejściowych, więc ma C_{we} jąder i jedno obciążenie b.

$$\begin{aligned} \#\text{parametrów} &= C_{\text{wy}}\cdot\big(C_{\text{we}}\cdot k_tk_p + 1\big) && \text{(po kanale wyjściowym)}\\ &= C_{\text{we}}C_{\text{wy}}k_tk_p + C_{\text{wy}}. && \text{(rozdzielność)} \end{aligned}$$

W wersji głębokościowej każdy kanał ma tylko jedno jądro (dla samego siebie): $C(k_t k_p + 1)$. Wagi są te same dla każdego położenia, więc liczba parametrów nie rośnie z długością sygnału. To kończy dowód. ■

Na konkretnych liczbach. Trzon Gen 6: konwolucja 3×7 z 9 kanałów (HCQT) do 48: $9\cdot 48\cdot 21+48 = 9120$. Konwolucja głębokościowa 1×5 na 48 kanałach: $48\cdot 5+48 = 288$. Konwolucja czasowa 3×1, $48\to 48$: $48\cdot 48\cdot 3+48 = 6960$. Konwolucja 1×1 ($336\to 48$): $336\cdot 48+48 = 16\,176$ (to warstwa liniowa działająca w każdym miejscu osobno).

Twierdzenie 9.4 (Konwolucja jest równoważna przesunięciom). *Niech $(Tx)[t] = x[t-s]$ będzie przesunięciem sygnału o s w czasie. Konwolucja C (bez dopełnienia, w nieskończonym sygnale) spełnia $C(Tx) = T(Cx)$.*

Pomysł dowodu. Wstawiamy przesunięty sygnał do definicji i przesuwamy indeks.

Dowód.

$$\begin{aligned}(C(Tx))[t] &= b + \sum_j w[j]\,(Tx)[t+j] && \text{(def. 9.2)}\\ &= b + \sum_j w[j]\,x[t+j-s] && \text{(def. } T\text{)}\\ &= (Cx)[t-s] = (T(Cx))[t]. && \text{(def. } C \text{ w punkcie } t-s\text{)}\end{aligned}$$

Przesunięcie wejścia o s klatek przesuwa wynik o s klatek, a niczego innego nie zmienia: ta sama nuta w innym momencie daje ten sam wzorzec odpowiedzi. To kończy dowód. ■

W praktyce to właśnie dlatego konwolucja po osi binów (na osi logarytmicznej, rozdział 3) wykrywa ten sam wzorzec nuty o dowolnej wysokości.

pole widzenia

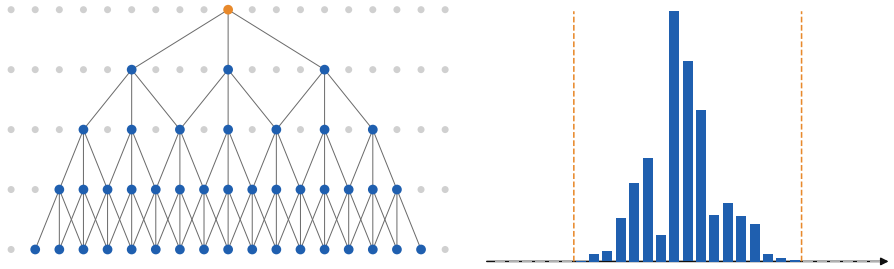
Twierdzenie 9.5 (Pole widzenia). *Stos n konwolucji w czasie z jądrami długości $k_i = 2r_i+1$ i dylatacjami d_i ma* pole widzenia *(liczbę klatek wejścia z każdej strony, które wpływają na jedną klatkę wyjścia) $R = \sum_{i=1}^{n} d_i r_i$.*

Pomysł dowodu. Indukcja po liczbie warstw: każda nowa warstwa rozszerza zbiór zależności o $d_i r_i$ klatek z każdej strony.

Dowód. Dla $n = 1$: wyjście w klatce t zależy od wejść w $t + d_1 j$, $|j| \le r_1$, czyli od klatek odległych najwyżej o $d_1 r_1$. Załóżmy, że wyjście warstwy $n-1$ w klatce u zależy od wejść odległych najwyżej o R_{n-1}. Wyjście warstwy n w klatce t zależy od wyjść warstwy $n-1$ w $u = t + d_n j$, $|j| \le r_n$, a każde z nich od wejść odległych o co najwyżej R_{n-1} od u. Najdalsza zależność od t to

$$|u - t| + R_{n-1} \le d_n r_n + R_{n-1} = R_n \qquad \text{(nierówność trójkąta)}$$

i ta odległość jest osiągana (dla $j = \pm r_n$ i skrajnej zależności wcześniejszej, gdy odpowiednie wagi są niezerowe). Zatem $R = \sum d_i r_i$. To kończy dowód. ■



(a) (b)

Rysunek 9.2: (a) Schemat czterech konwolucji czasowych z jądrem 3 i dylatacjami 1 (trzon), 1, 2, 4 (od wejścia na dole do wyjścia na górze): pomarańczowa kropka to jedna klatka wyjścia, niebieskie to klatki wejścia, od których zależy (zasięg $\pm 8 = 1+1+2+4$). Z dylatacją pole widzenia rośnie wykładniczo, a nie liniowo, przy tej samej liczbie parametrów. (b) Pomiar: moduł gradientu jednej wartości wyjścia po wejściu w funkcji odległości w klatkach dla stosu z trzonem 3×7 i trzema blokami z dylatacjami 1, 2, 4 (losowe wagi, PyTorch): gradient jest niezerowy dokładnie dla $|t| \le 8 = 1+(1+2+4)$ (niebieskie) i zerowy poza (szare).

Przykład 9.3 (Pole widzenia bloków Gen 6). Trzon ma jądro 3 w czasie ($r = 1$, $d = 1$) i trzy bloki mają jądro 3 z $d = 1, 2, 4$: $R = 1 + (1+2+4) = 8$ klatek, czyli $\pm 8 \cdot 23{,}2\,\text{ms} = \pm 186\,\text{ms}$. Pomiar na prawdziwym stosie (rys. 9.2b) potwierdza ± 8.

9.4 Normalizacja warstwy i połączenia resztkowe

LayerNorm

Definicja 9.6 (LayerNorm). Dla wektora $\mathbf{z} \in \mathbb{R}^D$ niech $\mu = \frac{1}{D}\sum z_i$ i $\sigma^2 = \frac{1}{D}\sum (z_i - \mu)^2$. *Normalizacja warstwy* to $\mathrm{LN}(\mathbf{z})_i = \gamma_i \dfrac{z_i - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta_i$, gdzie $\gamma, \beta \in \mathbb{R}^D$ są uczone ($\gamma = 1, \beta = 0$ na starcie), a $\varepsilon = 10^{-5}$ chroni przed dzieleniem przez zero.

Przykład 9.4. Dla $\mathbf{z} = (1, 2, 3, 6)$: $\mu = 3$, $\sigma^2 = (4+1+0+9)/4 = 3{,}5$, $\sigma = 1{,}871$. Wynik (przy $\gamma = 1$, $\beta = 0$, $\varepsilon \to 0$): $(-1{,}069;\ -0{,}535;\ 0;\ 1{,}604)$ ma średnią 0 i wariancję 1.

Twierdzenie 9.7 (Niezmienniczość LayerNorm). *Dla $\varepsilon = 0$, $\gamma = 1$, $\beta = 0$ i dowolnych $a > 0$, $c \in \mathbb{R}$: $\mathrm{LN}(a\mathbf{z} + c\mathbf{1}) = \mathrm{LN}(\mathbf{z})$.*

Pomysł dowodu. Skalowanie i przesunięcie zmieniają średnią i odchylenie dokładnie w taki sposób, że licznik i mianownik skracają się.

Dowód. Dla $\mathbf{z}' = a\mathbf{z} + c\mathbf{1}$: $\mu' = a\mu + c$ oraz

$$\begin{aligned}\sigma'^2 &= \frac{1}{D}\sum (a z_i + c - a\mu - c)^2 = a^2\sigma^2 && \text{(wyrazy } c \text{ się znoszą)}\\ \frac{z'_i - \mu'}{\sigma'} &= \frac{a(z_i - \mu)}{a\sigma} = \frac{z_i - \mu}{\sigma}. && \text{(} a > 0\text{, więc } \sqrt{a^2} = a\text{)}\end{aligned}$$

Obie strony równości są więc identyczne. To kończy dowód. ■

W zwykłym języku: LayerNorm usuwa informację o skali i przesunięciu wektora cech i zostawia tylko jego „kształt”; wymusza to stabilny rozmiar liczb płynących przez sieć. Wady: nie działa na wektorach stałych ($\sigma = 0$; stąd ε).

połączenie resztkowe

Definicja 9.8 (Połączenie resztkowe). Blok z połączeniem resztkowym liczy $\boldsymbol{y} = \boldsymbol{x} + F(\boldsymbol{x})$, gdzie F to dowolna warstwa lub kilka warstw (rys. 9.3).

Twierdzenie 9.9 (Gradient przez połączenie resztkowe). *Dla $\boldsymbol{y} = \boldsymbol{x} + F(\boldsymbol{x})$ macierz pochodnych (jakobian) to $\dfrac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} = I + \dfrac{\partial F}{\partial \boldsymbol{x}}$. Dla stosu L takich bloków*

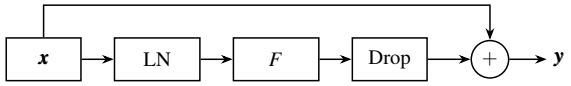
$$\frac{\partial \boldsymbol{y}_L}{\partial \boldsymbol{x}} = \prod_{l=1}^{L} \left(I + J_l\right) = I + \sum_{l} J_l + (\textit{wyrazy wyższych rzędów w } J). \tag{9.2}$$

Pomysł dowodu. Pochodna sumy to suma pochodnych, a pochodna $\boldsymbol{x}$ po $\boldsymbol{x}$ to macierz jednostkowa; dla stosu mnożymy jakobiany (reguła łańcuchowa).

Dowód. Z liniowości pochodnej $\partial(\boldsymbol{x} + F(\boldsymbol{x}))/\partial \boldsymbol{x} = \partial \boldsymbol{x}/\partial \boldsymbol{x} + \partial F/\partial \boldsymbol{x} = I + J$. Dla stosu reguła łańcuchowa daje iloczyn jakobianów kolejnych bloków. Rozwijając iloczyn $(I + J_L)\cdots(I + J_1)$ otrzymujemy I (wybór składnika I z każdego nawiasu), plus J_l (jeden nawias daje J), plus iloczyny dwóch i więcej J. Człon I nie zależy od F. To kończy dowód. ■

W zwykłym języku: nawet jeśli F ma bardzo małe pochodne, sygnał uczący przepływa przez „autostradę” I i nie znika. Dzięki temu można ułożyć wiele bloków bez ryzyka, że gradient wygaśnie po drodze.

Na konkretnych liczbach. Dla skalarnej $F(x) = 0{,}01x$ i $L = 50$ bloków: z połączeniem $\prod(1 + 0{,}01) = 1{,}01^{50} = 1{,}645$, bez niego $\prod 0{,}01 = 10^{-100}$. Gradient bez autostrady byłby praktycznie zerem.



Rysunek 9.3: Blok resztkowy typu „pre-norm” jak w warstwach Gen 6: wejście $\boldsymbol{x}$ jest normalizowane (LN), przechodzi przez F (konwolucja albo uwaga) i dropout, a następnie dodawane do niezmienionego $\boldsymbol{x}$ (górna ścieżka). Wynik: $\boldsymbol{y} = \boldsymbol{x} + \mathrm{Drop}(F(\mathrm{LN}(\boldsymbol{x})))$.

Definicja 9.10 (Dropout). W uczeniu *dropout* z prawdopodobieństwem ρ zeruje każdą współrzędną wektora, a pozostałe mnoży przez $\frac{1}{1-\rho}$. Przy wnioskowaniu nie robi nic.

Wniosek 9.11 (Dropout nie zmienia średniej). *Dla $\boldsymbol{x}$ ustalonego, $\mathbb{E}[\mathrm{Drop}(\boldsymbol{x})] = \boldsymbol{x}$.*

Dowód. Dla jednej współrzędnej x_i wynik wynosi 0 z prawdopodobieństwem ρ i $x_i/(1-\rho)$ z prawdopodobieństwem $1-\rho$. Stąd

$$\mathbb{E}[\mathrm{Drop}(x_i)] = \rho \cdot 0 + (1-\rho)\cdot \frac{x_i}{1-\rho} = x_i. \quad \text{(definicja wartości oczekiwanej)}$$

Skalowanie przez $\frac{1}{1-\rho}$ sprawia, że przy wnioskowaniu (bez dropoutu) liczby mają ten sam rząd wielkości co w uczeniu. Gen 6 używa $\rho = 0{,}1$. To kończy dowód. ■

Pułapka. LayerNorm i dropout zachowują się inaczej w uczeniu i wnioskowaniu (dropout) lub zależą od wymiaru (LayerNorm liczy po cechach jednego punktu, nie po paczce). Błąd typowy: zapomnieć wywołać `model.eval()` przed przewidywaniem; sieć wciąż losowo zeruje cechy i wyniki są inne przy każdym uruchomieniu. ♢

Podsumowanie

- Między warstwami liniowymi stawiamy nieliniowość GELU $= z\Phi(z)$.
- Konwolucja używa tych samych wag w każdym miejscu; liczba parametrów to $C_{\text{we}}C_{\text{wy}}k_t k_p + C_{\text{wy}}$ i nie zależy od długości sygnału (tw. 9.3); jest równoważna przesunięciom (tw. 9.4).
- Pole widzenia stosu konwolucji: $R = \sum d_i r_i$ (tw. 9.5); dla bloków Gen 6 $R = 8$ klatek.
- LayerNorm usuwa skalę i przesunięcie wektora cech (tw. 9.7).
- Połączenie resztkowe $\boldsymbol{x} + F(\boldsymbol{x})$ zachowuje gradient (tw. 9.9); dropout nie zmienia średniej (wn. 9.11).

Ćwiczenia

1. Policz konwolucję $x = (2,0,1,3)$ z jądrem $w = (1,2,1)$ (dla $j = -1,0,1$, $b = 0$) i dopełnieniem zerami.
2. Ile parametrów ma konwolucja 5×5 z 16 do 32 kanałów? A głębokościowa 5×5 na 32 kanałach?
3. Stos czterech konwolucji z jądrem 3 i dylatacjami $1, 2, 4, 8$. Jakie jest pole widzenia? Ile wynosiłoby bez dylatacji?
4. Policz $\mathrm{LN}(\boldsymbol{z})$ dla $\boldsymbol{z} = (4,4,8)$ ($\gamma = 1, \beta = 0, \varepsilon \to 0$).

Rozwiązania

1. $y[0] = 1\cdot 0 + 2\cdot 2 + 1\cdot 0 = 4$ (bo $x[-1] = 0$); $y[1] = 1\cdot 2 + 2\cdot 0 + 1\cdot 1 = 3$; $y[2] = 1\cdot 0 + 2\cdot 1 + 1\cdot 3 = 5$; $y[3] = 1\cdot 1 + 2\cdot 3 + 1\cdot 0 = 7$. Wynik $(4,3,5,7)$.
2. $16\cdot 32\cdot 25 + 32 = 12\,832$; głębokościowa: $32\cdot 25 + 32 = 832$.
3. $R = 1 + 2 + 4 + 8 = 15$ klatek z każdej strony; bez dylatacji $R = 4$.
4. $\mu = 16/3 = 5{,}333$; $\sigma^2 = \frac{1}{3}\left(2\cdot 1{,}778 + 7{,}111\right) = 3{,}556$, $\sigma = 1{,}886$. Wynik: $(-0{,}707;\ -0{,}707;\ 1{,}414)$.

10 Uwaga (attention)

10.1 Czemu konwolucja nie wystarcza?

Konwolucja patrzy na stały, mały sąsiad (rozdział 9). Tymczasem żeby ocenić, czy w danej klatce gra E3, sieć powinna sprawdzić, czy gra też E2 (oktawę niżej, której alikwoty zlewają się z E3) i czy ta sama nuta trwała w poprzednich klatkach. To są *dalekie* zależności, a ich siła zależy od treści: oktawa jest ważna zawsze, ale tylko wtedy, gdy dwie nuty rzeczywiście grają razem. Mechanizm, który wybiera, na co patrzeć, na podstawie treści, nazywamy *uwagą*.

Po tym rozdziale umiesz: (i) policzyć uwagę dla kilku elementów ręcznie, (ii) uzasadnić, że wynik jest średnią ważoną wartości, (iii) wyjaśnić, skąd się bierze dzielenie przez $\sqrt{d}$, (iv) policzyć liczbę parametrów warstwy uwagi i wskazać, jak nadać jej wiedzę o położeniu.

10.2 Uwaga pojedynczego zapytania

Każdy element sekwencji dostaje trzy wektory: *zapytanie* $\boldsymbol{q}$ („czego szukam”), *klucz* $\boldsymbol{k}$ („co oferuję”) i *wartość* $\boldsymbol{v}$ („co przekazuję, gdy mnie wybierzesz”). Powstają z wektora cech $\boldsymbol{h}$ przez trzy macierze: $\boldsymbol{q} = W_Q\boldsymbol{h}$, $\boldsymbol{k} = W_K\boldsymbol{h}$, $\boldsymbol{v} = W_V\boldsymbol{h}$ (rozdział 4).

uwaga

Definicja 10.1 (Uwaga skalowana iloczynem skalarnym). Dla zapytania $\boldsymbol{q} \in \mathbb{R}^d$, kluczy $\boldsymbol{k}_1, \dots, \boldsymbol{k}_n \in \mathbb{R}^d$ i wartości $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n \in \mathbb{R}^{d_v}$ oraz opcjonalnych *premii* $b_j \in \mathbb{R}$:

$$s_j = \frac{\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle}{\sqrt{d}} + b_j, \qquad \alpha_j = \operatorname{softmax}(s)_j, \qquad \operatorname{Attn}(\boldsymbol{q}) = \sum_{j=1}^{n} \alpha_j \boldsymbol{v}_j. \tag{10.1}$$

Liczby α_j nazywamy *wagami uwagi*.

Przykład 10.1 (Trzy elementy, policzone ręcznie). Niech $d = 2$, $\boldsymbol{q} = (1,0)$, klucze $\boldsymbol{k}_1 = (1,0)$, $\boldsymbol{k}_2 = (0,1)$, $\boldsymbol{k}_3 = (1,1)$, wartości $\boldsymbol{v}_1 = (1,0)$, $\boldsymbol{v}_2 = (0,1)$, $\boldsymbol{v}_3 = (2,2)$, premie $b = 0$. Wyniki $\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle = (1,0,1)$, dzielone przez $\sqrt{2}$: $s = (0{,}707;\, 0;\, 0{,}707)$. Wykładniki: $(2{,}028;\, 1;\, 2{,}028)$, suma 5,056, wagi $\alpha = (0{,}401;\, 0{,}198;\, 0{,}401)$. Wynik: $0{,}401 \cdot (1,0) + 0{,}198 \cdot (0,1) + 0{,}401 \cdot (2,2) = (1{,}203;\, 1{,}000)$. Zapytanie $(1,0)$ „pasuje” do kluczy 1 i 3 (oba mają pierwszą współrzędną 1), więc one dominują w wyniku. Gdyby klucz 3 dostał premię $b_3 = -1$, jego waga spadłaby do 0,198 i wynik zmieniłby się na $(0{,}933;\, 0{,}660)$.

Intuicja. Uwaga to miękkie wyszukiwanie w słowniku: zapytanie porównujemy ze wszystkimi kluczami (iloczyn skalarny = podobieństwo), zamieniamy podobieństwa na wagi (softmax) i zwracamy średnią wartości ważoną

tymi wagami. Zamiast jednego wyniku „dokładnie to hasło” dostajemy mieszankę wszystkich, z naciskiem na najlepiej pasujące. ♢

Twierdzenie 10.2 (Wynik uwagi to średnia ważona). *Wagi spełniają* $\alpha_j > 0$ *i* $\sum_j \alpha_j = 1$, *więc* $\operatorname{Attn}(\boldsymbol{q})$ *leży w otoczce wypukłej wartości* $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$*: dla każdej współrzędnej* l, $\min_j v_{j,l} \le \operatorname{Attn}(\boldsymbol{q})_l \le \max_j v_{j,l}$.

Pomysł dowodu. Wagi są wynikiem softmaksa (tw. 8.3); średnia ważona dodatnimi wagami o sumie 1 nie wychodzi poza zakres wartości.

Dowód. Z tw. 8.3(a): $\alpha_j > 0$ i $\sum \alpha_j = 1$. Niech $m = \min_j v_{j,l}$, $M = \max_j v_{j,l}$.

$$\operatorname{Attn}(\boldsymbol{q})_l = \sum_j \alpha_j v_{j,l} \le \sum_j \alpha_j M = M \qquad (\alpha_j > 0,\ v_{j,l} \le M)$$

$$\operatorname{Attn}(\boldsymbol{q})_l \ge \sum_j \alpha_j m = m. \qquad \text{(analogicznie)}$$

Wynik leży więc między skrajnymi wartościami. Warstwa uwagi nie „wymyśla” nowych wartości spoza zakresu, tylko je miesza; to ona wybiera, w jakich proporcjach. To kończy dowód. ■

10.3 Dlaczego dzielimy przez $\sqrt{d}$

Twierdzenie 10.3 (Wariancja iloczynu skalarnego). *Jeśli współrzędne* q_i, k_i *są niezależnymi zmiennymi losowymi o średniej* 0 *i wariancji* 1*, to* $\mathbb{E}[\langle \boldsymbol{q}, \boldsymbol{k} \rangle] = 0$ *i* $\operatorname{Var}(\langle \boldsymbol{q}, \boldsymbol{k} \rangle) = d$*. Zatem* $\langle \boldsymbol{q}, \boldsymbol{k} \rangle / \sqrt{d}$ *ma wariancję* 1 *niezależnie od* d.

Pomysł dowodu. Iloczyn skalarny to suma d niezależnych składników $q_i k_i$, z których każdy ma średnią 0 i wariancję 1; wariancje niezależnych składników się dodają.

Dowód. Dla jednego składnika, z niezależności q_i i k_i:

$$\mathbb{E}[q_i k_i] = \mathbb{E}[q_i]\,\mathbb{E}[k_i] = 0, \qquad \text{(niezależność)}$$

$$\operatorname{Var}(q_i k_i) = \mathbb{E}[q_i^2 k_i^2] = \mathbb{E}[q_i^2]\,\mathbb{E}[k_i^2] = 1 \cdot 1 = 1. \qquad \text{(średnia 0, więc Var} = \mathbb{E}[\cdot^2])$$

Składniki są niezależne, więc wariancja sumy to suma wariancji: $\operatorname{Var}\left(\sum_i q_i k_i\right) = d$. Dzielenie przez $\sqrt{d}$ dzieli wariancję przez d (stała wychodzi do kwadratu). To kończy dowód. ■

W zwykłym języku: im dłuższe wektory, tym większe losowe wyniki iloczynów. Duże wyniki wpychają softmax w nasycenie (jedna waga bliska 1, reszta ≈ 0), gdzie jego gradient zanika. Skalowanie utrzymuje wyniki w rozsądnym zakresie (rys. 10.1c: pomarańczowy rozrzut rośnie jak $\sqrt{d}$, niebieski, po skalowaniu, jest stały).

10.4 Uwaga dla całej sekwencji i premie położenia

Gdy każdy z n elementów jest też zapytaniem, wszystko zapisujemy macierzowo: $Q, K, V \in \mathbb{R}^{n \times d}$ (wiersze to wektory), $\operatorname{Attn}(Q,K,V) = \operatorname{softmax}\left(QK^\top/\sqrt{d} + B\right)V$, gdzie softmax działa na każdy wiersz, a $B \in \mathbb{R}^{n \times n}$ to macierz premii. Wynikiem jest nowy zestaw n wektorów.

Twierdzenie 10.4 (Bez premii uwaga nie zna kolejności). *Niech P będzie macierzą permutacji. Dla $B = 0$:* $\mathrm{Attn}(PQ, PK, PV) = P\,\mathrm{Attn}(Q,K,V)$.

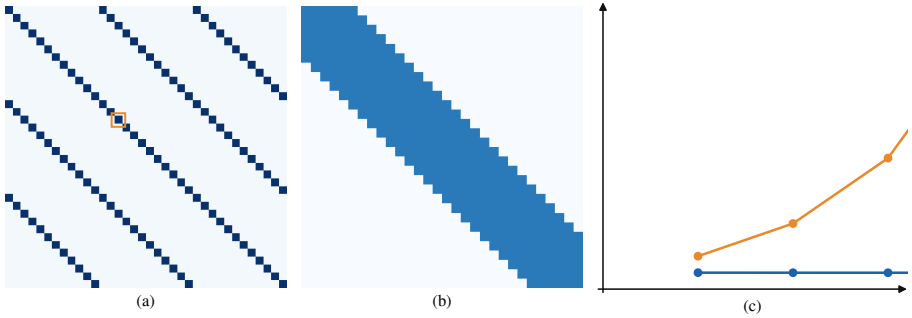
Pomysł dowodu. Permutacja wierszy Q,K permutuje wiersze i kolumny macierzy wyników w ten sam sposób; softmax po wierszach tego nie zauważa.

Dowód. $(PQ)(PK)^\top = PQK^\top P^\top$, więc macierz wyników S zamienia się w $PSP^\top$: wiersze i kolumny są przetasowane tak samo. Softmax liczony po wierszach przestawia kolumny wewnątrz wiersza bez zmiany wag, a P przestawia wiersze: $\mathrm{softmax}(PSP^\top) = P\,\mathrm{softmax}(S)\,P^\top$. Stąd

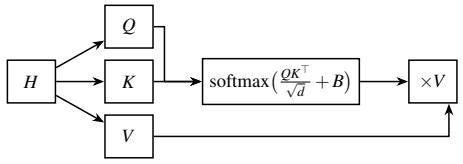
$$\begin{aligned}\mathrm{Attn}(PQ,PK,PV) &= P\,\mathrm{softmax}(S)\,P^\top PV && (P^\top P = I)\\ &= P\,\mathrm{Attn}(Q,K,V). && (\text{def.})\end{aligned}$$

Przetasowanie wejścia tylko przetasowuje wyjście. To kończy dowód. ■

W zwykłym języku: samo „co” nie mówi „gdzie”. Gdyby klatki wymieszać, uwaga nie zauważy. Dlatego dodajemy *premię zależną od odległości* b_{j-i} (wyuczoną liczbę dla każdej różnicy położeń): sieć może się nauczyć, że odległość 12 półtonów (oktawa) jest szczególnie ważna, albo że klatka sprzed 0,5 s ma inną wagę niż sąsiednia. Niektóre pary można też zablokować, ustawiając $b = -\infty$ (waga wtedy dokładnie 0): tak powstaje *okno* $|j-i| \le W$ (rys. 10.1b), które w Gen 6 ma $W = 43$ klatki (≈ 1 s) i kosztuje $O(n(2W+1))$ zamiast $O(n^2)$.



Rysunek 10.1: (a) Zabawka: 36 półtonów, a zapytanie i klucz to wskazanie klasy wysokości ($i \bmod 12$). Każdy wiersz macierzy wag α ma ciemne pola tylko dla tej samej klasy, czyli co 12 półtonów: wysokość 14 (pomarańczowa ramka) patrzy na 2, 14 i 26 — uwaga potrafi „zobaczyć” oktawy. (b) Maska okna $|t-u| \le 5$ dla 30 klatek: tylko pasmo wokół przekątnej ma niezerowe wagi. (c) Odchylenie standardowe $\langle \boldsymbol{q}, \boldsymbol{k} \rangle$ dla wymiarów $d = 4, 16, 64, 256$ (oś pozioma $\log_2 d$): bez skalowania (pomarańczowa) rośnie jak $\sqrt{d}$, po podzieleniu przez $\sqrt{d}$ (niebieska) jest równe 1. Obliczone z 10^5 losowych par.



Rysunek 10.2: Przepływ danych jednej głowicy uwagi. Wektory cech $H \in \mathbb{R}^{n\times D}$ są rzutowane na $Q,K,V \in \mathbb{R}^{n\times d_h}$; iloczyny $QK^\top \in \mathbb{R}^{n\times n}$ (wyniki dopasowania), dzielone przez $\sqrt{d}$ i powiększone o premie B, przechodzą przez softmax wiersz po wierszu; powstałe wagi mnożą V i dają wyjście $n \times d_h$.

10.5 Wiele głowic i liczba parametrów

Jedna uwaga potrafi śledzić jedną zależność naraz. *Wielogłowicowa* uwaga dzieli wektor D-wymiarowy na n_h części po $d_h = D/n_h$, w każdej liczy osobną uwagę (osobne W_Q, W_K, W_V i osobne premie), skleja wyniki i mnoży przez W_O. W Gen 6: $D = 64$, $n_h = 4$, $d_h = 16$.

Na konkretnych liczbach. Macierz W_{QKV}: $64 \to 192$ (trzy macierze naraz) ma $64 \cdot 192 + 192 = 12\,480$ parametrów; W_O: $64 \to 64$ ma $64 \cdot 64 + 64 = 4160$. Premie czasowe: $n_h(2W+1) = 4 \cdot 87 = 348$; premie między wysokościami: $n_h(2S-1) = 4 \cdot 105 = 420$ (dla $S = 53$). Uwaga w czasie ma więc $12\,480 + 4160 + 348 = 16\,988$ parametrów, a uwaga między wysokościami $12\,480 + 4160 + 420 = 17\,060$ — zgodnie z dodatkiem A.

Pułapka. Wagi uwagi (rys. 10.1a) bywają interpretowane jako „wyjaśnienie” decyzji modelu. To tylko część obrazu: po uwadze są jeszcze macierze W_O, normalizacja i kolejne warstwy, a każda głowica widzi inne części wektora. Wagi uwagi pokazują, skąd model brał informacje w jednym kroku, a nie dlaczego podjął decyzję. ♢

Podsumowanie

- Uwaga: $\mathrm{Attn}(\boldsymbol{q}) = \sum_j \mathrm{softmax}(\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle / \sqrt{d} + b_j)\,\boldsymbol{v}_j$.
- Wynik to średnia ważona wartości, więc nie wychodzi poza ich zakres (tw. 10.2).
- Dzielenie przez $\sqrt{d}$ utrzymuje wariancję wyników na 1 (tw. 10.3).
- Bez premii uwaga nie odróżnia kolejności (tw. 10.4); premia zależna od odległości daje jej wiedzę o położeniu i pozwala wyróżnić oktawę lub zablokować dalekie pary (okno).
- Wiele głowic = wiele zależności naraz; Gen 6: $n_h = 4$, $d_h = 16$.

Ćwiczenia

1. Dla $\boldsymbol{q} = (0,2)$, kluczy $(1,0), (0,1)$ i wartości $(5,0), (0,5)$ (z $d = 2$) policz wagi i wynik uwagi.
2. Pokaż, że dodanie tej samej stałej c do wszystkich premii b_j nie zmienia wag α_j.
3. Elementy mają $d = 100$ i współrzędne q_i, k_i o wariancji 1. Jakie odchylenie standardowe ma $\langle \boldsymbol{q}, \boldsymbol{k} \rangle$ bez skalowania, a jakie po skalowaniu?
4. Ile parametrów ma wielogłowicowa uwaga z $D = 128$, $n_h = 8$ (bez premii)?

Rozwiązania

1. $\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle = (0,2)$, dzielone przez $\sqrt{2}$: $(0;\,1{,}414)$, wykładniki $(1;\,4{,}113)$, suma 5,113, wagi $(0{,}196;\,0{,}804)$. Wynik $0{,}196(5,0) + 0{,}804(0,5) = (0{,}978;\,4{,}022)$.
2. Z tw. 8.3(b): $\mathrm{softmax}(s + c\mathbf{1}) = \mathrm{softmax}(s)$.

3. Bez skalowania $\sqrt{100} = 10$; po skalowaniu 1 (tw. 10.3).
4. W_{QKV}: $128 \cdot 384 + 384 = 49\,536$; W_O: $128 \cdot 128 + 128 = 16\,512$; razem $66\,048$ (liczba głowic nie zmienia liczby parametrów, tylko sposób ich podziału).

11 Optymalizacja: jak sieć się uczy

11.1 Od gradientu do działającego uczenia

W rozdziale 5 poznaliśmy spadek gradientu $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla L$. W praktyce potrzeba czterech poprawek: (i) gradient liczymy z *małej porcji* danych, nie ze wszystkich (SGD), (ii) dostosowujemy krok do każdego parametru osobno (Adam), (iii) dodajemy zanik wag, (iv) zmieniamy krok η w czasie (harmonogram). Ten rozdział uzasadnia każdy z tych kroków i podaje wartości użyte w Gen 6.

Po tym rozdziale umiesz: (i) wskazać największy bezpieczny krok uczenia dla paraboli, (ii) policzyć krok Adama, (iii) obliczyć wartość kroku w dowolnej chwili harmonogramu z rozgrzewką i kosinusem, (iv) uzasadnić przycinanie gradientu.

11.2 Kiedy spadek gradientu się zbiega?

Twierdzenie 11.1 (Kryterium stabilności). *Dla $L(\boldsymbol{x}) = \frac{1}{2}\sum_i \lambda_i x_i^2$ z $\lambda_i > 0$ spadek gradientu z krokiem η daje $x_i^{(k)} = (1-\eta\lambda_i)^k x_i^{(0)}$. Zbiega on do zera dla każdej współrzędnej wtedy i tylko wtedy, gdy $\eta < 2/\lambda_{\max}$. Najszybszy zbieżny wybór to $\eta^* = \dfrac{2}{\lambda_{\min}+\lambda_{\max}}$, z współczynnikiem $\rho = \dfrac{\lambda_{\max}-\lambda_{\min}}{\lambda_{\max}+\lambda_{\min}}$ na krok.*

Pomysł dowodu. Funkcja jest rozdzielona po współrzędnych, więc każda ewoluuje osobno jak ciąg geometryczny o ilorazie $1-\eta\lambda_i$; ciąg zbiega do zera, gdy $|1-\eta\lambda_i| < 1$.

Dowód. $\partial L/\partial x_i = \lambda_i x_i$, więc

$$\begin{aligned} x_i^{(k+1)} &= x_i^{(k)} - \eta\lambda_i x_i^{(k)} && \text{(def. 5.6)} \\ &= (1-\eta\lambda_i)\,x_i^{(k)}. && \text{(wyłączenie)} \end{aligned}$$

Z indukcji $x_i^{(k)} = (1-\eta\lambda_i)^k x_i^{(0)}$. Ciąg geometryczny zbiega do 0 dla dowolnej wartości początkowej wtedy i tylko wtedy, gdy $|1-\eta\lambda_i| < 1$, czyli $0 < \eta\lambda_i < 2$. Warunek dla wszystkich i jednocześnie to $\eta < 2/\lambda_{\max}$ (najostrzejszy). Tempo ogranicza współrzędna z największym $|1-\eta\lambda_i|$, czyli $\rho(\eta) = \max\big(|1-\eta\lambda_{\min}|, |1-\eta\lambda_{\max}|\big)$. Pierwszy argument maleje z η, drugi (dla $\eta > 1/\lambda_{\max}$) rośnie; przecinają się, gdy $1-\eta\lambda_{\min} = \eta\lambda_{\max} - 1$, czyli $\eta^* = 2/(\lambda_{\min}+\lambda_{\max})$, a wtedy $\rho = 1-\eta^*\lambda_{\min} = (\lambda_{\max}-\lambda_{\min})/(\lambda_{\max}+\lambda_{\min})$. To kończy dowód. ∎

W zwykłym języku: najbardziej „stromy” kierunek (największe λ) ogranicza krok dla całej doliny, a najbardziej płaski (najmniejsze λ) ogranicza

tempo. Im bardziej wydłużona dolina ($\lambda_{\max}/\lambda_{\min}$ duże), tym wolniej schodzimy.

Na konkretnych liczbach. Dolina z rozdziału 5: $\lambda = (1, 10)$. Granica kroku: $2/10 = 0{,}2$. Dla $\eta = 0{,}19$ współrzędna y mnoży się przez $1 - 1{,}9 = -0{,}9$ w każdym kroku: zbieżna, ale z drżeniem. Dla $\eta = 0{,}21$: $1 - 2{,}1 = -1{,}1$ — błąd rośnie 10% na krok i metoda się rozbiega. Najlepszy krok $\eta^* = 2/11 = 0{,}182$ daje $\rho = 9/11 = 0{,}818$: żeby zmniejszyć błąd 1000-krotnie, potrzeba $\ln 10^{-3} / \ln 0{,}818 \approx 34$ kroków (rys. 11.2a).

Intuicja. Wyobraź sobie kulkę w długim, wąskim korycie. Gradient w poprzek koryta jest ogromny, a wzdłuż niego malutki, więc zwykły spadek gradientu musi używać małego kroku (bezpiecznego dla ściany) i wolno posuwa się wzdłuż koryta. Adam dzieli ruch w każdej osi przez jej typową skalę gradientu, dzięki czemu obie osie robią krok podobnej wielkości *bez ręcznego dobierania η do skali każdego parametru*. Uczciwie trzeba dodać: na prostej paraboli z *idealnie* dobranym krokiem zwykły spadek gradientu jest lepszy (rys. 11.1); zaleta Adama ujawnia się w sieciach, gdzie skale gradientów różnią się między warstwami o wiele rzędów wielkości i jednego dobrego η nie da się wybrać. ♢

11.3 SGD i jego szum

Strata całego zbioru to średnia strat pojedynczych próbek: $L(\boldsymbol{\theta}) = \frac{1}{N}\sum_n \ell_n(\boldsymbol{\theta})$. Liczenie jej gradientu dla $N = 15\,600$ nagrań w każdym kroku byłoby za drogie, więc losujemy *paczkę* B i bierzemy $\hat{g} = \frac{1}{|B|}\sum_{n\in B}\nabla\ell_n$.

Twierdzenie 11.2 (Gradient z paczki jest nieobciążony). *Jeśli B składa się z $|B|$ próbek wylosowanych niezależnie i równomiernie z $\{1,\dots,N\}$, to* $\mathbb{E}[\hat{g}] = \nabla L(\boldsymbol{\theta})$.

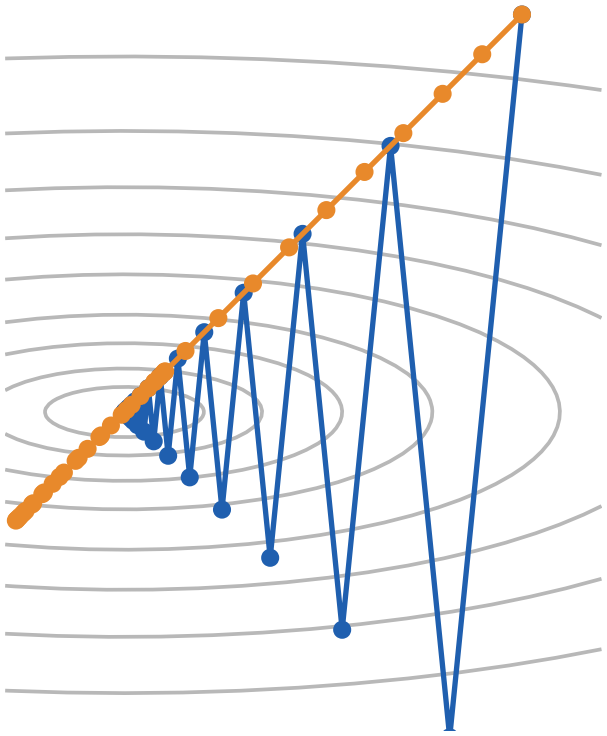
Pomysł dowodu. Każda próbka trafia do paczki z prawdopodobieństwem $\frac{1}{N}$; wartość oczekiwana średniej to średnia wartości oczekiwanych.

Dowód.

$$\begin{aligned}
\mathbb{E}[\hat{g}] &= \frac{1}{|B|}\sum_{j=1}^{|B|}\mathbb{E}\left[\nabla\ell_{n_j}\right] && \text{(liniowość } \mathbb{E}\text{)}\\
&= \frac{1}{|B|}\sum_{j=1}^{|B|}\sum_{n=1}^{N}\frac{1}{N}\nabla\ell_n && (n_j \text{ jednostajne})\\
&= \frac{1}{N}\sum_{n=1}^{N}\nabla\ell_n = \nabla L(\boldsymbol{\theta}). && (|B| \text{ jednakowych składników})
\end{aligned}$$

Gradient z paczki jest więc szumem wokół prawdziwego, ze średnią równą prawdziwemu; jego wariancja maleje jak $1/|B|$. To kończy dowód. ■

W Gen 6 paczka to 16 losowych wycinków po 192 klatki (4,4 s); wycinki są losowane z trzech źródeł z prawdopodobieństwami 0,5 (klasyka), 0,3 (GuitarSet) i 0,2 (środowiska).



Rysunek 11.1: Ta sama dolina $L = \frac{1}{2}(x^2 + 10y^2)$ co w rozdziale 5, start $(1, 1)$, 40 kroków. Niebieska: spadek gradientu z optymalnym krokiem $2/11$ (strata końcowa $6 \cdot 10^{-7}$). Pomarańczowa: Adam z $\eta = 0{,}1$ (strata końcowa 0,056: długie kroki w obu osiach, ale potem drży wokół minimum). Szare warstwice to poziomy strat. Na tej prostej paraboli, przy idealnie dobranym kroku, wygrywa zwykły spadek gradientu. Obie ścieżki obliczone programem.

11.4 Adam i AdamW

W różnych częściach sieci gradienty mają bardzo różną skalę. *Adam* utrzymuje dla każdego parametru wygładzoną średnią gradientu m i wygładzoną średnią jego kwadratu v:

$$\begin{aligned}
m_t &= \beta_1 m_{t-1} + (1-\beta_1) g_t, & v_t &= \beta_2 v_{t-1} + (1-\beta_2) g_t^2,\\
\hat{m}_t &= \frac{m_t}{1-\beta_1^t}, & \hat{v}_t &= \frac{v_t}{1-\beta_2^t},\\
\theta_t &= \theta_{t-1} - \eta\left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\varepsilon} + \lambda\,\theta_{t-1}\right),
\end{aligned}$$

z $m_0 = v_0 = 0$, zwykle $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$. Człon $\lambda\,\theta$ to *zanik wag* (w AdamW dodawany osobno; Gen 6: $\lambda = 10^{-4}$), który delikatnie ściąga wagi do zera i ogranicza przeuczenie.

Twierdzenie 11.3 (Korekta obciążenia i niezmienniczość skali). *(a) Jeśli $g_t = g$ jest stałe, to $m_t = (1-\beta_1^t)g$, więc $\hat m_t = g$. (b) Jeśli pomnożymy wszystkie gradienty przez $c > 0$, to przy $\varepsilon \to 0$ krok Adama się nie zmienia.*

Pomysł dowodu. (a) Indukcja po t; (b) $\hat m$ rośnie c razy, a $\sqrt{\hat v}$ też c razy; czynnik się skraca.

Dowód. (a) Dla $t=1$: $m_1 = (1-\beta_1)g = (1-\beta_1^1)g$. Jeśli $m_{t-1} = (1-\beta_1^{t-1})g$, to

$$\begin{aligned} m_t &= \beta_1(1-\beta_1^{t-1})g + (1-\beta_1)g && \text{(założenie indukcyjne)}\\ &= (\beta_1 - \beta_1^t + 1 - \beta_1)g = (1-\beta_1^t)g. && \text{(redukcja)}\end{aligned}$$

Dzielenie przez $1-\beta_1^t$ daje $\hat m_t = g$. Bez korekty pierwsze kroki byłyby $1-\beta_1 = 10\%$ właściwej wartości. (b) $\hat m \mapsto c\hat m$ (liniowość), $\hat v \mapsto c^2\hat v$, $\sqrt{\hat v} \mapsto c\sqrt{\hat v}$, więc $\hat m/\sqrt{\hat v}$ się nie zmienia. To kończy dowód. ∎

Przykład 11.1 (Pierwszy krok Adama). Dla $t=1$: $\hat m_1 = g_1$ i $\hat v_1 = g_1^2$, więc krok to $\eta g_1/|g_1| = \eta\,\mathrm{sgn}(g_1)$ ($\varepsilon \to 0$). Dla gradientów $(0{,}001;\ 100)$ oba parametry zmienią się o dokładnie $\eta = 10^{-3}$. Zwykły SGD zmieniłby je o 10^{-6} i $0{,}1$, czyli o liczby różniące się pięć rzędów wielkości.

przycinanie gradientu

Definicja 11.4 (Przycinanie gradientu). Zamiast g używamy $g \cdot \min(1, c/\|g\|)$ (norma po wszystkich parametrach). Dla $\|g\| \le c$ nic się nie zmienia; dla większej normy kierunek zostaje, a długość spada do c.

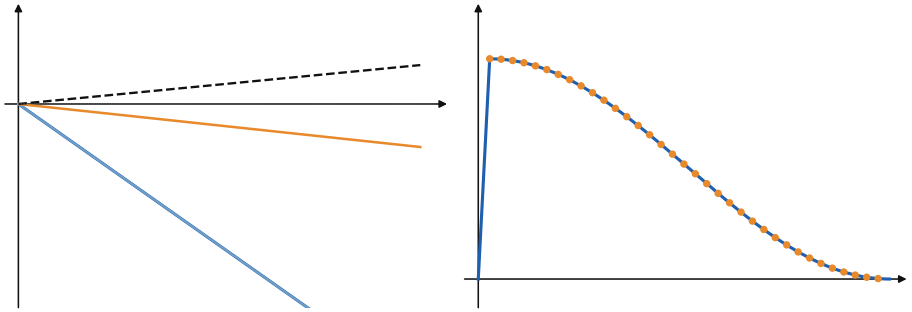
Przykład 11.2. Dla $g = (3,4)$, $\|g\| = 5$, $c = 1$: $g \cdot \min(1, 0{,}2) = (0{,}6;\ 0{,}8)$, długość 1. Gen 6 przycina do $c = 1$: pojedynczy dziwny wycinek nie wytrąci sieci z toru.

11.5 Harmonogram kroku

Na początku uczenia wagi są losowe, a Adam ma jeszcze niedokładne $\hat v$ — duży krok łatwo wszystko zepsuje; pod koniec chcemy kroku małego, by osiąść w dolinie. Stosujemy *rozgrzewkę* (liniowy wzrost od 0 do η_0 przez W kroków) i potem *spadek kosinusowy*:

$$\eta(t) = \begin{cases} \eta_0 \dfrac{t}{W}, & t < W, \\[2mm] \eta_0 \cdot \tfrac{1}{2}\bigl(1 + \cos \pi q\bigr), \quad q = \dfrac{t-W}{T-W}, & t \ge W. \end{cases} \tag{11.1}$$

Na konkretnych liczbach. Sesja 1 Gen 6: $\eta_0 = 10^{-3}$, $W = 1000$, $T = 36\,000$ (36 epok po 1000 kroków). Dla $t = 500$: $\eta = 5 \cdot 10^{-4}$. Dla $t = 15\,000$ ($q = 0{,}4$): $\eta = 10^{-3} \cdot \tfrac{1}{2}(1 + \cos 0{,}4\pi) = 6{,}55 \cdot 10^{-4}$, a dziennik uczenia zapisał na końcu epoki 14 wartość $6{,}55 \cdot 10^{-4}$. W połowie ($t = 18\,500$, $q = 0{,}5$): $5 \cdot 10^{-4}$. Na końcu $\eta \to 0$.



(a) (b)

Rysunek 11.2: (a) Spadek gradientu dla $\lambda = 10$ ($\log_{10}|x|$ w kolejnych krokach): $\eta = 0{,}05$ (niebieska) i $0{,}15$ (jasnoniebieska) zbiegają; $\eta = 0{,}19$ (pomarańczowa) zbiega z wolno gasnącym drżeniem; $\eta = 0{,}21 > 2/\lambda$ (czarna przerywana) rozbiega się. Szara kropkowana to poziom początkowy. (b) Harmonogram kroku z rozgrzewką i spadkiem kosinusowym (niebieska) oraz wartości zapisane w dzienniku prawdziwego uczenia Gen 6 po każdej epoce (pomarańczowe kropki): leżą dokładnie na krzywej.

W Gen 6 uczenie przebiegło w trzech sesjach (w sumie 97 epok): sesja 1 z $\eta_0 = 10^{-3}$, sesja 3 (restart) z $4 \cdot 10^{-4}$, sesja 4 z $3 \cdot 10^{-4}$ i harmonogramem kosinusowym liczonym od *czasu*, a nie od liczby kroków (żeby skończyć dokładnie w limicie GPU).

Pułapka. Ten sam model bez rozgrzewki lub z za dużym η może się „rozjechać” w pierwszych setkach kroków i nigdy nie dojść do dobrego wyniku; objaw to strata, która nagle skacze do dużej wartości lub `NaN`. Warto zapisywać stan modelu po każdej epoce (Gen 6 tak robi) i umieć wznowić uczenie od zapisu. ♢

Podsumowanie

- Spadek gradientu na paraboli zbiega, gdy $\eta < 2/\lambda_{\max}$; tempo zależy od $\lambda_{\max}/\lambda_{\min}$ (tw. 11.1).
- Gradient z paczki jest nieobciążonym, zaszumionym oszacowaniem gradientu pełnego (tw. 11.2).
- Adam normuje krok przez $\sqrt{\hat v}$: ma niezmienniczą skalę, a korekta obciążenia daje $\hat m = g$ dla stałego gradientu (tw. 11.3). AdamW dodaje zanik wag $\lambda = 10^{-4}$.
- Przycinanie gradientu do normy 1 chroni przed pojedynczymi dziwnymi paczkami.
- Harmonogram: rozgrzewka 1000 kroków, potem kosinus do zera; dziennik uczenia Gen 6 zgadza się ze wzorem.

Ćwiczenia

1. Dla $\lambda = (2, 50)$ podaj granicę kroku i najlepszy krok η^* oraz współczynnik ρ.
2. Policz pierwszy krok AdamW dla $\theta = 0{,}5$, $g = -0{,}2$, $\eta = 10^{-3}$, $\lambda = 10^{-4}$ ($t = 1$, $\varepsilon \to 0$).

3. Oblicz $\eta(t)$ dla $\eta_0 = 3 \cdot 10^{-4}$, $W = 1000$, $T = 49\,000$, $t = 25\,000$.
4. Pokaż, że przycinanie gradientu do normy c nie zmienia jego kierunku.

Rozwiązania

1. Granica $2/50 = 0{,}04$; $\eta^* = 2/52 = 0{,}0385$; $\rho = 48/52 = 0{,}923$ (bardzo wolno: wydłużona dolina).
2. $\hat{m}/\sqrt{\hat{v}} = g/|g| = -1$, więc $\theta \leftarrow \theta - \eta\big(-1 + \lambda\theta\big) = 0{,}5 - 10^{-3}(-1 + 0{,}5 \cdot 10^{-4}) = 0{,}5 + 10^{-3} \cdot 0{,}99995 = 0{,}50099995$.
3. $q = (25\,000 - 1000)/48\,000 = 0{,}5$, więc $\eta = 3 \cdot 10^{-4} \cdot \frac{1}{2}(1+0) = 1{,}5 \cdot 10^{-4}$.
4. Nowy wektor to $s\,g$ z $s = \min(1, c/\|g\|) > 0$, czyli dodatnia wielokrotność g: kierunek $(g/\|g\|)$ pozostaje ten sam, zmienia się tylko długość.

Część II

Model Gen 6

12 Zadanie, dane i etykiety

12.1 Co dokładnie ma zrobić model?

Mamy nagranie gitary. Chcemy dostać *listę nut*: dla każdej nuty wysokość (numer MIDI), moment początku, moment końca, a jeśli się da, strunę i próg, na których ją zagrano. Dziedzina nazywa się automatyczną transkrypcją muzyki (AMT). Dla gitary są w niej dwie szczególne trudności, które omawialiśmy w rozdziałach 3–7: wielogłosowość (kilka nut naraz i wspólne alikwoty) oraz niejednoznaczność tabulatury (ta sama wysokość na kilku strunach).

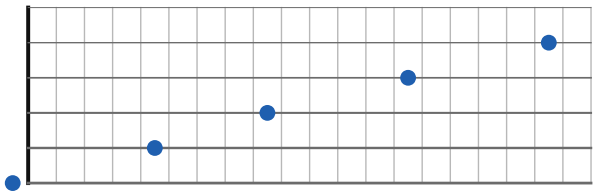
Po tym rozdziale umiesz: (i) wskazać, ile pozycji na gryfie odpowiada danej wysokości, (ii) policzyć mapy celów dla jednej nuty, (iii) uzasadnić, że klatka początku zawsze „brzmi”, (iv) wyjaśnić, po co są maski dostępności etykiet.

12.2 Niejednoznaczność tabulatury

tabulatura

Definicja 12.1 (Pozycja na gryfie). Gitara ma struny numerowane $i = 1,\dots,6$ od najcieńszej ($o_1 = 64$, E4) do najgrubszej ($o_6 = 40$, E2), gdzie o_i to wysokość MIDI struny pustej. *Pozycją* nuty m nazywamy parę (i, f) taką, że próg $f = m - o_i$ jest całkowity i $0 \le f \le 19$ (model zakłada progi 0–19).

Przykład 12.1. Nuta E4 ($m = 64$) ma $64 - o_i = 0; 5; 9; 14; 19; 24$ dla $i = 1,\dots,6$. Próg $24 > 19$ odpada, więc są *pięć* pozycji: struna 1 próg 0, struna 2 próg 5, struna 3 próg 9, struna 4 próg 14, struna 5 próg 19 (rys. 12.1). Nuta E2 ($m = 40$) ma tylko jedną pozycję (struna 6, próg 0).



Rysunek 12.1: Gryf z 20 progami; struny od najcieńszej (góra) do najgrubszej (dół). Niebieskie kropki to wszystkie pięć pozycji nuty E4: próg 0 (struna pusta, kropka przed siodełkiem), 5, 9, 14 i 19. Wysokość nie wystarcza do ustalenia pozycji; o strunie decyduje barwa dźwięku (struny o różnej grubości mają inny rozkład alikwotów) i kontekst muzyczny.

Intuicja. Wysokość mówi „co”, tabulatura mówi „jak to zagrać”. Ta sama nuta zagrana na grubej strunie wysoko na gryfie brzmi ciemniej niż na cienkiej strunie nisko: ma inną proporcję alikwotów (rozdział 3). Model może więc wnioskować strunę z widma, ale nie z samej wysokości. ♢

Na konkretnych liczbach. Liczba pozycji nuty m to $\#\{i : 0 \le m - o_i \le 19\}$. Dla $m = 40,\dots,44$ wynosi 1; dla $m = 59$ i $m = 64$ jest największa i wynosi 5; dla $m = 79,\dots,83$ znów 1. Z 44 wysokości $40,\dots,83$ aż 34 ma co najmniej dwie pozycje. Tabulatura nie jest więc dodatkiem, tylko osobnym problemem: sama lista wysokości zostawia wiele wyborów (zob. rozdział 16, wybór struny).

12.3 Dane uczące

Gen 6 uczono na danych trzech rodzajów. Wszystkie mają tę samą postać: lista nut z wysokością, początkiem i końcem (czasem struną i progiem), plus nagranie.

zbiór	nagrań (ucz./walid./test)	opis
klasyka, zestaw 1	5502/450/520	utwory z korpusu MIDI zagrane syntezatorem na 27 instrumentach w 11 miejscach, 4 formy utworu
klasyka, zestaw 2	9135 (tylko ucz.)	inne ziarna losowe: transpozycje, tempa, obsady
środowiska gitarowe	888	gitara w losowym pokoju z szumem, brumem i stukami
GuitarSet	168/12/180	prawdziwa gitara; gracze 00–02 uczenie, funk gracza 02 walidacja, gracze 03–05 test

Tabela 12.1: Zbiory danych Gen 6 (ok. 16 850 nagrań, z czego do uczenia ok. 15 600). Źródło: dokumentacja projektu (`docs/WYNIKI.md`). Korpus MIDI ma 3236 utworów (282 h, 8,2 mln nut): MAESTRO v3 i partytury z biblioteki music21.

Pułapka. **Tylko GuitarSet to prawdziwa gitara**, a stanowi niewielką część danych (168 nagrań uczących). Większość pozostałych to *synteza*: nagrania generowane programem z nut. To ważne przy ocenie wyników (rozdział 17): dobry wynik na syntezie nie dowodzi, że model równie dobrze zadziała na każdej prawdziwej gitarze, mikrofonie i pokoju. Podział na zbiory robiono *po utworach i po graczach*: utwór czy gracz z testu nigdy nie występuje w uczeniu. ♢

12.4 Mapy celów

Sieć zwraca dla każdej klatki t i półtonu $s = m - 36$ liczby $p_{\text{on}}, p_{\text{fr}}, p_{\text{off}} \in (0,1)$ oraz inne (rozdział 14). Żeby ją uczyć, trzeba z listy nut zbudować takie same mapy *wzorcowe* $y_{\text{on}}, y_{\text{fr}}, y_{\text{off}}$. Niech $\tau_t = (256t + 2048)/11\,025$ będzie środkiem czasowym klatki t (środek okna długiego, rozdział 7) i $\Delta = 256/11\,025 = 23{,}2\,\text{ms}$.

mapy celów

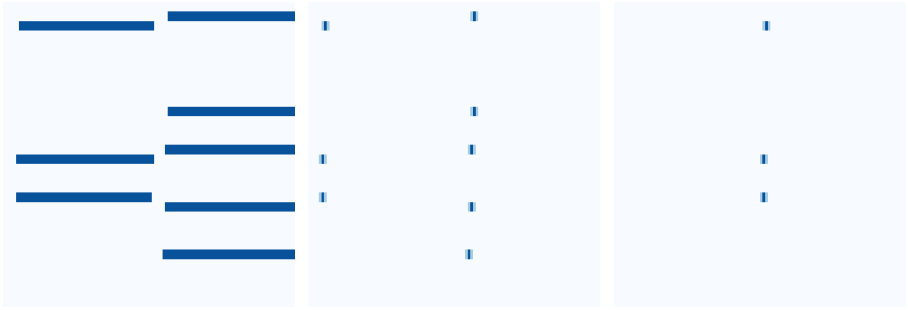
Definicja 12.2 (Mapy celów). Dla nuty o wysokości m, początku t_{on} i końcu t_{end} niech $s = m - 36$ i $k_{\text{on}} = \operatorname{round}\big((t_{\text{on}} f_s - 2048)/256\big)$, $k_{\text{off}} = \operatorname{round}\big((t_{\text{end}} f_s - 2048)/256\big)$, gdzie $f_s = 11\,025\,\text{Hz}$. Wtedy:

- *brzmi:* $y_{\text{fr}}(t,s) = 1 \iff t_{\text{on}} - \frac{1}{2}\Delta \le \tau_t \le \max(t_{\text{end}}, t_{\text{on}})$;
- *początek:* $y_{\text{on}}(k_{\text{on}}, s) = 1$ i $y_{\text{on}}(k_{\text{on}} \pm 1, s) = 0{,}4$ (miękkie sąsiedztwo);

- *koniec:* tak samo, z k_{off}.

Gdy nuty się nakładają, bierzemy maksimum; poza tym wartości są 0.

Przykład 12.2 (Jedna nuta policzona do końca). Nuta E4 ($m = 64$, $s = 28$) zaczyna się w $t_{\text{on}} = 1{,}000$ s i kończy w $t_{\text{end}} = 1{,}400$ s. Wtedy $k_{\text{on}} = \text{round}\big((11\,025 - 2048)/256\big) = \text{round}(35{,}07) = 35$, więc y_{on} w klatkach $34, 35, 36$ wynosi 0,4; 1; 0,4. Brzmi od $\tau_t \geq 1{,}000 - 0{,}0116 = 0{,}9884$ s: klatka 34 ma $\tau = 0{,}9752$ (jeszcze nie), klatka 35 ma $\tau = 0{,}9985$ (tak), więc od $t = 35$. Do $\tau_t \leq 1{,}4$: $\tau_{52} = 1{,}3932$ (tak), $\tau_{53} = 1{,}4164$ (nie), więc do $t = 52$. Koniec: $k_{\text{off}} = \text{round}(52{,}29) = 52$, wartości 0,4; 1; 0,4 w klatkach $51, 52, 53$. Jeśli ta nuta jest grana na strunie 2 ($o = 59$), próg to $64 - 59 = 5$, czyli klasa tabulatury $1 + 5 = 6$ na strunie 2 w klatkach 35–52, a na pozostałych strunach 0 (milczą).



(a) (b) (c)

Rysunek 12.2: Mapy celów syntetycznego nagrania z 15 nutami (fragment: 110 klatek, półtony 4–35): (a) „brzmi” — poziome kreski trwających nut, (b) początki — pojedyncze kropki (jasne punkty to 1, ich pionowe sąsiedztwo w czasie to miękkie 0,4), (c) końce. Mapy początków i końców są rzadkie: tylko 0,12% komórek początków jest równa 1 (rozdział 8). Mapy zbudowane kodem z repozytorium.

Twierdzenie 12.3 (Klatka początku zawsze brzmi). *Niech nuta trwa co najmniej $\frac{1}{2}\Delta$. Dla k_{on} z def. 12.2 zachodzi $y_{\text{fr}}(k_{\text{on}}, s) = 1$.*

Pomysł dowodu. Zaokrąglenie przesuwa indeks o co najwyżej $\frac{1}{2}$ klatki, więc środek klatki początku leży nie dalej niż $\frac{1}{2}\Delta$ od t_{on} — czyli mieści się w oknie definicji.

Dowód. Niech $x = (t_{\text{on}} f_s - 2048)/256$, więc $k_{\text{on}} = \text{round}(x)$ i $|k_{\text{on}} - x| \leq \frac{1}{2}$. Środek klatki k_{on}:

$$\begin{aligned} \tau_{k_{\text{on}}} - t_{\text{on}} &= \frac{256 k_{\text{on}} + 2048}{f_s} - \frac{256x + 2048}{f_s} && \text{(def. } \tau, x\text{)} \\ &= \frac{256}{f_s}\,(k_{\text{on}} - x) = \Delta\,(k_{\text{on}} - x). && \text{(upraszczanie)} \end{aligned}$$

Zatem $|\tau_{k_{\text{on}}} - t_{\text{on}}| \leq \frac{1}{2}\Delta$, czyli $\tau_{k_{\text{on}}} \geq t_{\text{on}} - \frac{1}{2}\Delta$ (dolna granica). Górna: $\tau_{k_{\text{on}}} \leq t_{\text{on}} + \frac{1}{2}\Delta \leq t_{\text{end}}$ z założenia o długości nuty. Obie nierówności zachodzą, więc $y_{\text{fr}} = 1$. To kończy dowód. ■

W zwykłym języku: nie ma nut, które mają początek, ale „nie brzmią” w tej samej klatce. W poprzedniej generacji (Gen 5) warunek zaczynał się od $\tau_t \geq t_{\text{on}}$, więc klatka początku mogła mieć $y_{\text{fr}} = 0$, a dekoder wymaga p_{fr} w klatce początku (rozdział 16); taka nuta była gubiona.

Intuicja. Miękkie sąsiedztwo 0,4 wokół początku mówi sieci: „nie jesteś karana za pomyłkę o jedną klatkę (23 ms)”. Dokładność czasowa człowieka i etykiet jest rzędu dziesiątek milisekund, a ocena przyjmuje tolerancję 50 ms. Z twierdzenia 8.6 wiemy, że przy BCE etykieta 0,4 uczy wyniku $\approx 0{,}4$. ♢

12.5 Dostępność etykiet

Nie każde źródło ma wszystkie etykiety: GuitarSet ma struny i progi, ale nie głośności; korpus MIDI ma głośności i brak strun na gitarze; przy niektórych danych brak końców. Każdy przykład niesie więc wektor $\boldsymbol{a} \in \{0, 1\}^5$ (które z pięciu głowic: początek, brzmi, koniec, głośność, tabulatura ma *naprawdę* zaadnotowane), a strata danej głowicy jest mnożona przez $a_{\text{głowica}}$ (rozdział 15). Dzięki temu można łączyć źródła o różnych adnotacjach bez udawania, że brakujące etykiety są zerami.

Pułapka. Uczenie na brakujących etykietach traktowanych jako zera *aktywnie szkodzi*: model uczy się, że „tu nie ma nuty”, a nie że „tu nie wiemy”. Maska dostępności jest tanim sposobem, by tego uniknąć. W Gen 6 żadne źródło nie ma etykiet głośności, więc głowica głośności pozostała nieuczona (jej wyjście nie jest zwracane). ♢

Podsumowanie

- Wynik modelu to lista nut; wysokość nie wyznacza tabulatury (34 z 44 wysokości mają ≥ 2 pozycje).
- Dane to głównie synteza ($\approx 16\,850$ nagrań) i niewielki zbiór prawdziwej gitary (GuitarSet); testujemy na utworach i graczach nieobecnych w uczeniu.
- Mapy celów: *brzmi*, *początek* i *koniec* (z miękkim sąsiedztwem 0,4) oraz klasa tabulatury $0 \ldots 20$ na strunę.
- Klatka początku zawsze też „brzmi” (tw. 12.3), co poprawiono względem Gen 5.
- Maski dostępności pozwalają łączyć dane o różnych adnotacjach.

Ćwiczenia

1. Podaj wszystkie pozycje (i, f) nuty $m = 55$ (G3). Ile ich jest?
2. Nuta A3 ($m = 57$) zaczyna się w $t_{\text{on}} = 2{,}000$ s i kończy w $t_{\text{end}} = 2{,}500$ s. Policz k_{on}, k_{off} i pierwszą klatkę, w której $y_{\text{fr}} = 1$.
3. Pokaż, że mapa początków dla jednej nuty ma sumę $1 + 2 \cdot 0{,}4 = 1{,}8$ (dla nuty bez nakładania z innymi).
4. Dlaczego przy mapie „brzmi” w Gen 5 (start $\tau_t \geq t_{\text{on}}$) klatka początku mogła mieć etykietę 0? Podaj przykład liczbowy.

Rozwiązania

1. $55 - o_i = -9; -4; 0; 5; 10; 15$ dla $i = 1..6$ ($o = 64, 59, 55, 50, 45, 40$): dopuszczalne 0 (struna 3), 5 (struna 4), 10 (struna 5), 15 (struna 6), a ujemne odpadają. Cztery pozycje: $(3,0), (4,5), (5,10), (6,15)$.

2. $k_{\text{on}} = \text{round}((2 \cdot 11\,025 - 2048)/256) = \text{round}(78{,}13) = 78$; $k_{\text{off}} = \text{round}((2{,}5 \cdot 11\,025 - 2048)/256) = \text{round}(99{,}67) = 100$. Dolna granica $\tau_t \geq 2{,}0 - 0{,}0116 = 1{,}9884$: $\tau_{78} = (78 \cdot 256 + 2048)/11\,025 = 1{,}9969$ (tak), $\tau_{77} = 1{,}9737$ (nie). Pierwsza klatka to 78.

3. W k_{on} wartość 1, w $k_{\text{on}} \pm 1$ po 0,4 (przy założeniu, że obie klatki mieszczą się w nagraniu i nie nakładają się inne nuty): suma $1 + 0{,}4 + 0{,}4 = 1{,}8$.

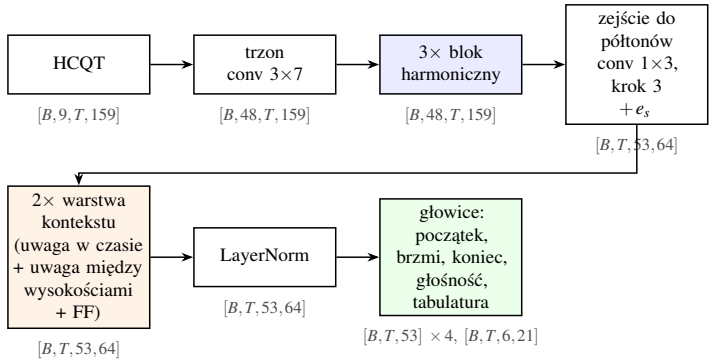
4. Dla $t_{\text{on}} = 1{,}000$ klatka początku $k = 35$ ma środek $\tau_{35} = 0{,}9985 < 1{,}000$, więc przy warunku $\tau_t \geq t_{\text{on}}$ miałaby etykietę 0; dopiero przesunięcie granicy o $\frac{1}{2}\Delta$ ($0{,}9884 \leq 0{,}9985$) daje 1.

13 Architektura I: trzon i blok harmoniczny

13.1 Przegląd całości

Mamy wszystkie cegiełki: HCQT (rozdział 7), konwolucje, LayerNorm, połączenia resztkowe (rozdział 9), uwagę (rozdział 10), straty (rozdział 8). Teraz składamy z nich sieć. W tym rozdziale opisujemy jej pierwszą połowę, która zamienia cechy HCQT na wektor opisu dla każdej pary (klatka, półton); w następnym — drugą połowę z uwagą i głowicami.

Po tym rozdziale umiesz: (i) narysować przepływ tensorów przez Gen 6 z kształtami, (ii) policzyć wyjście bloku harmonicznego dla małych liczb, (iii) uzasadnić, że blok wykrywa wzorzec nuty o dowolnej wysokości, (iv) policzyć liczbę parametrów trzonu, bloków i zejścia.



Rysunek 13.1: Przepływ tensorów w Gen 6 (B — liczba nagrań w paczce, T — liczba klatek). Pierwsza połowa (rozdz. 13, niebieskie pole): cechy HCQT przechodzą przez trzon i trzy bloki harmoniczne, a potem „schodzą" z 159 binów do 53 półtonów (64 liczby opisu na każdą parę klatka–półton). Druga połowa (rozdz. 14): dwie warstwy kontekstu (pomarańczowe pole), normalizacja i pięć głowic (zielone pole). Łącznie 249 219 parametrów.

13.2 Trzon

Trzon to pojedyncza konwolucja 3×7 (rozdział 9) z 9 kanałów HCQT do $H = 48$ kanałów, po której stosujemy GELU: $h^{(0)} = \text{GELU}\left(\text{Conv}_{3\times 7}(X)\right) \in \mathbb{R}^{48 \times T \times 159}$. Jądro ma 3 klatki w czasie i 7 binów (≈ 2 półtony) po wysokości: łączy sąsiednie klatki i sąsiednie biny, ucząc się prostych wzorców (wzrost energii, pik, cienkie prążki). Parametrów: $9 \cdot 48 \cdot 21 + 48 = 9120$ (przykład z rozdziału 9).

13.3 Blok harmoniczny

To najważniejsza nowość Gen 6. Z rozdziału 3 wiemy, że alikwoty nuty o numerze binu p leżą w binach $p+k_h$ z $k_h = \operatorname{round}(36\log_2 h)$. Przesunięcia dla $h = 0{,}5; 1; 2; 3; 4; 5; 6$ to $K = (-36, 0, 36, 57, 72, 84, 93)$ (wniosek 3.5). Blok pozwala jednej warstwie zobaczyć wszystkie te miejsca naraz.

przesunięcie po wysokości

Definicja 13.1 (Operator przesunięcia). Dla tensora $h \in \mathbb{R}^{H\times T\times P}$ i całkowitego k definiujemy $\operatorname{shift}_k(h)[c,t,p] = h[c,t,p+k]$, a wartości spoza zakresu $0 \le p+k < P$ zastępujemy zerami.

Przykład 13.1. Dla jednego kanału i jednej klatki: $x = (1,2,3,4,5,6,7,8)$, $k=2$: $\operatorname{shift}_2(x) = (3,4,5,6,7,8,0,0)$; $k=-2$: $\operatorname{shift}_{-2}(x) = (0,0,1,2,3,4,5,6)$. Wartość na pozycji p to wartość z pozycji $p+k$; na brzegach wchodzi zero.

Blok harmoniczny o wejściu $x \in \mathbb{R}^{H\times T\times P}$ liczy (z $H = 48$, 7 przesunięciami, d — dylatacja czasowa):

$$\tilde{h} = \mathrm{LN}_{\mathrm{kan}}(x), \qquad u = W_h\left[\operatorname{shift}_{k_1}(\tilde{h}) \,\|\, \cdots \,\|\, \operatorname{shift}_{k_7}(\tilde{h})\right], \tag{13.1}$$

$$v = \mathrm{GELU}\Big(\mathrm{DW}_{1\times 5}\left(\mathrm{GELU}(u)\right)\Big), \qquad y = x + \mathrm{Drop}\Big(\mathrm{GELU}\left(\mathrm{Conv}^{(d)}_{3\times 1}(v)\right)\Big). \tag{13.2}$$

Znaczenie symboli: $\mathrm{LN}_{\mathrm{kan}}$ — LayerNorm po H kanałach w każdym punkcie (t,p) osobno; $\|$ — sklejenie wzdłuż osi kanałów (siedem kopii po 48 daje 336 kanałów); W_h — konwolucja 1×1 ($336 \to 48$), czyli ta sama warstwa liniowa w każdym punkcie; $\mathrm{DW}_{1\times 5}$ — konwolucja głębokościowa po 5 sąsiednich binach (na rozstrojenie i nieharmoniczność, por. rozdział 3); $\mathrm{Conv}^{(d)}_{3\times 1}$ — konwolucja w czasie z dylatacją $d \in \{1,2,4\}$ w kolejnych blokach.

Na konkretnych liczbach. Mały model bloku: jeden kanał, jedna klatka, $x = (1,\dots,8)$, dwa przesunięcia $k \in \{0,2\}$, $W_h = (0{,}5;\ 1)$ (czyli $u[p] = 0{,}5x[p] + 1\cdot x[p+2]$), $b = 0$. Z przykładu 13.1: $\operatorname{shift}_0(x) = x$, $\operatorname{shift}_2(x) = (3,4,5,6,7,8,0,0)$, więc $u = (0{,}5\cdot 1+3,\ 0{,}5\cdot 2+4, \dots) = (3{,}5;\ 5;\ 6{,}5;\ 8;\ 9{,}5;\ 11;\ 3{,}5;\ 4)$. Pozycja p „widzi” teraz jednocześnie siebie i miejsce o 2 dalej; w prawdziwym bloku to miejsca $p-36, p, p+36, p+57, \dots, p+93$, a wagi W_h są uczone.

Intuicja. W pozycji p (kandydat na podstawową) blok dostaje jednocześnie energię z siedmiu miejsc: subharmonicznej, podstawy i alikwotów od drugiego do szóstego. W_h uczy się „wzorca nuty”: duża wartość w kilku z tych miejsc naraz świadczy o nucie w p. Ponieważ oś jest logarytmiczna, wzorzec jest ten sam dla każdej wysokości (tw. 3.4), więc jedna wspólna W_h działa wszędzie. To „zszycie” alikwotów w jedną kolumnę robi z błędu oktawowego problem uczenia, a nie kombinatoryki. ♢

Twierdzenie 13.2 (Blok harmoniczny jest równoważny przesunięciom wysokości). *Niech $x'[c,t,p] = x[c,t,p-s]$ (wejście przesunięte w górę o s binów). Wtedy wyjście bloku harmonicznego spełnia $y'[c,t,p] = y[c,t,p-s]$ dla wszystkich p oddalonych od brzegu zakresu na tyle, że żaden z użytych indeksów $p-s+k_j$, $p-s\pm 2$ nie wychodzi poza $\{0,\dots,P-1\}$.*

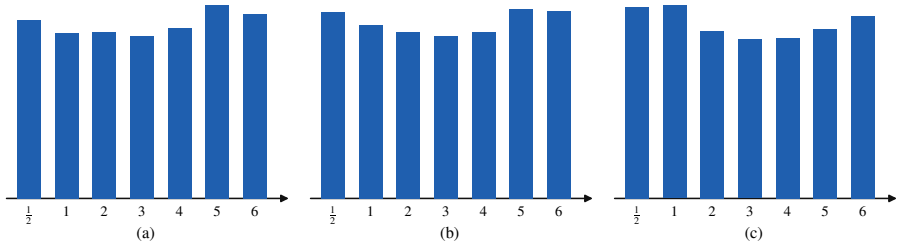
Pomysł dowodu. Każda operacja bloku jest albo punktowa (działa w każdym punkcie niezależnie), albo splotem lub przesunięciem po p, albo splotem w czasie; wszystkie przemieniają się z przesunięciem po p. Złożenie takich operacji też.

Dowód. Oznaczmy przesunięcie $(S_s x)[p] = x[p-s]$. Sprawdzamy każdy krok (z dala od brzegu, gdzie dopełnienie zerami nie gra roli):

$\mathrm{LN}_{\mathrm{kan}}(S_s x) = S_s\,\mathrm{LN}_{\mathrm{kan}}(x)$	(osobno w każdym (t,p))
$\operatorname{shift}_k(S_s x)[p] = x[p+k-s] = (S_s \operatorname{shift}_k x)[p]$	(def. 13.1)
W_h, GELU, Drop działają punktowo	(przemienne z S_s)
$\mathrm{DW}_{1\times 5}(S_s x) = S_s\,\mathrm{DW}_{1\times 5}(x)$	(tw. 9.4)
$\mathrm{Conv}_{3\times 1}(S_s x) = S_s\,\mathrm{Conv}_{3\times 1}(x)$	(czas, nie p)

Składanie operacji przemiennych z S_s daje operację przemienną z S_s, a dodanie x (połączenie resztkowe) też zachowuje tę własność. Stąd $y' = S_s y$. To kończy dowód. ■

W zwykłym języku: jeśli ta sama nuta zagrana jest o s binów wyżej, blok widzi dokładnie ten sam wzorzec, przesunięty o s. Dlatego sieć nie musi uczyć się osobnych detektorów dla każdej z 53 nut. Cena: nic nie wie o *bezwzględnej* wysokości (np. że niskie nuty gitary brzmią inaczej niż wysokie) — tę wiedzę wprowadzamy dopiero przy zejściu do półtonów, dodając wyuczone osadzenie wysokości.



Rysunek 13.2: Średnie wartości bezwzględne wag W_h w grupach wejść odpowiadających alikwotom $h = \frac{1}{2}, 1, 2, 3, 4, 5, 6$ (pod słupkami) dla trzech bloków (a), (b), (c) prawdziwego, wytrenowanego modelu Gen 6 (skala pionowa wspólna, od zera). Wszystkie siedem miejsc ma wagi podobnej wielkości (0,088–0,107): żadne nie zostało „wyłączone”. Wielkość wag nie dowodzi jednak ważności (brak badania ablacyjnego, zob. rozdział 17).

13.4 Zejście do półtonów

Po trzech blokach tensor ma 159 binów na wysokość; chcemy po jednym wektorze na półton. Konwolucja 1×3 z krokiem 3 w osi wysokości (każde wyjście widzi biny $3s, 3s+1, 3s+2$) zmienia liczbę kanałów z 48 na $D = 64$. Dodajemy wyuczony wektor $e_s \in \mathbb{R}^{64}$ dla każdego półtonu:

$$h^{(1)}_{t,s} = \mathrm{Conv}_{1\times 3,\ \text{krok } 3}(y)_{t,s} + e_s \in \mathbb{R}^{64}, \qquad s = 0,\dots,52. \tag{13.3}$$

Parametrów: konwolucja $48 \cdot 64 \cdot 3 + 64 = 9280$ i osadzenie $53 \cdot 64 = 3392$.

Przykład 13.2. Dla E2 ($s = 4$) wyjście widzi biny $12, 13, 14$ (środek 13, rozdział 7). Ponieważ bloki harmoniczne wcześniej przepuściły informację z binów $p+36, \ldots, p+93$ do p, wektor $h^{(1)}_{t,4}$ niesie wiedzę o alikwotach E2 aż do szóstego.

Na konkretnych liczbach. Parametry pierwszej połowy: trzon 9120; blok harmoniczny: LN $2 \cdot 48 = 96$, W_h $336 \cdot 48 + 48 = 16\,176$, DW $48 \cdot 5 + 48 = 288$, $\mathrm{Conv}_{3\times1}$ $48 \cdot 48 \cdot 3 + 48 = 6960$, razem 23 520 na blok i 70 560 w trzech; zejście 9280; osadzenie 3392. Suma $9120 + 70\,560 + 9280 + 3392 = 92\,352$. Resztę ($249\,219 - 92\,352 = 156\,867$) stanowią warstwy kontekstu, LN i głowice (rozdział 14). Liczby te są sprawdzone programem względem prawdziwego modelu.

Pułapka. Operator shift_k wprowadza zera poza zakresem, więc dla nut o skrajnych wysokościach część alikwotów jest niewidoczna: wynik bloku dla najwyższych półtonów opiera się na mniejszej liczbie miejsc. Tw. 13.2 obowiązuje tylko *z dala od brzegów*; sieć uczy się radzić sobie z brzegiem przez osadzenie wysokości e_s. ♢

Podsumowanie

- Gen 6 to złożenie: trzon → 3× blok harmoniczny → zejście do półtonów → 2× warstwa kontekstu → LN → głowice (rys. 13.1).
- Blok harmoniczny skleja 7 przesuniętych kopii cech ($-36, 0, 36, 57, 72, 84, 93$ binów) i łączy je warstwą 1×1; jest równoważny przesunięciom po wysokości (tw. 13.2).
- Trzon ma 9120 parametrów, blok 23 520 (razem 70 560), zejście 9280, osadzenie wysokości 3392.
- Kształt po zejściu: $[B, T, 53, 64]$ — wektor 64 liczb na każdą parę klatka–półton.

Ćwiczenia

1. Policz $\mathrm{shift}_3(x)$ i $\mathrm{shift}_{-1}(x)$ dla $x = (2, 4, 6, 8, 10)$.
2. Dla $x = (1, 2, 3, 4, 5, 6)$, przesunięć $k \in \{0, 3\}$ i wag $W_h = (1; -1)$ policz $u[p] = x[p] - x[p+3]$.
3. Ile parametrów miałby blok harmoniczny, gdyby zamiast 7 przesunięć użyć 5 (reszta bez zmian)?
4. Dlaczego w tw. 13.2 nie można pominąć założenia o oddaleniu od brzegu? Podaj przykład.

Rozwiązania

1. $\mathrm{shift}_3(x) = (8, 10, 0, 0, 0)$; $\mathrm{shift}_{-1}(x) = (0, 2, 4, 6, 8)$.
2. $\mathrm{shift}_3(x) = (4, 5, 6, 0, 0, 0)$, więc $u = (1-4, 2-5, 3-6, 4-0, 5-0, 6-0) = (-3, -3, -3, 4, 5, 6)$.

3. W_h zmieni się na $5 \cdot 48 \to 48$: $240 \cdot 48 + 48 = 11\,568$ (zamiast 16 176); pozostałe: LN 96, DW 288, $\mathrm{Conv}_{3\times1}$ 6960; razem 18 912.
4. Dla p blisko brzegu np. $p + k_j \geq P$ i shift wstawia zero zamiast wartości z poza zakresu. Wejście przesunięte o s ma w tym miejscu *prawdziwą* wartość, a nieprzesunięte zero (lub odwrotnie), więc wyjścia różnią się.

14 Architektura II: uwaga, kontekst i głowice

14.1 Co jeszcze potrafi poprawić wektor opisu?

Po pierwszej połowie sieci każda para (klatka t, półton s) ma wektor $h_{t,s} \in \mathbb{R}^{64}$ opisujący, ile jest tam „śladów nuty” (rozdział 13). Brakuje dwóch rzeczy. Po pierwsze *czasu*: czy nuta trwa od poprzedniej klatki, czy to nowe szarpnięcie, czy koniec? Po drugie *sąsiedztwa*: jeśli oktawę niżej też coś gra, czy to naprawdę osobna nuta, czy tylko alikwot? Obie rzeczy załatwia uwaga (rozdział 10): raz wzdłuż osi czasu, raz wzdłuż osi wysokości.

Po tym rozdziale umiesz: (i) zapisać jedną warstwę kontekstu, (ii) policzyć pole widzenia całej sieci i porównać je z pomiarem, (iii) wyjaśnić działanie głowic i głowicy tabulatury, (iv) policzyć liczbę parametrów całej sieci.

14.2 Warstwa kontekstu

warstwa kontekstu

Definicja 14.1 (Warstwa kontekstu). Wejście $h \in \mathbb{R}^{T\times S\times D}$ (T klatek, $S = 53$ półtony, $D = 64$). *Warstwa kontekstu* liczy kolejno (zawsze z normalizacją przed funkcją i połączeniem resztkowym, rys. 9.3):

$$\begin{aligned} h' &= h + \mathrm{Drop}\big(\mathrm{TA}(\mathrm{LN}(h))\big),\\ h'' &= h' + \mathrm{Drop}\big(\mathrm{PA}(\mathrm{LN}(h'))\big),\\ h''' &= h'' + \mathrm{Drop}\big(\mathrm{FF}(\mathrm{LN}(h''))\big), \end{aligned}$$

gdzie TA to uwaga w czasie, PA uwaga między wysokościami, a $\mathrm{FF}(z) = W_2\,\mathrm{GELU}(W_1 z)$ z $W_1\colon \mathbb{R}^{64}\to\mathbb{R}^{256}$, $W_2\colon \mathbb{R}^{256}\to\mathbb{R}^{64}$. Sieć ma dwie takie warstwy.

Przykład 14.1. Parametry jednej warstwy: trzy LayerNorm po $2\cdot 64 = 128$ (384), TA (16 988), PA (17 060) i FF ($64\cdot 256 + 256 + 256\cdot 64 + 64 = 33\,088$), razem 67 520. Dwie warstwy mają 135 040 parametrów, czyli ponad połowę całej sieci (249 219).

14.3 Uwaga w czasie

Dla każdego półtonu s osobno bierzemy ciąg wektorów $h_{1,s},\dots,h_{T,s}$ i stosujemy uwagę z rozdziału 10 z oknem $|j-i| \le W = 43$ klatek ($43\cdot 23{,}2\,\mathrm{ms} \approx 1$ s) w obie strony i wyuczoną premią $b^{(\mathrm{czas})}_{j-i}$ (osobną dla każdej z $n_h = 4$ głowic, 87 wartości):

$$\alpha^{(\mathrm{czas})}_{ij} = \mathrm{softmax}_{j:\,|j-i|\le W}\Big(\frac{\langle \boldsymbol{q}_i, \boldsymbol{k}_j\rangle}{\sqrt{d_h}} + b^{(\mathrm{czas})}_{j-i}\Big), \qquad d_h = \frac{D}{n_h} = 16. \tag{14.1}$$

Intuicja. Sieć sprawdza, czy ten sam półton brzmiał w klatkach sprzed i po: jeśli tak, to nuta „trwa”; jeśli ślad zaczyna się nagle i wcześniej go nie było, to początek; jeśli zanika, to koniec. Okno ± 1 s wystarcza, by rozstrzygnąć powtórzenie nuty lub jej koniec. Wariant przyczynowy (tylko $j \le i$) nadaje się do pracy na żywo, ale Gen 6 w tej książce jest używany w trybie dwukierunkowym (analiza całego nagrania). ♢

Okno ma praktyczną zaletę: koszt to $O(T\cdot(2W+1))$ zamiast $O(T^2)$. Implementacja w repozytorium dzieli oś czasu na bloki długości W i pozwala blokowi patrzeć na dwa sąsiednie.

14.4 Uwaga między wysokościami

W jednej klatce t traktujemy 53 półtony jako sekwencję i stosujemy uwagę *bez okna* (53×53 wag), z premią zależną od odległości w półtonach r_{j-i}, $j-i \in \{-52,\dots,52\}$ (105 wartości na głowicę):

$$\alpha^{(\mathrm{wys})}_{ij} = \mathrm{softmax}_j\Big(\frac{\langle \boldsymbol{q}_i, \boldsymbol{k}_j\rangle}{\sqrt{d_h}} + r_{j-i}\Big). \tag{14.2}$$

Zadanie tej uwagi jest dokładnie tym, czego brakowało w rozdziale 3: pozwolić każdemu półtonowi zerknąć na pozostałe, w szczególności na te leżące o 12, 19, 24 półtonów od niego (interwały alikwotów) oraz na inne nuty akordu.

Na konkretnych liczbach. Rozmiary dla klatki: $Q,K,V \in \mathbb{R}^{53\times 16}$ dla każdej z 4 głowic, macierz wag $53\times 53 = 2809$ liczb na głowicę. Jeśli zapytanie jest podobne tylko do własnego klucza i do kluczy odległych o ± 12, a premia $r_{\pm 12}$ jest duża, to waga skupia się na tych trzech półtonach (zabawkowy przypadek w rozdziale 10, rys. 10.1a).

Twierdzenie 14.2 (Pole widzenia sieci). *Niech część konwolucyjna ma pole widzenia w czasie R_{conv} (tw. 9.5), a n_{ctx} warstw kontekstu używa uwagi z oknem $|j-i| \le W$. Wtedy wynik w klatce t zależy od wejść w klatkach t' z $|t'-t| \le R = R_{\mathrm{conv}} + n_{\mathrm{ctx}} W$ i (dla niezerowych wag) tylko od nich.*

Pomysł dowodu. Każda warstwa uwagi z oknem W miesza cechy z klatek odległych o najwyżej W; kolejne warstwy rozszerzają zasięg tak jak kolejne konwolucje: odległości się dodają.

Dowód. Indukcja po warstwach, jak w dowodzie tw. 9.5. Po części konwolucyjnej wektor $h_{t,\cdot}$ zależy od wejść $X_{t'}$ z $|t'-t| \le R_{\mathrm{conv}}$. Uwaga w czasie liczy nowy wektor w klatce t jako średnią ważoną wartości z klatek u z $|u-t| \le W$, a każda z nich zależy od wejść odległych o $\le R_{\mathrm{conv}}$ od u:

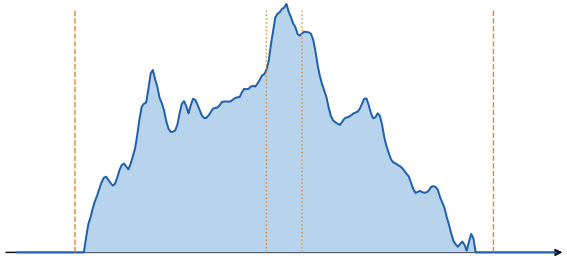
$$|t'-t| \le |t'-u| + |u-t| \le R_{\mathrm{conv}} + W \qquad \text{(nierówność trójkąta)}$$

Uwaga między wysokościami działa w jednej klatce i nie zmienia zasięgu w czasie; FF i LN są punktowe. Po n_{ctx} warstwach zasięg to $R_{\mathrm{conv}} + n_{\mathrm{ctx}} W$. To kończy dowód. ■

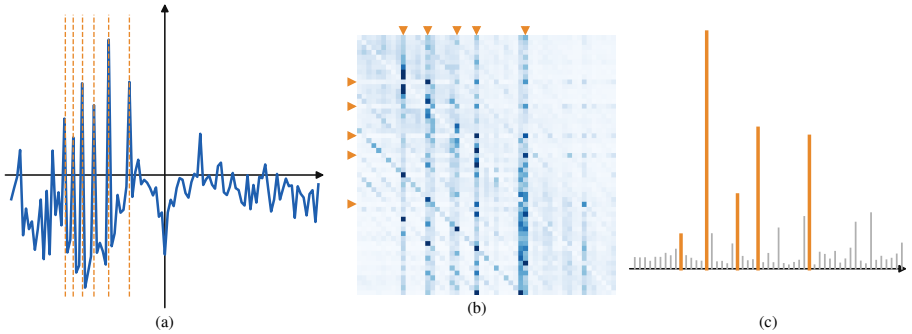
Dla Gen 6: $R_{\mathrm{conv}} = 8$ (przykład 9.3), $n_{\mathrm{ctx}} = 2$, $W = 43$, czyli $R = 8 + 2\cdot 43 = 94$ klatki, czyli $\pm 94\cdot 23{,}2\,\mathrm{ms} = \pm 2{,}18$ s. **Pomiar potwierdza**:

gradient logitu początku w jednej klatce po wejściu jest niezerowy dokładnie dla $|t'-t| \le 94$ i równy zeru od 95 (rys. 14.1). Gradient maleje szybko z odległością: 37,5 dla $t'=t$, 2,6 dla odległości 40, 0,035 dla 90. Model „słucha" więc głównie najbliższych ok. ± 1 s, a dalszy kontekst ma niewielki wpływ.

Kod repozytorium używa przy wnioskowaniu kawałkami zakładki `halo`$=1+7+n_{\text{ctx}}\cdot 2W = 180$ klatek z każdej strony; to *zapas bezpieczeństwa* prawie dwukrotnie większy niż rzeczywiste 94 (każdą warstwę policzono jak $2W$ zamiast W). Dlatego wynik nie zależy od długości kawałka; sprawdzono to numerycznie (różnica poniżej 10^{-5}).



Rysunek 14.1: Pomiar pola widzenia prawdziwego modelu Gen 6: $\log_{10}$ modułu gradientu logitu początku w klatce t (jeden półton) po cechach wejściowych w klatce $t+\Delta t$, od -125 do 125 klatek (pomarańczowe pionowe: kropkowane ± 8 — zasięg samej części konwolucyjnej, przerywane ± 94 — zasięg całej sieci). Poza ± 94 zależności nie ma (wypełnienie opada do dna skali); wewnątrz maleje o kilka rzędów wielkości.



Rysunek 14.2: Uwaga między wysokościami w prawdziwym modelu Gen 6 (warstwa kontekstu 0). (a) Wyuczona premia r_d głowicy 2: niebieska krzywa, pomarańczowe przerywane linie to odległości $-12\log_2 h$ dla $h=2,\dots,7$ ($-12,-19,-24,-28,-31,-34$). Dokładnie siedem odległości ma premię powyżej 0,6: sześć z nich to te interwały alikwotów, a siódma to $+12$. (b) Macierz wag uwagi (średnia z czterech głowic; wiersz — zapytanie, kolumna — klucz) w klatce nagrania, w której gra 5 nut (pomarańczowe znaczniki przy osiach to ich półtony). (c) Wiersz najniższej nuty ($m=45$): pomarańczowe słupki to pozostałe nuty akordu; trafia w nie 45% całej wagi, podczas gdy równomierny rozkład dałby $4/53 = 7{,}5\%$.

14.4.1 *Co się nauczyła uwaga: obserwacja, nie dowód*

Rysunek 14.2 pokazuje dwie rzeczy, które sieć odkryła sama, bez żadnej podpowiedzi poza stratą. **(1)** Jedna z czterech głowic pierwszej warstwy ma największe premie na odległościach równych interwałom szeregu alikwotów ($12, 19, 24, 28, 31, 34$ półtonów w dół): dokładnie tym, które w rozdziale 3 wyliczyliśmy jako $12\log_2 h$. Taką głowicę można czytać tak: „kandydat s patrzy na półtony, w których leżałyby jego alikwoty, i sprawdza, czy tam coś jest". **(2)** W klatce z akordem uwaga najniższej nuty koncentruje się na pozostałych nutach akordu. Inne głowice mają premie największe na małych odległościach (± 1 do ± 5): sąsiedzi półtonowi.

Uczciwie: to *korelacje w wagach*, nie dowód przyczynowy. Nie badaliśmy, co się stanie, gdy dany interwał lub głowicę usuniemy (brak badań ablacyjnych — zob. rozdział 17); premie nie mówią, czy dana głowica jest *potrzebna*, tylko czego sieć użyła.

Pułapka. Zwykła pokusa: zobaczyć na mapie uwagi „ładny wzór" i uznać, że sieć działa zgodnie z naszą teorią. Wagi w jednym nagraniu i jednej klatce to jeden punkt; warto sprawdzić, czy wzór utrzymuje się na wielu nagraniach (tu: premie są własnością wag, więc nie zależą od nagrania, a mapa (b) tak). ♢

14.5 Głowice

Po dwóch warstwach kontekstu i LayerNorm mamy $h_{t,s} \in \mathbb{R}^{64}$. Każda głowica to małe MLP, $\text{MLP}(z) = W_2\,\text{GELU}(W_1 z)$:

$$p_{\text{on}} = \sigma\big(\text{MLP}_{\text{on}}(h)\big), \qquad p_{\text{fr}} = \sigma\big(\text{MLP}_{\text{fr}}([h;\ \text{sg}(p_{\text{on}})])\big),$$
$$p_{\text{off}} = \sigma\big(\text{MLP}_{\text{off}}(h)\big), \qquad \hat{v} = \sigma\big(\text{MLP}_{\text{vel}}(h)\big),$$

gdzie $[\cdot;\cdot]$ to sklejenie (65 wejść do głowicy „brzmi"), a $\text{sg}(\cdot)$ to *stop-gradient*: głowica „brzmi" dostaje p_{on} jako cechę, ale jej strata nie zmienia głowicy początku (pomysł z *Onsets and Frames*). Obciążenia ostatnich warstw ustawiono na -3 (początek, koniec) i -2 (brzmi), by zacząć od „nut jest mało" (rozdział 8).

Na konkretnych liczbach. Głowica początku: $64\cdot 64+64+64+1 = 4225$. Głowica „brzmi" z 65 wejściami: $65\cdot 64+64+65 = 4289$. Głowice końca i głośności po 4225. Razem z tabulaturą (4735) i końcowym LayerNorm (128): $4225+4289+4225+4225+4735+128 = 21\,827$. Pełna suma: 92 352 (pierwsza połowa) + 135 040 (kontekst) + 21 827 = 249 219 — dokładnie tyle, ile liczy sieć w repozytorium (sprawdzone programem).

głowica tabulatury

Definicja 14.3 (Głowica tabulatury). Dla struny $i \in \{1,\dots,6\}$ z wysokością struny pustej o_i i progu $f \in \{0,\dots,19\}$ półton $s_{i,f} = o_i + f - 36$ (jeśli leży w $[0,52]$; inaczej logit jest $-\infty$). Logit

$$g_{i,f}(t) = \mathbf{w}_i^{\top} h_{t,s_{i,f}} + c_i + \beta_{i,f}, \tag{14.3}$$

gdzie $\mathbf{w}_i \in \mathbb{R}^{64}$, c_i — wagi i obciążenie *osobne dla każdej struny*, a $\beta_{i,f}$ — wyuczona premia za próg (wysokie progi są rzadsze). Klasa „struna i milczy": $g_{i,\varnothing}(t) = \text{MLP}_{\text{sil}}\big(\max_f h_{t,s_{i,f}}\big)$ (maksimum po f dla każdego kanału osobno). Wynik: $p_i = \text{softmax}(g_{i,\varnothing}, g_{i,0},\dots,g_{i,19})$, czyli 21 klas na strunę.

Przykład 14.2. Struna 2 (B3, $o_2 = 59$): progi $f = 0,\dots,19$ odpowiadają półtonom $s = 23,\dots,42$ (nuty MIDI 59–78). Logit „struna 2 gra próg 5” to $\boldsymbol{w}_2^\top h_{t,28} + c_2 + \beta_{2,5}$, czyli liczy się z cech półtonu 28 (E4), a nie z cech dla progu. Parametry głowicy: $\boldsymbol{w}_i, c_i$ razem $6 \cdot 65 = 390$, premie β $6 \cdot 20 = 120$, MLP ciszy $64 \cdot 64 + 64 + 64 + 1 = 4225$; razem 4735.

Intuicja. Logit „struna i gra próg f” liczymy z cech tego półtonu, który ten próg produkuje. Dzięki temu tabulatura jest *powiązana* z detekcją wysokości: gdy sieć wie, że gra E4, pozostaje jej rozstrzygnąć, na której z pięciu strun (rozdział 12). Osobne $\boldsymbol{w}_i$ pozwalają każdej strunie mieć własną „barwę” (rozkład alikwotów zależy od grubości struny). ♢

Podsumowanie

- Warstwa kontekstu: uwaga w czasie (okno ± 43 klatki), uwaga między wysokościami (53×53) i FF, każda z LN i połączeniem resztkowym; dwie warstwy $= 135\,040$ parametrów.
- Pole widzenia sieci $R = R_{\text{conv}} + n_{\text{ctx}} W = 8 + 86 = 94$ klatki ($\pm 2{,}18$ s) — potwierdzone pomiarem gradientu; kod używa zapasu 180.
- Jedna z głowic uwagi między wysokościami ma największe premie na interwałach alikwotów; uwaga najniższej nuty akordu trafia w pozostałe nuty (obserwacja z wag, bez ablacji).
- Pięć głowic: początek, brzmi (z $\operatorname{sg}(p_{\text{on}})$), koniec, głośność (nieuczona), tabulatura (softmax po 21 klasach na strunę).
- Parametry: $92\,352 + 135\,040 + 21\,827 = 249\,219$.

Ćwiczenia

1. Policz pole widzenia R, gdyby $n_{\text{ctx}} = 3$, $W = 30$ i $R_{\text{conv}} = 8$. Ile to sekund przy kroku 23,2 ms?
2. Ile parametrów miałaby warstwa kontekstu bez uwagi między wysokościami (zostają LN dla TA i FF: dwa LayerNorm)?
3. Wyznacz półtony $s_{i,f}$ dla struny 6 ($o_6 = 40$) i progów $f = 0, 12, 19$. Ile klas ma głowica tabulatury łącznie dla wszystkich strun?
4. Dla jakich $s_{1,f}$ (struna 1, $o_1 = 64$) logit jest $-\infty$ w modelu z $S = 53$ półtonami i progami 0–19?

Rozwiązania

1. $R = 8 + 3 \cdot 30 = 98$ klatek; $98 \cdot 23{,}2\,\text{ms} = 2{,}27$ s.
2. $2 \cdot 128 + 16\,988 + 33\,088 = 50\,332$ (zamiast 67 520; różnica $17\,188 = 17\,060 + 128$).
3. $s_{6,f} = 40 + f - 36$: 4, 16, 23. Klas: $6 \cdot 21 = 126$ (liczba wyjść głowicy tabulatury w jednej klatce).
4. $s_{1,f} = 64 + f - 36 = 28 + f$; dla $f = 0,\dots,19$ to $28,\dots,47 \le 52$, więc żaden logit nie jest $-\infty$ dla struny 1 (wszystkie pozycje mieszczą się w zakresie 0–52).

15 Strata całkowita i uczenie

15.1 Jak z pięciu głowic zrobić jedną liczbę?

Sieć ma pięć głowic, każda ze swoją stratą (rozdział 8). Uczyć możemy tylko jedną liczbą, więc je sumujemy z wagami; po drodze musimy zadbać o dwie rzeczy: o rzadkie etykiety (waga klasy dodatniej) i o *brakujące* etykiety (maski dostępności, rozdział 12). Potem opisujemy, jak wyglądało uczenie: skąd brano dane, jak je zniekształcano (augmentacje), jakim harmonogramem i jak wybrano model końcowy.

Po tym rozdziale umiesz: (i) zapisać pełną funkcję straty Gen 6, (ii) uzasadnić, że etykieta niedostępna nie daje gradientu, (iii) policzyć całkowitą stratę z zapisanych składowych, (iv) odczytać z dziennika uczenia przebieg trzech sesji.

15.2 Strata całkowita

Niech $\text{valid}_t \in \{0,1\}$ oznacza, że klatka t nie jest dopełnieniem krótkiego wycinka, a $a_g \in \{0,1\}$ — czy dla danego przykładu dostępna jest etykieta głowicy g. Maska głowicy to $m_g(t,s) = \text{valid}_t\, a_g$. Dla głowic z mapami (początek, brzmi, koniec):

$$\mathcal{L}_g = \frac{\sum_{t,s} m_g(t,s)\, \ell_{\alpha_g}\big(p_g(t,s), y_g(t,s)\big)}{\sum_{t,s} m_g(t,s)}, \qquad g \in \{\text{on}, \text{fr}, \text{off}\}, \tag{15.1}$$

z wagami klasy dodatniej $\alpha_{\text{on}} = 4$, $\alpha_{\text{fr}} = 1$, $\alpha_{\text{off}} = 2$ (def. 8.4). Strata głośności to błąd kwadratowy $\mathcal{L}_{\text{vel}} = \sum \mu (\hat{v} - y_{\text{vel}})^2 \big/ \max(1, \sum \mu)$ z maską μ równą 1 tylko tam, gdzie znana jest głośność. Strata tabulatury to średnia $-\ln p_i(t)[c_i(t)]$ po parach (klatka, struna) z etykietą znaną ($c_i(t) \ge 0$) i $a_{\text{tab}} = 1$. Całość:

$$\boxed{\mathcal{L} = 1{,}0\,\mathcal{L}_{\text{on}} + 1{,}0\,\mathcal{L}_{\text{fr}} + 0{,}5\,\mathcal{L}_{\text{off}} + 0{,}5\,\mathcal{L}_{\text{vel}} + 0{,}5\,\mathcal{L}_{\text{tab}}} \tag{15.2}$$

Twierdzenie 15.1 (Niedostępna etykieta nie daje gradientu). *Jeśli $a_g = 0$ dla wszystkich przykładów w paczce, to $\mathcal{L}_g$ nie zależy od parametrów sieci, a jej gradient wynosi* 0.

Pomysł dowodu. Licznik jest sumą wyrazów pomnożonych przez maskę równą zero; mianownik też, więc trzeba ustalić konwencję dzielenia przez zero — w kodzie mianownik jest zastąpiony przez $\max(1, \cdot)$.

Dowód. Przy $a_g = 0$ mamy $m_g \equiv 0$, więc

$$\mathcal{L}_g = \frac{\sum m_g \ell}{\max\big(1, \sum m_g\big)} = \frac{0}{\max(1,0)} = 0 \quad \text{(maska zerowa)}$$

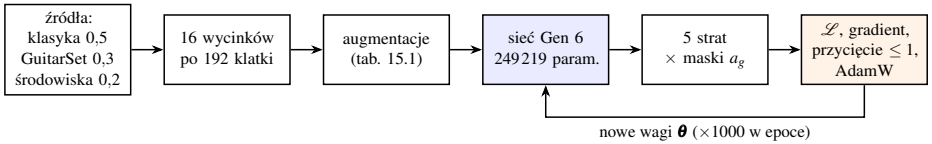
$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_g = \frac{\sum_{t,s} m_g \nabla_{\boldsymbol{\theta}} \ell}{\max(1, \cdot)} = \mathbf{0}. \quad \text{(każdy składnik ma czynnik } m_g = 0\text{)}$$

Strata jest więc stałym zerem i nie wpływa na $\nabla\mathscr{L}$. Stąd w Gen 6, w którym żadne źródło nie ma etykiet głośności, głowica głośności pozostała w stanie początkowym i nie jest używana. To kończy dowód. ■

Na konkretnych liczbach. Składowe zapisane w dzienniku uczenia dla epoki 5 (wartości na zbiorze uczącym): $\mathscr{L}_{\text{on}} = 0{,}0239$, $\mathscr{L}_{\text{fr}} = 0{,}0336$, $\mathscr{L}_{\text{off}} = 0{,}0227$, $\mathscr{L}_{\text{vel}} = 0$, $\mathscr{L}_{\text{tab}} = 0{,}123$. Ze wzoru (15.2): $\mathscr{L} = 0{,}0239 + 0{,}0336 + 0{,}5\cdot 0{,}0227 + 0{,}5\cdot 0 + 0{,}5\cdot 0{,}123 = 0{,}1304$. Największy wkład ma tabulatura (0,0615, czyli 47%) mimo wagi 0,5, bo jej strata jest najwyższa: wybór struny to trudne zadanie.

15.3 Jak dobierano dane i zniekształcano

Paczka. W każdym kroku losuje się 16 wycinków po 192 klatki (4,46 s, razem 71 s dźwięku). Źródło losuje się z prawdopodobieństwami 0,5 (klasyka), 0,3 (GuitarSet), 0,2 (środowiska gitarowe), a nagranie w obrębie źródła proporcjonalnie do długości. Epoka to 1000 kroków.



Rysunek 15.1: Jeden krok uczenia Gen 6. Z trzech źródeł (wagi losowania w ramce) losuje się 16 wycinków po 4,46 s, zniekształca je augmentacjami, przepuszcza przez sieć, liczy pięć strat z maskami dostępności etykiet, sumuje je do $\mathscr{L}$, przycina gradient do normy 1 i aktualizuje wagi optymalizatorem AdamW; po 1000 takich krokach kończy się epoka.

Augmentacje (każda losowana niezależnie) zmieniają cechy i etykiety w kontrolowany sposób, żeby sieć nie nauczyła się zapamiętywać:

augmentacja	parametry	co symuluje
poziom	± 6 dB ($+g/60$ do cech)	lokalnie cichszy/głośniejszy fragment
szum	$\sigma = 0{,}02$	szum cech
maska pasm i chwil	15%	utracone pasma i krótkie ubytki
tempo	$\times e^{u}$, $u \sim U(-\ln 1{,}12, \ln 1{,}12)$, $p = 0{,}5$	grę szybszą/wolniejszą
rozstrojenie	± 1 bin (± 33 centy), $p = 0{,}3$	gitarę rozstrojoną
niedokładne etykiety	początki/końce ± 1 klatka, $p = 0{,}3$	błędy adnotacji
transpozycja	± 2 półtony, $p = 0{,}3$	inną tonację (tabulatura wtedy nieznana)

Tabela 15.1: Augmentacje użyte w uczeniu Gen 6 (konfiguracja `gen6_kaggle.json`).

Intuicja. Augmentacja to „kłamstwo z kontrolowanym skutkiem”: wiemy, jak zmiana cech zmienia etykiety (albo że ich nie zmienia), więc możemy sztucznie mnożyć dane. Rozstrojenie przesuwa cechy o 1 bin (33 centy), a etykiety zostają: sieć uczy się, że nuta rozstrojona o ćwierć półtonu to wciąż ta sama nuta. ♢

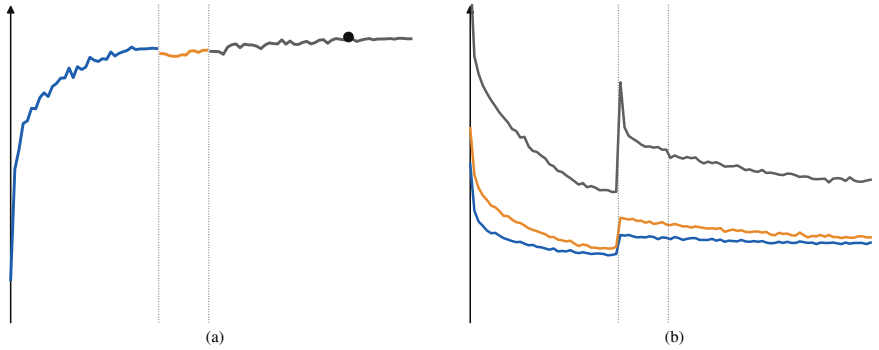
Pułapka. Augmentacja poziomu bywa mylona z niezależnością od głośności (tw. 7.4). Stałe przeskalowanie *całego* nagrania jest już zneutralizowane przez normalizację. Augmentacja ± 6 dB zmienia głośność *wycinka względem referencji całego nagrania*, czyli symuluje, że ten fragment jest cichszy niż reszta utworu (dynamika), a nie że cały utwór jest cichszy. ♢

15.4 Przebieg uczenia

Uczenie przebiegło w trzech sesjach (pomijając przerwaną sesję 2), razem 97 epok po 1000 kroków (czasy z dziennika epok: $7{,}3 + 2{,}4 + 9{,}5 \approx 19$ godzin na GPU Tesla T4, mieszana precyzja fp16; dokumentacja projektu podaje $7{,}3 + 2{,}9 + 11 \approx 21$ godzin łącznie z uruchamianiem sesji).

- Sesja 1: epoki 0–35 (36 epok), $\eta_0 = 10^{-3} \to 0$ (kosinus, rozdział 11); dane: zestaw 1 klasyki, środowiska, GuitarSet.
- Sesja 3: epoki 36–47 (12 epok), restart $\eta = 4 \cdot 10^{-4}$, dodano drugi zestaw klasyki i augmentacje tempa, rozstrojenia i jittera etykiet; zatrzymana przez mechanizm wczesnego zatrzymania po 12 epokach bez poprawy rekordu (to było niezamierzone: plan zakładał dłuższe uczenie).
- Sesja 4: epoki 48–96 (49 epok), $\eta = 3 \cdot 10^{-4} \to 0$ z harmonogramem liczonym od czasu.

Dobrym wynikiem uczenia jest to, co widać na rys. 15.2: F1 nut na walidacji rośnie z 69,7% (epoka 0) do 84,2% (epoka 5), 88,3% (epoka 20), 89,4% (epoka 29, najlepsza w sesji 1); po restarcie w sesji 3 spada (dane trudniejsze, η wyższy), a w sesji 4 znów rośnie do rekordu 90,27% w epoce 81. Straty uczące maleją jak $\log_{10}$: tabulatura z 0,61 do 0,046, początki z 0,056 do 0,021.



Rysunek 15.2: Prawdziwy przebieg uczenia Gen 6 (dziennik `docs/wyniki/epoki.csv`, 97 epok). (a) F1 nut na stałej próbie walidacyjnej 180 nagrań (skala od 66 do 93%): sesja 1 niebieska, sesja 3 pomarańczowa, sesja 4 ciemnoszara; czarna kropka to wybrana epoka 81 (90,27%). Pionowe linie rozdzielają sesje. (b) $\log_{10}$ strat uczących: początki (niebieska), brzmi (pomarańczowa), tabulatura (ciemnoszara). Skok strat na początku sesji 3 i 4 to efekt restartu kroku i nowych, trudniejszych danych.

Wybór modelu. Po każdej epoce liczono F1 nut na stałej próbie walidacyjnej (180 nagrań ze wszystkich źródeł) i zapamiętywano najlepszą epokę: 81 (90,27%). To jest model końcowy (plik `best.pt`, 249 219 parametrów). Uczciwie: próba walidacyjna zawiera tylko 12 nagrań prawdziwej gitary,

więc istnieje niewielkie ryzyko dopasowania wyboru epoki do walidacji; wyniki końcowe liczymy osobno na zbiorze testowym (rozdział 17).

Podsumowanie

- $\mathscr{L} = 1{,}0\mathscr{L}_{\text{on}} + 1{,}0\mathscr{L}_{\text{fr}} + 0{,}5\mathscr{L}_{\text{off}} + 0{,}5\mathscr{L}_{\text{vel}} + 0{,}5\mathscr{L}_{\text{tab}}$, z maskami dostępności i ważoną BCE.
- Niedostępna etykieta daje zerowy gradient (tw. 15.1); głowica głośności pozostała nieuczona.
- Paczka: 16×192 klatki, źródła $0{,}5/0{,}3/0{,}2$; augmentacje: poziom, szum, maski, tempo, rozstrojenie, jitter, transpozycja.
- 97 epok w trzech sesjach; najlepsza epoka 81 ma F1 nut 90,27% na walidacji.

Ćwiczenia

1. Dla epoki 20: $\mathscr{L}_{\text{on}} = 0{,}0198$, $\mathscr{L}_{\text{fr}} = 0{,}0228$, $\mathscr{L}_{\text{off}} = 0{,}0193$, $\mathscr{L}_{\text{tab}} = 0{,}0545$, $\mathscr{L}_{\text{vel}} = 0$. Policz $\mathscr{L}$ i udział tabulatury.
2. Wycinek ma 192 klatki, krok 256 próbek przy 11 025 Hz. Ile sekund trwa? Ile sekund dźwięku jest w jednej paczce 16 wycinków?
3. W paczce są 3 nagrania z etykietami tabulatury i 13 bez (maska $a_{\text{tab}} = 0$). Czy $\mathscr{L}_{\text{tab}}$ uśrednia po wszystkich 16 nagraniach? Uzasadnij.
4. Krok uczenia w sesji 4 wynosi $3 \cdot 10^{-4} \to 0$ kosinusem od czasu. Ile wynosi w połowie czasu sesji?

Rozwiązania

1. $\mathscr{L} = 0{,}0198 + 0{,}0228 + 0{,}0097 + 0 + 0{,}0273 = 0{,}0795$ (dokładnie 0,07950); udział tabulatury $0{,}0273/0{,}0795 = 34\%$.
2. $192 \cdot 256/11\,025 = 4{,}46$ s; paczka: $16 \cdot 4{,}46 = 71{,}3$ s.
3. Nie: licznik i mianownik zawierają maskę, więc uśrednianie odbywa się tylko po parach (klatka, struna) z $a_{\text{tab}} = 1$, czyli po 3 nagraniach; pozostałe 13 nie wnoszą ani składnika, ani wagi (tw. 15.1).
4. Połowa czasu: $q = 0{,}5$, więc $\eta = 3 \cdot 10^{-4} \cdot \frac{1}{2}(1 + \cos\frac{\pi}{2}) = 1{,}5 \cdot 10^{-4}$.

16 Dekoder: od map prawdopodobieństw do listy nut

16.1 Sieć nie zwraca nut

Sieć zwraca *mapy*: dla każdej klatki i półtonu liczby $p_{\text{on}}, p_{\text{fr}}, p_{\text{off}} \in (0,1)$. My chcemy listę nut (wysokość, początek, koniec, struna). Przejście od map do listy robi *dekoder* — zwykły algorytm, bez parametrów uczonych gradientem (jest nieróżniczkowalny: zawiera progi i wybór maksimów, zob. rys. 1.4c). Jego progi to *hiperparametry* i trzeba je dobrać osobno (na walidacji).

Po tym rozdziale umiesz: (i) przeprowadzić dekoder ręcznie dla jednego półtonu, (ii) wybrać strunę nuty z mapy tabulatury, (iii) uzasadnić, że przeszukiwanie progów po współrzędnych nie pogarsza celu, (iv) odczytać, co zmienia dostrojenie progów.

16.2 Algorytm dla jednego półtonu

Dekoder działa na każdy półton s osobno, przeglądając klatki $t = 0, 1, \ldots, T-1$ i pamiętając stan: klatkę początku `start`, ostatnią klatkę brzmienia `last` i licznik przerwy `gap`.

pik

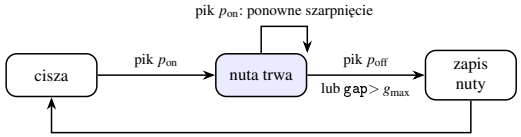
Definicja 16.1 (Pik początku). Klatka t jest *pikiem początku* w półtonie s, gdy $p_{\text{on}}(t,s) \geq \theta_{\text{on}}$ jest lokalnym maksimum ($p_{\text{on}}(t,s) \geq p_{\text{on}}(t-1,s)$ i $> p_{\text{on}}(t+1,s)$) oraz $p_{\text{fr}}(t,s) \geq \theta_{\text{on,fr}}$. Analogicznie *pik końca*: lokalne maksimum $p_{\text{off}} \geq \theta_{\text{off}}$.

Reguły (dla klatki t po kolei):

1. *Początek.* Na piku początku zaczynamy nową nutę ze `start`$= t$ (jeśli trwała poprzednia, najpierw ją kończymy: to ponowne szarpnięcie). Gdy nie ma piku, a nie ma trwającej nuty, nuta może wystartować, jeśli $p_{\text{fr}} \geq \theta_{\text{start}}$ przez $n_{\min}$ klatek (w modelu końcowym wyłączone: $\theta_{\text{start}} = 1{,}01 > 1$).
2. *Trwanie.* Dopóki $p_{\text{fr}}(t,s) \geq \theta_{\text{fr}}$, nuta trwa (`last`$= t$, `gap`$= 0$); w przeciwnym razie `gap`$+= 1$, a gdy `gap`$> g_{\max}$, nuta się kończy.
3. *Koniec z głowicy.* Jeśli $t >$`start` jest pikiem końca, nuta kończy się w t.

Wynik nuty: wysokość $36 + s$, początek $t_0 = \max(0, \tau_{\text{start}})$, koniec $t_1 = \max\left(t_0 + d_{\min},\ \tau_{\text{last}} + \frac{1}{2}\Delta\right)$ (gdzie τ to środek klatki, $\Delta = 23{,}2$ ms), pewność = średnie p_{fr} w klatkach nuty. Nuty krótsze niż $n_{\min} = 2$ klatki odrzucamy; dwie nuty tej samej wysokości o początkach bliższych niż θ_{merge} scalamy w jedną.

Przykład 16.1 (Jedna nuta ręcznie). Półton E4 ($s = 28$), progi dostrojone ($\theta_{\text{on}} = 0{,}6$, $\theta_{\text{on,fr}} = 0{,}1$, $\theta_{\text{fr}} = 0{,}6$, $\theta_{\text{off}} = 0{,}8$). W klatkach 33–37: $p_{\text{on}} = (0{,}05; 0{,}30; 0{,}85; 0{,}40; 0{,}05)$, a $p_{\text{fr}} = (0{,}2; 0{,}7; 0{,}9; 0{,}9; 0{,}9)$ i dalej 0,9 do klatki 53. W klatce 35: $p_{\text{on}} = 0{,}85 \geq 0{,}6$, większe od sąsiadów (0,30 i 0,40), a $p_{\text{fr}} = 0{,}9 \geq 0{,}1$ — to pik: początek nuty. Czas: $t_0 = \tau_{35} = (35 \cdot 256 + 2048)/11\,025 = 0{,}998$ s. Dalej $p_{\text{fr}} \geq 0{,}6$, więc nuta trwa. W klatce 53 niech $p_{\text{off}} = 0{,}9 \geq 0{,}8$ (lokalne maksimum): koniec, $t_1 = \tau_{53} + \frac{1}{2}\Delta = 1{,}4164 + 0{,}0116 = 1{,}428$ s. Wynik: nuta (E4; 0,998 s; 1,428 s). Ten sam wynik daje kod repozytorium.



Rysunek 16.1: Maszyna stanów dekodera dla jednego półtonu. Z ciszy wychodzi się na piku początku; nuta trwa, dopóki $p_{\text{fr}} \geq \theta_{\text{fr}}$; kończy ją pik końca albo przerwa dłuższa niż $g_{\max}$ klatek; nowy pik początku w trakcie nuty kończy ją i zaczyna następną.

Intuicja. Początek bierzemy z *pików* głowicy początku, bo ona jest ostra (rzadkie etykiety, miękkie 0,4 obok); trwanie z głowicy „brzmi”, bo ona jest szeroka; koniec z piku końca, a gdy go nie ma — z tego, że „brzmi” opadło. Trzy głowice dają trzy niezależne wskazówki, dekoder je łączy. ♢

Na konkretnych liczbach. Przypadek bez piku końca: jeśli w klatce 53 jest $p_{\text{off}} = 0{,}3 < 0{,}8$, a po klatce 53 $p_{\text{fr}} = 0{,}1 < 0{,}6$, to w klatkach $54, 55, 56$ licznik gap rośnie do $3 > g_{\max} = 2$ i nuta się kończy z $\texttt{last} = 53$: koniec jest ten sam, 1,428 s. Przypadek za niskiego piku: gdyby p_{on} w klatce 35 wynosiło $0{,}55 < 0{,}6$, dostrojony dekoder *zgubi nutę* (bo θ_{start} jest wyłączony), a dekoder domyślny ($\theta_{\text{on}} = 0{,}5$, $\theta_{\text{on,fr}} = 0{,}3$) znajdzie ją.

16.3 Wybór struny

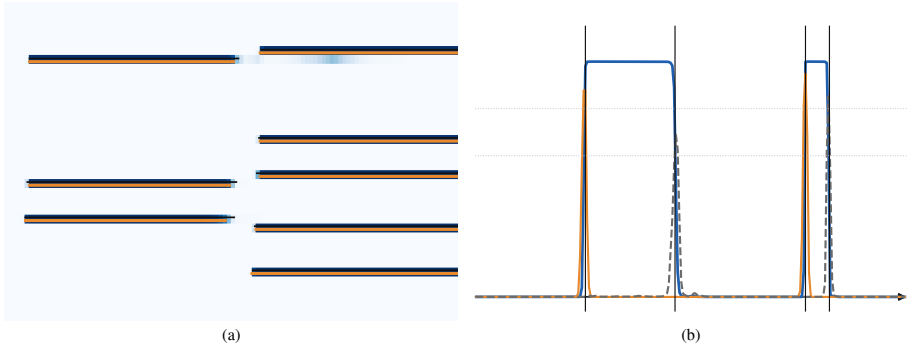
Dla nuty o wysokości m i klatkach $\mathcal{N} = \{\text{start}, \ldots, \text{last}\}$ strunę wybiera się jako tę o największym *średnim* prawdopodobieństwie właściwej klasy:

$$i^* = \operatorname*{arg\,max}_{i:\ 0 \leq m - o_i < 20} \frac{1}{|\mathcal{N}|} \sum_{t \in \mathcal{N}} p_i(t) \big[1 + (m - o_i)\big]. \tag{16.1}$$

Przykład 16.2. Nuta $m = 52$ (E3) ma trzy pozycje: struna 6 próg 12, struna 5 próg 7, struna 4 próg 2 (struny 3, 2, 1 odpadają, bo $52-55, 52-59, 52-64 < 0$). Jeśli średnie prawdopodobieństwa tych klas w klatkach nuty to 0,10 (struna 6), 0,20 (struna 5), 0,70 (struna 4), dekoder wybiera strunę 4 (D3), próg 2. Sprawdzone kodem repozytorium.

16.4 Strojenie progów

Progów nie da się wyznaczyć gradientem, więc dobieramy je na *walidacji* (222 nagrania: 12 GuitarSet, 150 klasyki, 60 środowisk) *przeszukiwaniem po*



(a) (b)

Rysunek 16.2: Dekoder na wyjściach prawdziwego modelu Gen 6 (syntetyczne nagranie z 15 nutami). (a) Mapa p_{fr} (jasność), fragment 110 klatek i półtony 4–39; czarne kreski — prawdziwe nuty, pomarańczowe — nuty z dekodera (każda para blisko siebie; największy błąd początku 18,7 ms). (b) Trzy głowice dla jednego półtonu z dwiema nutami: p_{fr} (niebieska), p_{on} (pomarańczowa), p_{off} (szara przerywana) i progi $\theta_{\text{on}} = 0{,}6$, $\theta_{\text{off}} = 0{,}8$ (kropkowane poziome); czarne pionowe kreski to początki i końce nut z dekodera.

współrzędnych: dla każdego progu po kolei próbujemy siatkę wartości przy pozostałych ustalonych, zostawiamy najlepszą, i tak dwa przebiegi. Cel:

$$J = 100 \cdot \frac{\sum_z w_z \overline{\frac{1}{2}\left(F_{\text{on}} + F_{\text{on+off}}\right)}_z}{\sum_z w_z}, \tag{16.2}$$

z wagami grup $w_{\text{GuitarSet}} = 0{,}4$, $w_{\text{klasyka}} = 0{,}4$, $w_{\text{rodowiska}} = 0{,}2$, gdzie F_{on} to F1 nut, a $F_{\text{on+off}}$ F1 nut z końcem (rozdział 17), uśrednione po nagraniach każdej grupy z.

Twierdzenie 16.2 (Przeszukiwanie po współrzędnych jest monotoniczne). *Niech siatka wartości dla każdego progu jest skończona i zawiera aktualną wartość. Jeśli w każdym kroku wybieramy wartość maksymalizującą J (przy remisie — dotychczasową), to J nigdy nie maleje, a procedura kończy się po skończonej liczbie kroków.*

Pomysł dowodu. Aktualna wartość jest jednym z kandydatów, więc maksimum po siatce jest nie mniejsze niż dotychczasowa wartość celu.

Dowód. Niech $\boldsymbol{\theta}$ będzie bieżącym wektorem progów, a G_k siatką dla progu k z $\theta_k \in G_k$. Po kroku dla progu k nowa wartość θ_k' spełnia

$$\begin{aligned} J(\theta_k', \boldsymbol{\theta}_{-k}) &= \max_{g \in G_k} J(g, \boldsymbol{\theta}_{-k}) && \text{(wybór najlepszego kandydata)} \\ &\geq J(\theta_k, \boldsymbol{\theta}_{-k}) && (\theta_k \in G_k) \end{aligned}$$

więc J nie maleje. Liczba przebiegów jest ustalona (dwa), a każdy przebieg ma skończoną liczbę progów i skończone siatki, więc procedura się kończy. To kończy dowód. ■

Warto pamiętać, czego twierdzenie *nie* mówi: nie gwarantuje globalnego maksimum (tylko lokalne w kierunku osi) ani, że poprawa na walidacji przeniesie się na dane nowe.

próg	znaczenie	domyślny	dostrojony
θ_{on}	próg piku początku	0,5	**0,6**
$\theta_{\text{on,fr}}$	wymagane p_{fr} przy początku	0,3	**0,1**
θ_{fr}	próg trwania nuty	0,5	**0,6**
θ_{off}	próg piku końca	0,5	**0,8**
θ_{start}	nuta bez piku początku	0,7	**1,01** (wyłączone)
$g_{\max}$	przerwa kończąca nutę [klatki]	1	**2**
θ_{merge}	scalanie duplikatów [s]	0,03	**0,08**

Tabela 16.1: Progi dekodera Gen 6: domyślne i dostrojone na walidacji (plik `decode.json`). Pozostałe: $n_{\min} = 2$ klatki, $d_{\min} = 0{,}06$ s bez zmian.

Efekt. Cel na walidacji wzrósł z 79,57 do 80,87. Największy wkład (+0,75) dało *wyłączenie nut bez wykrytego początku*; pozostałe zmiany to 0,02–0,12 punktu, na granicy szumu. Na teście (700 nagrań, makro; progi tam nie były dobierane): F1 nut 85,9 → 86,6 (+0,64, 95% przedział [0,46; 0,83]), precyzja 88,8 → 93,5, czułość 84,2 → 82,1, F1 klatkowe 88,5 → 87,3 (−1,29). Dostrojony dekoder jest więc *ostrożniejszy*: tworzy mniej fałszywych nut kosztem pominięcia kilku prawdziwych — dla listy nut (MIDI, tabulatura) to korzystny kompromis, a miara klatkowa na tym traci, bo nuty są nieco krótsze.

Pułapka. Zysk na teście (+0,64) jest o połowę mniejszy niż na walidacji (+1,30): typowa sytuacja przy strojeniu na niewielkim zbiorze (tylko 12 nagrań prawdziwej gitary). Nie należy oczekiwać, że każda poprawka wartości celu na walidacji przeniesie się na nowe dane w całości. Gdy ważniejsza jest czułość niż precyzja, wystarczy użyć progów domyślnych (usunąć `decode.json`). ♢

Podsumowanie

- Dekoder zamienia mapy $p_{\text{on}}, p_{\text{fr}}, p_{\text{off}}$ na nuty: początek z piku, trwanie z progu p_{fr}, koniec z piku końca lub z opadnięcia; nie jest różniczkowalny.
- Struna to $\arg\max$ średniego prawdopodobieństwa właściwej klasy w klatkach nuty.
- Progi strojone po współrzędnych na walidacji; procedura nie pogarsza celu (tw. 16.2), ale nie gwarantuje przeniesienia na nowe dane.
- Dostrojenie progów: precyzja 88,8 → 93,5%, czułość 84,2 → 82,1%, F1 nut +0,64.

Ćwiczenia

1. Dla danych z przykładu 16.1 podaj czas końca nuty, gdyby pik końca (0,9) wypadł w klatce 50 zamiast 53.
2. Nuta $m = 55$ (G3) ma średnie prawdopodobieństwa pozycji: struna 3 próg 0: 0,15; struna 4 próg 5: 0,55; struna 5 próg 10: 0,20; struna 6 próg 15: 0,10. Którą strunę wybierze dekoder?
3. Z jakiego powodu pik początku wymaga dodatkowo $p_{\text{fr}} \geq \theta_{\text{on,fr}}$? (Wskazówka: rozdział 12, tw. 12.3.)

4. Przeszukiwanie po współrzędnych dla dwóch progów z siatką $\{0{,}5; 0{,}6\}$ i $J(0{,}5;0{,}5) = 1$, $J(0{,}6;0{,}5) = 2$, $J(0{,}5;0{,}6) = 3$, $J(0{,}6;0{,}6) = 2{,}5$ startuje z $(0{,}5;0{,}5)$. Jaki jest wynik jednego przebiegu? Czy to globalne maksimum?

Rozwiązania

1. $\tau_{50} = (50 \cdot 256 + 2048)/11\,025 = 14\,848/11\,025 = 1{,}3468$ s, więc $t_1 = \tau_{50} + \frac{1}{2}\Delta = 1{,}3468 + 0{,}0116 = 1{,}358$ s (nuta kończy się wcześniej, na piku końca w klatce 50; dalsze wysokie p_{fr} nie zaczyna nowej nuty, bo θ_{start} jest wyłączony).
2. Wybierze strunę 4 (próg 5), bo 0,55 jest największe.
3. Bo etykieta „brzmi” w klatce początku jest zawsze 1 (tw. 12.3); jeśli sieć mówi tam wysokie p_{on}, ale niskie p_{fr}, to sygnały są sprzeczne i pik jest podejrzany.
4. Przebieg: zmieniamy pierwszy próg: $J(0{,}6;0{,}5) = 2 > 1$, więc $\theta_1 = 0{,}6$; drugi próg: $J(0{,}6;0{,}6) = 2{,}5 > 2$, więc $\theta_2 = 0{,}6$; wynik $(0{,}6;0{,}6)$ z $J = 2{,}5$. Nie jest to maksimum globalne: $J(0{,}5;0{,}6) = 3$ jest większe, ale wybór $\theta_1 = 0{,}6$ (który w pierwszym kroku wyglądał dobrze) zamknął drogę do niego; to ilustracja, że wynik zależy od kolejności współrzędnych.

17 Ewaluacja, wyniki i ograniczenia

17.1 Jak uczciwie zmierzyć, czy model działa?

Model zwrócił listę nut. Skąd wiemy, że jest dobra? Potrzebujemy trzech rzeczy: (i) *definicji poprawnej nuty* i miary, która łączy trafność z kompletnością (F1), (ii) *zbioru testowego*, którego model nigdy nie widział, ani w uczeniu, ani przy wyborze epoki, ani przy strojeniu progów, (iii) *niepewności* wyniku (przedział ufności). Ten rozdział wyjaśnia wszystkie trzy, a potem podaje wyniki i — równie ważne — to, czego pomiar nie pokazuje.

Po tym rozdziale umiesz: (i) policzyć precyzję, czułość i F1 z liczby trafień, (ii) wyjaśnić, czemu średnia z F1 po nagraniach różni się od F1 policzonego razem, (iii) policzyć błąd standardowy metodą bootstrap, (iv) odczytać wyniki Gen 6 i wskazać ich ograniczenia.

17.2 Poprawna nuta, precyzja, czułość, F1

dopasowanie nut

Definicja 17.1 (Trafienie). Nuta przewidziana (m, t_{on}) *trafia* nutę wzorca (m^*, t^*_{on}), gdy wysokości różnią się o mniej niż 50 centów (czyli $m = m^*$ dla całkowitych numerów MIDI) i $|t_{\text{on}} - t^*_{\text{on}}| \le 50\,\text{ms}$. Każda nuta wzorca może być trafiona co najwyżej raz, a każda przewidziana liczy się co najwyżej raz (dopasowanie jeden do jednego; wyznacza się je algorytmem dla grafów dwudzielnych, np. Hopcrofta–Karpa). Dla miary *z końcem* dodatkowo koniec musi się mieścić w tolerancji $\max(50\,\text{ms}, 0{,}2\,\delta)$, gdzie δ to długość nuty wzorca.

Przykład 17.1. Wzorzec ma jedną nutę (64; 1,010), a model zwrócił dwie: (64; 1,000) i (64; 1,030). Obie są w tolerancji 50 ms, ale dopasowanie jest jeden do jednego: jedna jest trafieniem (TP), druga fałszywym alarmem (FP). Gdyby model nie zwrócił nic, nuta wzorca byłaby pominięta (FN).

Niech TP będzie liczbą trafień, FP liczbą przewidzianych niezatrafionych, FN liczbą pominiętych nut wzorca. Wtedy

$$P = \frac{\text{TP}}{\text{TP}+\text{FP}}\ \text{(precyzja)}, \qquad R = \frac{\text{TP}}{\text{TP}+\text{FN}}\ \text{(czułość)}, \qquad F_1 = \frac{2PR}{P+R}. \tag{17.1}$$

Twierdzenie 17.2 (Postać F1 i położenie między P i R). *Przy* $\text{TP} > 0$*:* $F_1 = \dfrac{2\,\text{TP}}{2\,\text{TP}+\text{FP}+\text{FN}}$ *oraz* $\min(P,R) \le F_1 \le \max(P,R)$.

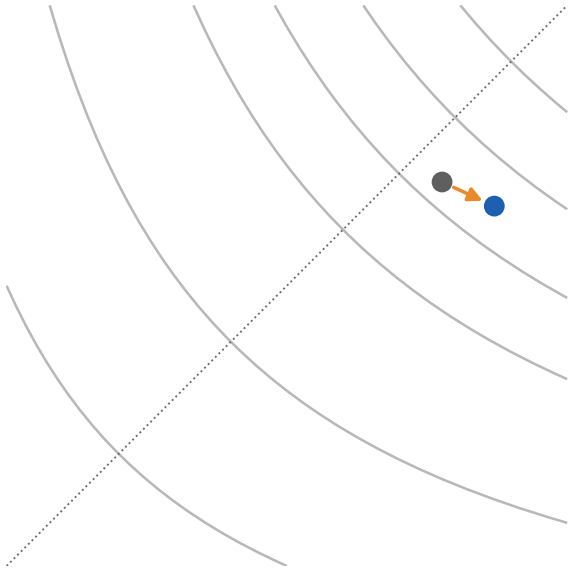
Pomysł dowodu. F1 to średnia harmoniczna P i R; po wstawieniu ułamków licznik i mianownik upraszczają się do liczb zliczeń. Nierówność wynika z tego, że średnia harmoniczna leży między składnikami.

Dowód. Niech $a = \text{TP}+\text{FP}$ i $b = \text{TP}+\text{FN}$, więc $P = \text{TP}/a$, $R = \text{TP}/b$.

$$\begin{aligned} F_1 &= \frac{2\,\frac{\text{TP}}{a}\frac{\text{TP}}{b}}{\frac{\text{TP}}{a}+\frac{\text{TP}}{b}} && \text{(def.)}\\ &= \frac{2\,\text{TP}^2}{\text{TP}(a+b)} = \frac{2\,\text{TP}}{a+b} && \text{(mnożenie przez } ab\text{, skrócenie TP)}\\ &= \frac{2\,\text{TP}}{2\,\text{TP}+\text{FP}+\text{FN}}. && (a+b \text{ rozpisane}) \end{aligned}$$

Dla nierówności załóżmy $P \le R$ (drugi przypadek jest symetryczny): $F_1 = \dfrac{2PR}{P+R} \ge \dfrac{2PR}{2R} = P$, bo $P+R \le 2R$; oraz $F_1 \le \dfrac{2PR}{2P} = R$, bo $P+R \ge 2P$. To kończy dowód. ∎

W zwykłym języku: F1 zlicza trafienia podwójnie i dzieli przez sumę „wszystkiego, co się liczyło” — trafień, fałszywych alarmów i pominięć. Nie da się mieć dobrego F1 ani przez mówienie bardzo mało (wysokie P, niskie R), ani przez mówienie bardzo dużo (odwrotnie).



Rysunek 17.1: Płaszczyzna precyzja (poziom) – czułość (pion), od 0,5 do 1, z poziomicami F1 (szare linie, od 0,6 do 0,95; kropkowana to $P = R$). Szara kropka: dekoder domyślny ($P = 88{,}8\%$, $R = 84{,}2\%$), niebieska: dostrojony (93,5%, 82,1%); strzałka pokazuje zmianę. Precyzja rośnie o 4,7 punktu, czułość spada o 2,1, a punkt przechodzi na wyższą poziomicę (F1 ze średnich P, R: $86{,}5\% \to 87{,}4\%$); F1 jest tym większe, im bliżej górnego prawego rogu i im bliżej przekątnej. Raporto-

Na konkretnych liczbach. Model na teście (średnie): $P = 88{,}84\%$, $R = 84{,}25\%$. Gdyby policzyć F_1 z tych dwóch średnich, wyszłoby

$2PR/(P+R) = 86{,}5\%$. Tymczasem raportowane F1 nut ma 85,94% — mniej. Różnica nie jest błędem: to *średnia z F1 po nagraniach* (makro), a nie F1 ze średnich.

Przykład 17.2 (Makro i mikro). Dwa nagrania: A ma TP $= 9$, FP $= 1$, FN $= 1$ ($F_1 = 0{,}9$), B ma TP $= 1$, FP $= 3$, FN $= 3$ ($F_1 = 0{,}25$). *Makro* (średnia z F1): $(0{,}9 + 0{,}25)/2 = 0{,}575$. *Mikro* (zsumowane zliczenia TP $= 10$, FP $= 4$, FN $= 4$): $F_1 = 20/28 = 0{,}714$. Mikro daje większą wagę nagraniom z większą liczbą nut; makro traktuje każde nagranie jednakowo. W książce podajemy makro, chyba że napisano inaczej.

17.3 Niepewność: bootstrap

Test ma 700 nagrań; wynik zależy od tego, które to nagrania. *Bootstrap* szacuje tę zależność: losujemy ze zwracaniem n nagrań z n dostępnych, liczymy średnią, powtarzamy wiele razy i patrzymy na rozrzut.

Twierdzenie 17.3 (Wariancja średniej bootstrapowej). *Niech $x_1, \dots, x_n$ będą wynikami (np. F1) n nagrań, $\bar{x}$ ich średnią, a $\bar{x}^*$ średnią z n losowań ze zwracaniem. Wtedy $\mathbb{E}[\bar{x}^*] = \bar{x}$ oraz*

$$\operatorname{Var}(\bar{x}^*) = \frac{\hat{\sigma}^2}{n}, \qquad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2. \tag{17.2}$$

Pomysł dowodu. Każde losowanie to niezależna zmienna o rozkładzie równomiernym na $\{x_1, \dots, x_n\}$; średnia n takich zmiennych ma średnią $\bar{x}$ i wariancję równą wariancji pojedynczego losowania podzielonej przez n.

Dowód. Niech $X_1^*, \dots, X_n^*$ będą niezależnymi losowaniami z $\{x_i\}$, każde z prawdopodobieństwem $1/n$. Wtedy

$$\mathbb{E}[X_j^*] = \frac{1}{n}\sum_{i} x_i = \bar{x}, \qquad \text{(def. wartości oczekiwanej)}$$

$$\operatorname{Var}(X_j^*) = \frac{1}{n}\sum_{i}(x_i - \bar{x})^2 = \hat{\sigma}^2, \qquad \text{(def. wariancji)}$$

$$\operatorname{Var}(\bar{x}^*) = \frac{1}{n^2}\sum_{j=1}^{n}\operatorname{Var}(X_j^*) = \frac{\hat{\sigma}^2}{n}. \qquad \text{(niezależność)}$$

Średnia ma więc dokładnie wariancję $\hat{\sigma}^2/n$, czyli odchylenie standardowe maleje jak $1/\sqrt{n}$: czterokrotnie więcej nagrań zmniejsza niepewność o połowę. To kończy dowód. ∎

Na konkretnych liczbach. Dla sześciu wyników $x = (84, 88, 90, 79, 91, 86)$: $\bar{x} = 86{,}33$, $\hat{\sigma}^2 = 16{,}22$, więc błąd standardowy $\sqrt{16{,}22/6} = 1{,}644$. Symulacja bootstrap ($2 \cdot 10^5$ powtórzeń) daje 1,645 i 95% przedział percentylowy [82,8; 89,3]. Przedział 95% to ok. ± 2 błędy standardowe.

Gdy porównujemy dwa warianty (np. dekoder domyślny i dostrojony), stosujemy *sparowany* bootstrap: losujemy te same indeksy nagrań dla obu wariantów i bootstrapujemy *różnicę* wyników. Szum związany z trudnością nagrań (wspólny dla obu wariantów) wtedy się znosi, i przedział różnicy jest wąski: np. F1 nut $+0{,}64$ z przedziałem [0,46; 0,83] (rozdział 16).

Pułapka. Przedział ufności bootstrap opisuje niepewność związaną z *doborem nagrań testowych*, nie z innymi źródłami błędu: z tym, że dane są syntetyczne, że inny mikrofon da inny wynik, że model był uczony tylko raz (jedno ziarno). Wąski przedział nie znaczy, że wynik przeniesie się na inne dane. ♢

17.4 Wyniki Gen 6

Test: 700 nagrań, w tym 180 prawdziwej gitary (GuitarSet, gracze 03–05) i 520 syntezy klasyki; wszystkie utwory i gracze nieobecni w uczeniu (rozdział 12). Wszystkie miary liczy ten sam moduł, zgodny z biblioteką `mir_eval` do 10^{-9}.

miara (makro, 700 nagrań)	dekoder domyślny	dekoder dostrojony	zmiana (95%)
F1 nut	85,9 [85,0; 86,8]	**86,6**	+0,64 [0,46; 0,83]
F1 nut z końcem	69,4 [67,9; 71,0]	**70,0**	+0,59 [0,32; 0,85]
F1 klatkowe	88,5 [87,9; 89,1]	87,3	−1,29 [−1,50; −1,10]
precyzja / czułość nut	88,8 / 84,2	93,5 / 82,1	—

Tabela 17.1: Wyniki Gen 6 (model z epoki 81) na zbiorze testowym. Źródło: `docs/WYNIKI.md`.

GuitarSet 03–05	Gen 5	Gen 6 (końcowy)	Gen 6 + dostrojony dekoder
F1 nut razem	79,5	87,2	—
akompaniament / melodie	75,6 / 83,4	85,1 / 89,2	87,3 / 90,7 (makro)
nuty z końcem, razem	40,9	74,8	—

Tabela 17.2: Gen 5 i Gen 6 na prawdziwej gitarze (GuitarSet, gracze 03–05). Liczby Gen 5 pochodzą z opisu projektu (ten sam podział, wcześniejszy kod oceny), więc porównanie jest przybliżone. Tabulatura (Gen 6, mikro): akompaniament — F1 par struna–próg 82,2%, trafna struna 91,3%, TDR 91,7%; melodie — 75,1%, 83,2%, 84,6%.

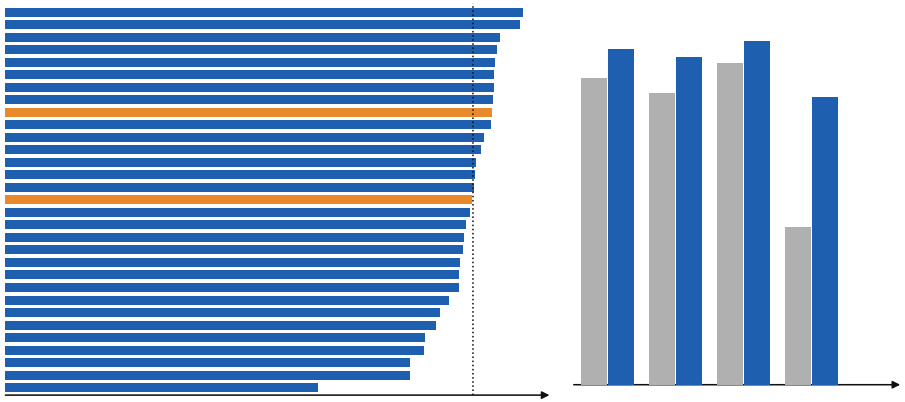
Jak to czytać. Najlepiej wypadają instrumenty o szarpanym, wyraźnym początku (pizzicato, ukulele, gitara): tolerancja 50 ms jest dla nich łatwa. Najgorzej — chór, smyczki, instrumenty z wibrato i rozmytym początkiem: tam sam początek nuty jest niejednoznaczny nawet dla człowieka, a bogate alikwoty utrudniają odróżnienie nut. Wzorzec zgadza się z fizyką problemu (rozdziały 3 i 6). Grupy z kilkoma nagraniami ($n < 12$) są niepewne.

Szybkość: dla nagrania 39 s na 4 rdzeniach CPU cechy zajmują 1,9 s, sieć 2,1 s, razem 4,0 s, czyli 0,10 *czasu nagrania* (na 1 rdzeniu 0,30): trzy minuty gry to ok. 19 s na 4 rdzeniach.

17.5 Co ten pomiar *nie* pokazuje

Uczciwa lista ograniczeń (część to wnioski wprost z dokumentacji projektu):

1. **Dane syntetyczne.** Tylko GuitarSet (168 nagrań uczących) to prawdziwa gitara; kolejne sesje uczenia dołożyły głównie syntezę i na GuitarSet dały najmniej (+0,4 i +0,7 punktu). Dokładność dla gitary z innym mikrofonem, pomieszczeniem czy przetwornikiem piezo jest *niezmierzona*.



Rysunek 17.2: (a) F1 nut (makro) dla każdej z 31 grup testowych modelu końcowego (dekoder domyślny), od najlepszej do najgorszej; pomarańczowe słupki to prawdziwa gitara (GuitarSet), niebieskie — syntetyczne nagrania klasyki; kropkowana pionowa to wynik ogólny 85,94%. Najlepsze: pizzicato (95,0%), ukulele (94,5%), gitara klasyczna (90,9%, $n = 74$); najsłabsze: chór (57,5%), wiolonczela (74,3%), syntezator (74,3%). (b) Gen 5 (szare) i Gen 6 (niebieskie) na GuitarSet: F1 nut razem, akompaniament, melodie, nuty z końcem (od lewej).

2. **Brak badań ablacyjnych.** Nie zmierzono osobno wpływu bloków harmonicznych, uwagi między wysokościami, poszczególnych augmentacji ani długości uczenia. Poprawa Gen 5→Gen 6 jest łączna (cechy, architektura, dane, głowice). Teza, że uwaga między wysokościami ogranicza błędy oktawowe, jest *motywacją projektową*, nie wynikiem eksperymentu. Błąd oktawowy pozostaje wysoki: 24,4% fałszywych alarmów klatkowych leży oktawę od prawdziwej nuty.

3. **Głośność.** Głowica głośności jest nieuczona (żadne źródło nie ma etykiet).

4. **Progi dekodera** zostały dobrane na małej walidacji (222 nagrania, w tym tylko 12 prawdziwej gitary); zysk na teście (+0,64) jest o połowę mniejszy niż na walidacji (+1,30).

5. **Wybór epoki** odbył się na walidacji, która zawiera tylko 12 nagrań GuitarSet — niewielkie ryzyko dopasowania do walidacji.

6. **Nie sprawdzono** trybu przyczynowego (analizy na żywo) ani działania po przeniesieniu wag do silnika C++/WebAssembly (jest zaplanowane).

7. **Jedno uruchomienie uczenia** (jedno ziarno losowości): nie znamy zmienności wyniku między powtórzeniami uczenia.

Intuicja. Dobra ewaluacja to nie tylko duża liczba, ale też jasne granice jej ważności. Wynik 86,6% znaczy: *na tych* 700 nagraniach, *z tym* dekoderem, *przy tej* tolerancji i *tym* podziale. Każda z tych części jest założeniem, które trzeba pamiętać, mówiąc, że „model działa”. ♢

Podsumowanie

- Trafienie: ta sama wysokość i początek w ± 50 ms, dopasowanie jeden do jednego; $F_1 = 2\mathrm{TP}/(2\mathrm{TP}+\mathrm{FP}+\mathrm{FN})$ leży między P i R (tw. 17.2).
- Średnia z F1 po nagraniach (makro) nie jest F1 ze średnich P i R (przykład 17.2).
- Bootstrap: $\mathrm{Var}(\bar{x}^*) = \hat{\sigma}^2/n$ (tw. 17.3); porównania robimy sparowanym bootstrapem.
- Gen 6 na 700 niewidzianych nagraniach: F1 nut 85,9% (86,6% z dostrojonym dekoderem); na GuitarSet 87,3 / 90,7% (akompaniament/melodie) wobec 75,6 / 83,4% w Gen 5 (porównanie przybliżone).
- Ograniczenia: głównie dane syntetyczne, brak ablacji, jedno ziarno, niezmierzona gitara w innych warunkach.

Ćwiczenia

1. Model zwrócił 50 nut, z czego 40 trafiło; wzorzec miał 60 nut. Policz P, R, F_1 i sprawdź wzór z tw. 17.2.
2. Nagranie ma $\mathrm{TP} = 18$, $\mathrm{FP} = 2$, $\mathrm{FN} = 6$. Ile wynosi F_1? Co się stanie z F_1, gdy zmienimy próg dekodera tak, że FP spadnie do 0, ale TP spadnie do 15 (a FN wzrośnie do 9)?
3. Dla $n = 10$ wyników z $\hat{\sigma} = 5$ policz błąd standardowy bootstrap. Ile nagrań trzeba, żeby był o połowę mniejszy?
4. Dlaczego sparowany bootstrap daje węższy przedział różnicy niż porównanie dwóch niezależnych przedziałów?

Rozwiązania

1. $P = 40/50 = 0{,}8$, $R = 40/60 = 0{,}667$, $F_1 = 2 \cdot 0{,}8 \cdot 0{,}667/(1{,}467) = 0{,}727$; ze wzoru $2 \cdot 40/(80+10+20) = 80/110 = 0{,}727$. ✓
2. $F_1 = 36/(36+2+6) = 36/44 = 0{,}818$. Po zmianie: $F_1 = 30/(30+0+9) = 30/39 = 0{,}769$ — spadek: precyzja wzrosła do 1, ale czułość spadła z 0,75 do 0,625; zmiana, która poprawia jedną z miar kosztem drugiej, nie musi poprawić F1.
3. $\hat{\sigma}/\sqrt{n} = 5/\sqrt{10} = 1{,}58$; żeby błąd był o połowę mniejszy, trzeba $4\times$ więcej nagrań, czyli $n = 40$ ($5/\sqrt{40} = 0{,}79$).
4. Obie wersje liczone są na tych samych nagraniach, więc „trudność” nagrania (wspólny składnik) wpływa na oba wyniki podobnie i znosi się w różnicy; różnica ma mniejszą wariancję niż suma wariancji niezależnych szacunków.

Część III

Opis matematyczny modelu

18 Gen 6 w jednym miejscu: pełny opis matematyczny

18.1 Po co jeszcze jeden rozdział?

W poprzednich rozdziałach model powstawał kawałek po kawałku. Teraz zbieramy go w całość: jedna lista oznaczeń, jedno złożenie funkcji, jeden wzór na liczbę parametrów, jedna tabela kształtów. Rozdział można czytać samodzielnie jako *specyfikację* modelu; wszystkie wzory były już wyprowadzone, a odsyłacze wskazują, gdzie.

Po tym rozdziale umiesz: (i) zapisać Gen 6 jako złożenie funkcji z kształtami, (ii) policzyć liczbę parametrów dla dowolnych hiperparametrów, (iii) przeprowadzić nagranie przez cały model od fali do listy nut, (iv) odesłać każdy element do rozdziału, w którym jest uzasadniony.

18.2 Oznaczenia

symbol	wartość	znaczenie
f_s	11 025 Hz	częstotliwość próbkowania po zmianie
T	—	liczba klatek ($T = \lfloor (N-4096)/256 \rfloor + 1$)
C, P, S	9, 159, 53	kanały HCQT, biny wysokości, półtony ($P = 3S$)
H, D	48, 64	szerokość części konwolucyjnej i kontekstowej
n_h, d_h	4, 16	głowice uwagi i ich wymiar ($D = n_h d_h$)
W	43	półokno uwagi w czasie (klatki)
$K = (k_1, \ldots, k_7)$	$(-36, 0, 36, 57, 72, 84, 93)$	przesunięcia alikwotów w binach
d_1, d_2, d_3	$1, 2, 4$	dylatacje czasowe bloków
$o_1, \ldots, o_6$	$64, 59, 55, 50, 45, 40$	struny puste (od najcieńszej)
θ	249 219 liczb	wszystkie parametry sieci

Tabela 18.1: Stałe i hiperparametry Gen 6 (`gen6_kaggle.json`).

18.3 Model jako złożenie

Nagranie $x \in \mathbb{R}^N$ (po zmianie próbkowania do f_s) przechodzi przez osiem etapów. Wszystkie znaki zostały zdefiniowane wcześniej: GELU (def. 9.1), LN (def. 9.6), Drop (def. 9.10), shift (def. 13.1), Conv i DW (def. 9.2).

Definicja 18.1 (Model Gen 6). (0) Cechy. $X = \mathrm{HCQT}(x) \in \mathbb{R}^{C \times T \times P}$ (def. 7.2, 7.3).
(1) Trzon. $A^0 = \mathrm{GELU}\big(\mathrm{Conv}_{3\times 7}(X)\big) \in \mathbb{R}^{H \times T \times P}$.
(2) Bloki harmoniczne, $l = 1, 2, 3$:

$$\tilde{A} = \mathrm{LN}_{\mathrm{kan}}(A^{l-1}), \qquad U^l = W_h^l\big[\,\mathrm{shift}_{k_1}(\tilde{A}) \,\|\, \cdots \,\|\, \mathrm{shift}_{k_7}(\tilde{A})\big],$$

$$V^l = \mathrm{GELU}\big(\mathrm{DW}_{1\times 5}(\mathrm{GELU}(U^l))\big), \qquad A^l = A^{l-1} + \mathrm{Drop}\Big(\mathrm{GELU}\big(\mathrm{Conv}_{3\times 1}^{(d_l)}(V^l)\big)\Big).$$

(3) Zejście do półtonów. $Z^0_{t,s} = \mathrm{Conv}_{1\times 3,\ \text{krok }3}(A^3)_{t,s} + e_s \in \mathbb{R}^D$, $Z^0 \in \mathbb{R}^{T\times S\times D}$.
(4) Warstwy kontekstu, $l = 1,2$ (def. 14.1):

$$Z' = Z^{l-1} + \mathrm{Drop}\big(\mathrm{TA}^l(\mathrm{LN}\, Z^{l-1})\big), \qquad Z'' = Z' + \mathrm{Drop}\big(\mathrm{PA}^l(\mathrm{LN}\, Z')\big),$$
$$Z^l = Z'' + \mathrm{Drop}\big(\mathrm{FF}^l(\mathrm{LN}\, Z'')\big).$$

(5) Głowice. $G = \mathrm{LN}(Z^2) \in \mathbb{R}^{T\times S\times D}$ oraz

$$p_{\mathrm{on}} = \sigma\big(\mathrm{MLP}_{\mathrm{on}}(G)\big), \qquad p_{\mathrm{off}} = \sigma\big(\mathrm{MLP}_{\mathrm{off}}(G)\big),$$
$$p_{\mathrm{fr}} = \sigma\big(\mathrm{MLP}_{\mathrm{fr}}([G; \mathrm{sg}(p_{\mathrm{on}})])\big), \qquad \hat{v} = \sigma\big(\mathrm{MLP}_{\mathrm{vel}}(G)\big),$$
$$p_i(t) = \mathrm{softmax}\big(g_{i,\varnothing}(t), g_{i,0}(t), \ldots, g_{i,19}(t)\big), \qquad i = 1,\ldots,6 \ \text{(def. 14.3)}.$$

(6) Strata (tylko uczenie). $\mathscr{L} = \mathscr{L}_{\mathrm{on}} + \mathscr{L}_{\mathrm{fr}} + \frac{1}{2}\mathscr{L}_{\mathrm{off}} + \frac{1}{2}\mathscr{L}_{\mathrm{vel}} + \frac{1}{2}\mathscr{L}_{\mathrm{tab}}$ (wzór (15.2)).
(7) Dekoder (tylko wnioskowanie). $\mathscr{D}(p_{\mathrm{on}}, p_{\mathrm{fr}}, p_{\mathrm{off}}, p_{1..6}) =$ lista nut (m, t_0, t_1, i^*) (rozdział 16).

Twierdzenie 18.2 (Poprawność wymiarów). *Złożenie z def. 18.1 jest dobrze określone, a dla wejścia o T klatkach ma wyjścia $p_{\mathrm{on}}, p_{\mathrm{fr}}, p_{\mathrm{off}}, \hat{v} \in (0,1)^{T\times S}$ i $p \in \Delta^{T\times 6\times 21}$ (Δ — sympleks prawdopodobieństw).*

Pomysł dowodu. Sprawdzamy po kolei, że wyjście każdego etapu ma kształt wymagany przez wejście następnego (tak jak w rys. 1.2).

Dowód. Sprawdzamy po kolei kształt przed i po każdym etapie (przy dopełnianiu zerami konwolucje zachowują T i P):

1. $X \in \mathbb{R}^{9\times T\times 159} \ \to\ A^0 \in \mathbb{R}^{48\times T\times 159}$ (trzon, $\mathrm{Conv}_{3\times 7}$);
2. blok: $A^{l-1} \to$ shift, $\| \to \mathbb{R}^{336\times T\times 159} \to W_h \to \mathbb{R}^{48\times T\times 159} \to \mathrm{DW}, \mathrm{Conv} \to \mathbb{R}^{48\times T\times 159}$; suma z A^{l-1} ma ten sam kształt, więc $A^l \in \mathbb{R}^{48\times T\times 159}$;
3. zejście: $A^3 \to \mathbb{R}^{64\times T\times 53} \simeq \mathbb{R}^{T\times 53\times 64}$, bo $159/3 = 53$;
4. warstwa kontekstu: TA, PA i FF zachowują kształt $T\times 53\times 64$, więc sumy resztkowe są poprawne;
5. głowice: $G \in \mathbb{R}^{T\times 53\times 64} \to \mathbb{R}^{T\times 53}$ (początek, koniec, głośność, brzmi z 65 wejść) oraz $G \to \mathbb{R}^{T\times 6\times 21}$ (tabulatura).

Jedyne miejsce wymagające uwagi to połączenia resztkowe: sumujemy tensory o jednakowym kształcie, bo każda gałąź zachowuje kształt. Sigmoida i softmax nie zmieniają kształtu i dają wartości w $(0,1)$ oraz sumujące się do 1 po klasach (tw. 8.3). Stąd zdanie twierdzenia. To kończy dowód. ■

Zdanie ludzkim językiem: sieć jest rurą o stałych przekrojach; zmieniają się tylko liczba kanałów na początku ($9 \to 48$), rozdzielczość po wysokości na zejściu ($159 \to 53$) i szerokość cech ($48 \to 64$). Zgodność z prawdziwym modelem sprawdzono, uruchamiając sieć na nagraniu 6-sekundowym:

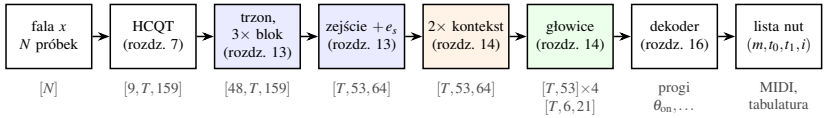
18.4 Liczba parametrów dla dowolnych hiperparametrów

Twierdzenie 18.3 (Wzór na liczbę parametrów). *Dla $K = 7$ przesunięć, n_{b} bloków harmonicznych, n_{c} warstw kontekstu, n_h głowic i 6 strun z 20 progami liczba parametrów wynosi*

$$N = N_{\mathrm{trzon}} + n_{\mathrm{b}} N_{\mathrm{blok}} + N_{\mathrm{zejcie}} + n_{\mathrm{c}} N_{\mathrm{ctx}} + N_{\mathrm{głowice}}, \tag{18.1}$$

etap	kształt (zmierzony, $T = 243$)	liczb
wejście X	$[1, 9, 243, 159]$	347 733
trzon, bloki 1–3	$[1, 48, 243, 159]$	1 854 576
(wnętrze bloku: 336 kanałów)	$[1, 336, 243, 159]$	12 982 032
zejście (64 kanały)	$[1, 64, 243, 53]$	824 256
warstwy kontekstu, LN	$[1, 243, 53, 64]$	824 256
głowice: początek, brzmi, koniec, głośność	$[1, 243, 53]$ każda	12 879
głowica tabulatury	$[1, 243, 6, 21]$	30 618

Tabela 18.2: Kształty tensorów w prawdziwym modelu Gen 6 dla nagrania 6-sekundowego ($T = 243$). Największe tablice powstają wewnątrz bloku harmonicznego (siedem kopii cech, prawie 13 mln liczb): tu jest koszt pamięci sieci.



Rysunek 18.1: Cała droga od fali do listy nut z kształtami tensorów (liczby zmierzone na prawdziwym modelu dla $T = 243$ w tab. 18.2). Pola niebieskie to część konwolucyjna, pomarańczowe — kontekst z uwagą, zielone — głowice; dekoder nie ma parametrów uczonych gradientem.

gdzie

$$N_{\mathrm{trzon}} = 21CH + H, \qquad N_{\mathrm{blok}} = 2H + (KH^2 + H) + 6H + (3H^2 + H),$$
$$N_{\mathrm{zejcie}} = 3HD + D + SD, \qquad N_{\mathrm{ctx}} = 6D + N_{\mathrm{TA}} + N_{\mathrm{PA}} + N_{\mathrm{FF}},$$
$$N_{\mathrm{TA}} = 4D^2 + 4D + n_h(2W + 1), \qquad N_{\mathrm{PA}} = 4D^2 + 4D + n_h(2S - 1),$$
$$N_{\mathrm{FF}} = 8D^2 + 5D, \qquad N_{\mathrm{głowice}} = 5D^2 + 19D + 131.$$

Dla Gen 6 ($C = 9$, $H = 48$, $D = 64$, $S = 53$, $W = 43$, $n_h = 4$, $n_{\mathrm{b}} = 3$, $n_{\mathrm{c}} = 2$) daje to $N = 249\,219$.

Pomysł dowodu. Sumujemy parametry modułów, korzystając ze wzorów na warstwę liniową ($mn + m$, rozdział 4) i konwolucję (tw. 9.3).

Dowód. Moduły po kolei:

$$N_{\mathrm{trzon}} = C \cdot H \cdot (3 \cdot 7) + H \qquad \text{(tw. 9.3)}$$
$$N_{\mathrm{blok}} = \underbrace{2H}_{\mathrm{LN}} + \underbrace{KH \cdot H + H}_{W_h} + \underbrace{5H + H}_{\mathrm{DW}} + \underbrace{3H \cdot H + H}_{\mathrm{Conv}_{3\times 1}} \qquad \text{(tw. 9.3)}$$
$$N_{\mathrm{zejcie}} = H \cdot D \cdot 3 + D + SD \qquad \text{(konwolucja } 1\times 3 \text{ i osadzenie } e_s\text{)}$$
$$N_{\mathrm{TA}} = \underbrace{D \cdot 3D + 3D}_{W_{QKV}} + \underbrace{D^2 + D}_{W_O} + n_h(2W + 1) \qquad \text{(rozdział 10)}$$
$$N_{\mathrm{PA}} = (D \cdot 3D + 3D) + (D^2 + D) + n_h(2S - 1)$$
$$N_{\mathrm{FF}} = (D \cdot 4D + 4D) + (4D \cdot D + D) = 8D^2 + 5D$$
$$N_{\mathrm{ctx}} = 3 \cdot 2D + N_{\mathrm{TA}} + N_{\mathrm{PA}} + N_{\mathrm{FF}} \qquad \text{(trzy LN)}$$

Głowice: początek $(D^2 + D) + (D + 1) = D^2 + 2D + 1$; brzmi $((D+1)D + D) + (D+1) = D^2 + 3D + 1$; koniec i głośność po $D^2 + 2D + 1$; tabulatura $6D + 6$ (wagi $\boldsymbol{w}_i$ i c_i) $+ 6 \cdot 20$ (premie progów) $+ (D^2 + D) + (D + 1)$ (MLP

ciszy) $= D^2+8D+127$; końcowy LN ma $2D$. Razem

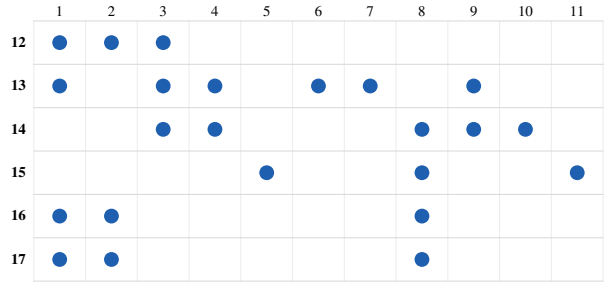
$$N_{\text{głowice}} = 3\big(D^2+2D+1\big)+\big(D^2+3D+1\big)+\big(D^2+8D+127\big)+2D = 5D^2+19D+131.$$

Po wstawieniu liczb: $N_{\text{trzon}} = 9120$, $N_{\text{blok}} = 23\,520$, $N_{\text{zejcie}} = 12\,672$, $N_{\text{ctx}} = 67\,520$, $N_{\text{głowice}} = 21\,827$, więc $N = 9120+3\cdot 23\,520+12\,672+2\cdot 67\,520+21\,827 = 249\,219$. To kończy dowód. ■

Sprawdzenie. Wzór zgadza się z prawdziwym modelem nie tylko dla Gen 6, ale i dla innych hiperparametrów: model z $H = 32$, $D = 48$, $W = 20$ ma 134 243 parametry (wzór daje to samo), a model z 2 blokami i 3 warstwami kontekstu 293 219 (wzór: to samo); zbudowano oba w PyTorch i policzono parametry.

Na konkretnych liczbach. Z wzoru widać, skąd bierze się większość parametrów: warstwy kontekstu ($2\cdot 67\,520 = 135\,040$, 54%) są $\sim D^2$ (kwadratowo w D), a bloki harmoniczne (70 560, 28%) — $\sim KH^2$. Zwiększenie D z 64 do 96 podniosłoby liczbę parametrów mniej więcej 2,25 razy w tej części. Z kolei liczba klatek T w ogóle nie wpływa na liczbę parametrów (tw. 9.3): długie nagranie to tylko więcej obliczeń.

18.5 Mapa: skąd się bierze każdy element



Rysunek 18.2: Macierz zależności książki. Poziomo — rozdziały matematyki i narzędzi (1–11), pionowo — rozdziały o modelu (12–17); niebieska kropka oznacza, że rozdział o modelu wymaga danego rozdziału matematyki. Np. blok harmoniczny (rozdz. 13) wymaga alikwotów (3), widma i HCQT (6, 7), macierzy (4) i konwolucji (9); uczenie (rozdz. 15) — pochodnych (5), straty (8) i optymalizacji (11).

Intuicja. Gen 6 to nie jeden pomysł, tylko składanka kilku prostych: *logarytm* (żeby wzorzec nuty był niezmienny przy przesunięciu), *widmo* (żeby zobaczyć alikwoty), *konwolucja* (żeby ten sam wzorzec działał wszędzie), *uwaga* (żeby nuty i klatki mogły się nawzajem sprawdzać) i *entropia krzyżowa z gradientem* (żeby to wszystko dało się nauczyć). Każdy z elementów da się zrozumieć osobno — i o to chodziło w tej książce. ♢

Podsumowanie całości

- Gen 6: HCQT → trzon → 3× blok harmoniczny → zejście → 2× kontekst → LN → 5 głowic; potem dekoder (def. 18.1).
- Wymiary się zgadzają (tw. 18.2); największe tablice są wewnątrz bloku harmonicznego (tab. 18.2).

- Liczba parametrów: wzór z tw. 18.3; dla Gen 6 249 219, niezależnie od długości nagrania.
- Mocne strony: logarytmiczna oś i blok harmoniczny; uwaga między wysokościami i w czasie; maski dostępności etykiet. Ograniczenia: dane syntetyczne, brak ablacji, jedno uruchomienie (rozdział 17).

Ćwiczenia

1. Policz N dla modelu z $H = 32$, $D = 48$, $W = 20$ (pozostałe jak w Gen 6) ze wzoru z tw. 18.3, rozpisując moduły.
2. Podaj kształty po każdym etapie dla nagrania z $T = 100$ klatek.
3. O ile zmieni się N, gdyby model obejmował $S = 60$ półtonów zamiast 53 (reszta bez zmian)?
4. Który etap ma największy koszt pamięci aktywacji i ile liczb zajmuje dla $T = 243$ (tab. 18.2)? Ile razy więcej niż wejście?

Rozwiązania

1. Trzon: $9\cdot 32\cdot 21+32 = 6080$. Blok: $64+7200+192+3104 = 10\,560$, trzy bloki 31 680. Zejście: $32\cdot 48\cdot 3+48+53\cdot 48 = 4656+2544 = 7200$. Kontekst: $3\cdot 96 = 288$, TA 9572, PA 9828, FF 18 672, razem 38 360; dwie warstwy 76 720. Głowice razem z LN: 12 563. Suma $6080+31\,680+7200+76\,720+12\,563 = 134\,243$.
2. Wejście $[1, 9, 100, 159]$; trzon i bloki $[1, 48, 100, 159]$; zejście $[1, 64, 100, 53]$; kontekst i LN $[1, 100, 53, 64]$; głowice $[1, 100, 53]$ (cztery) i $[1, 100, 6, 21]$.
3. Zmieniają się tylko osadzenie wysokości ($S\cdot D$: $+7\cdot 64 = 448$) i premie uwagi między wysokościami ($n_h(2S-1)$: z 420 na 476, czyli $+56$ w każdej z dwóch warstw, $+112$ razem). Razem $+560$: $N = 249\,779$.
4. Wnętrze bloku harmonicznego (336 kanałów): 12 982 032 liczb, czyli 37,3 razy więcej niż wejście (347 733).

A Skąd bierze się 249 219 parametrów

Tabela rozpisuje każdy moduł prawdziwego, wytrenowanego modelu Gen 6 ($H=48$, $D=64$, $n_h=4$, $S=53$, $W=43$). Każdą liczbę da się policzyć ze wzorów: warstwa liniowa $n\to m$ ma $mn+m$ parametrów (rozdział 4), konwolucja $C_{\text{we}}C_{\text{wy}}k_tk_p+C_{\text{wy}}$ (tw. 9.3), LayerNorm $2\times$ wymiar. Sumy zostały porównane programem z liczbą parametrów modelu wczytanego z pliku `best.pt`.

moduł	obliczenie	parametry
trzon: konwolucja 3×7, $9\to48$	$9\cdot48\cdot21+48$	9 120
blok harmoniczny ($\times3$): LN(48)	$2\cdot48$	96
konwolucja 1×1, $336\to48$	$336\cdot48+48$	16 176
konwolucja głębokościowa 1×5	$48\cdot5+48$	288
konwolucja czasowa 3×1, $48\to48$	$48\cdot48\cdot3+48$	6 960
suma bloku $\times3$	$23\,520\cdot3$	70 560
zejście: konwolucja 1×3, $48\to64$	$48\cdot64\cdot3+64$	9 280
osadzenie wysokości e_s	$53\cdot64$	3 392
warstwa kontekstu ($\times2$): trzy LN	$3\cdot128$	384
uwaga w czasie (W_{QKV}, W_O, premie)	$12\,480+4160+4\cdot87$	16 988
uwaga między wysokościami	$12\,480+4160+4\cdot105$	17 060
FF: $64\to256\to64$	$16\,640+16\,448$	33 088
suma warstwy $\times2$	$67\,520\cdot2$	135 040
LN końcowy	$2\cdot64$	128
głowica początku	$(64\cdot64+64)+(64+1)$	4 225
głowica „brzmi” (65 wejść)	$(65\cdot64+64)+65$	4 289
głowica końca	jak początku	4 225
głowica głośności (nieuczona)	jak początku	4 225
głowica tabulatury: $\boldsymbol{w}_i, c_i$; premie progów; MLP ciszy	$390+120+4\,225$	4 735
razem		**249 219**

Tabela A.1: Rozbicie liczby parametrów Gen 6 (zgodne z tw. 18.3).

Przykład A.1 (Kontrola sumy). $9120+70\,560+9280+3392=92\,352$ (pierwsza połowa), $+135\,040$ (kontekst) $=227\,392$, $+128+4225+4289+4225+4225+4735=21\,827$ (głowice i LN), razem 249 219.

B Ściąga wzorów

Najważniejsze wzory książki w jednym miejscu, z odesłaniem do miejsca, w którym zostały uzasadnione.

co	wzór	gdzie
nuta $\to$ częstotliwość	$f(m)=440\cdot2^{(m-69)/12}$	tw. 2.5
odstęp w centach	$c=1200\log_2(f_2/f_1)$	def. 2.6
alikwot w binach	$k_h=\operatorname{round}(36\log_2 h)$	wn. 3.5
Nyquist	$f_s/2=5512{,}5\,\text{Hz}$	tw. 2.3
liczba klatek	$T=\lfloor(N-4096)/256\rfloor+1$	prz. 2.5
DFT	$X[k]=\sum x[n]e^{-2\pi ikn/N}$	def. 6.2
okno Hanna	$w[n]=\frac{1}{2}(1-\cos(2\pi n/N))$	def. 6.6
cecha HCQT	$\operatorname{clip}\big((20\log_{10}A-L_{\text{ref}})/60+1,0,1{,}3\big)$	def. 7.3
iloczyn skalarny	$\langle\boldsymbol{u},\boldsymbol{v}\rangle=\|\boldsymbol{u}\|\,\|\boldsymbol{v}\|\cos\theta$	tw. 4.2
pochodna sigmoidy	$\sigma'=\sigma(1-\sigma)$	tw. 5.3
gradient BCE po logicie	$\sigma(z)-y$	tw. 8.5
optimum przy wadze	$p^*=\alpha q/(\alpha q+1-q)$	tw. 8.6
softmax	$e^{z_i}/\sum_j e^{z_j}$	def. 8.2
GELU	$z\Phi(z)$	def. 9.1
LayerNorm	$\gamma(z-\mu)/\sqrt{\sigma^2+\varepsilon}+\beta$	def. 9.6
resztka	$\boldsymbol{y}=\boldsymbol{x}+F(\boldsymbol{x})$, $\partial\boldsymbol{y}/\partial\boldsymbol{x}=I+J$	tw. 9.9
uwaga	$\operatorname{softmax}\big(QK^\top/\sqrt{d}+B\big)V$	def. 10.1
parametry konwolucji	$C_{\text{we}}C_{\text{wy}}k_tk_p+C_{\text{wy}}$	tw. 9.3
pole widzenia	$R=\sum d_i r_i$; sieć: $R=8+n_{\text{ctx}}W=94$	tw. 14.2
stabilność GD	$\eta<2/\lambda_{\max}$	tw. 11.1
AdamW	$\theta\leftarrow\theta-\eta\big(\hat{m}/(\sqrt{\hat{v}}+\varepsilon)+\lambda\theta\big)$	rozdz. 11
kosinus	$\eta=\eta_0\frac{1}{2}(1+\cos\pi q)$	rozdz. 11
strata całkowita	$\mathscr{L}_{\text{on}}+\mathscr{L}_{\text{fr}}+\frac{1}{2}(\mathscr{L}_{\text{off}}+\mathscr{L}_{\text{vel}}+\mathscr{L}_{\text{tab}})$	wz. (15.2)
klatka początku	$k=\operatorname{round}\big((t_{\text{on}}f_s-2048)/256\big)$	def. 12.2
F1	$2\text{TP}/(2\text{TP}+\text{FP}+\text{FN})$	tw. 17.2
błąd standardowy bootstrap	$\hat{\sigma}/\sqrt{n}$	tw. 17.3
liczba parametrów	$N=249\,219$ (wzór ogólny)	tw. 18.3

Tabela B.1: Ściąga wzorów.

C Jak odtworzyć wyniki z tej książki

Książka powstała tak, by każdą liczbę i każdy wykres dało się odtworzyć z repozytorium `Gutar`. Poniżej opis, co gdzie leży i jak sprawdzić, że tekst zgadza się z kodem.

Co jest czym

- `ksiazka/rozdzial-NN.tex`, `dodatek-X.tex` — źródła rozdziałów; `ksiazka.tex` — plik główny; `preambula.tex` — styl.
- `ksiazka/figures/gen_rozdzial_NN.py` — po jednym skrypcie wykresów na rozdział; każdy rysunek jest zapisywany jako PDF wektorowy i *sprawdzany asercjami* (np. że gradient jest niezerowy dokładnie dla $|t| \leq 94$).
- `ksiazka/figures/gutar.py` — most do repozytorium: ładuje wytrenowany model `tools/gen6/server/model/best.pt`, liczy HCQT funkcją z `tools/gen6/features.py` i wyjścia sieci.
- `ksiazka/weryfikacja.py` — sprawdza programem wszystkie liczby z przykładów, twierdzeń i rozwiązań ćwiczeń (po jednej funkcji na rozdział), także na prawdziwym modelu.
- Dane z dokumentacji projektu: `docs/wyniki/epoki.csv` (dziennik 97 epok), `docs/wyniki/test_grupy.csv` (wyniki testu po grupach), `docs/WYNIKI.md`, `docs/GEN6.md`.

Polecenia

- Zbudowanie książki: `bash build.sh .` w katalogu `ksiazka/` (generuje wykresy, składa PDF przez `latexmk`).
- Kontrola struktury: `python3 lint.py .` (każde twierdzenie ma dowód, każda definicja przykład, każdy rozdział co najmniej dwa rysunki i zadania).
- Kontrola liczb: `python3 weryfikacja.py` (kończy się błędem, jeśli jakaś liczba w tekście nie zgadza się z obliczeniem).
- Wymagane pakiety: `numpy`, `matplotlib`, `torch` (wersja CPU wystarcza), `texlive` z polskim, `sidenotes`, `tikz`.

Czego nie da się odtworzyć

Wytrenowania modelu od zera: wymaga ok. 70 GB zrzutów cech i kilkunastu godzin na GPU (rozdział 15); w repozytorium jest gotowy model, dziennik uczenia i skrypty. Dane GuitarSet i korpus MIDI trzeba pobrać osobno

(skrypty `tools/gen6/fetch_classical.py` i `make_gen6.sh`). Nagrania użyte do rysunków (rozdziały 3, 7, 13–16) są *syntetyczne* i generowane z ustalonym ziarnem (`tools/gen6/synth.py`); to nie są nagrania prawdziwej gitary.