Jak słyszy Gen 6

Matematyka od zera i model transkrypcji gitary: od fali dźwiękowej do listy nut

Projekt Gutar

Spis treści

1 Zapis, tensory i logarytm **1**
- 1.1 Po co ten rozdział? 1
- 1.2 Sumy i indeksy 1
- 1.3 Wektory, macierze i tensory 2
- 1.4 Funkcje i ich składanie 2
- 1.5 Potęgi i logarytm 3
- 1.6 Funkcje pomocnicze 4

2 Dźwięk, próbkowanie i wysokość **6**
- 2.1 Od drgania do liczb 6
- 2.2 Sinusoida 6
- 2.3 Próbkowanie 6
- 2.4 Półtony, MIDI i centy 8
- 2.5 Klatki czasu 9

3 Struna gitary i alikwoty **11**
- 3.1 Dlaczego nuta to nie jedna sinusoida? 11
- 3.2 Drgania własne struny 11
- 3.3 Wspólne alikwoty: skąd błąd oktawowy 12
- 3.4 Oś logarytmiczna: wzorzec, który się nie zmienia 13
- 3.5 Salience: jak wygląda błąd oktawowy w liczbach 14

4 Wektory i macierze **16**
- 4.1 Dlaczego algebra liniowa? 16
- 4.2 Wektor i iloczyn skalarny 16
- 4.3 Macierz jako przekształcenie 18
- 4.4 Ile parametrów ma warstwa? 19

5 Pochodne, gradient i propagacja wsteczna **21**
- 5.1 Jak poprawić model, który się myli? 21
- 5.2 Pochodna funkcji jednej zmiennej 21
- 5.3 Gradient i spadek gradientu 23
- 5.4 Propagacja wsteczna na jednym neuronie 24

6 Transformata Fouriera: z drgań do widma **27**
- 6.1 Co jest w tym nagraniu? 27
- 6.2 Liczby zespolone w dwóch zdaniach 27
- 6.3 Dyskretna transformata Fouriera 27
- 6.4 Przeciek i okno 28
- 6.5 Rozdzielczość: kiedy dwa dźwięki są jednym 30

7 HCQT: widmo ułożone harmonicznie **33**

7.1 Pomysł: niech każdy kandydat widzi swoje alikwoty w jednym miejscu 33
7.2 Biny logarytmiczne i alikwoty 33
7.3 Decybele i normalizacja 34
7.4 Kanały to przesunięte kopie jednego widma 35
7.5 Co dokładnie dostaje sieć 36

8 Prawdopodobieństwo i funkcje straty 38
8.1 Jak powiedzieć modelowi, że się myli? 38
8.2 Sigmoida i softmax 38
8.3 Entropia krzyżowa 39
8.4 Dlaczego rzadkie etykiety są trudne 41
8.5 Softmax i tabulatura 42

9 Sieć neuronowa: warstwy, konwolucja i normalizacja 43
9.1 Z czego zbudowana jest sieć? 43
9.2 Nieliniowość: po co i jaka 43
9.3 Konwolucja 43
9.4 Normalizacja warstwy i połączenia resztkowe 46

10 Uwaga (attention) 49
10.1 Czemu konwolucja nie wystarcza? 49
10.2 Uwaga pojedynczego zapytania 49
10.3 Dlaczego dzielimy przez $\sqrt{d}$ 50
10.4 Uwaga dla całej sekwencji i premie położenia 50
10.5 Wiele głowic i liczba parametrów 52

11 Optymalizacja: jak sieć się uczy 54
11.1 Od gradientu do działającego uczenia 54
11.2 Kiedy spadek gradientu się zbiega? 54
11.3 SGD i jego szum 55
11.4 Adam i AdamW 56
11.5 Harmonogram kroku 57

1 Zapis, tensory i logarytm

1.1 Po co ten rozdział?

Model, któremu poświęcona jest ta książka, bierze nagranie gitary i zwraca listę nut. W środku nie dzieje się nic magicznego: to ciąg operacji na tablicach liczb. Zanim opiszemy te operacje, musimy się umówić, jak zapisywać tablice, sumy i funkcje. Ten rozdział jest krótką umową o języku. Kto zna sumy, indeksy i logarytmy, może go przejrzeć i przejść do rozdziału 2; wszystko, co tu zdefiniujemy, jest używane do końca książki.

Po tym rozdziale umiesz: (i) odczytać kształt tensora i policzyć, ile ma liczb, (ii) zapisać złożenie funkcji jako ciąg kroków, (iii) uzasadnić, dlaczego logarytm zamienia mnożenie na dodawanie.

1.2 Sumy i indeksy

suma

Definicja 1.1 (Suma). Dla liczb $a_1, a_2, \dots, a_n$ zapis

$$\sum_{i=1}^{n} a_i \;=\; a_1 + a_2 + \cdots + a_n \tag{1.1}$$

oznacza ich sumę. Literę i nazywamy *indeksem*; może być dowolna, bo znika po rozpisaniu sumy. Gdy $n = 0$, suma jest pusta i wynosi 0.

Przykład 1.1. $\sum_{i=1}^{4} i^2 = 1+4+9+16 = 30$. Ta sama suma zapisana z indeksem k od 0 do 3 wygląda $\sum_{k=0}^{3} (k+1)^2$ i też daje 30. Zmiana nazwy indeksu ani jego zakresu (z odpowiednim przesunięciem we wzorze) nie zmienia wyniku.

Intuicja. Znak $\sum$ to pętla `for`, która dodaje: `s=0; for i in range(1,n+1): s+=a[i]`. W kodzie indeksy zaczynają się od 0, w matematyce od 1; w tej książce zawsze powiemy, od czego. ♢

Sumy będą nam potrzebne wszędzie: iloczyn skalarny to suma iloczynów, średnia to suma podzielona przez liczbę elementów, a strata modelu to średnia po tysiącach klatek.

Twierdzenie 1.2 (Liniowość sumy). *Dla dowolnych liczb a_i, b_i i stałej c zachodzi*

$$\sum_{i=1}^{n} (c\,a_i + b_i) = c \sum_{i=1}^{n} a_i + \sum_{i=1}^{n} b_i. \tag{1.2}$$

Pomysł dowodu. Rozpisujemy sumę na składniki i korzystamy z przemienności oraz rozdzielności dodawania.

Dowód.

$$\begin{aligned}\sum_{i=1}^{n}(c\,a_i+b_i) &= (c\,a_1+b_1)+(c\,a_2+b_2)+\cdots+(c\,a_n+b_n) && \text{(def. sumy)}\\ &= (c\,a_1+\cdots+c\,a_n)+(b_1+\cdots+b_n) && \text{(zmiana kolejności)}\\ &= c\,(a_1+\cdots+a_n)+(b_1+\cdots+b_n) && \text{(rozdzielność)}\\ &= c\sum_{i=1}^{n}a_i+\sum_{i=1}^{n}b_i. && \text{(def. sumy)}\end{aligned}$$

Każdy krok zmienia tylko zapis albo kolejność dodawania, więc równość zachodzi. ■

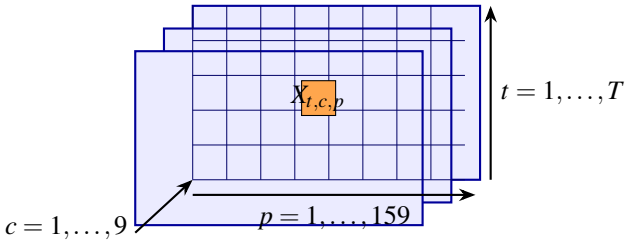
W zwykłym języku: stałą wolno wyciągnąć przed sumę, a sumę sum wolno rozbić. Użyjemy tego, gdy będziemy liczyć pochodną straty (rozdział 5).

1.3 Wektory, macierze i tensory

tensor

Definicja 1.3 (Tensor i jego kształt). *Tensorem* nazywamy tablicę liczb rzeczywistych indeksowaną jedną lub kilkoma liczbami całkowitymi. Liczba indeksów to *rząd* tensora. Ciąg długości zakresów indeksów to *kształt*. Tensor rzędu 1 to *wektor*, rzędu 2 to *macierz*. Zapis $X \in \mathbb{R}^{n_1\times n_2\times\cdots\times n_r}$ oznacza tensor kształtu $(n_1,\ldots,n_r)$; ma on $n_1 n_2\cdots n_r$ liczb.

Przykład 1.2 (Cechy jednego nagrania). Model Gen 6 zamienia nagranie na tensor $X \in \mathbb{R}^{T\times 9\times 159}$ (rozdział 7): T klatek czasu, 9 kanałów i 159 binów częstotliwości. Nagranie trwające 6 sekund daje $T = 243$ klatek, więc X ma $243\cdot 9\cdot 159 = 347\,733$ liczb. Element $X_{t,c,p}$ to liczba z klatki t, kanału c i binu p.



Rysunek 1.1: Tensor $X \in \mathbb{R}^{T\times 9\times 159}$ jako stos dziewięciu macierzy (kanałów) o T wierszach i 159 kolumnach. Pomarańczowy kwadracik to jeden element $X_{t,c,p}$; trzy indeksy jednoznacznie wskazują jedną liczbę.

Pułapka. Kształt (T,C,P) i kształt (C,T,P) to dwa różne tensory, nawet gdy mają tyle samo liczb. W kodzie PyTorch sieć dostaje tensor $[B,C,T,P]$ (paczka, kanały, czas, biny), a cechy zapisujemy jako $[T,C,P]$. Zawsze sprawdzaj kształt przed operacją; błąd w kolejności osi daje poprawnie działający program z bezsensownym wynikiem. ♢

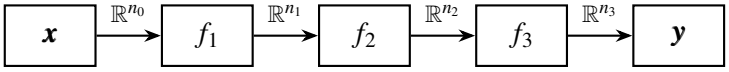
1.4 Funkcje i ich składanie

złożenie funkcji

Definicja 1.4 (Funkcja i złożenie). *Funkcja* $f\colon A\to B$ przypisuje każdemu elementowi zbioru A dokładnie jeden element zbioru B. *Złożeniem* funkcji $f\colon A\to B$ i $g\colon B\to C$ jest funkcja $g\circ f\colon A\to C$, $(g\circ f)(x) = g(f(x))$.

Przykład 1.3. Niech $f(x) = 2x$ i $g(x) = x + 3$. Wtedy $(g \circ f)(5) = g(10) = 13$, a $(f \circ g)(5) = f(8) = 16$. Kolejność ma znaczenie: złożenie nie jest przemienne.

Intuicja. Cały model Gen 6 to jedno długie złożenie model $= f_n \circ \cdots \circ f_2 \circ f_1$: cechy wchodzą do pierwszej warstwy, jej wynik do drugiej itd. W rozdziale **??** rozpiszemy je w całości. Dlatego ważne jest, by każda warstwa miała jasno określone wejście i wyjście: ich kształty muszą do siebie pasować. ♢



Rysunek 1.2: Złożenie trzech funkcji $\boldsymbol{y} = f_3(f_2(f_1(\boldsymbol{x})))$. Nad strzałkami stoją przestrzenie, w których żyje wynik każdego kroku; wyjście jednej funkcji musi mieć kształt wejścia następnej.

1.5 Potęgi i logarytm

Wysokość dźwięku, głośność w decybelach i położenie binu na osi częstotliwości są w tej książce mierzone *logarytmicznie*. Powód zobaczymy w rozdziale 2; tu przypominamy narzędzie.

logarytm

Definicja 1.5 (Logarytm). Dla $b > 0$, $b \neq 1$ i $x > 0$ *logarytmem* $\log_b x$ nazywamy jedyną liczbę y, dla której $b^y = x$. Logarytm przy podstawie e oznaczamy $\ln x$, a przy podstawie 10 po prostu $\log_{10} x$.

Przykład 1.4. $\log_2 8 = 3$, bo $2^3 = 8$. $\log_2 \frac{1}{2} = -1$, bo $2^{-1} = \frac{1}{2}$. $\log_2 3 \approx 1{,}585$, bo $2^{1{,}585} \approx 3$. Logarytmu z liczby niedodatniej nie ma, bo żadna potęga liczby dodatniej nie jest ujemna ani zerowa.

Twierdzenie 1.6 (Logarytm iloczynu). *Dla $x, y > 0$ zachodzi $\log_b(xy) = \log_b x + \log_b y$ oraz $\log_b(x^k) = k \log_b x$ dla każdej liczby rzeczywistej k.*

Pomysł dowodu. Zamieniamy x i y na potęgi podstawy b i dodajemy wykładniki.

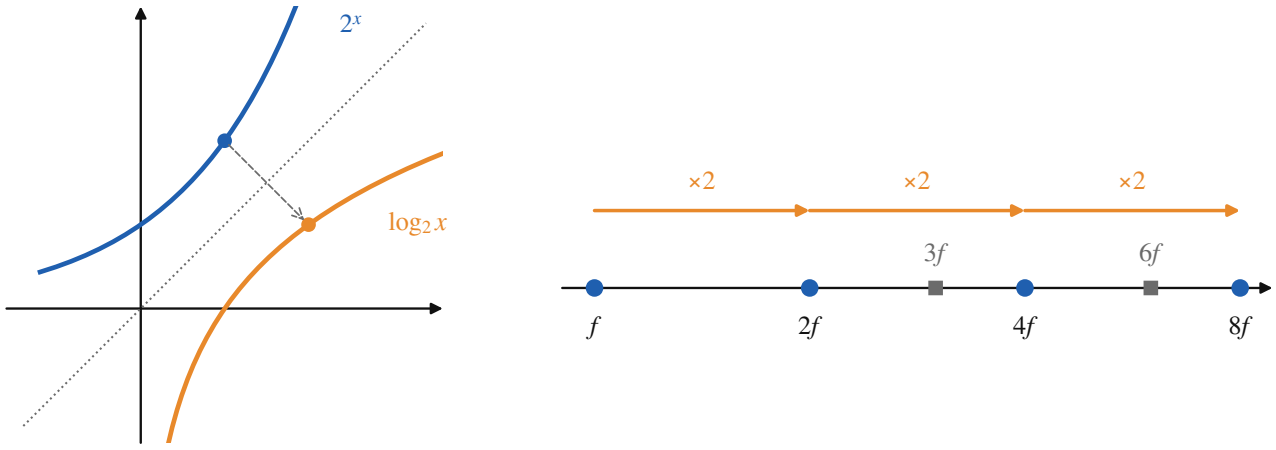
Dowód. Niech $u = \log_b x$ i $v = \log_b y$, czyli $x = b^u$ i $y = b^v$. Wtedy

$$\begin{aligned} xy &= b^u b^v = b^{u+v} && \text{(wykładniki się dodają)} \\ \log_b(xy) &= u + v = \log_b x + \log_b y && \text{(def. 1.5)} \end{aligned}$$

Dla potęgi: $x^k = (b^u)^k = b^{uk}$, więc $\log_b(x^k) = uk = k \log_b x$. ■

Zdanie ludzkim językiem: logarytm zamienia *mnożenie* na *dodawanie*. Mnożenie częstotliwości przez 2 (oktawa wyżej) staje się dodaniem stałej 1 do $\log_2 f$, bez względu na to, od jakiej częstotliwości zaczynamy (rys. 1.3b). To jest sedno całej książki.

Na konkretnych liczbach. Ile wynosi $\log_2 12$? Zapisujemy $12 = 3 \cdot 2^2$ i stosujemy twierdzenie 1.6: $\log_2 12 = \log_2 3 + 2 \log_2 2 = 1{,}585 + 2 = 3{,}585$. Sprawdzenie: $2^{3{,}585} \approx 12{,}0$. Ta sztuczka (rozbicie na iloczyn



(a) (b)

Rysunek 1.3: (a) Funkcje 2^x (niebieska) i $\log_2 x$ (pomarańczowa) są swoimi lustrzanymi odbiciami względem prostej $y = x$ (kropkowana): odbicie punktu $(2,4)$ to $(4,2)$. (b) Na osi logarytmicznej kolejne podwojenia $f, 2f, 4f, 8f$ leżą w równych odstępach (pomarańczowe strzałki mają tę samą długość); punkty $3f$ i $6f$ też dzieli dokładnie jeden taki krok, bo $\log_2 6 - \log_2 3 = 1$.

znanych czynników) pozwoli nam w rozdziale 3 policzyć, ile półtonów leży nad daną nutą jej trzeci alikwot.

Twierdzenie 1.7 (Zmiana podstawy). *Dla $a, b > 0$, $a, b \neq 1$ i $x > 0$ zachodzi* $\log_b x = \dfrac{\log_a x}{\log_a b}$.

Pomysł dowodu. Logarytmujemy obie strony równości $x = b^{\log_b x}$ przy podstawie a.

Dowód. Niech $y = \log_b x$, czyli $x = b^y$. Stosujemy $\log_a$ do obu stron:

$$\begin{aligned} \log_a x &= \log_a\left(b^y\right) && \text{(podstawienie)} \\ &= y \log_a b && \text{(tw. 1.6)} \\ \Rightarrow\ y &= \frac{\log_a x}{\log_a b}. && \text{(dzielimy przez } \log_a b \neq 0) \end{aligned}$$

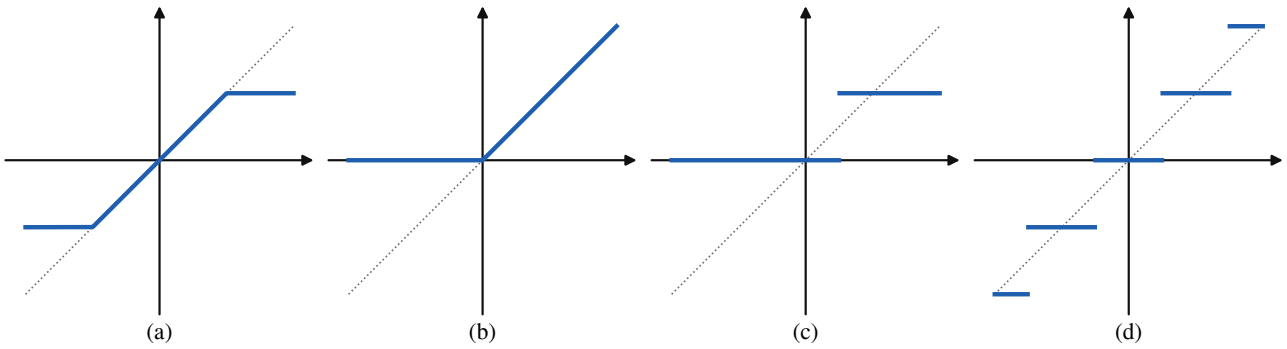
Ponieważ $y = \log_b x$, to jest dokładnie dowodzony wzór. ■

W praktyce: kalkulator ma zwykle tylko ln i $\log_{10}$, więc $\log_2 x = \ln x / \ln 2$. W programie `np.log2(x)` daje to samo.

1.6 Funkcje pomocnicze

W modelu pojawi się kilka prostych funkcji, które warto poznać od razu.

zapis	znaczenie	przykład
$\mathrm{clip}(x, a, b)$	$\min(\max(x, a), b)$	$\mathrm{clip}(1{,}7; 0; 1{,}3) = 1{,}3$
$\max_i a_i$	największa z liczb	$\max(2,5,3) = 5$
$\arg\max_i a_i$	*numer* największej	$\arg\max(2,5,3) = 2$ (od 1)
$\mathbb{1}[\text{warunek}]$	1, gdy prawda, inaczej 0	$\mathbb{1}[3 > 2] = 1$
$\mathrm{round}(x)$	najbliższa całkowita	$\mathrm{round}(35{,}07) = 35$
$\lfloor x \rfloor$	część całkowita w dół	$\lfloor 2{,}9 \rfloor = 2$



Rysunek 1.4: Cztery proste funkcje jednej zmiennej na tle prostej $y = x$ (kropkowana). (a) $\mathrm{clip}(x, -1, 1)$ przycina wartości do przedziału. (b) $\max(0, x)$, czyli ReLU, zeruje wartości ujemne. (c) Wskaźnik $\mathbb{1}\left[x \geq \frac{1}{2}\right]$ jest równy 1 albo 0. (d) $\mathrm{round}(x)$ zaokrągla do najbliższej całkowitej. Funkcje (c) i (d) mają skoki, więc nie da się ich używać w uczeniu przez gradient; dlatego dekoder w rozdziale **??** jest poza siecią.

Pułapka. arg max zwraca *miejsce*, a max *wartość*. Pomylenie ich jest tak częste, że w kodzie dekodera (rozdział **??**) wybór struny to arg max po strunach, a pewność nuty to max. ♢

Podsumowanie

- Suma $\sum$ to pętla dodająca; stałą wolno wyciągnąć przed sumę (tw. 1.2).
- Tensor to tablica liczb o kształcie $(n_1, \ldots, n_r)$; cechy modelu to $X \in \mathbb{R}^{T \times 9 \times 159}$.
- Model to złożenie funkcji; kształty wyjść i wejść muszą do siebie pasować.
- Logarytm zamienia mnożenie na dodawanie, a podwojenie częstotliwości na stały krok (tw. 1.6).
- clip, max, arg max, wskaźnik i zaokrąglenie to cegiełki dekodera i normalizacji cech.

Ćwiczenia

1. Policz $\sum_{i=1}^{5}(2i-1)$ i podaj wynik w prostszej postaci. (Wskazówka: tw. 1.2 oraz $\sum i = n(n+1)/2$.)
2. Ile liczb ma tensor kształtu $[16, 9, 192, 159]$ (paczka 16 wycinków po 192 klatki)? Ile to megabajtów w formacie `float16` (2 bajty na liczbę)?
3. Policz $\log_2 48$ i $\log_2 \sqrt{2}$ bez kalkulatora, znając $\log_2 3 \approx 1{,}585$.
4. Czy $\log_b(x+y) = \log_b x + \log_b y$? Podaj kontrprzykład liczbowy.

Rozwiązania

1. $\sum_{i=1}^{5}(2i-1) = 2 \cdot 15 - 5 = 25$ (suma pierwszych n nieparzystych to n^2); sprawdzenie: $1+3+5+7+9 = 25$.
2. $16 \cdot 9 \cdot 192 \cdot 159 = 4\,396\,032$ liczb, czyli $\approx 8{,}8$ MB w `float16`.
3. $48 = 3 \cdot 2^4$, więc $\log_2 48 = 1{,}585 + 4 = 5{,}585$; $\log_2 \sqrt{2} = \frac{1}{2}$.
4. Nie. Dla $b = 2$ i $x = y = 4$ mamy $\log_2(4+4) = \log_2 8 = 3$, a $\log_2 4 + \log_2 4 = 2+2 = 4$. Prawdziwy jest wzór na *iloczyn*: $\log_2(4 \cdot 4) = \log_2 16 = 4$.

2 Dźwięk, próbkowanie i wysokość

2.1 Od drgania do liczb

Struna gitary drga, pudło przekazuje drgania powietrzu, mikrofon zamienia zmiany ciśnienia na napięcie, a komputer zapisuje to napięcie jako ciąg liczb. Cała wiedza, jaką model ma o nagraniu, to ten ciąg liczb. Żeby ją wydobyć, trzeba najpierw zrozumieć dwie rzeczy: czym jest wysokość dźwięku i co się traci przy zamianie fali ciągłej na liczby.

Po tym rozdziale umiesz: (i) policzyć częstotliwość dowolnej nuty z jej numeru MIDI, (ii) zmierzyć odstęp dwóch dźwięków w centach, (iii) uzasadnić, dlaczego model pracuje przy 11 025 Hz i nie widzi wyższych częstotliwości niż 5512,5 Hz, (iv) policzyć, ile klatek ma nagranie.

2.2 Sinusoida

częstotliwość

Definicja 2.1 (Sinusoida, częstotliwość, okres). *Sinusoidą* nazywamy sygnał $x(t) = A\sin(2\pi ft + \varphi)$ zmiennej t (czas w sekundach). Liczba $A \geq 0$ to *amplituda*, f to *częstotliwość* w hercach (1 Hz = jeden pełny obieg na sekundę), a φ to *faza*. Sygnał powtarza się co $T = 1/f$ sekund; T nazywamy *okresem*.

Przykład 2.1. Strojowe A (nuta A4) ma $f = 440\,\text{Hz}$, więc okres $T = 1/440 \approx 2{,}27\,\text{ms}$. W ciągu jednej sekundy powietrze wykonuje 440 pełnych drgań. Dla sinusoidy $x(t) = 0{,}5\sin(2\pi \cdot 440t)$ największe wychylenie wynosi 0,5 i powtarza się co 2,27 ms.

Intuicja. Sinusoida to ruch punktu po okręgu oglądany z boku: faza mówi, skąd zaczynamy, a częstotliwość, ile obiegów robimy na sekundę. Każdy dźwięk muzyczny to suma sinusoid; w rozdziale 3 zobaczymy, że nuta gitary to sinusoida f_0 i jej całkowite wielokrotności. ♢

2.3 Próbkowanie

Komputer nie widzi sygnału w każdej chwili, tylko co ułamek sekundy.

próbkowanie

Definicja 2.2 (Próbkowanie). Dla sygnału $x(t)$ i *częstotliwości próbkowania* f_s ciąg próbek to $x[n] = x(n/f_s)$ dla $n = 0, 1, 2, \ldots$. Jedna próbka to jedna liczba; nagranie trwające τ sekund ma $N = \tau f_s$ próbek.

Przykład 2.2. Płyta CD ma $f_s = 44\,100$ Hz, więc minuta dźwięku to $60 \cdot 44\,100 = 2\,646\,000$ liczb. Model Gen 6 zmienia próbkowanie nagrania na $f_s = 11\,025$ Hz (dokładnie ćwierć 44 100): 6 sekund to $N = 66\,150$ próbek.

Pojawia się pytanie: ile informacji tracimy? Okazuje się, że dwie różne sinusoidy mogą dać *identyczne* próbki.

Twierdzenie 2.3 (Aliasing). *Niech $f_s > 0$. Dla każdej liczby całkowitej k sinusoidy o częstotliwościach f i $f + kf_s$ mają te same próbki. Ponadto sinusoidy $\sin(2\pi ft)$ i $-\sin(2\pi(f_s - f)t)$ mają te same próbki. W szczególności sygnały o częstotliwościach powyżej $f_s/2$ są nierozróżnialne od sygnałów o częstotliwościach poniżej $f_s/2$.*

Pomysł dowodu. Wstawiamy $t = n/f_s$ i korzystamy z tego, że sinus ma okres 2π, a n jest całkowite.

Dowód. Dla $t = n/f_s$ i $k \in \mathbb{Z}$:

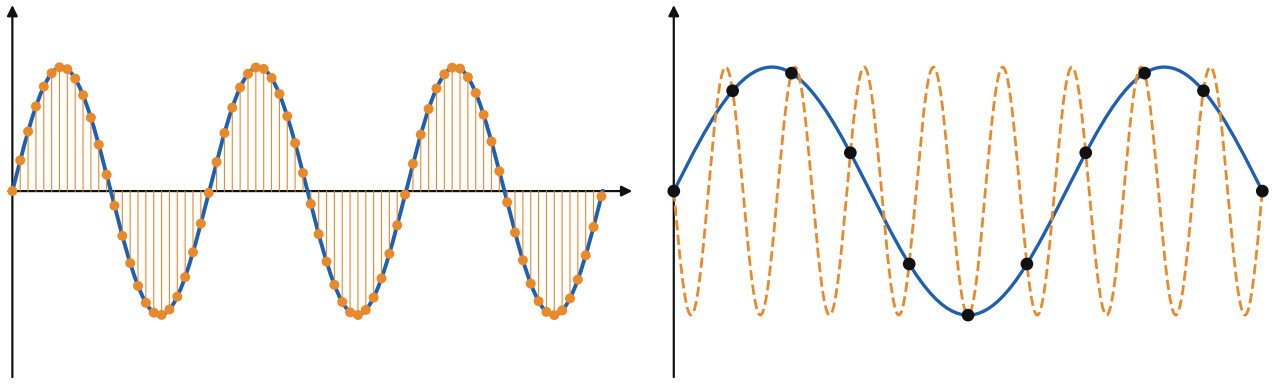
$$\begin{aligned} \sin\big(2\pi(f + kf_s)\tfrac{n}{f_s}\big) &= \sin\big(2\pi f\tfrac{n}{f_s} + 2\pi kn\big) && \text{(rozdzielność)} \\ &= \sin\big(2\pi f\tfrac{n}{f_s}\big) && (kn \in \mathbb{Z}\text{, okres } 2\pi) \end{aligned}$$

To jest pierwsza część. Dla drugiej częstotliwość $f_s - f$ daje

$$\begin{aligned} \sin\big(2\pi(f_s - f)\tfrac{n}{f_s}\big) &= \sin\big(2\pi n - 2\pi f\tfrac{n}{f_s}\big) && \text{(wymnożenie)} \\ &= -\sin\big(2\pi f\tfrac{n}{f_s}\big) && \text{(nieparzystość sinusa, okres)} \end{aligned}$$

Zatem $-\sin(2\pi(f_s - f)n/f_s) = \sin(2\pi fn/f_s)$. Skoro każda częstotliwość większa niż $f_s/2$ ma postać $f_s - f$ z $f < f_s/2$ (po odjęciu odpowiedniej wielokrotności f_s), jej próbki zgadzają się z próbkami niższej częstotliwości. To kończy dowód. ∎

W zwykłym języku: przy próbkowaniu f_s da się odróżnić tylko częstotliwości z przedziału $[0, f_s/2]$; wyższe „zawijają się” w niższe (rys. 2.1b). Liczbę $f_s/2$ nazywamy *częstotliwością Nyquista*.



(a) (b)

Rysunek 2.1: (a) Sinusoida 440 Hz (niebieska) i jej próbki przy $f_s = 11\,025$ Hz (pomarańczowe kropki): około 25 próbek na okres. (b) Aliasing: niebieska sinusoida $0{,}15 f_s$ i pomarańczowa przerywana $-\sin$ o częstotliwości $0{,}85 f_s$ przechodzą przez te same punkty (czarne kropki), więc po spróbkowaniu nie da się ich rozróżnić.

Na konkretnych liczbach. Przy $f_s = 11\,025$ Hz częstotliwość Nyquista wynosi 5512,5 Hz. Najwyższa nuta, którą obsługuje Gen 6, to MIDI 88 (1318,5 Hz). Jej trzeci alikwot (3955,5 Hz) jest jeszcze poniżej Nyquista, ale szósty (7911 Hz) już nie. Dlatego HCQT (rozdział 7) zeruje kanały, w których alikwot wypada powyżej $0{,}46 f_s = 5071{,}5$ Hz: tam i tak nie ma wiarygodnej informacji.

Pułapka. Nie można „odzyskać” wysokich częstotliwości po zmniejszeniu f_s. Przy zmianie próbkowania nagrania z 44 100 na 11 025 Hz trzeba najpierw odfiltrować wszystko powyżej 5512,5 Hz; inaczej aliasing wmiesza wysokie dźwięki w niskie i sieć zobaczy „duchy”, których w nagraniu nie było. ♢

2.4 Półtony, MIDI i centy

Ucho nie słyszy różnicy częstotliwości, tylko ich *stosunek*: oktawa to zawsze podwojenie. Dlatego muzycy dzielą oktawę na 12 równych *stosunkowo* kroków (półtonów).

półton

Definicja 2.4 (Skala równomiernie temperowana i numer MIDI). Nutom przypisujemy numery $m \in \mathbb{Z}$ (*numer MIDI*) tak, że $m = 69$ to A4 o częstotliwości 440 Hz, a kolejne numery różnią się o jeden półton: stosunek częstotliwości sąsiednich nut jest stały, a po 12 krokach częstotliwość się podwaja. Częstotliwość nuty m oznaczamy $f(m)$.

Twierdzenie 2.5 (Wzór na częstotliwość nuty). *Stosunek częstotliwości sąsiednich półtonów wynosi* $2^{1/12} \approx 1{,}0595$ *oraz*

$$f(m) = 440 \cdot 2^{(m-69)/12}. \tag{2.1}$$

Pomysł dowodu. Stały stosunek r i podwojenie po 12 krokach dają $r^{12} = 2$; reszta to kolejne mnożenie przez r.

Dowód. Niech $r = f(m+1)/f(m)$ będzie stałe dla każdego m. Z definicji 2.4 po dwunastu krokach częstotliwość się podwaja:

$$\begin{aligned} f(m+12) &= r^{12} f(m) && \text{(12 mnożeń przez } r\text{)} \\ &= 2 f(m) && \text{(oktawa)} \end{aligned}$$

Stąd $r^{12} = 2$, czyli $r = 2^{1/12}$ (jedyne dodatnie rozwiązanie). Kolejne mnożenie przez r od $m = 69$ daje $f(m) = f(69)\, r^{m-69} = 440 \cdot 2^{(m-69)/12}$, także dla $m < 69$ (dzielenie przez r). To kończy dowód. ■

struna	6	5	4	3	2	1
nuta	E2	A2	D3	G3	B3	E4
numer MIDI m	40	45	50	55	59	64
$f(m)$ [Hz]	82,41	110,00	146,83	196,00	246,94	329,63

Tabela 2.1: Struny gitary w stroju standardowym i ich częstotliwości z wzoru (2.1).

Przykład 2.3 (Częstotliwość najniższej struny). Struna E2 ma $m = 40$, więc $f(40) = 440 \cdot 2^{(40-69)/12} = 440 \cdot 2^{-29/12} \approx 82{,}41\,\text{Hz}$. Sprawdzenie: E2 leży dwie oktawy ($64 - 40 = 24 = 2 \cdot 12$ półtonów) pod E4, więc $f = 329{,}63/2^2 = 82{,}41\,\text{Hz}$.

Odstępy mniejsze niż półton mierzymy w *centach*: półton ma 100 centów.

cent

Definicja 2.6 (Cent). Odstęp dwóch dźwięków o częstotliwościach f_1 i f_2 wynosi

$$c = 1200 \log_2 \frac{f_2}{f_1} \quad \text{centów.} \tag{2.2}$$

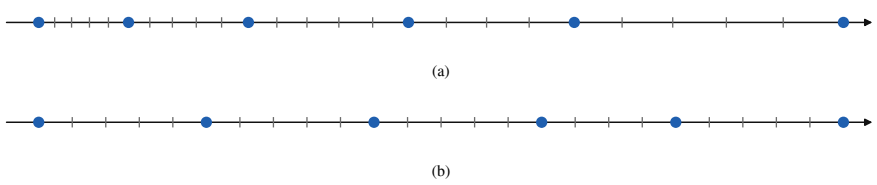
Przykład 2.4. Czysta kwinta ($f_2/f_1 = 3/2$) to $1200 \log_2 1{,}5 = 701{,}96$ centa, czyli prawie dokładnie 7 półtonów (700). Struna rozstrojona z 440 do 445 Hz jest podwyższona o $1200 \log_2(445/440) \approx 19{,}6$ centa.

Wniosek 2.7 (Centy się dodają). *Jeśli c_{12} to odstęp od f_1 do f_2, a c_{23} od f_2 do f_3, to odstęp od f_1 do f_3 wynosi $c_{12} + c_{23}$. Odstęp jednego półtonu to* 100 *centów.*

Dowód.

$$\begin{aligned} c_{12} + c_{23} &= 1200 \log_2 \frac{f_2}{f_1} + 1200 \log_2 \frac{f_3}{f_2} && \text{(def. 2.6)} \\ &= 1200 \log_2 \left(\frac{f_2}{f_1} \cdot \frac{f_3}{f_2} \right) && \text{(tw. 1.6)} \\ &= 1200 \log_2 \frac{f_3}{f_1}. && \text{(skrócenie } f_2\text{)} \end{aligned}$$

Dla półtonu $f_2/f_1 = 2^{1/12}$, więc $c = 1200 \cdot \frac{1}{12} \log_2 2 = 100$. Odstępy dodają się jak długości odcinków na osi $\log_2 f$. ∎



Rysunek 2.2: Nuty od E2 do E4 (kreski) i sześć strun (niebieskie kropki). (a) Na osi liniowej częstotliwości odstępy między półtonami rosną: ostatni jest ok. 3,8 raza większy niż pierwszy ($2^{23/12}$), więc niskie nuty tłoczą się przy zerze. (b) Na osi $\log_2 f$ wszystkie półtony są równo oddalone o $1/12$ (z tw. 1.6). Dlatego model liczy bliskość nut w półtonach, a nie w hercach.

W modelu Gen 6 jedna nuta ma 3 biny na półton, czyli bin to $100/3 \approx 33{,}3$ centa. Ewaluacja uznaje wysokość za poprawną, jeśli różni się od wzorca o mniej niż 50 centów (ćwierć tonu) — to ok. półtora biną.

2.5 Klatki czasu

Model nie analizuje całego nagrania naraz, tylko *klatkami*: co h próbek (krok, ang. *hop*) bierze okno długości N_w próbek i liczy z niego widmo (rozdział 6).

Przykład 2.5 (Liczba klatek). Gen 6 używa okna $N_w = 4096$ próbek (371,5 ms) i kroku $h = 256$ próbek (23,2 ms). Okno mieści się w nagraniu o N próbkach dla $t = 0, \ldots, \lfloor (N - N_w)/h \rfloor$, więc $T = \lfloor (N - N_w)/h \rfloor + 1$. Dla $N = 66\,150$ (6 s): $T = \lfloor 62\,054/256 \rfloor + 1 = 242 + 1 = 243$ klatki.

Ćwiczenia

1. Oblicz częstotliwość nuty $m = 52$ (E3) i nuty $m = 76$. Ile półtonów i ile centów dzieli E3 od E2?
2. Nuta ma częstotliwość $f_1 = 200\,\text{Hz}$, a druga $f_2 = 206\,\text{Hz}$. Ile centów je dzieli? Czy mieści się w tolerancji 50 centów?
3. Sinusoida 7000 Hz jest próbkowana przy $f_s = 11\,025\,\text{Hz}$. Jaką częstotliwość zobaczy komputer? Skorzystaj z tw. 2.3.
4. Nagranie ma $N = 11\,025 \cdot 30$ próbek. Ile klatek T daje okno 4096 z krokiem 256?

Rozwiązania

1. $f(52) = 440 \cdot 2^{-17/12} = 164{,}81\,\text{Hz}$ oraz $f(76) = 440 \cdot 2^{7/12} = 659{,}26\,\text{Hz}$. E3 jest 12 półtonów, czyli 1200 centów, nad E2 (stosunek $164{,}81/82{,}41 = 2$).
2. $c = 1200 \log_2(206/200) = 1200 \cdot 0{,}0426 = 51{,}2$ centa, czyli o włos powyżej tolerancji 50.
3. $f_s - 7000 = 4025\,\text{Hz}$ (z drugiej części twierdzenia; znak jest przeciwny). Komputer zobaczy ton 4025 Hz w przeciwnej fazie.
4. $N = 330\,750$ i $(330\,750 - 4096)/256 = 1275{,}99\ldots$, więc $T = 1275 + 1 = 1276$ klatek.

3 Struna gitary i alikwoty

3.1 Dlaczego nuta to nie jedna sinusoida?

Gdy zagramy na gitarze nutę A2, w nagraniu nie ma jednej sinusoidy 110 Hz. Jest cały szereg sinusoid: 110, 220, 330, 440… Hz. Te dodatkowe składowe nazywamy *alikwotami* (harmonicznymi). To one nadają instrumentowi barwę, ale też sprawiają największy kłopot w transkrypcji: alikwoty jednej nuty lądują dokładnie tam, gdzie leżą *inne* nuty. Ten rozdział wyjaśnia, skąd się biorą i dlaczego na osi logarytmicznej wyglądają jak niezmienny wzorzec — na tym wzorcu opiera się pierwszy blok sieci Gen 6.

Po tym rozdziale umiesz: (i) uzasadnić, że struna drga z częstotliwościami kf_0, (ii) wskazać, które nuty dzielą alikwoty, (iii) policzyć położenie h-tego alikwotu w półtonach i binach, (iv) wyjaśnić, skąd bierze się błąd oktawowy.

3.2 Drgania własne struny

Struna o długości L jest zamocowana na obu końcach. Jej wychylenie $u(x,t)$ w punkcie $x \in [0,L]$ i chwili t spełnia równanie falowe $u_{tt} = v^2 u_{xx}$, gdzie v to prędkość fali na strunie (zależy od naciągu i masy), oraz warunki brzegowe $u(0,t) = u(L,t) = 0$.

fala stojąca

Definicja 3.1 (Fala stojąca (tryb własny)). *Falą stojącą* nazywamy rozwiązanie równania falowego postaci $u(x,t) = \phi(x)\cos(2\pi f t)$, w którym kształt $\phi(x)$ nie zmienia się w czasie, tylko jego wychylenie pulsuje z częstotliwością f.

Twierdzenie 3.2 (Częstotliwości własne struny). *Funkcje*

$$u_k(x,t) = \sin\Big(\frac{k\pi x}{L}\Big)\cos(2\pi f_k t), \qquad k = 1,2,3,\ldots,$$

są falami stojącymi spełniającymi równanie falowe i warunki brzegowe wtedy i tylko wtedy, gdy

$$f_k = k\,\frac{v}{2L} = k f_1. \tag{3.1}$$

Pomysł dowodu. Wstawiamy u_k do równania $u_{tt} = v^2 u_{xx}$, policzymy obie drugie pochodne i porównamy współczynniki.

Dowód. Warunki brzegowe są spełnione, bo $\sin(0) = 0$ oraz $\sin(k\pi) = 0$ dla całkowitego k. Liczymy pochodne (wzory $(\sin ax)'' = -a^2 \sin ax$ i $(\cos bt)'' = -b^2 \cos bt$ są znane ze szkoły):

$$u_{tt} = -(2\pi f_k)^2 u_k, \qquad \text{(po czasie)}$$
$$u_{xx} = -\big(\tfrac{k\pi}{L}\big)^2 u_k. \qquad \text{(po położeniu)}$$

Równanie $u_{tt} = v^2 u_{xx}$ jest więc równoważne $(2\pi f_k)^2 = v^2 (k\pi/L)^2$, czyli $2\pi f_k = vk\pi/L$, skąd $f_k = kv/(2L)$ (bierzemy dodatni pierwiastek, bo $f_k > 0$). Dla dowolnego innego f równość nie zachodzi, więc $f = f_k$ jest warunkiem koniecznym i wystarczającym. Struna może więc drgać z częstotliwościami będącymi całkowitymi wielokrotnościami najniższej z nich. To kończy dowód. ■

Że *każde* drganie struny jest sumą takich fal, orzekł Daniel Bernoulli (rozwinięcie w szereg Fouriera; dowód wykracza poza zakres tej książki). Dlatego nuta gitary to suma sinusoid:

$$x(t) = \sum_{h=1}^{H} A_h \sin\bigl(2\pi h f_0 t + \varphi_h\bigr), \qquad f_0 = f_1, \tag{3.2}$$

gdzie f_0 nazywamy *częstotliwością podstawową*, a składową $h = 2, 3, \dots$ *alikwotem* (dokładnie: h-tą *harmoniczną*). Amplitudy A_h zwykle maleją z h, ale nie znikają.

Przykład 3.1 (Najniższa struna). Struna E2 ($f_0 = 82{,}41\,\text{Hz}$) ma długość drgającą $L \approx 0{,}65\,\text{m}$. Z tw. 3.2 prędkość fali to $v = 2Lf_0 \approx 2 \cdot 0{,}65 \cdot 82{,}41 = 107{,}1$ m/s. Alikwoty $h = 1, \dots, 6$ mają częstotliwości 82,4; 164,8; 247,2; 329,6; 412,0; 494,4 Hz. Alikwot $h = 4$ (329,6 Hz) to dokładnie częstotliwość nuty E4 — najwyższej, otwartej struny.

Intuicja. Struna może drgać jako całość ($k = 1$), w dwóch połowach ($k = 2$), w trzech trzecich ($k = 3$) itd. Każdy sposób ma swoją częstotliwość i wszystkie występują naraz. Szarpnięcie w środku wzbudza głównie nieparzyste, przy końcu struny — bogatszy zestaw. ♢

Pułapka. Prawdziwa struna jest sztywna, więc jej alikwoty są *nieco wyższe* niż hf_0: $f_h \approx hf_0\sqrt{1 + Bh^2}$, gdzie $B \geq 0$ to współczynnik nieharmoniczności. Dla $B = 10^{-4}$ szósty alikwot jest za wysoki o $1200 \log_2 \sqrt{1 + 36 \cdot 10^{-4}} \approx 3{,}1$ centa, a dla $B = 10^{-3}$ o 30,6 centa, prawie cały bin. Dlatego blok harmoniczny w rozdziale **??** ma dodatkowy filtr po sąsiednich binach. ♢

3.3 Wspólne alikwoty: skąd błąd oktawowy

Twierdzenie 3.3 (Alikwoty oktawy). *Niech nuta A ma częstotliwość podstawową f_0, a nuta B częstotliwość $2f_0$ (oktawa wyżej). Wtedy każdy alikwot nuty B jest alikwotem nuty A: $h \cdot 2f_0 = (2h)\, f_0$. Odwrotnie nie: nieparzyste alikwoty A nie są alikwotami B.*

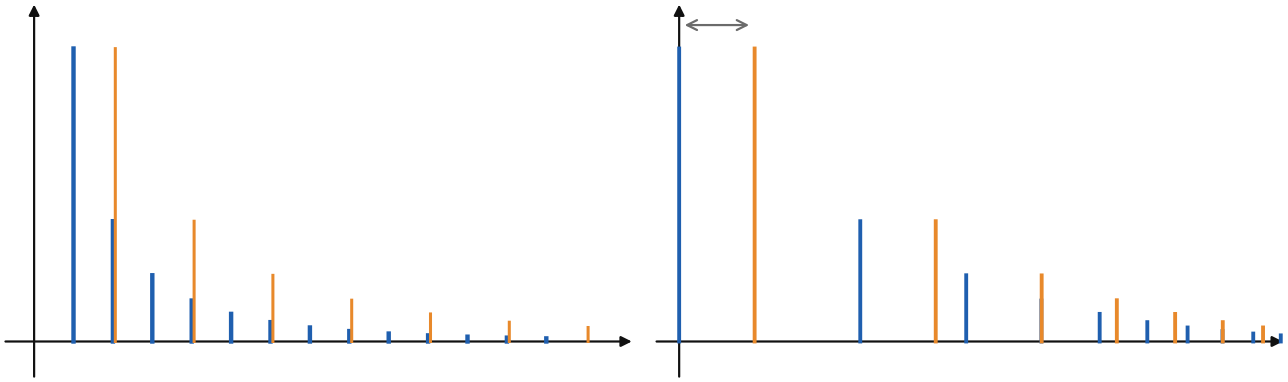
Pomysł dowodu. Wystarczy przepisać $h \cdot 2f_0$ jako $(2h)f_0$ i zauważyć, że $2h$ jest całkowite i parzyste.

Dowód. Niech $h \in \{1, 2, \dots\}$.

$$h \cdot (2f_0) = (2h) \cdot f_0 \qquad \text{(łączność mnożenia)}$$

Liczba $2h$ jest całkowita, więc $(2h)f_0$ to $2h$-ty alikwot nuty A. Natomiast $3f_0$ ($h = 3$ dla A) byłoby alikwotem B tylko dla h' spełniającego $h' \cdot 2f_0 = 3f_0$, czyli $h' = 1{,}5 \notin \mathbb{N}$. Zatem parzyste alikwoty A pokrywają się z alikwotami B, a nieparzyste nie. To kończy dowód. ■

W zwykłym języku: gdy gra E3, w widmie jest wszystko, co zgłosiłoby E2 — z wyjątkiem co drugiego prążka. A skoro wyższe alikwoty bywają słabe, E3 do złudzenia przypomina E2 z wyciszonym podstawowym tonem. To jest *błąd oktawowy*: najtrudniejsza pomyłka w transkrypcji gitary (w naszych pomiarach ok. 24% fałszywych alarmów klatkowych leży dokładnie oktawę od prawdziwej nuty).



(a) (b)

Rysunek 3.1: Widma szarpniętych strun liczone FFT. (a) Oś liniowa: prążki E2 (niebieskie) i E3 (pomarańczowe, nieco przesunięte w prawo, żeby były widoczne). Każdy prążek E3 pada na parzysty prążek E2 (tw. 3.3). (b) Oś w półtonach $12\log_2(f/f_{E2})$: wzorzec prążków E2 (niebieskie) i A2 (pomarańczowe) to ta sama figura przesunięta o 5 półtonów (strzałka); kształt zależy tylko od numeru alikwotu, nie od wysokości.

3.4 Oś logarytmiczna: wzorzec, który się nie zmienia

Teraz najważniejsze twierdzenie rozdziału. Zmierzmy położenie na osi w półtonach względem ustalonej nuty odniesienia (np. $f_{\text{ref}} = 440\,\text{Hz}$): $u(f) = 12\log_2(f/f_{\text{ref}})$.

Twierdzenie 3.4 (Niezmienniczość wzorca alikwotów). *Jeśli nuta ma częstotliwość podstawową f_0 i położenie $u_0 = u(f_0)$, to jej h-ty alikwot leży w punkcie*

$$u(hf_0) = u_0 + 12\log_2 h. \tag{3.3}$$

Przesunięcie $12\log_2 h$ zależy od h, ale nie *zależy od f_0.*

Pomysł dowodu. Logarytm iloczynu jest sumą logarytmów (tw. 1.6): mnożenie przez h staje się dodaniem stałej.

Dowód.

$$\begin{aligned} u(hf_0) &= 12\log_2 \frac{hf_0}{f_{\text{ref}}} && \text{(definicja } u\text{)} \\ &= 12\log_2 h + 12\log_2 \frac{f_0}{f_{\text{ref}}} && \text{(tw. 1.6)} \\ &= 12\log_2 h + u_0. && \text{(definicja } u_0\text{)} \end{aligned}$$

Stała $12\log_2 h$ nie zawiera f_0, więc wzorzec alikwotów ma na tej osi ten sam kształt dla każdej nuty (rys. 3.1b). To kończy dowód. ∎

Wniosek 3.5 (Biny alikwotów). *Przy 3 binach na półton alikwot h leży o $k_h = 36\log_2 h$ binów od podstawy. Zaokrąglone wartości dla alikwotów używanych w Gen 6:*

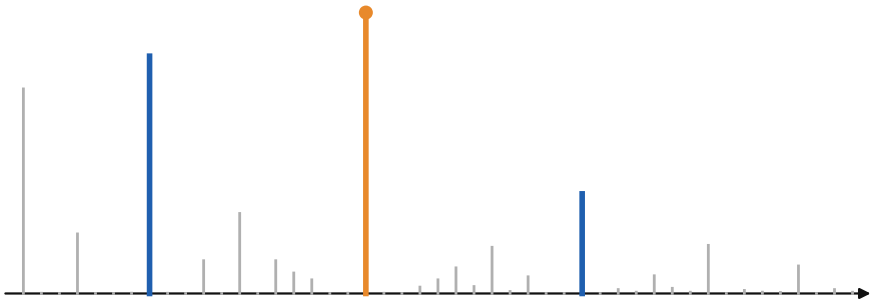
h	0,5	1	2	3	4	5	6
$12\log_2 h$ *[półtony]*	-12	0	12	19,02	24	27,86	31,02
$k_h = \mathrm{round}(36\log_2 h)$ *[biny]*	-36	0	36	57	72	84	93

Dowód. Z tw. 3.4 odstęp w półtonach to $12\log_2 h$; przy 3 binach na półton mnożymy przez 3: $k_h = 36\log_2 h$. Wartości w tabeli to $36\log_2 h$: 36, 57,06, 72, 83,59, 93,06 zaokrąglone do najbliższej liczby całkowitej; np. $\mathrm{round}(83{,}59) = 84$, a 84 biny to dokładnie 28 półtonów, czyli nuta temperowana. Zaokrąglenie przesuwa więc piąty alikwot o 0,41 bina (13,7 centa), czyli dokładnie o tyle, o ile ten alikwot jest za niski względem skali temperowanej. ■

Na konkretnych liczbach. Struna A2 (110 Hz) ma piąty alikwot 550 Hz. Leży on $12\log_2 5 = 27{,}86$ półtonów nad A2, czyli blisko nuty o numerze $45 + 28 = 73$ (cis^3, 554,4 Hz), ale o $1200\log_2(550/554{,}4) = -13{,}7$ centa niżej. To nie błąd modelu, tylko fizyka: trzeci i piąty alikwot nigdy nie trafiają dokładnie w temperowaną skalę.

3.5 Salience: jak wygląda błąd oktawowy w liczbach

Najprostszy detektor wysokości sumuje energię widma w miejscach, gdzie leżałyby alikwoty kandydata: $\mathrm{sal}(f) = \frac{1}{H}\sum_{h=1}^{H} S(hf)$, gdzie S to amplituda widma. Dla prawdziwej nuty wszystkie składniki są duże. Ale dla kandydata o oktawę niżej, $f/2$, składniki o parzystym h trafiają w alikwoty prawdziwej nuty, więc salience też jest wysoka (rys. 3.2).



Rysunek 3.2: Salience (suma energii sześciu pierwszych alikwotów) dla szarpniętej struny E3 ($m = 52$) w funkcji numeru kandydata m. Prawdziwa nuta (pomarańczowa) ma najwyższy słupek, ale kandydat o oktawę niżej ($m = 40$, niebieski) jest niewiele niższy, a ten o oktawę wyżej ($m = 64$) też wyraźnie się wyróżnia. Wszystkie wartości liczone z widma FFT jednej nuty.

Wniosek praktyczny: samo sumowanie nie wystarcza i trzeba, by sieć porównywała kandydatów *ze sobą*. Do tego służy uwaga między wysokościami (rozdział **??**).

Podsumowanie

- Struna drga z częstotliwościami kf_1 (tw. 3.2); nuta to suma alikwotów hf_0.
- Prawdziwe struny są lekko nieharmoniczne: $f_h \approx hf_0\sqrt{1+Bh^2}$.
- Alikwoty nuty o oktawę wyższej zawierają się w alikwotach niższej (tw. 3.3): źródło błędu oktawowego.
- Na osi półtonów alikwot h leży o $12\log_2 h$ nad podstawą, niezależnie od f_0 (tw. 3.4).

- Przy 3 binach na półton przesunięcia to $-36, 0, 36, 57, 72, 84, 93$ (wn. 3.5); na nich opiera się blok harmoniczny.

Ćwiczenia

1. Wypisz częstotliwości alikwotów $h = 1, \ldots, 8$ struny A2 (110 Hz). Które z nich są częstotliwościami podstawowymi nut A3 i E4?
2. Oblicz $12\log_2 7$ i $36\log_2 7$. O ile centów siódmy alikwot odbiega od najbliższej nuty temperowanej?
3. Pokaż, że alikwoty nuty o częstotliwości $3f_0$ (dwunasta wyżej) są alikwotami nuty f_0. Które z nich się pokrywają?
4. Struna ma $B = 10^{-3}$. O ile centów podwyższony jest alikwot $h = 4$? Czy mieści się w jednym binie (33,3 centa)?

Rozwiązania

1. 110, 220, 330, 440, 550, 660, 770, 880 Hz. A3 to 220 Hz ($h = 2$); E4 to 329,6 Hz, a 330 Hz ($h = 3$) jest blisko, ale to E_4 temperowane (329,63) tylko w przybliżeniu (o 2 centy).
2. $12\log_2 7 = 33{,}69$ półtonów, $36\log_2 7 = 101{,}06$ binów. Najbliższa nuta jest 34 półtony wyżej, więc alikwot jest za niski o 0,31 półtonu, czyli 31 centów.
3. $h \cdot 3f_0 = (3h)f_0$; pokrywają się alikwoty $h' = 3, 6, 9, \ldots$ nuty f_0 (co trzeci).
4. $1200\log_2 \sqrt{1 + 16 \cdot 10^{-3}} = 600\log_2(1{,}016) = 600 \cdot 0{,}02289 = 13{,}7$ centa, więc mieści się w jednym binie ($< 33{,}3$).

4 Wektory i macierze

4.1 Dlaczego algebra liniowa?

Prawie każda warstwa modelu Gen 6 to mnożenie przez macierz. Macierz zamienia jeden wektor cech na inny, a iloczyn skalarny mierzy, jak bardzo dwa wektory są do siebie podobne; uwaga (rozdział 10) to nic więcej niż iloczyny skalarne wstawione do softmaksa. Wystarczy nam kilka pojęć, ale musimy je rozumieć geometrycznie.

Po tym rozdziale umiesz: (i) policzyć iloczyn skalarny, normę i kąt, (ii) uzasadnić nierówność Cauchy'ego–Schwarza, (iii) pomnożyć macierz przez wektor i dwie macierze przez siebie, (iv) policzyć liczbę parametrów warstwy liniowej.

4.2 Wektor i iloczyn skalarny

iloczyn skalarny

Definicja 4.1 (Iloczyn skalarny i norma). Dla wektorów $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$ ich *iloczynem skalarnym* jest liczba

$$\langle \boldsymbol{u}, \boldsymbol{v} \rangle = \sum_{i=1}^{n} u_i v_i = \boldsymbol{u}^\top \boldsymbol{v}, \tag{4.1}$$

a *normą* (długością) wektora $\|\boldsymbol{u}\| = \sqrt{\langle \boldsymbol{u}, \boldsymbol{u} \rangle}$.

Przykład 4.1. Dla $\boldsymbol{u} = (2, 1, -1)$ i $\boldsymbol{v} = (1, 3, 2)$: $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = 2 \cdot 1 + 1 \cdot 3 + (-1) \cdot 2 = 3$, $\|\boldsymbol{u}\| = \sqrt{6} \approx 2{,}449$, $\|\boldsymbol{v}\| = \sqrt{14} \approx 3{,}742$. Iloczyn skalarny wektora z samym sobą to kwadrat jego długości: $\langle \boldsymbol{u}, \boldsymbol{u} \rangle = 4 + 1 + 1 = 6$.

Intuicja. Iloczyn skalarny pyta: „w ile wektor $\boldsymbol{u}$ jest skierowany tak jak $\boldsymbol{v}$?". Wynik jest duży i dodatni, gdy wskazują ten sam kierunek, zero, gdy są prostopadłe, ujemny, gdy przeciwne. W modelu wektor $\boldsymbol{q}$ („czego szukam") i wektor $\boldsymbol{k}$ („co mam") są porównywane właśnie tak. ♢

Twierdzenie 4.2 (Cauchy'ego–Schwarza). *Dla dowolnych $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$ zachodzi $|\langle \boldsymbol{u}, \boldsymbol{v} \rangle| \le \|\boldsymbol{u}\| \, \|\boldsymbol{v}\|$, przy czym równość jest równoważna temu, że wektory są równoległe (jeden jest wielokrotnością drugiego).*

Pomysł dowodu. Rozkładamy $\boldsymbol{v}$ na część równoległą do $\boldsymbol{u}$ i prostopadłą do niej. Część prostopadła ma nieujemną długość.

Dowód. Jeśli $\boldsymbol{u} = \boldsymbol{0}$, obie strony są zerem. Niech $\boldsymbol{u} \neq \boldsymbol{0}$ i niech $\boldsymbol{p} = \dfrac{\langle \boldsymbol{u}, \boldsymbol{v} \rangle}{\|\boldsymbol{u}\|^2} \boldsymbol{u}$

oraz $\boldsymbol{r} = \boldsymbol{v} - \boldsymbol{p}$. Sprawdzamy, że $\boldsymbol{r} \perp \boldsymbol{u}$:

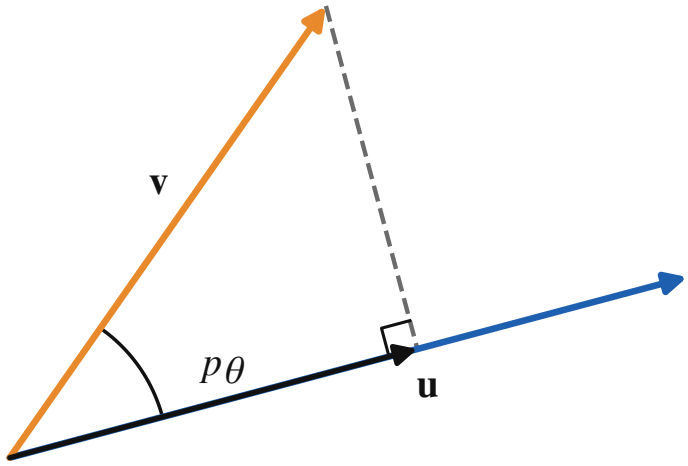
$$\begin{aligned} \langle \boldsymbol{r}, \boldsymbol{u} \rangle &= \langle \boldsymbol{v}, \boldsymbol{u} \rangle - \frac{\langle \boldsymbol{u}, \boldsymbol{v} \rangle}{\|\boldsymbol{u}\|^2} \langle \boldsymbol{u}, \boldsymbol{u} \rangle && \text{(liniowość)} \\ &= \langle \boldsymbol{u}, \boldsymbol{v} \rangle - \langle \boldsymbol{u}, \boldsymbol{v} \rangle = 0. && (\langle \boldsymbol{u}, \boldsymbol{u} \rangle = \|\boldsymbol{u}\|^2) \end{aligned}$$

Skoro $\boldsymbol{v} = \boldsymbol{p} + \boldsymbol{r}$ z $\boldsymbol{p} \perp \boldsymbol{r}$, to $\|\boldsymbol{v}\|^2 = \|\boldsymbol{p}\|^2 + \|\boldsymbol{r}\|^2 \geq \|\boldsymbol{p}\|^2$ (Pitagoras). A $\|\boldsymbol{p}\|^2 = \dfrac{\langle \boldsymbol{u}, \boldsymbol{v} \rangle^2}{\|\boldsymbol{u}\|^2}$, więc

$$\|\boldsymbol{v}\|^2 \geq \frac{\langle \boldsymbol{u}, \boldsymbol{v} \rangle^2}{\|\boldsymbol{u}\|^2} \quad \Longrightarrow \quad \langle \boldsymbol{u}, \boldsymbol{v} \rangle^2 \leq \|\boldsymbol{u}\|^2 \, \|\boldsymbol{v}\|^2 .$$

Równość zachodzi dokładnie wtedy, gdy $\boldsymbol{r} = \boldsymbol{0}$, czyli $\boldsymbol{v} = \boldsymbol{p}$ jest wielokrotnością $\boldsymbol{u}$. Pierwiastkowanie obu stron daje tezę. ■

W zwykłym języku: iloczyn skalarny nigdy nie jest większy niż iloczyn długości, a największy jest dla wektorów równoległych. Stąd wynika, że liczba $\cos\theta := \langle \boldsymbol{u}, \boldsymbol{v} \rangle / (\|\boldsymbol{u}\| \, \|\boldsymbol{v}\|)$ leży w $[-1, 1]$ i można ją nazwać cosinusem kąta θ między wektorami (rys. 4.1). Tę samą nierówność wykorzystamy w rozdziale 5, by pokazać, w którą stronę gradient rośnie najszybciej.



Rysunek 4.1: Rozkład z dowodu tw. 4.2. Wektor $\boldsymbol{v}$ (pomarańczowy) rzutujemy na kierunek $\boldsymbol{u}$ (niebieski): rzut p (czarny) jest równoległy do $\boldsymbol{u}$, a odcinek kreskowany $\boldsymbol{r} = \boldsymbol{v} - \boldsymbol{p}$ jest do niego prostopadły (kąt prosty). Długość rzutu to $\|\boldsymbol{v}\| \cos\theta$, więc $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = \|\boldsymbol{u}\| \, \|\boldsymbol{v}\| \cos\theta$.

Na konkretnych liczbach. Dla wektorów z przykładu 4.1: $\cos\theta = 3/\sqrt{6 \cdot 14} = 3/9{,}165 = 0{,}327$, czyli $\theta \approx 70{,}9°$. Rzut $\boldsymbol{v}$ na $\boldsymbol{u}$ to $\boldsymbol{p} = \frac{3}{6}\boldsymbol{u} = (1;\, 0{,}5;\, -0{,}5)$, a reszta $\boldsymbol{r} = \boldsymbol{v} - \boldsymbol{p} = (0;\, 2{,}5;\, 2{,}5)$. Sprawdzenie prostopadłości: $\langle \boldsymbol{r}, \boldsymbol{u} \rangle = 0 \cdot 2 + 2{,}5 \cdot 1 + 2{,}5 \cdot (-1) = 0$. ✓

Pułapka. Iloczyn skalarny rośnie wraz z długością wektorów, nie tylko z podobieństwem kierunków. Dwa długie, słabo podobne wektory mogą mieć większy iloczyn niż dwa krótkie, równoległe. Dlatego w uwadze dzielimy iloczyn przez $\sqrt{d_h}$ (rozdział 10), a w sieci normalizujemy cechy (rozdział 9). ♢

4.3 Macierz jako przekształcenie

macierz

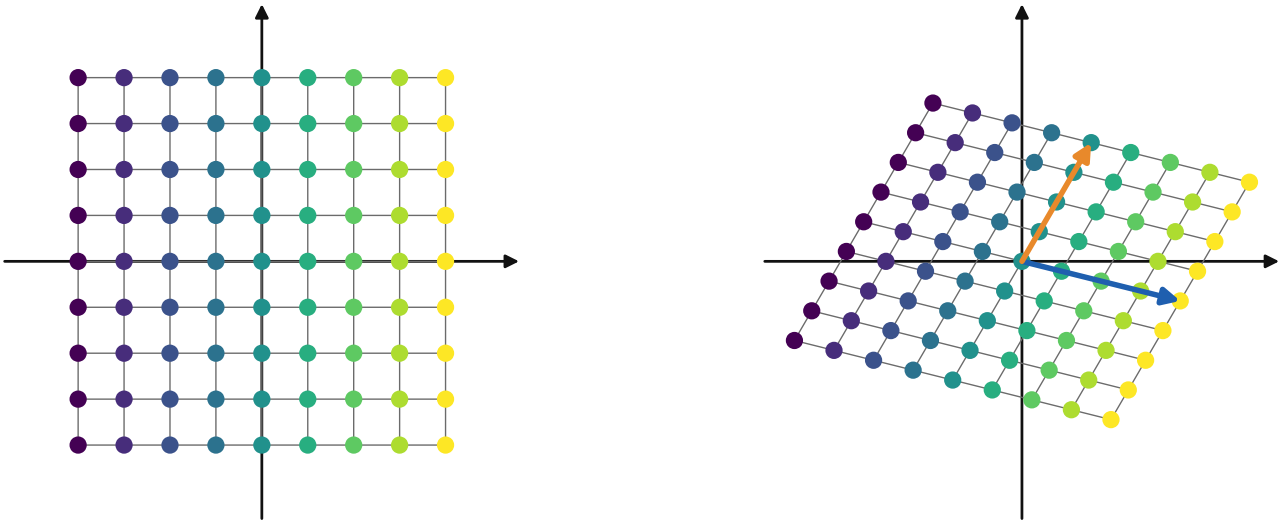
Definicja 4.3 (Iloczyn macierzy i wektora). Dla macierzy $W \in \mathbb{R}^{m\times n}$ i wektora $\boldsymbol{x} \in \mathbb{R}^n$ wektor $W\boldsymbol{x} \in \mathbb{R}^m$ ma współrzędne

$$(W\boldsymbol{x})_i = \sum_{j=1}^{n} W_{ij}x_j = \langle \boldsymbol{w}_i, \boldsymbol{x}\rangle\,, \tag{4.2}$$

gdzie $\boldsymbol{w}_i$ to i-ty wiersz W. Każda współrzędna wyniku to iloczyn skalarny wiersza z wektorem.

Przykład 4.2. Niech $W = \begin{pmatrix} 1 & 2 \\ 0 & 1 \\ -1 & 1 \end{pmatrix} \in \mathbb{R}^{3\times 2}$ i $\boldsymbol{x} = (2,1)$. Wtedy $W\boldsymbol{x} = (1\cdot 2 + 2\cdot 1,\ 0\cdot 2 + 1\cdot 1,\ -1\cdot 2 + 1\cdot 1) = (4,1,-1)$: wektor z $\mathbb{R}^2$ trafił do $\mathbb{R}^3$. Dodając wektor obciążenia (ang. *bias*) $\boldsymbol{b} = (0{,}5; 0; 1)$ dostajemy *warstwę liniową* $W\boldsymbol{x} + \boldsymbol{b} = (4{,}5;\ 1;\ 0)$.

Intuicja. Macierz 2×2 działa na całą płaszczyznę naraz: prosta zostaje prostą, początek układu zostaje na miejscu, a siatka kwadratów zamienia się w siatkę równoległoboków. Kolumny W to obrazy wektorów bazowych (rys. 4.2). ♢



(a) (b)

Rysunek 4.2: (a) Siatka punktów 9×9 w kwadracie $[-1,1]^2$, pokolorowana według współrzędnej x (od fioletu do żółci). (b) Obraz tej siatki po przekształceniu $\boldsymbol{x} \mapsto A\boldsymbol{x}$ z kolumnami $A\boldsymbol{e}_1$ (niebieska strzałka) i $A\boldsymbol{e}_2$ (pomarańczowa). Kolory pozwalają śledzić każdy punkt: proste zostają prostymi, a pole kwadratu rośnie $|\det A| = 1{,}2\cdot 1{,}6 + 0{,}7\cdot 0{,}4 = 2{,}2$ razy.

Twierdzenie 4.4 (Mnożenie macierzy to składanie przekształceń). *Dla $A \in \mathbb{R}^{m\times n}$ i $B \in \mathbb{R}^{n\times p}$ macierz $AB \in \mathbb{R}^{m\times p}$ o elementach $(AB)_{ik} = \sum_j A_{ij}B_{jk}$ spełnia $(AB)\boldsymbol{x} = A(B\boldsymbol{x})$ dla każdego $\boldsymbol{x} \in \mathbb{R}^p$.*

Pomysł dowodu. Rozpisujemy obie strony na współrzędne i zamieniamy kolejność sumowania.

Dowód.

$$\begin{aligned}
\big(A(B\boldsymbol{x})\big)_i &= \sum_{j=1}^{n} A_{ij}\,(B\boldsymbol{x})_j && \text{(def. 4.3)}\\
&= \sum_{j=1}^{n} A_{ij} \sum_{k=1}^{p} B_{jk}x_k && \text{(def. 4.3)}\\
&= \sum_{k=1}^{p} \Big(\sum_{j=1}^{n} A_{ij}B_{jk} \Big) x_k && \text{(zmiana kolejności sum)}\\
&= \sum_{k=1}^{p} (AB)_{ik}\,x_k = \big((AB)\boldsymbol{x}\big)_i. && \text{(def. } AB\text{)}
\end{aligned}$$

Obie strony mają te same współrzędne, więc są równe. Wymiary zgadzają się, bo $B\boldsymbol{x} \in \mathbb{R}^n$, a A przyjmuje wektory z $\mathbb{R}^n$. ■

W zwykłym języku: dwie warstwy liniowe pod rząd to jedna warstwa liniowa o macierzy AB. Dlatego sieci wstawiają między warstwy funkcje nieliniowe (rozdział 9); bez nich głębokość nic by nie dała.

Przykład 4.3 (Kolejność ma znaczenie). Dla $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ i $B = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix}$ mamy $AB = \begin{pmatrix} 3 & 1 \\ 1 & 1 \end{pmatrix}$, ale $BA = \begin{pmatrix} 2 & 2 \\ 1 & 2 \end{pmatrix}$. Mnożenie macierzy nie jest przemienne.

4.4 Ile parametrów ma warstwa?

Warstwa liniowa $\boldsymbol{x} \mapsto W\boldsymbol{x} + \boldsymbol{b}$ z n wejściami i m wyjściami ma $mn + m$ parametrów (W ma mn liczb, $\boldsymbol{b}$ ma m). To najprostszy rachunek, który będziemy powtarzać w dodatku **??**.

Na konkretnych liczbach. Warstwa $64 \to 256$ (pierwsza w bloku feed-forward modelu Gen 6): $256 \cdot 64 + 256 = 16\,640$ parametrów. Warstwa $256 \to 64$: $64 \cdot 256 + 64 = 16\,448$. Razem blok ma $33\,088$ parametrów.

Podsumowanie

- $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = \sum u_i v_i = \|\boldsymbol{u}\|\,\|\boldsymbol{v}\| \cos\theta$ mierzy zgodność kierunków (tw. 4.2).
- Rzut $\boldsymbol{v}$ na $\boldsymbol{u}$ to $\frac{\langle \boldsymbol{u},\boldsymbol{v} \rangle}{\|\boldsymbol{u}\|^2}\boldsymbol{u}$; reszta jest prostopadła do $\boldsymbol{u}$.
- $W\boldsymbol{x}$: każda współrzędna to iloczyn skalarny wiersza z wektorem; $m \times n$ to $n \to m$.
- $(AB)\boldsymbol{x} = A(B\boldsymbol{x})$; mnożenie macierzy nie jest przemienne.
- Warstwa liniowa $n \to m$ ma $mn + m$ parametrów.

Ćwiczenia

1. Dla $\boldsymbol{u} = (1,2,2)$ i $\boldsymbol{v} = (2,0,1)$ policz $\langle \boldsymbol{u}, \boldsymbol{v} \rangle$, obie normy i $\cos\theta$. Czy wektory są prostopadłe?
2. Znajdź wektor $\boldsymbol{w}$ prostopadły do $\boldsymbol{u} = (1,2,2)$, taki że $\boldsymbol{w} = (a,1,0)$.

3. Policz AB dla $A = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix}$, $B = \begin{pmatrix} 1 & 3 \\ 0 & 2 \end{pmatrix}$ i sprawdź tw. 4.4 dla $\boldsymbol{x} = (1,1)$.
4. Ile parametrów ma warstwa $159 \to 48$? A konwolucja 1×1 z 336 kanałów do 48 (zob. rozdz. 9)?

Rozwiązania

1. $\langle \boldsymbol{u}, \boldsymbol{v} \rangle = 2+0+2 = 4$, $\|\boldsymbol{u}\| = 3$, $\|\boldsymbol{v}\| = \sqrt{5}$, $\cos\theta = 4/(3\sqrt{5}) = 0{,}596$. Nie są prostopadłe (iloczyn $\neq 0$).
2. $\langle \boldsymbol{u}, \boldsymbol{w} \rangle = a + 2 = 0$, więc $a = -2$ i $\boldsymbol{w} = (-2,1,0)$.
3. $AB = \begin{pmatrix} 2 & 6 \\ 1 & 5 \end{pmatrix}$. $AB\boldsymbol{x} = (8,6)$; $B\boldsymbol{x} = (4,2)$, $A(B\boldsymbol{x}) = (8, 4+2) = (8,6)$. ✓
4. $159 \cdot 48 + 48 = 7680$. Konwolucja 1×1 to warstwa liniowa w każdym punkcie: $336 \cdot 48 + 48 = 16\,176$ parametrów.

5 Pochodne, gradient i propagacja wsteczna

5.1 Jak poprawić model, który się myli?

Model ma miliony pokręteł, czyli parametrów. Po każdej pomyłce chcemy wiedzieć: *w którą stronę i jak mocno przekręcić każde pokrętło, żeby błąd zmalał?* Odpowiedzią jest gradient, a narzędziem do jego liczenia reguła łańcuchowa. Ten rozdział wyprowadza obie rzeczy od początku i pokazuje na malutkiej sieci (jeden neuron), jak wygląda propagacja wsteczna.

Po tym rozdziale umiesz: (i) policzyć pochodną złożenia funkcji, (ii) uzasadnić, że gradient wskazuje kierunek najszybszego wzrostu, (iii) zrobić krok spadku gradientu, (iv) policzyć ręcznie gradient strat dla jednego neuronu i sprawdzić go numerycznie.

5.2 Pochodna funkcji jednej zmiennej

pochodna

Definicja 5.1 (Pochodna). *Pochodną* funkcji f w punkcie x nazywamy granicę (o ile istnieje)

$$f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}. \tag{5.1}$$

Liczba $f'(x)$ to nachylenie stycznej do wykresu w punkcie x.

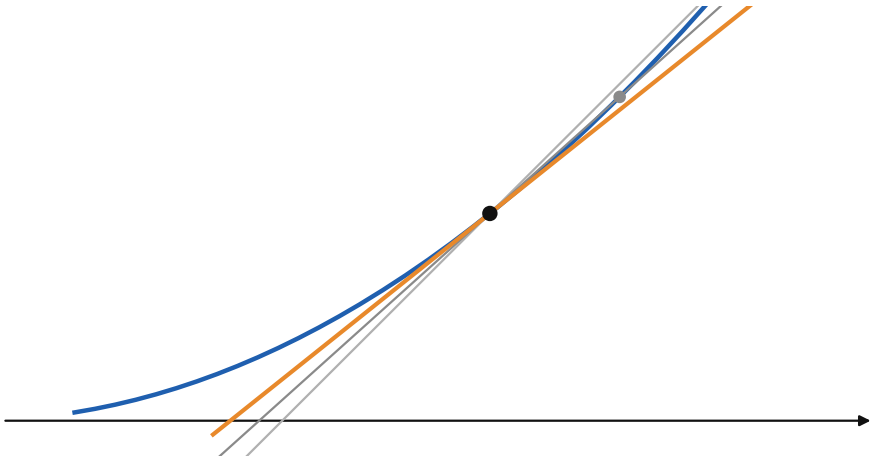
Przykład 5.1. Dla $f(x) = x^2$: $\dfrac{(x+h)^2 - x^2}{h} = \dfrac{2xh + h^2}{h} = 2x + h \to 2x$. W punkcie $x = 3$ nachylenie wynosi 6. Nachylenia siecznych przez $(3,9)$ i $(3+h,(3+h)^2)$ to 7, 6,5, 6,1, 6,01 dla $h = 1; 0{,}5; 0{,}1; 0{,}01$: zbliżają się do 6 (rys. 5.1).

Intuicja. Pochodna odpowiada na pytanie: „o ile zmieni się wynik, jeśli wejście poruszę o drobinę?”. Zmiana wyniku $\approx f'(x) \cdot$ zmiana wejścia. To przybliżenie liniowe jest sercem uczenia: nie trzeba znać całej funkcji, wystarczy jej lokalne nachylenie. ♢

Zbierzmy reguły, których użyjemy (pierwsze dwie wynikają wprost z def. 5.1): $(af + bg)' = af' + bg'$, $(fg)' = f'g + fg'$. Najważniejsza jest trzecia.

Twierdzenie 5.2 (Reguła łańcuchowa). *Jeśli g jest różniczkowalna w x, a f w $u = g(x)$, to $(f \circ g)'(x) = f'(g(x)) \cdot g'(x)$.*

Pomysł dowodu. Przybliżamy g prostą o nachyleniu $g'(x)$, a potem f prostą o nachyleniu $f'(u)$. Nachylenia mnożą się.



Rysunek 5.1: Pochodna jako granica nachyleń. Funkcja x^2 (niebieska) i sieczne (szare) przez punkt $(3,9)$ (czarny) i punkty oddalone o $h = 1{,}5$ oraz $0{,}75$. Gdy $h \to 0$, sieczna dąży do stycznej (pomarańczowa) o nachyleniu $f'(3) = 6$.

Dowód. Różniczkowalność g w x oznacza $g(x+h) - g(x) = g'(x)h + \varepsilon_1(h)h$, gdzie $\varepsilon_1(h) \to 0$ przy $h \to 0$. Podobnie dla f w $u = g(x)$ i $k = g(x+h) - g(x)$: $f(u+k) - f(u) = f'(u)k + \varepsilon_2(k)k$, $\varepsilon_2(k) \to 0$ przy $k \to 0$ (ustalamy $\varepsilon_2(0) = 0$). Zatem

$$\begin{aligned}
\frac{f(g(x+h)) - f(g(x))}{h} &= \frac{f'(u)\,k + \varepsilon_2(k)\,k}{h} && \text{(rozwinięcie } f\text{)} \\
&= \big(f'(u) + \varepsilon_2(k)\big) \cdot \frac{k}{h} && \text{(wyłączenie } k\text{)} \\
&= \big(f'(u) + \varepsilon_2(k)\big)\big(g'(x) + \varepsilon_1(h)\big). && (k/h \text{ z rozwinięcia } g)
\end{aligned}$$

Gdy $h \to 0$, to $k \to 0$ (bo g jest ciągła), więc $\varepsilon_1, \varepsilon_2 \to 0$ i całość dąży do $f'(u)g'(x)$. To kończy dowód. ∎

W zwykłym języku: pochodna złożenia to iloczyn pochodnych kolejnych etapów. Sieć neuronowa to długie złożenie, więc jej pochodna to długi iloczyn.

Twierdzenie 5.3 (Pochodna sigmoidy). *Funkcja* $\sigma(z) = \dfrac{1}{1+e^{-z}}$ *spełnia* $\sigma'(z) = \sigma(z)\big(1 - \sigma(z)\big)$.

Pomysł dowodu. Zapisujemy $\sigma = (1+e^{-z})^{-1}$ i stosujemy regułę łańcuchową.

Dowód. Niech $u = 1 + e^{-z}$, więc $\sigma = u^{-1}$, $\dfrac{d\sigma}{du} = -u^{-2}$ i $\dfrac{du}{dz} = -e^{-z}$. Z tw. 5.2:

$$\begin{aligned}
\sigma'(z) &= -u^{-2} \cdot (-e^{-z}) = \frac{e^{-z}}{(1+e^{-z})^2} && \text{(reguła łańcuchowa)} \\
&= \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} && \text{(rozbicie)} \\
&= \sigma(z)\Big(1 - \frac{1}{1+e^{-z}}\Big) = \sigma(z)\big(1 - \sigma(z)\big). && \big(\tfrac{e^{-z}}{1+e^{-z}} = 1 - \sigma\big)
\end{aligned}$$

Pochodną można więc policzyć z samej wartości σ, bez ponownego liczenia wykładnika. To kończy dowód. ∎

Największa pochodna wynosi $\sigma'(0) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$; dla $|z|$ dużego pochodna dąży do zera (*nasycenie*) — to jedna z przyczyn, dla których głębokie sieci z samymi sigmoidami uczą się wolno.

5.3 Gradient i spadek gradientu

gradient

Definicja 5.4 (Pochodna cząstkowa i gradient). Dla $f\colon \mathbb{R}^n \to \mathbb{R}$ *pochodna cząstkowa* $\partial f/\partial x_i$ to pochodna po x_i przy pozostałych współrzędnych traktowanych jak stałe. *Gradient* to wektor tych pochodnych: $\nabla f(\boldsymbol{x}) = \left(\frac{\partial f}{\partial x_1}, \ldots, \frac{\partial f}{\partial x_n}\right)$.

Przykład 5.2. Dla $f(x,y) = x^2 + 3xy$: $\partial f/\partial x = 2x + 3y$, $\partial f/\partial y = 3x$. W punkcie $(1,2)$ gradient to $(8,3)$ o długości $\sqrt{73} \approx 8{,}54$. Zwiększenie x o 0,01 zwiększa f o ok. 0,08, zwiększenie y o 0,01 o ok. 0,03.

Twierdzenie 5.5 (Gradient wskazuje kierunek najszybszego wzrostu). *Niech f będzie różniczkowalna w $\boldsymbol{x}$ i $\nabla f(\boldsymbol{x}) \neq \boldsymbol{0}$. Wśród wektorów jednostkowych $\boldsymbol{d}$ pochodna kierunkowa $\frac{d}{dt} f(\boldsymbol{x} + t\boldsymbol{d})\big|_{t=0}$ jest największa dla $\boldsymbol{d} = \nabla f / \|\nabla f\|$ i wynosi wtedy $\|\nabla f\|$.*

Pomysł dowodu. Reguła łańcuchowa zamienia pochodną kierunkową na iloczyn skalarny $\langle \nabla f, \boldsymbol{d} \rangle$, a tu działa nierówność Cauchy'ego–Schwarza (tw. 4.2).

Dowód. Niech $\phi(t) = f(\boldsymbol{x} + t\boldsymbol{d})$. Z reguły łańcuchowej dla wielu zmiennych (każda współrzędna zależy od t z pochodną d_i):

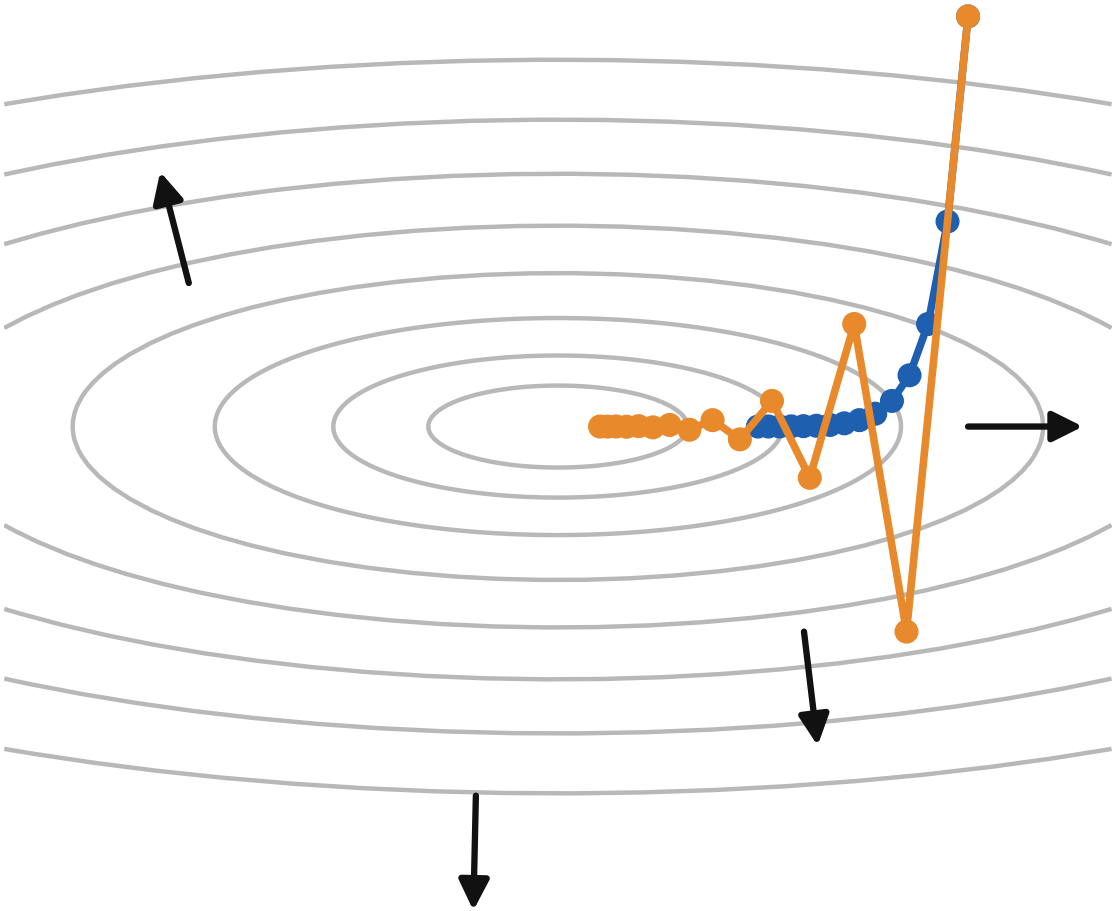
$$\begin{aligned} \phi'(0) &= \sum_{i=1}^{n} \frac{\partial f}{\partial x_i} d_i && \text{(reguła łańcuchowa)} \\ &= \langle \nabla f(\boldsymbol{x}), \boldsymbol{d} \rangle \leq \|\nabla f\| \, \|\boldsymbol{d}\| = \|\nabla f\| . && \text{(tw. 4.2, } \|\boldsymbol{d}\| = 1) \end{aligned}$$

Równość w Cauchy'ego–Schwarza zachodzi, gdy $\boldsymbol{d}$ jest równoległy do ∇f, czyli $\boldsymbol{d} = \nabla f / \|\nabla f\|$ (dodatnia wielokrotność, żeby wynik był dodatni). Wtedy $\phi'(0) = \langle \nabla f, \nabla f \rangle / \|\nabla f\| = \|\nabla f\|$. To kończy dowód. ■

W zwykłym języku: stoisz na zboczu i chcesz iść w górę jak najszybciej — idź wzdłuż gradientu. Chcemy *zmniejszać* stratę, więc idziemy *przeciwnie*.

Definicja 5.6 (Spadek gradientu). Dla funkcji straty $L(\boldsymbol{\theta})$ i *kroku uczenia* $\eta > 0$ kolejne przybliżenia to $\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \eta \, \nabla L(\boldsymbol{\theta}_k)$.

Na konkretnych liczbach. Weźmy $L(x,y) = \frac{1}{2}(x^2 + 10y^2)$, $\nabla L = (x, 10y)$ i start $(1,1)$. Dla $\eta = 0{,}05$ kolejne punkty to $(0{,}95; 0{,}5)$, $(0{,}902; 0{,}25)$, $(0{,}857; 0{,}125)$: schodzimy gładko, ale wolno wzdłuż x. Dla $\eta = 0{,}15$: $(0{,}85; -0{,}5)$, $(0{,}722; 0{,}25)$, $(0{,}614; -0{,}125)$: współrzędna y zmienia znak w każdym kroku (zygzak) i jest dwa razy mniejsza w kolejnych krokach. Dla $\eta = 0{,}21$ zygzak rośnie i metoda się rozbiega (dlaczego, wyjaśnia tw. 11.1 w rozdziale 11).



Rysunek 5.2: Spadek gradientu dla $L = \frac{1}{2}(x^2 + 10y^2)$ (szare warstwice) z punktu $(1, 1)$. Czarne strzałki to gradient w kilku punktach: zawsze prostopadły do warstwicy i skierowany pod górę, więc krok idzie w przeciwną stronę. Niebieska ścieżka ($\eta = 0{,}05$, 14 kroków) schodzi gładko, ale wolno; pomarańczowa ($\eta = 0{,}15$) przeskakuje przez dolinę i zygzakuje. Obie obliczone programem.

5.4 Propagacja wsteczna na jednym neuronie

Przykład 5.3 (Gradient strat dla neuronu). Neuron: $z = wx + b$, $\hat{y} = \sigma(z)$, strata $L = (\hat{y} - y)^2$. Dane: $x = 2$, $w = 0{,}5$, $b = -0{,}3$, cel $y = 1$. *Przód:* $z = 0{,}7$, $\hat{y} = \sigma(0{,}7) = 0{,}6682$, $L = (0{,}6682 - 1)^2 = 0{,}1101$. *Tył*

(reguła łańcuchowa, od wyniku ku wejściu):

$$\frac{\partial L}{\partial \hat{y}} = 2(\hat{y}-y) = -0{,}6636,$$
$$\frac{\partial \hat{y}}{\partial z} = \hat{y}(1-\hat{y}) = 0{,}2217 \qquad \text{(tw. 5.3)}$$
$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial w} = (-0{,}6636)(0{,}2217)(2) = -0{,}2943,$$
$$\frac{\partial L}{\partial b} = (-0{,}6636)(0{,}2217)(1) = -0{,}1471.$$

Sprawdzenie numeryczne: $\big(L(w+10^{-6}) - L(w-10^{-6})\big)/(2\cdot 10^{-6}) = -0{,}2943$. ✓Ujemny gradient oznacza, że *zwiększenie* w zmniejsza stratę: neuron powinien być bardziej pewny odpowiedzi 1.

Intuicja. Propagacja wsteczna to reguła łańcuchowa wykonana od końca: zaczynamy od „jak strata zależy od wyniku" i cofając się przez każdą operację, mnożymy przez jej lokalną pochodną. Każda warstwa musi znać tylko własną pochodną i gradient przychodzący z góry; dzięki temu da się to zautomatyzować dla dowolnej sieci (PyTorch robi dokładnie to). ♢

Pułapka. Gradient policzony ręcznie warto *zawsze* porównać z ilorazem różnicowym (jak wyżej). Błąd znaku albo brakującego czynnika nie powoduje awarii, tylko powolne, dziwne uczenie, które trudno zdiagnozować. Granice stosowalności: różnica 10^{-6} w `float64` jest dobra; w `float32` zbyt mały krok tonie w błędach zaokrągleń. ♢

Podsumowanie

- Pochodna to nachylenie stycznej; zmiana wyniku $\approx f'(x)\cdot$ zmiana wejścia.
- Reguła łańcuchowa: pochodna złożenia to iloczyn pochodnych (tw. 5.2); $\sigma' = \sigma(1-\sigma)$.
- Gradient to wektor pochodnych cząstkowych i wskazuje kierunek najszybszego wzrostu (tw. 5.5).
- Spadek gradientu: $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla L$; za duży krok powoduje zygzak i rozbieżność.
- Propagacja wsteczna to reguła łańcuchowa liczona od wyniku w stronę wejść; wynik sprawdzamy ilorazem różnicowym.

Ćwiczenia

1. Policz pochodną $f(x) = \sigma(3x-1)$ w $x = 0$. (Wskazówka: tw. 5.2 i 5.3.)
2. Dla $f(x,y) = x^2 + 3xy$ w punkcie $(1,2)$ podaj kierunek jednostkowy najszybszego wzrostu i wartość pochodnej kierunkowej w tym kierunku.
3. Wykonaj jeden krok spadku gradientu z $(1,2)$ dla $L = x^2 + 3xy$ i $\eta = 0{,}01$. O ile (w przybliżeniu) zmieni się L?
4. Neuron z przykładu 5.3 ma $y = 0$ zamiast 1. Jaki jest teraz $\partial L/\partial w$?

Rozwiązania

1. $\sigma(-1) = 0{,}2689$, więc $f'(0) = 3\sigma(-1)(1-\sigma(-1)) = 3 \cdot 0{,}2689 \cdot 0{,}7311 = 0{,}590$.
2. $\nabla f = (8,3)$, kierunek $(8,3)/8{,}544 = (0{,}936;\, 0{,}351)$, pochodna kierunkowa $\|\nabla f\| = 8{,}544$.
3. Krok: $(1,2) - 0{,}01(8,3) = (0{,}92;\, 1{,}97)$. $L(1,2) = 1+6 = 7$; $L(0{,}92;1{,}97) = 0{,}8464 + 5{,}4372 = 6{,}2836$. Zmiana $\approx -0{,}716$ (przybliżenie liniowe: $-\eta \|\nabla f\|^2 = -0{,}01 \cdot 73 = -0{,}73$).
4. $\partial L/\partial \hat{y} = 2(0{,}6682 - 0) = 1{,}3364$, więc $\partial L/\partial w = 1{,}3364 \cdot 0{,}2217 \cdot 2 = 0{,}5926$ (dodatni: w należy *zmniejszyć*).

6 Transformata Fouriera: z drgań do widma

6.1 Co jest w tym nagraniu?

Nagranie to ciąg liczb zmieniających się w czasie. Nas interesuje coś innego: *jakie częstotliwości w nim grają?* Odpowiada na to transformata Fouriera, która rozkłada sygnał na sinusoidy. Dla krótkiego okna dźwięku zamienia N próbek w N liczb mówiących, ile energii niesie każda częstotliwość. To jest pierwszy krok liczenia cech Gen 6 (rozdział 7). Poznamy jej własności i, co ważne, *ograniczenia*: przeciek i skończoną rozdzielczość.

Po tym rozdziale umiesz: (i) policzyć DFT małego sygnału ręcznie, (ii) uzasadnić, że wiąże ona sinusoidy z pojedynczymi prążkami, (iii) wyjaśnić, czemu stosuje się okno Hanna, (iv) policzyć rozdzielczość f_s/N i ocenić, czy dwa dźwięki da się rozdzielić.

6.2 Liczby zespolone w dwóch zdaniach

wzór Eulera

Definicja 6.1 (Jednostka urojona i wzór Eulera). Liczba i spełnia $i^2 = -1$. Dla rzeczywistego θ definiujemy $e^{i\theta} = \cos\theta + i\sin\theta$ — punkt na okręgu jednostkowym o kącie θ. Moduł $|a+ib| = \sqrt{a^2+b^2}$. Zachodzi $e^{i\alpha}e^{i\beta} = e^{i(\alpha+\beta)}$ oraz $\left|e^{i\theta}\right| = 1$.

Przykład 6.1. $e^{i\pi} = \cos\pi + i\sin\pi = -1$, $e^{i\pi/2} = i$, $e^{-i\pi/2} = -i$. Zatem $\cos\theta = \frac{1}{2}(e^{i\theta}+e^{-i\theta})$ i $\sin\theta = \frac{1}{2i}(e^{i\theta}-e^{-i\theta})$ — sinus i cosinus to „składowe” punktu na okręgu.

6.3 Dyskretna transformata Fouriera

DFT

Definicja 6.2 (DFT). Dla ciągu $x[0],\ldots,x[N-1]$ jego *dyskretna transformata Fouriera* to ciąg liczb zespolonych

$$X[k] = \sum_{n=0}^{N-1} x[n]\, e^{-2\pi i k n/N}, \qquad k = 0,1,\ldots,N-1. \tag{6.1}$$

Numer k odpowiada częstotliwości $f_k = k\,f_s/N$; $|X[k]|$ nazywamy *widmem amplitudowym*. Odstęp $\Delta f = f_s/N$ między sąsiednimi k to *rozdzielczość* (szerokość binu) DFT.

Przykład 6.2 ($N=4$ ręcznie). Niech $x = (1,0,-1,0)$, czyli jeden okres cosinusa w 4 próbkach. Ponieważ $e^{-2\pi i k n/4} = (-i)^{kn}$: $X[0] = 1+0-1+0 = 0$; $X[1] = 1+(-1)(-i)^2 = 1+1 = 2$; $X[2] = 1+(-1)(-i)^4 =$

$1-1=0$; $X[3]=1+(-1)(-i)^6=1+1=2$. Widmo $|X|=(0,2,0,2)$: cosinus daje dwa prążki, w $k=1$ i lustrzany $k=3=N-1$. Przy $f_s=4\,\mathrm{Hz}$ prążek $k=1$ to $1\,\mathrm{Hz}$.

Intuicja. $X[k]$ mierzy, jak bardzo sygnał „zgadza się" z sinusoidą o k obiegach na okno: mnożymy sygnał przez tę sinusoidę i sumujemy (to iloczyn skalarny z rozdziału 4!). Gdy sygnał ją zawiera, wszystkie składniki sumy dodają się; gdy nie, wzajemnie się znoszą. ♢

Twierdzenie 6.3 (Ortogonalność sinusoid). *Dla całkowitych k,l:*

$$\sum_{n=0}^{N-1} e^{2\pi i(k-l)n/N} = \begin{cases} N, & k \equiv l \pmod N, \\ 0, & \textit{w przeciwnym razie.} \end{cases} \tag{6.2}$$

Pomysł dowodu. To suma wyrazów ciągu geometrycznego o ilorazie $q = e^{2\pi i(k-l)/N}$, a $q^N = 1$.

Dowód. Niech $q = e^{2\pi i(k-l)/N}$. Gdy $k \equiv l \pmod N$, to $q=1$ i suma ma N składników równych 1, czyli wynosi N. W przeciwnym razie $q \neq 1$ i ze wzoru na sumę ciągu geometrycznego

$$\begin{aligned} \sum_{n=0}^{N-1} q^n &= \frac{1-q^N}{1-q} && \text{(suma geometryczna)} \\ &= \frac{1-e^{2\pi i(k-l)}}{1-q} = \frac{1-1}{1-q} = 0. && (q^N = e^{2\pi i(k-l)} = 1) \end{aligned}$$

Sinusoidy o różnych numerach są więc wzajemnie prostopadłe (iloczyn skalarny zero), a o tym samym mają „długość" $\sqrt{N}$. To kończy dowód. ■

Wniosek 6.4 (DFT sinusoidy o całkowitej liczbie okresów). *Jeśli $x[n] = A\cos(2\pi k_0 n/N)$ dla całkowitego $0 < k_0 < N/2$, to $X[k_0] = X[N-k_0] = AN/2$, a pozostałe $X[k]=0$.*

Dowód. Z przykładu 6.1: $x[n] = \frac{A}{2}\left(e^{2\pi i k_0 n/N} + e^{-2\pi i k_0 n/N}\right)$. Wstawiamy do (6.1):

$$\begin{aligned} X[k] &= \frac{A}{2}\sum_n e^{2\pi i(k_0-k)n/N} + \frac{A}{2}\sum_n e^{-2\pi i(k_0+k)n/N} && \text{(rozdzielność)} \\ &= \frac{A}{2}N\mathbb{1}[k=k_0] + \frac{A}{2}N\mathbb{1}[k=N-k_0]\,. && \text{(tw. 6.3)} \end{aligned}$$

Dla $N=4$, $k_0=1$, $A=1$ daje to $X[1]=X[3]=2$, zgodnie z przykładem 6.2. Czysty ton daje więc dokładnie jeden prążek (i jego lustro). ■

6.4 Przeciek i okno

Jest haczyk: wniosek 6.4 wymaga, by ton miał *całkowitą* liczbę okresów w oknie. Częstotliwości nut tego nie spełniają. Co się dzieje, gdy k_0 nie jest całkowite?

Twierdzenie 6.5 (Przeciek). *Niech $x[n] = e^{2\pi i \kappa n/N}$ z dowolnym rzeczywistym κ i niech $\delta = \kappa - k$. Wtedy*

$$|X[k]| = \left| \frac{\sin(\pi\delta)}{\sin(\pi\delta/N)} \right|. \tag{6.3}$$

Jest to N dla $\delta = 0$, zero dla niezerowych całkowitych δ i ok. $\frac{2}{\pi}N \approx 0{,}64N$ dla $\delta = \frac{1}{2}$ (dla dużych N).

Pomysł dowodu. To znów suma geometryczna, tym razem z ilorazem $e^{2\pi i\delta/N} \neq 1$; moduł licznika i mianownika daje sinusy.

Dowód. Z (6.1) i definicji δ:

$$\begin{aligned} X[k] &= \sum_{n=0}^{N-1} e^{2\pi i\delta n/N} = \frac{1 - e^{2\pi i\delta}}{1 - e^{2\pi i\delta/N}} && \text{(suma geometryczna)} \\ &= \frac{e^{i\pi\delta}\left(e^{-i\pi\delta} - e^{i\pi\delta}\right)}{e^{i\pi\delta/N}\left(e^{-i\pi\delta/N} - e^{i\pi\delta/N}\right)} && \text{(wyłączenie połówek kątów)} \\ &= e^{i\pi\delta(1-1/N)}\,\frac{\sin(\pi\delta)}{\sin(\pi\delta/N)}. && \text{(wzór Eulera na sinus)} \end{aligned}$$

Moduł czynnika $e^{i\cdots}$ wynosi 1, więc zostaje podany wzór. Dla $\delta = 0$ granica to N; dla całkowitego $\delta \neq 0$ licznik jest zerem; dla $\delta = \frac{1}{2}$ mianownik $\sin(\pi/2N) \approx \pi/2N$, a licznik 1, czyli $\approx 2N/\pi$. To kończy dowód. ■

W zwykłym języku: ton między binami „rozlewa się" na sąsiednie prążki i traci w najgorszym miejscu ok. 3,9 dB głośności ($20\log_{10}(2/\pi) = -3{,}9\,\text{dB}$). Poza tym ogony przecieku opadają wolno: pierwszy listek boczny okna prostokątnego to tylko -13 dB. Silny ton zasłoni więc słabe składowe daleko od siebie. Rozwiązaniem jest okno.

okno Hanna

Definicja 6.6 (Okno Hanna). *Oknem Hanna* nazywamy $w[n] = \frac{1}{2}\big(1 - \cos(2\pi n/N)\big)$, $n = 0, \ldots, N-1$. Przed liczeniem DFT mnożymy próbki przez $w[n]$.

Przykład 6.3. Dla $N = 8$: $w = (0;\, 0{,}146;\, 0{,}5;\, 0{,}854;\, 1;\, 0{,}854;\, 0{,}5;\, 0{,}146)$: okno łagodnie zaczyna się od zera, osiąga 1 w środku i znów opada. Brzegi okna nie są więc ucinane gwałtownie, a to właśnie nagła krawędź powoduje długi ogon przecieku.

Twierdzenie 6.7 (Widmo okna Hanna). *Jeśli $Y[k]$ jest DFT sygnału $y[n]$ z oknem prostokątnym, to DFT sygnału $y[n]w[n]$ z oknem Hanna wynosi $\frac{1}{2}Y[k] - \frac{1}{4}Y[k-1] - \frac{1}{4}Y[k+1]$.*

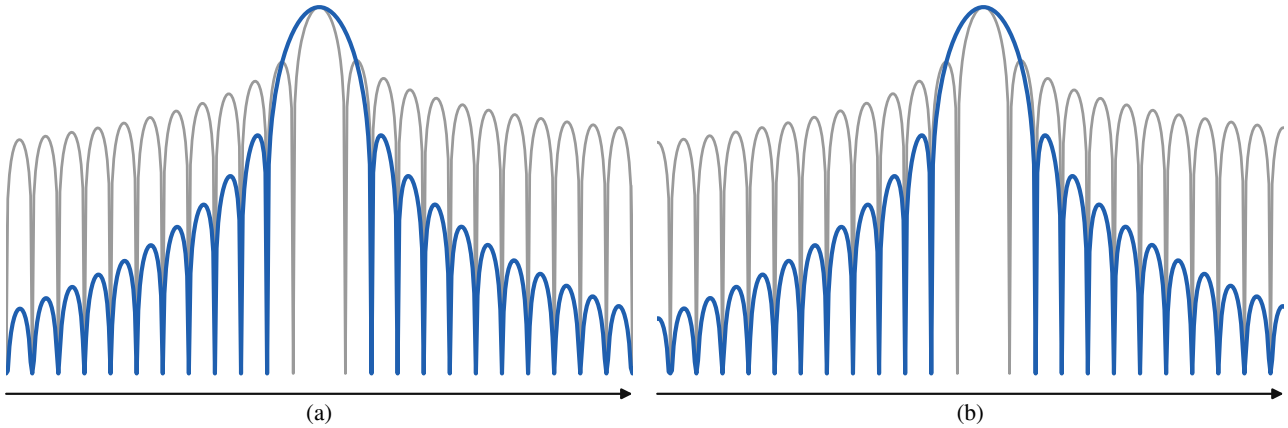
Pomysł dowodu. Zapisujemy $w[n] = \frac{1}{2} - \frac{1}{4}e^{2\pi in/N} - \frac{1}{4}e^{-2\pi in/N}$ i zauważamy, że mnożenie przez $e^{2\pi in/N}$ przesuwa widmo o jeden bin.

Dowód. Z wzoru Eulera $\cos(2\pi n/N) = \frac{1}{2}\big(e^{2\pi in/N} + e^{-2\pi in/N}\big)$, więc $w[n] = \frac{1}{2} - \frac{1}{4}e^{2\pi in/N} - \frac{1}{4}e^{-2\pi in/N}$. Dla składnika z $e^{2\pi in/N}$:

$$\sum_n y[n]e^{2\pi in/N}e^{-2\pi ikn/N} = \sum_n y[n]e^{-2\pi i(k-1)n/N} = Y[k-1]. \quad \text{(złączenie wykładników)}$$

Analogicznie $e^{-2\pi in/N}$ daje $Y[k+1]$. Z liniowości DFT otrzymujemy podany wzór. To kończy dowód. ■

Skutki (to już obserwacja liczbowa, rys. 6.1, a nie część dowodu): kopie z $k \pm 1$ mają znak przeciwny niż środkowa, więc kasują ogon przecieku, a główny listek robi się szerszy (4 biny między zerami zamiast 2). Pierwszy listek boczny spada z $-13{,}3\,\mathrm{dB}$ (okno prostokątne) do $-31{,}5\,\mathrm{dB}$.



Rysunek 6.1: Widmo (w decybelach, skala pionowa wspólna, od -90 do $0\,\mathrm{dB}$) tonu z $N = 128$ próbek. (a) Ton dokładnie w prążku: okno prostokątne (szare) daje wąski pik, ale ze słabo opadającymi listkami (pierwszy $-13\,\mathrm{dB}$); okno Hanna (niebieskie) ma szerszy pik i listki o ok. $18\,\mathrm{dB}$ niższe. (b) Ton w połowie między prążkami: pik jest niższy, a listki prostokątnego okna jeszcze wyższe względem Hanna.

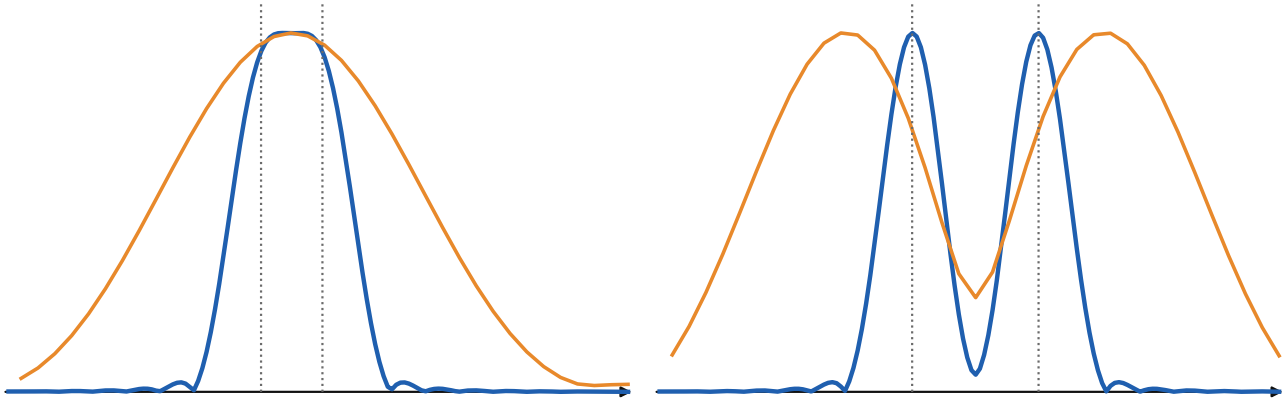
Pułapka. Okno Hanna nie jest za darmo: rozszerza główny listek dwukrotnie, więc *pogarsza rozdzielczość*. Zyskujemy czystość widma (brak „duchów" od silnych tonów), tracimy zdolność do rozdzielania dwóch bliskich dźwięków. Wybór okna to zawsze kompromis. ♢

6.5 Rozdzielczość: kiedy dwa dźwięki są jednym

Gen 6 liczy FFT dla okna $N = 4096$ przy $f_s = 11\,025\,\mathrm{Hz}$ (czas $372\,\mathrm{ms}$), więc $\Delta f = 2{,}69\,\mathrm{Hz}$; główny listek Hanna ma $\pm 2\Delta f = \pm 5{,}4\,\mathrm{Hz}$. Zero-padding (dopisanie zer, rozdział 7) dzieli siatkę na $0{,}67\,\mathrm{Hz}$, ale *nie zwiększa rozdzielczości* — tylko interpoluje ten sam kształt.

Na konkretnych liczbach. Najniższe nuty gitary leżą blisko siebie: E2 ($82{,}41\,\mathrm{Hz}$) i F2 ($87{,}31\,\mathrm{Hz}$) dzieli $4{,}9\,\mathrm{Hz}$, mniej niż $5{,}4\,\mathrm{Hz}$ połowy głównego listka. Numerycznie (rys. 6.2a) widmo sumy z oknem 4096 ma dwa „piki" w $84{,}1$ i $85{,}5\,\mathrm{Hz}$: to artefakt interferencji, nie prawdziwe położenia nut. Dla E2 i F#2 ($10{,}1\,\mathrm{Hz}$ różnicy) piki są już rozdzielone i leżą w $82{,}8$ i $92{,}2\,\mathrm{Hz}$, czyli mniej niż $0{,}4\,\mathrm{Hz}$ od prawdy (b). Okno $N = 1024$ ($\Delta f = 10{,}8\,\mathrm{Hz}$) daje dla pary (b) dwa piki w błędnych miejscach ($78{,}1$ i $96{,}9\,\mathrm{Hz}$).

Wniosek jest uczciwy i ważny: z samego widma jednej klatki nie da się wiarygodnie odróżnić sąsiednich niskich półtonów. Dlatego dalsze rozdziały dodają kontekst w czasie (uwaga między klatkami) i szereg alikwotów (wyższe alikwoty są szerzej rozstawione w hercach, więc łatwiej je rozdzielić).



(a) (b)

Rysunek 6.2: Widmo (okno Hanna) sumy dwóch sinusoid z oknem $N = 4096$ (niebieskie) i $N = 1024$ (pomarańczowe); kropkowane pionowe linie to prawdziwe częstotliwości. (a) E2 i F2 (półton, 4,9 Hz): długie okno daje dwa bliskie piki w złych miejscach (interferencja), krótkie jeden szeroki pagórek. (b) E2 i F#2 (10,1 Hz): długie okno rozdziela dwa tony prawie bez błędu położenia, krótkie daje dwa piki odsunięte od prawdy o kilka herców. Dlatego model dostaje dwa okna — długie dla wysokości, krótkie dla czasu — i uczy się łączyć wskazówki z wielu klatek.

Podsumowanie

- DFT $X[k] = \sum x[n] e^{-2\pi i k n/N}$; bin k to $k f_s/N$ Hz; rozdzielczość $\Delta f = f_s/N$.
- Sinusoidy o różnych k są ortogonalne (tw. 6.3); ton o całkowitej liczbie okresów daje jeden prążek.
- Ton między binami „przecieka” (tw. 6.5); okno prostokątne ma listki -13 dB.
- Okno Hanna to trzy przesunięte kopie okna prostokątnego (tw. 6.7): listki -31 dB, ale główny listek dwa razy szerszy.
- Dla $N = 4096$ rozdzielczość to 2,7 Hz, a sąsiednie niskie półtony (odstęp 4,9 Hz) nie rozdzielają się czysto.

Ćwiczenia

1. Policz ręcznie DFT dla $x = (1, 1, 0, 0)$ ($N = 4$) i podaj widmo amplitudowe.
2. Ile wynosi Δf dla $N = 1024$ i $N = 16\,384$ przy $f_s = 11\,025$ Hz? Który z nich ma większą *rozdzielczość* i dlaczego $N = 16\,384$ z zero-paddingiem z 4096 nie jest dokładniejszy niż 4096?
3. Ton $A\cos(2\pi \cdot 10 n/64)$ ma $N = 64$. Które k mają niezerowe $X[k]$ i ile wynosi $|X|$ dla $A = 2$?
4. Pokaż, że $\sum_{n=0}^{N-1} w[n] = N/2$ dla okna Hanna (wskazówka: tw. 6.3 z $k = l \pm 1$).

Rozwiązania

1. $X[k] = 1 + e^{-2\pi i k/4} = 1 + (-i)^k$: $X[0] = 2$, $X[1] = 1 - i$, $X[2] = 0$, $X[3] = 1 + i$. $|X| = (2, \sqrt{2}, 0, \sqrt{2})$.

2. $\Delta f = 10{,}77\,\text{Hz}$ i $0{,}673\,\text{Hz}$. Zero-padding z 4096 do 16384 daje siatkę $0{,}673\,\text{Hz}$, ale okno nadal trwa 372 ms, więc rozdzielczość pozostaje $2{,}69\,\text{Hz}$ (główny listek tak samo szeroki). Prawdziwe $N = 16384$ próbek (1,5 s) miałoby $\Delta f = 0{,}673\,\text{Hz}$ *prawdziwej* rozdzielczości.

3. $k = 10$ i $k = 54$; $|X| = AN/2 = 2 \cdot 64/2 = 64$.

4. $\sum w = \frac{1}{2}N - \frac{1}{4}\sum e^{2\pi i n/N} - \frac{1}{4}\sum e^{-2\pi i n/N} = \frac{N}{2} - 0 - 0 = \frac{N}{2}$, bo sumy z $k-l = \pm 1$ są zerami.

7 HCQT: widmo ułożone harmonicznie

7.1 Pomysł: niech każdy kandydat widzi swoje alikwoty w jednym miejscu

Mamy widmo $|X[k]|$ okna dźwięku (rozdział 6) i wiemy, że nuta to szereg alikwotów (rozdział 3). Chcemy, żeby sieć uczyła się „wzorca nuty". Gdyby ułożyć widmo tak, by dla *każdego kandydata na wysokość* wszystkie jego alikwoty leżały w tym samym miejscu tensora, zwykła konwolucja (rozdział 9) mogłaby je porównywać bez żadnej kombinatoryki. Tak działa HCQT (ang. *harmonic constant-Q transform*): to stos kopii widma, z których h-ta jest „ściśnięta" h-krotnie. Nasz opis opiera się na pomyśle Bittnera i in. (2017).

Po tym rozdziale umiesz: (i) zdefiniować wartość HCQT w binie p kanału h, (ii) policzyć decybele i normalizację, (iii) udowodnić, że cechy nie zależą od głośności nagrania, (iv) udowodnić, że kanały to przesunięte kopie jednego widma, (v) odczytać kształt $X \in \mathbb{R}^{T\times 9\times 159}$.

7.2 Biny logarytmiczne i alikwoty

Zamiast równych odstępów w hercach (jak w DFT) używamy równych odstępów w *półtonach*: wprost z rozdziału 3 wiemy, że wtedy wzorzec alikwotów jest niezmienniczy względem przesunięcia.

bin logarytmiczny

Definicja 7.1 (Bin wysokości i jego częstotliwość). Niech $b = 3$ (liczba binów na półton) i $m_{\min} = 36$. Bin o numerze $p = 0, 1, \ldots, 158$ ma wysokość $m_p = m_{\min} + \dfrac{p-1}{3}$ (w skali MIDI) i częstotliwość środkową $f(p) = 440 \cdot 2^{(m_p-69)/12}$. Bin $p = 3s+1$ jest środkiem półtonu $s = 0, \ldots, 52$ (nuta MIDI $36+s$); biny $3s$ i $3s+2$ leżą 33,3 centa niżej i wyżej.

Przykład 7.1. Nuta E2 ($m = 40$, $s = 4$) leży w binie $p = 3\cdot 4+1 = 13$: $m_{13} = 36+12/3 = 40$ i $f = 82{,}41$ Hz. Biny 12 i 14 to $m = 39{,}67$ i $40{,}33$, czyli ∓ 33 centy od E2. Zakres wszystkich 159 binów to $m = 35{,}67$ do $88{,}33$.

HCQT

Definicja 7.2 (Wartość HCQT). Niech $S_t[k]$ będzie widmem amplitudowym okna o środku w klatce t (okno Hanna, FFT z zero-paddingiem $\times 4$). Dla *numeru alikwotu* $h \in \{0{,}5; 1; 2; 3; 4; 5\}$ definiujemy amplitudę w binie p:

$$A_h[t,p] = \max\left\{ S_t[k] \;:\; hf(p)\,2^{-1/72} \le f_k \le hf(p)\,2^{1/72} \right\}. \tag{7.1}$$

Przedział to $\pm\frac{1}{6}$ półtonu (czyli $\frac{1}{72}$ oktawy) wokół częstotliwości $hf(p)$. Zakres jest pusty ($A_h := 0$), gdy $hf(p) > 0{,}46 f_s$ (ponad Nyquistem).

Przykład 7.2. Dla $p = 13$ (E2, $f = 82{,}41\,\mathrm{Hz}$) i $h = 2$ szukamy maksimum widma w przedziale $[2 \cdot 82{,}41 \cdot 2^{-1/72},\, 2 \cdot 82{,}41 \cdot 2^{1/72}] = [163{,}3;\ 166{,}4]\,\mathrm{Hz}$ wokół drugiego alikwotu (164,8 Hz). Przy zero-paddingu $\times 4$ bin FFT ma 0,67 Hz, więc przedział zawiera ok. 5 binów FFT, a $A_2[t, 13]$ to największa z ich amplitud.

Intuicja. $A_h[t,p]$ odpowiada na pytanie: „gdyby w binie p grała nuta, a ja podsłuchałbym jej h-ty alikwot — ile energii bym tam usłyszał?”. Kanał $h = 1$ to zwykłe widmo, kanał $h = 2$ pokazuje, ile energii jest o oktawę wyżej niż każdy kandydat, itd. ♢

7.3 Decybele i normalizacja

Ucho ocenia głośność logarytmicznie (rozdział 1), więc amplitudy zamieniamy na decybele.

decybel

Definicja 7.3 (Decybel i cecha). Poziom amplitudy $A > 0$ w decybelach to $L = 20\log_{10} A$ dB. Dla ustalonej *referencji* L_{ref} definiujemy *cechę*

$$\varphi = \mathrm{clip}\Big(\frac{L - L_{\mathrm{ref}}}{60} + 1,\ 0,\ 1{,}3\Big). \tag{7.2}$$

Referencją jest 99,5. percentyl wszystkich poziomów L nagrania (osobno dla okna długiego i krótkiego).

Na konkretnych liczbach. Niech $L_{\mathrm{ref}} = -20\,\mathrm{dB}$ (czyli $A_{\mathrm{ref}} = 0{,}1$). Piksel o $A = 0{,}1$ ma $\varphi = 1$. Piksel o $A = 10^{-3}$ ($L = -60\,\mathrm{dB}$): $\varphi = (-60 + 20)/60 + 1 = 0{,}333$. Piksel o $A = 0{,}12$ ($L = -18{,}4\,\mathrm{dB}$): $\varphi = 1{,}026$ (cecha bywa > 1, bo A może przewyższać percentyl). Piksel o $A = 10^{-5}$ ($L = -100\,\mathrm{dB}$): $\varphi = -0{,}333$, po przycięciu 0. Zakres 60 dB znaczy: wszystko cichsze niż 60 dB poniżej referencji to dla sieci cisza.

Twierdzenie 7.4 (Niezależność od głośności nagrania). *Niech nagranie x zostanie pomnożone przez stałą $g > 0$. Pomijając wpływ stałej 10^{-9} w logarytmie, cechy φ obliczone dla gx i dla x są identyczne.*

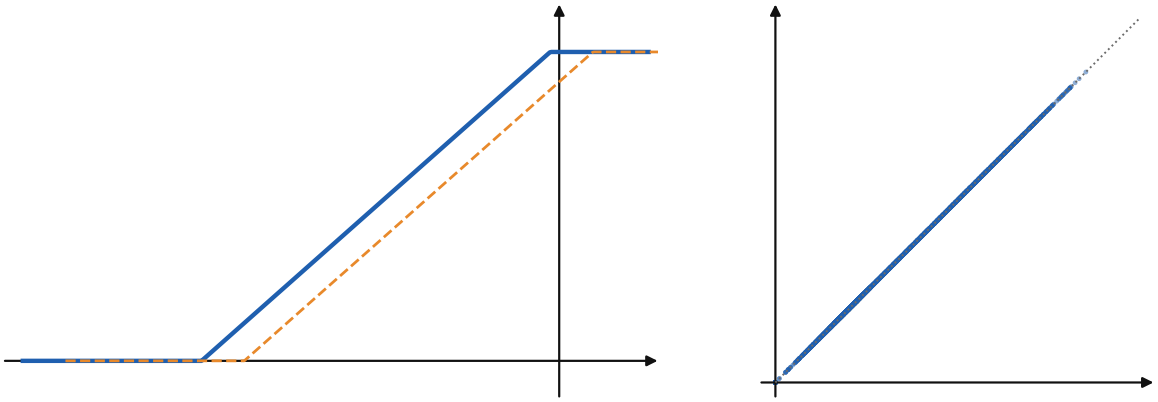
Pomysł dowodu. Skalowanie sygnału dodaje stałą do wszystkich decybeli, a percentyl przesuwa się o tę samą stałą; różnica $L - L_{\mathrm{ref}}$ się nie zmienia.

Dowód. Widmo jest liniowe w sygnale, więc $S_t[k] \mapsto g S_t[k]$, a maksimum z dodatnich liczb też się skaluje: $A \mapsto gA$ (maksimum jest jednorodne). Zatem

$$\begin{aligned}
L' &= 20\log_{10}(gA) = L + 20\log_{10} g && \text{(tw. 1.6)}\\
L'_{\mathrm{ref}} &= \mathrm{perc}_{99,5}\{L + c\} = L_{\mathrm{ref}} + c, \quad c = 20\log_{10} g && \text{(percentyl przesuwa się o } c\text{)}\\
L' - L'_{\mathrm{ref}} &= L - L_{\mathrm{ref}}. && (c \text{ się skraca})
\end{aligned}$$

Cecha zależy tylko od $L - L_{\mathrm{ref}}$, więc jest taka sama. Percentyl przesuwa się o c, bo dodanie stałej nie zmienia kolejności elementów. ■

W zwykłym języku: czy nagranie jest ciche, czy głośne, sieć dostaje te same liczby. Jeżeli $g = 3$, wszystkie poziomy rosną o $20\log_{10} 3 = 9{,}54\,\mathrm{dB}$, a referencja o tyle samo. Numerycznie (rys. 7.1b) dla nagrania i nagrania 10 razy cichszego największa różnica cech to $4 \cdot 10^{-5}$, czyli błąd zaokrągleń `float32`.



(a) (b)

Rysunek 7.1: (a) Cecha jako funkcja $\log_{10} A$ (niebieska): płaski początek (cisza poniżej 60 dB od referencji), liniowy wzrost i przycięcie na 1,3. Nagranie 3 razy głośniejsze (pomarańczowa przerywana) ma tę samą krzywą, bo referencja przesuwa się razem z poziomami (tw. 7.4). (b) Wartości cech tego samego nagrania (poziomo) i nagrania 10 razy cichszego (pion): wszystkie punkty leżą na przekątnej (kropkowana).

Pułapka. Niezależność od głośności dotyczy *stałego* przeskalowania całego nagrania. Nie obejmuje szumu: jeśli głośniejsza jest tylko jedna część, albo tło ma stały poziom, normalizacja nie pomoże. Stała 10^{-9} w logarytmie psuje twierdzenie tylko dla amplitud tak małych, że i tak są obcięte do zera. ♢

7.4 Kanały to przesunięte kopie jednego widma

Twierdzenie 7.5 (Przesunięcie kanałów). *Jeśli $k_h = 36\log_2 h$ jest liczbą całkowitą, to dla każdej klatki i każdego binu p zachodzi $A_h[t,p] = A_1[t, p+k_h]$.*

Pomysł dowodu. Bin $p+k_h$ ma częstotliwość środkową dokładnie h razy większą niż bin p, więc obie amplitudy to maksimum z tego samego przedziału widma.

Dowód. Z def. 7.1 mamy $m_{p+k_h} = m_p + k_h/3$. Zatem

$$\begin{aligned} f(p+k_h) &= 440 \cdot 2^{(m_p+k_h/3-69)/12} = f(p) \cdot 2^{k_h/36} && \text{(dodanie wykładników)} \\ &= f(p) \cdot 2^{\log_2 h} = h f(p). && (k_h = 36\log_2 h) \end{aligned}$$

Przedział w def. 7.2 dla $A_h[t,p]$ to $[hf(p)2^{-1/72}, hf(p)2^{1/72}]$, a dla $A_1[t, p+k_h]$ to $[f(p+k_h)2^{-1/72}, f(p+k_h)2^{1/72}]$; są identyczne. Maksimum z tego samego zbioru jest to samo. (Rozważamy tylko p, dla których $p+k_h$ mieści się w $0,\ldots,158$.) To kończy dowód. ■

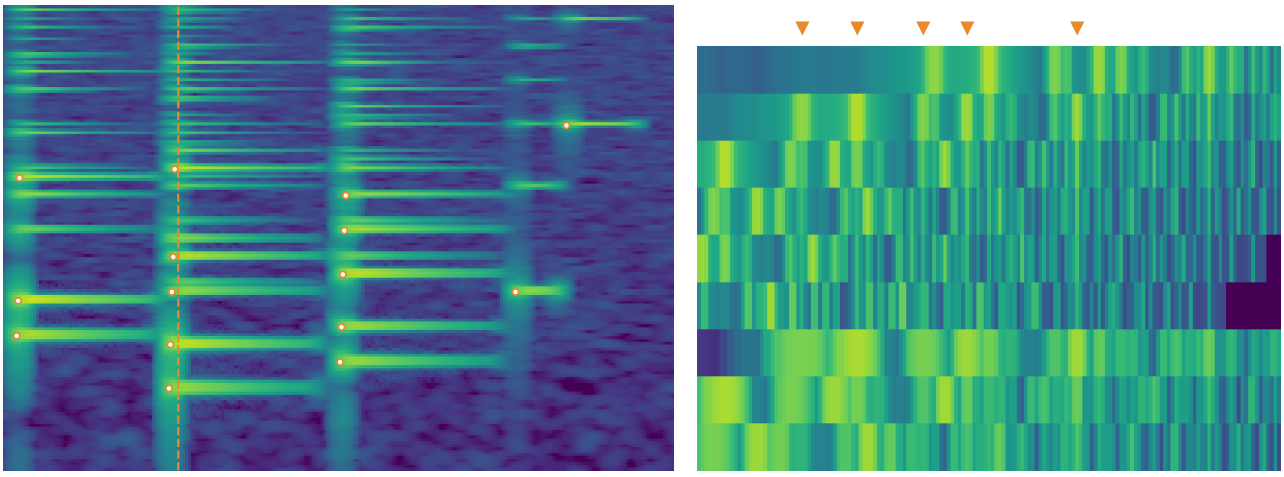
Dla $h = 0{,}5; 2; 4$ mamy $k_h = -36; 36; 72$, więc równość jest dokładna; dla $h = 3$ i 5 ($k_h = 57{,}06$ i $83{,}59$) przesunięcie całkowite jest tylko przybliżeniem, a błąd to poniżej pół bina. Sprawdziliśmy to na prawdziwym

kodzie: dla kanałów $h = 0{,}5; 2; 4$ różnica $A_h[t, p] - A_1[t, p + k_h]$ wynosi dokładnie 0 w całym nagraniu, a dla $h = 3$ średnio 0,007 (maksymalnie 0,18). Ta własność uzasadnia blok harmoniczny sieci (rozdział **??**): sieć sama może „doprzesunąć" własne cechy o k_h binów i uzyskać alikwoty także wyższe niż 5.

7.5 Co dokładnie dostaje sieć

parametr	wartość	znaczenie
f_s	11 025 Hz	po zmianie próbkowania
okna	4096 i 1024 próbek	długie (wysokość), krótkie (czas)
krok	256 próbek = 23,2 ms	odstęp klatek
zero-padding	$\times 4$	gładsze położenie pików
alikwoty długie	0,5; 1; 2; 3; 4; 5	kanały 1–6
alikwoty krótkie	1; 2; 3	kanały 7–9
biny	$3 \times 53 = 159$	MIDI 36–88
normalizacja	99,5 perc., 60 dB, clip 1,3	def. 7.3

Tabela 7.1: Parametry HCQT w modelu Gen 6. Wynik: $X \in \mathbb{R}^{T \times 9 \times 159}$.



(a) (b)

Rysunek 7.2: HCQT syntetycznego, 6-sekundowego nagrania gitary. (a) Kanał $h = 1$: czas poziomo (243 klatki), wysokość pionowo (159 binów); jasne ślady to alikwoty grających nut, kółka z pomarańczowym brzegiem to początki prawdziwych nut, przerywana linia to klatka pokazana w (b). (b) Cała jedna klatka: 9 kanałów (wiersze) $\times$ 159 binów (kolumny). Pomarańczowe trójkąty wskazują prawdziwe nuty: pod każdym z nich w kolumnie pojawiają się jasne plamy w wielu kanałach naraz, bo alikwoty kandydata ustawiono w jednej kolumnie.

W obu oknach analizujemy tę samą klatkę t (środek wspólny). Dla nagrania 6-sekundowego $T = 243$ i X ma $243 \cdot 9 \cdot 159 = 347\,733$ liczby (przykład 1.2). Rysunek 7.2b to najważniejszy obrazek książki: siatka nut jako kolumny, siedem „pięter" alikwotów jako wiersze. Zadaniem sieci jest rozpoznać w tej siatce wzorzec „ta kolumna jest zajęta przez nutę" i odróżnić go od kolumn, które tylko udają nutę, bo leżą oktawę niżej.

Podsumowanie

- Bin wysokości ma $\frac{1}{3}$ półtonu; $p = 3s + 1$ jest środkiem półtonu s.

- $A_h[t,p]$ to maksimum widma wokół $hf(p)$ ($\pm\frac{1}{6}$ półtonu); $h = 0{,}5\ldots5$ (okno długie), $1,2,3$ (krótkie): razem 9 kanałów.
- Cecha $= \mathrm{clip}((L - L_{\mathrm{ref}})/60 + 1, 0, 1{,}3)$ jest niezależna od głośności nagrania (tw. 7.4).
- Jeśli $36\log_2 h$ jest całkowite, kanał h to kanał 1 przesunięty o tyle binów (tw. 7.5).
- Wejście sieci to $X \in \mathbb{R}^{T\times 9\times 159}$ ze krokiem 23,2 ms.

Ćwiczenia

1. O ile decybeli rośnie poziom, gdy amplituda podwaja się? A gdy rośnie 10 razy?
2. Dla $L_{\mathrm{ref}} = -30\,\mathrm{dB}$ policz cechę piksela o $A = 0{,}005$. (Wskazówka: $L = 20\log_{10} A$.)
3. Który bin odpowiada nucie A2 ($m = 45$)? Jaki jest numer binu jej trzeciego alikwotu ($h = 3$), w przybliżeniu całkowitym?
4. Od jakiej wysokości kanał $h = 5$ jest zerowy? Użyj progu $0{,}46 f_s$ i podaj najniższy bin p, dla którego tak jest.

Rozwiązania

1. $20\log_{10} 2 = 6{,}02\,\mathrm{dB}$, a $20\log_{10} 10 = 20\,\mathrm{dB}$.
2. $L = 20\log_{10} 0{,}005 = -46{,}02\,\mathrm{dB}$, $\varphi = (-46{,}02 + 30)/60 + 1 = 0{,}733$.
3. $p = 3\cdot(45-36)+1 = 28$. Trzeci alikwot: $k_3 = \mathrm{round}(36\log_2 3) = 57$, czyli bin $28 + 57 = 85$ ($m_{85} = 36 + 84/3 = 64$, to E4; dokładnie oczekiwane $45 + 19{,}02 = 64{,}02$).
4. Zero, gdy $5f(p) > 5071{,}5\,\mathrm{Hz}$, czyli $f(p) > 1014{,}3\,\mathrm{Hz}$, czyli $m_p > 69 + 12\log_2(1014{,}3/440) = 83{,}48$. Z $m_p = 36 + (p-1)/3$ dostajemy $p - 1 > 142{,}4$, więc najniższy zerowy bin to $p = 144$. Zerowych jest więc $159 - 144 = 15$ binów (najwyższe 5 półtonów: ok. 83,5–88,3).

8 Prawdopodobieństwo i funkcje straty

8.1 Jak powiedzieć modelowi, że się myli?

Wyjściem sieci jest, dla każdej klatki i półtonu, liczba z przedziału $(0,1)$: „z jakim prawdopodobieństwem w tej klatce gra ta nuta?". Żeby uczyć sieć gradientem (rozdział 5), potrzebujemy funkcji straty: jednej liczby, która jest mała, gdy odpowiedzi są dobre, i duża, gdy złe. Tu wyprowadzimy dwie funkcje używane w Gen 6 (sigmoidę z entropią krzyżową dla początków, ramek i końców; softmax dla tabulatury) i pokażemy, *dlaczego* akurat takie.

Po tym rozdziale umiesz: (i) zamienić liczbę rzeczywistą na prawdopodobieństwo sigmoidą i softmaksem, (ii) policzyć stratę BCE i jej gradient, (iii) uzasadnić, że BCE jest najmniejsza dla prawdziwego prawdopodobieństwa, (iv) powiedzieć, co robi waga klasy dodatniej.

8.2 Sigmoida i softmax

sigmoida

Definicja 8.1 (Sigmoida). Funkcja $\sigma(z) = \dfrac{1}{1+e^{-z}}$ przekształca dowolną liczbę $z \in \mathbb{R}$ (zwaną *logitem*) w liczbę z przedziału $(0,1)$. Zachodzi $\sigma(-z) = 1-\sigma(z)$ i $\sigma(0) = \frac{1}{2}$.

Przykład 8.1. $\sigma(0) = 0{,}5$; $\sigma(2) = 0{,}881$; $\sigma(-2) = 0{,}119$; $\sigma(-3) = 0{,}0474$. Duży dodatni logit oznacza „prawie na pewno tak", duży ujemny „prawie na pewno nie". Odwrotność: $z = \ln \frac{p}{1-p}$ (logarytm szans).

softmax

Definicja 8.2 (Softmax). Dla wektora logitów $\boldsymbol{z} \in \mathbb{R}^K$ (K klas) *softmaksem* nazywamy wektor o współrzędnych $\operatorname{softmax}(\boldsymbol{z})_i = \dfrac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$.

Przykład 8.2. Dla $\boldsymbol{z} = (2; 1; 0{,}1)$ mamy $e^{z} = (7{,}389;\ 2{,}718;\ 1{,}105)$, suma $11{,}212$, więc softmax to $(0{,}659;\ 0{,}242;\ 0{,}099)$. Największy logit dostaje największe prawdopodobieństwo, ale mniejsze też nie giną.

Twierdzenie 8.3 (Własności softmaksa). *Dla każdego $\boldsymbol{z}$: (a)* $\operatorname{softmax}(\boldsymbol{z})_i > 0$ *i* $\sum_i \operatorname{softmax}(\boldsymbol{z})_i = 1$*; (b)* $\operatorname{softmax}(\boldsymbol{z} + c\mathbf{1}) = \operatorname{softmax}(\boldsymbol{z})$ *dla dowolnej stałej c.*

Pomysł dowodu. (a) wynika z dodatniości wykładnika i z tego, że dzielimy przez sumę; (b): czynnik e^{c} skraca się w liczniku i mianowniku.

Dowód. (a) $e^{z_i} > 0$ dla każdego z_i, a mianownik jest sumą takich liczb, więc wynik jest dodatni; suma ułamków o wspólnym mianowniku $\sum_j e^{z_j}$ daje 1. (b)

$$\begin{aligned} \frac{e^{z_i+c}}{\sum_j e^{z_j+c}} &= \frac{e^c e^{z_i}}{e^c \sum_j e^{z_j}} && (e^{a+b} = e^a e^b) \\ &= \frac{e^{z_i}}{\sum_j e^{z_j}}. && (\text{skrócenie } e^c) \end{aligned}$$

W praktyce odejmujemy od logitów ich maksimum ($c = -\max z$), żeby uniknąć przepełnienia e^z dla dużych z — wynik się nie zmienia. To kończy dowód. ∎

Sigmoida to softmax dwóch klas $(z, 0)$: $\operatorname{softmax}(z,0)_1 = e^z/(e^z+1) = \sigma(z)$. Używamy sigmoidy, gdy klasy nie wykluczają się (w jednej klatce może grać wiele półtonów naraz), a softmaksu, gdy dokładnie jedna odpowiedź jest prawdziwa (na strunie dokładnie jedna z 21 klas: milczy albo któryś próg).

8.3 Entropia krzyżowa

entropia krzyżowa

Definicja 8.4 (Strata BCE). Dla prawdopodobieństwa $p \in (0,1)$ i etykiety $y \in [0,1]$ (zwykle 0 lub 1) *binarna entropia krzyżowa* wynosi

$$\ell(p,y) = -\big[\, y \ln p + (1-y)\ln(1-p) \,\big]. \tag{8.1}$$

Z *wagą klasy dodatniej* $\alpha > 0$: $\ell_\alpha(p,y) = -\big[\alpha\, y \ln p + (1-y)\ln(1-p)\big]$.

Przykład 8.3. Dla $y = 1$ i $p = 0{,}9$: $\ell = -\ln 0{,}9 = 0{,}105$. Dla $p = 0{,}2$: $\ell = -\ln 0{,}2 = 1{,}609$; z wagą $\alpha = 4$ strata wynosi 6,44. Dla $y = 0$ i $p = 0{,}2$: $\ell = -\ln 0{,}8 = 0{,}223$. Pewność w złą stronę ($p \to 0$ przy $y = 1$) jest karana nieograniczenie: $-\ln p \to \infty$ (rys. 8.1a).

Intuicja. Strata BCE to „zaskoczenie" modelu: $-\ln p$ to ile bitów (nat) informacji niesie zdarzenie, któremu przypisaliśmy p. Model, który był pewien złej odpowiedzi, jest bardzo zaskoczony, więc ponosi dużą karę. ♢

Twierdzenie 8.5 (Gradient BCE po logicie). *Dla* $p = \sigma(z)$*:* $\dfrac{\partial \ell}{\partial z} = \sigma(z) - y$.
Z wagą α*:* $\dfrac{\partial \ell_\alpha}{\partial z} = (\alpha y + 1 - y)\,\sigma(z) - \alpha y$.

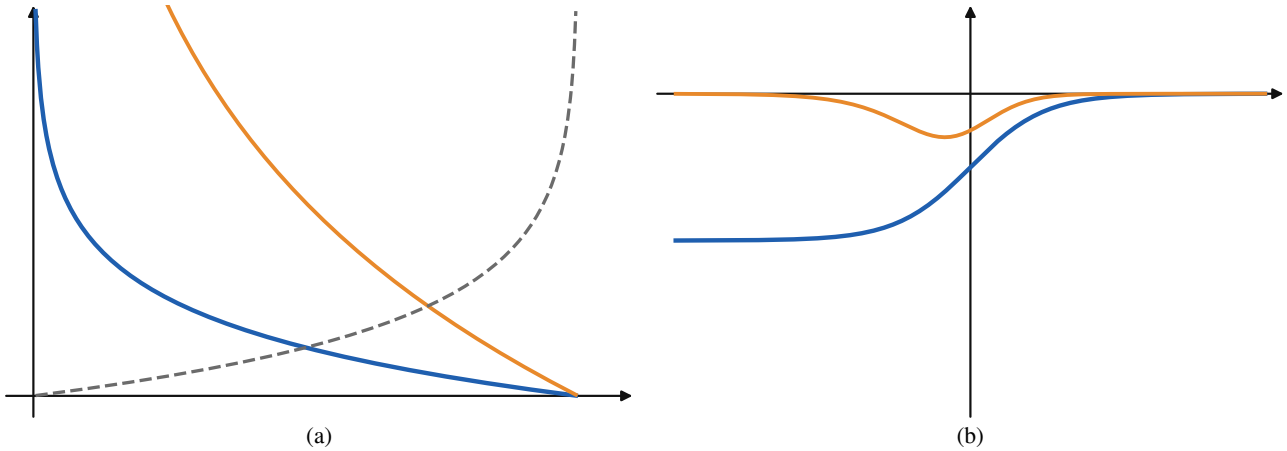
Pomysł dowodu. Regułą łańcuchową przez $p = \sigma(z)$ i pochodną sigmoidy $\sigma' = \sigma(1-\sigma)$ (tw. 5.3); czynniki $p(1-p)$ się skracają.

Dowód. Niech $p = \sigma(z)$, więc $\partial p/\partial z = p(1-p)$. Dla ℓ_α:

$$\begin{aligned} \frac{\partial \ell_\alpha}{\partial p} &= -\frac{\alpha y}{p} + \frac{1-y}{1-p} && (\text{pochodna ln}) \\ \frac{\partial \ell_\alpha}{\partial z} &= \Big(-\frac{\alpha y}{p} + \frac{1-y}{1-p}\Big) p(1-p) && (\text{reguła łańcuchowa}) \\ &= -\alpha y(1-p) + (1-y)p && (\text{skrócenie}) \\ &= (\alpha y + 1 - y)\, p - \alpha y. && (\text{wyłączenie } p) \end{aligned}$$

Dla $\alpha = 1$ to $p - y$. Dla $y = 1$ gradient to $-\alpha(1-p)$, dla $y = 0$ to p. To kończy dowód. ■

W zwykłym języku: gradient po logicie to po prostu „odpowiedź modelu minus prawda". Gdy $y = 1$ i model mówi $p \approx 0$ (bardzo się myli), gradient jest bliski -1 — silny sygnał do poprawy. Dla błędu kwadratowego $(p-y)^2$ ten sam gradient to $2(p-y)p(1-p)$, który *znika*, gdy sigmoida jest nasycona (rys. 8.1b): np. dla $z = -5$ i $y = 1$ gradient BCE wynosi $-0{,}993$, a błędu kwadratowego tylko $-0{,}013$. Dlatego do klasyfikacji używamy BCE.



(a) (b)

Rysunek 8.1: (a) Strata BCE w funkcji p: dla $y = 1$ ($-\ln p$, niebieska) i z wagą $\alpha = 4$ (pomarańczowa) rośnie do nieskończoności, gdy $p \to 0$; dla $y = 0$ ($-\ln(1-p)$, szara przerywana) rośnie, gdy $p \to 1$. (b) Gradient po logicie dla $y = 1$: BCE (niebieska, $\sigma - 1$) pozostaje blisko -1 przy dużym błędzie; gradient błędu kwadratowego (pomarańczowa) zanika w nasyceniu.

Twierdzenie 8.6 (BCE uczy prawdziwego prawdopodobieństwa). *Niech etykieta $y \in \{0,1\}$ wypada 1 z prawdopodobieństwem $q \in (0,1)$. Średnia strata $\mathbb{E}[\ell_\alpha(p,y)] = -\alpha q \ln p - (1-q)\ln(1-p)$ jest najmniejsza dla*

$$p^* = \frac{\alpha q}{\alpha q + 1 - q}. \tag{8.2}$$

W szczególności dla $\alpha = 1$ jest to $p^* = q$.

Pomysł dowodu. Różniczkujemy średnią stratę po p, przyrównujemy do zera i sprawdzamy, że to minimum.

Dowód. Niech $J(p) = -\alpha q \ln p - (1-q)\ln(1-p)$ dla $p \in (0,1)$.

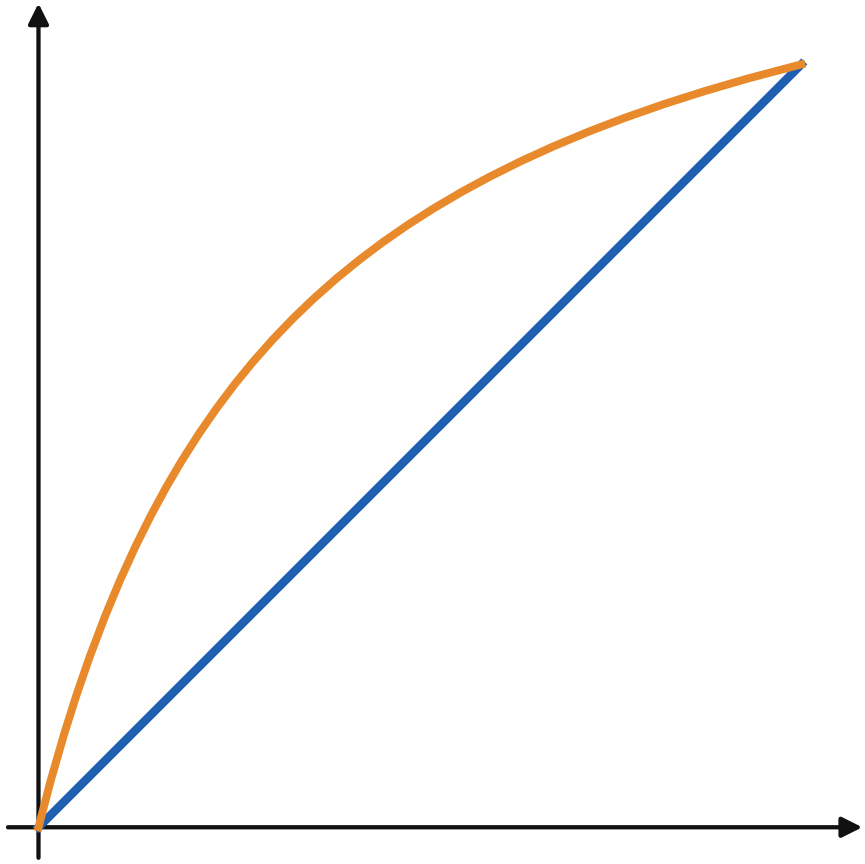
$$J'(p) = -\frac{\alpha q}{p} + \frac{1-q}{1-p} = 0 \qquad \text{(warunek konieczny)}$$

$$\Rightarrow\ \alpha q(1-p) = (1-q)p \ \Rightarrow\ p^* = \frac{\alpha q}{\alpha q + 1 - q}. \qquad \text{(rozwiązanie względem } p\text{)}$$

Druga pochodna $J''(p) = \alpha q/p^2 + (1-q)/(1-p)^2 > 0$, więc to jedyne minimum. To kończy dowód. ■

Na konkretnych liczbach. Jeśli w danym półtonie początek nuty występuje w $q = 10\%$ przypadków, a waga to $\alpha = 4$, model uczony BCE nauczy się mówić $p^* = 0{,}4/(0{,}4 + 0{,}9) = 0{,}308$, a nie $0{,}1$. Waga za-

wyża więc prawdopodobieństwa (rys. 8.2). Podobnie miękka etykieta $y = 0{,}4$ (sąsiednie klatki wokół początku w Gen 6) przy $\alpha = 1$ i q interpretowanym jako średnia etykieta daje $p^* = 0{,}4$: model nie jest karany za niepewność o jedną klatkę.



Rysunek 8.2: Optymalne prawdopodobieństwo p^* (pion) w zależności od prawdziwej częstości q (poziom) dla wagi $\alpha = 1$ (niebieska, leży na przekątnej) i $\alpha = 4$ (pomarańczowa, nad przekątną). Waga klasy dodatniej przesuwa wyjścia sieci w górę; dekoder (rozdział **??**) musi to uwzględnić przez progi dobrane na walidacji.

Pułapka. Wyjścia sieci uczonej z wagą $\alpha > 1$ *nie są* prawdziwymi prawdopodobieństwami. Próg 0,5 w dekoderze nie ma wtedy żadnego szczególnego znaczenia; dlatego progi dekodera Gen 6 stroimy osobno (rozdział **??**). ♢

8.4 Dlaczego rzadkie etykiety są trudne

Weźmy prawdziwy przykład: nagranie z rozdziału 7 ($T = 243$ klatek, 53 półtony, 12 879 komórek) ma 15 nut. Mapa początków ma więc tylko 15 komórek równych 1 (i 30 równych 0,4): to 0,12% wszystkich. Sieć, która zawsze odpowiada „zero”, ma niemal idealną dokładność, a zupełnie nie nadaje się do niczego. Dwa środki zaradcze używane w Gen 6: waga $\alpha = 4$ dla początków ($\alpha = 2$ dla końców) oraz *inicjalizacja obciążenia* ostatniej warstwy na -3 dla początków (i -2 dla ramek). Na starcie $\sigma(-3) = 0{,}047$, więc strata na komórkę to $-\big[0{,}0012 \ln 0{,}047 + 0{,}9988 \ln 0{,}953\big] = 0{,}052$, a przy $\sigma(0) = 0{,}5$ byłoby 0,693: sieć nie musi tracić pierwszych kroków na samo „nauczenie się, że nut jest mało”.

8.5 Softmax i tabulatura

Dla jednej struny w jednej klatce sieć zwraca 21 logitów (klasa 0: struna milczy, klasy $1+f$ dla progów $f = 0, \ldots, 19$). Strata to ujemny logarytm prawdopodobieństwa klasy prawdziwej: $\ell = -\ln \mathrm{softmax}(\boldsymbol{z})_c = -z_c + \ln \sum_j e^{z_j}$. Jej gradient po logitach to $\mathrm{softmax}(\boldsymbol{z}) - \boldsymbol{e}_c$ (analogicznie do tw. 8.5).

Na konkretnych liczbach. Dla trzech klas $\boldsymbol{z} = (2; 1; 0{,}1)$ i prawdziwej klasy $c = 1$ (pierwszej): softmax $= (0{,}659;\ 0{,}242;\ 0{,}099)$, strata $-\ln 0{,}659 = 0{,}417$, gradient po logitach $(0{,}659 - 1;\ 0{,}242;\ 0{,}099) = (-0{,}341;\ 0{,}242;\ 0{,}099)$. Zwróćmy uwagę: suma gradientu to zero, bo suma softmaksu to 1 — podnoszenie jednego logitu odbywa się kosztem pozostałych.

Podsumowanie

- σ zamienia logit na prawdopodobieństwo; softmax robi to dla wielu wykluczających się klas i jest niezmienniczy względem dodania stałej.
- BCE $= -[y \ln p + (1-y)\ln(1-p)]$; jej gradient po logicie to $\sigma(z) - y$ (tw. 8.5).
- BCE jest najmniejsza dla prawdziwej częstości; waga α zawyża wyjścia do $\frac{\alpha q}{\alpha q + 1 - q}$ (tw. 8.6).
- Etykiety początków są rzadkie (0,12% komórek), więc używamy wagi i obciążenia początkowego -3.
- Tabulatura: softmax po 21 klasach na strunę i strata $-\ln p_{\text{klasa}}$.

Ćwiczenia

1. Policz $\sigma(1)$, $\sigma(-1)$ i sprawdź, że sumują się do 1.
2. Dla $y = 1$ policz stratę BCE z $\alpha = 1$ oraz $\alpha = 2$ przy $p = 0{,}3$, a także gradient po logicie w obu przypadkach.
3. Pokaż, że $\mathrm{softmax}(z, 0)_1 = \sigma(z)$.
4. Przy $q = 0{,}05$ i $\alpha = 2$ ile wynosi p^*? Jaką wagę α trzeba wziąć, by $p^* = 0{,}5$ przy $q = 0{,}05$?

Rozwiązania

1. $\sigma(1) = 0{,}7311$, $\sigma(-1) = 0{,}2689$, suma 1,0000.
2. $\alpha = 1$: $-\ln 0{,}3 = 1{,}204$, gradient $0{,}3 - 1 = -0{,}7$. $\alpha = 2$: strata 2,408, gradient $-2(1 - 0{,}3) = -1{,}4$.
3. $\mathrm{softmax}(z, 0)_1 = e^z/(e^z + e^0) = e^z/(e^z + 1) = 1/(1 + e^{-z}) = \sigma(z)$ (dzielimy licznik i mianownik przez e^z).
4. $p^* = 2 \cdot 0{,}05/(0{,}1 + 0{,}95) = 0{,}095$. Z równania $\alpha q = 1 - q$: $\alpha = (1 - q)/q = 19$ daje $p^* = 0{,}5$.

9 Sieć neuronowa: warstwy, konwolucja i normalizacja

9.1 Z czego zbudowana jest sieć?

Sieć neuronowa to złożenie prostych funkcji (rozdział 1); każda z nich ma kilka parametrów, które dobieramy gradientem (rozdział 5). Model Gen 6 używa pięciu rodzajów cegiełek: warstwy liniowej (rozdział 4), funkcji nieliniowej GELU, konwolucji, normalizacji warstwy i połączeń resztkowych. Poznajmy je po kolei, ze sprawdzeniem na małych liczbach.

Po tym rozdziale umiesz: (i) policzyć GELU i konwolucję jednowymiarową ręcznie, (ii) policzyć liczbę parametrów konwolucji, (iii) wyznaczyć pole widzenia stosu konwolucji z dylatacją, (iv) uzasadnić własności LayerNorm i połączenia resztkowego.

9.2 Nieliniowość: po co i jaka

Z twierdzenia 4.4 wiemy, że dwie warstwy liniowe to jedna warstwa liniowa. Żeby głębokość coś dawała, między warstwami wstawiamy funkcję nieliniową działającą na każdą liczbę osobno.

GELU

Definicja 9.1 (GELU). Niech $\Phi(z) = \frac{1}{2}\big(1 + \operatorname{erf}(z/\sqrt{2})\big)$ będzie dystrybuantą rozkładu normalnego $N(0,1)$. Funkcja $\operatorname{GELU}(z) = z\Phi(z)$ „bramkuje” wejście: mnoży je przez prawdopodobieństwo, że losowa liczba $N(0,1)$ jest mniejsza od z. Dla porównania $\operatorname{ReLU}(z) = \max(0, z)$.

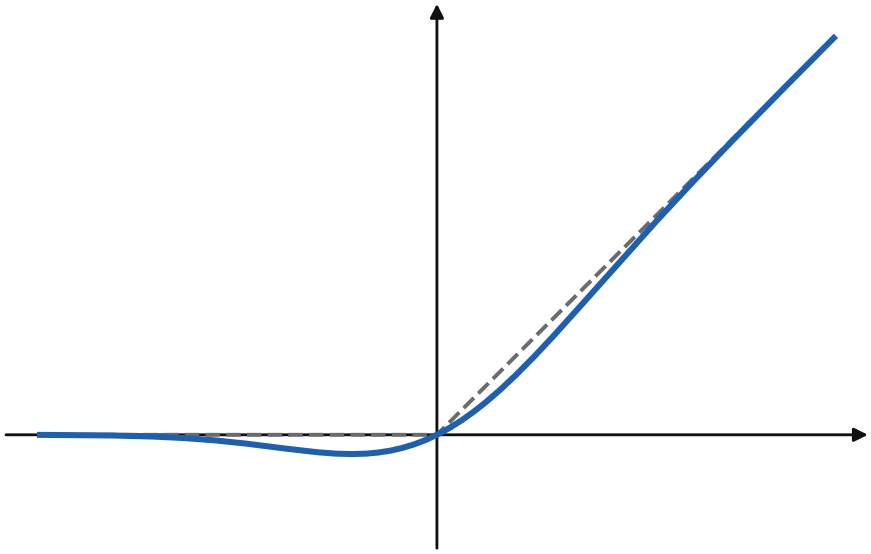
Przykład 9.1. $\operatorname{GELU}(2) = 2 \cdot 0{,}9772 = 1{,}9545$, $\operatorname{GELU}(1) = 0{,}8413$, $\operatorname{GELU}(0) = 0$, $\operatorname{GELU}(-1) = -0{,}1587$, $\operatorname{GELU}(-3) = -0{,}0040$. Dla dużych dodatnich z funkcja zachowuje się jak z, dla dużych ujemnych dąży do zera; w okolicy zera jest gładka (rys. 9.1).

Intuicja. ReLU wycina wszystko ujemne. GELU robi to łagodnie: małe ujemne wartości są tylko osłabiane. Przez to pochodna zmienia się płynnie i sieć uczy się stabilniej. Sam kształt nie jest świętością — ważne jest, by funkcja była nieliniowa. ♢

9.3 Konwolucja

Warstwa liniowa łączy każde wejście z każdym wyjściem. Dla sygnałów, w których ten sam wzorzec może wystąpić w różnych miejscach (nuta w dowolnej klatce, wzorzec alikwotów w dowolnej wysokości), lepsza jest warstwa, która *używa tych samych wag w każdym miejscu*.

konwolucja



Rysunek 9.1: GELU (niebieska) i ReLU (szara przerywana). GELU jest gładką wersją ReLU: w odróżnieniu od niego ma niewielką ujemną „zatokę” (minimum ok. $-0{,}17$) i nie ma ostrego załamania w zerze, więc ma pochodną wszędzie.

Definicja 9.2 (Konwolucja jednowymiarowa). Dla sygnału $x[t]$ i *jądra* $w[-r],\dots,w[r]$ (długość $k = 2r+1$) wynik konwolucji z krokiem 1 i dopełnieniem zerami to

$$y[t] = b + \sum_{j=-r}^{r} w[j]\,x[t+j], \tag{9.1}$$

przy czym $x[s] = 0$ poza zakresem. *Dylatacja* d rozstawia próbki jądra co d: $y[t] = b + \sum_j w[j]\,x[t + d\,j]$. *Krok* (stride) s oblicza wynik tylko co s-te t.

Przykład 9.2. Sygnał $x = (1,2,3,4,5,6)$, jądro $w = (1,0,-1)$ (dla $j = -1,0,1$), $b = 0$: $y[t] = x[t-1] - x[t+1]$. Wynik: $y = (-2,-2,-2,-2,-2,5)$. Różnica „poprzedni minus następny” wynosi -2 wszędzie, gdzie sygnał rośnie liniowo; ostatnia wartość $5 = x[5] - 0$ pochodzi z dopełnienia zerem, które udaje, że za końcem jest $x = 0$. Takie jądro wykrywa nachylenie sygnału, czyli działa jak pochodna.

W obrazach i widmach (dwa wymiary: czas i bin) jądro ma kształt $k_t \times k_p$ i przesuwa się w obu osiach. Jeśli każde z C_{we} kanałów wejściowych ma osobne jądro, a wyniki sumujemy do C_{wy} kanałów:

Twierdzenie 9.3 (Liczba parametrów konwolucji). *Konwolucja $k_t \times k_p$ z C_{we} kanałów do C_{wy} kanałów ma $C_{\text{we}} C_{\text{wy}}\, k_t k_p + C_{\text{wy}}$ parametrów, a konwolucja* głębokościowa *(osobne jądro dla każdego kanału, $C_{\text{we}} = C_{\text{wy}} = C$) ma $C\,k_t k_p + C$ parametrów. Liczba ta* nie zależy *od długości sygnału.*

Pomysł dowodu. Każdy z C_{wy} kanałów wyjściowych ma po jednym jądrze $k_t \times k_p$ dla każdego kanału wejściowego i jedno obciążenie.

Dowód. Jedno jądro ma $k_t k_p$ liczb. Kanał wyjściowy sumuje wkłady wszystkich kanałów wejściowych, więc ma C_{we} jąder i jedno obciążenie b.

$$\begin{aligned} \#\text{parametrów} &= C_{\text{wy}} \cdot \big(C_{\text{we}} \cdot k_t k_p + 1\big) && \text{(po kanale wyjściowym)} \\ &= C_{\text{we}} C_{\text{wy}} k_t k_p + C_{\text{wy}}. && \text{(rozdzielność)} \end{aligned}$$

W wersji głębokościowej każdy kanał ma tylko jedno jądro (dla samego siebie): $C(k_t k_p + 1)$. Wagi są te same dla każdego położenia, więc liczba parametrów nie rośnie z długością sygnału. To kończy dowód. ■

Na konkretnych liczbach. Trzon Gen 6: konwolucja 3×7 z 9 kanałów (HCQT) do 48: $9 \cdot 48 \cdot 21 + 48 = 9120$. Konwolucja głębokościowa 1×5 na 48 kanałach: $48 \cdot 5 + 48 = 288$. Konwolucja czasowa 3×1, $48 \to 48$: $48 \cdot 48 \cdot 3 + 48 = 6960$. Konwolucja 1×1 ($336 \to 48$): $336 \cdot 48 + 48 = 16\,176$ (to warstwa liniowa działająca w każdym miejscu osobno).

Twierdzenie 9.4 (Konwolucja jest równoważna przesunięciom). *Niech $(Tx)[t] = x[t-s]$ będzie przesunięciem sygnału o s w czasie. Konwolucja C (bez dopełnienia, w nieskończonym sygnale) spełnia $C(Tx) = T(Cx)$.*

Pomysł dowodu. Wstawiamy przesunięty sygnał do definicji i przesuwamy indeks.

Dowód.

$$\begin{aligned}
(C(Tx))[t] &= b + \sum_j w[j]\,(Tx)[t+j] && \text{(def. 9.2)}\\
&= b + \sum_j w[j]\,x[t+j-s] && \text{(def. } T\text{)}\\
&= (Cx)[t-s] = (T(Cx))[t]. && \text{(def. } C \text{ w punkcie } t-s\text{)}
\end{aligned}$$

Przesunięcie wejścia o s klatek przesuwa wynik o s klatek, a niczego innego nie zmienia: ta sama nuta w innym momencie daje ten sam wzorzec odpowiedzi. To kończy dowód. ■

W praktyce to właśnie dlatego konwolucja po osi binów (na osi logarytmicznej, rozdział 3) wykrywa ten sam wzorzec nuty o dowolnej wysokości.

pole widzenia

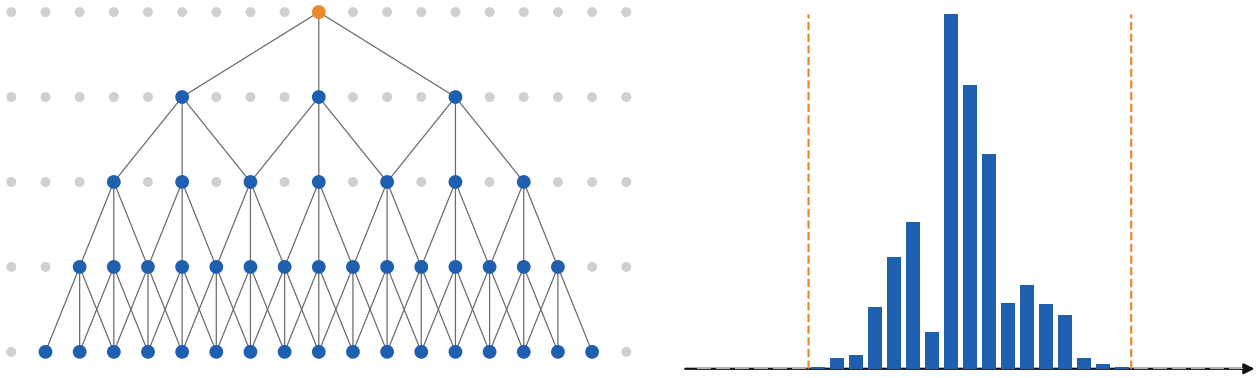
Twierdzenie 9.5 (Pole widzenia). *Stos n konwolucji w czasie z jądrami długości $k_i = 2r_i + 1$ i dylatacjami d_i ma* pole widzenia *(liczbę klatek wejścia z każdej strony, które wpływają na jedną klatkę wyjścia) $R = \sum_{i=1}^{n} d_i r_i$.*

Pomysł dowodu. Indukcja po liczbie warstw: każda nowa warstwa rozszerza zbiór zależności o $d_i r_i$ klatek z każdej strony.

Dowód. Dla $n = 1$: wyjście w klatce t zależy od wejść w $t + d_1 j$, $|j| \le r_1$, czyli od klatek odległych najwyżej o $d_1 r_1$. Załóżmy, że wyjście warstwy $n-1$ w klatce u zależy od wejść odległych najwyżej o R_{n-1}. Wyjście warstwy n w klatce t zależy od wyjść warstwy $n-1$ w $u = t + d_n j$, $|j| \le r_n$, a każde z nich od wejść odległych o co najwyżej R_{n-1} od u. Najdalsza zależność od t to

$$|u - t| + R_{n-1} \le d_n r_n + R_{n-1} = R_n \qquad \text{(nierówność trójkąta)}$$

i ta odległość jest osiągana (dla $j = \pm r_n$ i skrajnej zależności wcześniejszej, gdy odpowiednie wagi są niezerowe). Zatem $R = \sum d_i r_i$. To kończy dowód. ■



(a) (b)

Rysunek 9.2: (a) Schemat czterech konwolucji czasowych z jądrem 3 i dylatacjami 1 (trzon), 1,2,4 (od wejścia na dole do wyjścia na górze): pomarańczowa kropka to jedna klatka wyjścia, niebieskie to klatki wejścia, od których zależy (zasięg $\pm 8 = 1+1+2+4$). Z dylatacją pole widzenia rośnie wykładniczo, a nie liniowo, przy tej samej liczbie parametrów. (b) Pomiar: moduł gradientu jednej wartości wyjścia po wejściu w funkcji odległości w klatkach dla stosu z trzonem 3×7 i trzema blokami z dylatacjami 1,2,4 (losowe wagi, PyTorch): gradient jest niezerowy dokładnie dla $|t| \le 8 = 1+(1+2+4)$ (niebieskie) i zerowy poza (szare).

Przykład 9.3 (Pole widzenia bloków Gen 6). Trzon ma jądro 3 w czasie ($r = 1$, $d = 1$) i trzy bloki mają jądro 3 z $d = 1,2,4$: $R = 1+(1+2+4) = 8$ klatek, czyli $\pm 8 \cdot 23{,}2\,\text{ms} = \pm 186\,\text{ms}$. Pomiar na prawdziwym stosie (rys. 9.2b) potwierdza ± 8.

9.4 Normalizacja warstwy i połączenia resztkowe

LayerNorm

Definicja 9.6 (LayerNorm). Dla wektora $\boldsymbol{z} \in \mathbb{R}^D$ niech $\mu = \frac{1}{D}\sum z_i$ i $\sigma^2 = \frac{1}{D}\sum (z_i - \mu)^2$. *Normalizacja warstwy* to $\mathrm{LN}(\boldsymbol{z})_i = \gamma_i \dfrac{z_i - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta_i$, gdzie $\gamma, \beta \in \mathbb{R}^D$ są uczone ($\gamma = 1, \beta = 0$ na starcie), a $\varepsilon = 10^{-5}$ chroni przed dzieleniem przez zero.

Przykład 9.4. Dla $\boldsymbol{z} = (1,2,3,6)$: $\mu = 3$, $\sigma^2 = (4+1+0+9)/4 = 3{,}5$, $\sigma = 1{,}871$. Wynik (przy $\gamma = 1$, $\beta = 0$, $\varepsilon \to 0$): $(-1{,}069;\ -0{,}535;\ 0;\ 1{,}604)$ ma średnią 0 i wariancję 1.

Twierdzenie 9.7 (Niezmienniczość LayerNorm). *Dla $\varepsilon = 0$, $\gamma = 1$, $\beta = 0$ i dowolnych $a > 0$, $c \in \mathbb{R}$:* $\mathrm{LN}(a\boldsymbol{z} + c\mathbf{1}) = \mathrm{LN}(\boldsymbol{z})$.

Pomysł dowodu. Skalowanie i przesunięcie zmieniają średnią i odchylenie dokładnie w taki sposób, że licznik i mianownik skracają się.

Dowód. Dla $\boldsymbol{z}' = a\boldsymbol{z} + c\mathbf{1}$: $\mu' = a\mu + c$ oraz

$$\sigma'^2 = \frac{1}{D}\sum (a z_i + c - a\mu - c)^2 = a^2\sigma^2 \qquad \text{(wyrazy } c \text{ się znoszą)}$$

$$\frac{z'_i - \mu'}{\sigma'} = \frac{a(z_i - \mu)}{a\sigma} = \frac{z_i - \mu}{\sigma}. \qquad \text{(} a > 0\text{, więc } \sqrt{a^2} = a\text{)}$$

Obie strony równości są więc identyczne. To kończy dowód. ∎

W zwykłym języku: LayerNorm usuwa informację o skali i przesunięciu wektora cech i zostawia tylko jego „kształt”; wymusza to stabilny rozmiar liczb płynących przez sieć. Wady: nie działa na wektorach stałych ($\sigma = 0$; stąd ε).

połączenie resztkowe

Definicja 9.8 (Połączenie resztkowe). Blok z połączeniem resztkowym liczy $\boldsymbol{y} = \boldsymbol{x} + F(\boldsymbol{x})$, gdzie F to dowolna warstwa lub kilka warstw (rys. 9.3).

Twierdzenie 9.9 (Gradient przez połączenie resztkowe). *Dla $\boldsymbol{y} = \boldsymbol{x} + F(\boldsymbol{x})$ macierz pochodnych (jakobian) to $\dfrac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} = I + \dfrac{\partial F}{\partial \boldsymbol{x}}$. Dla stosu L takich bloków*

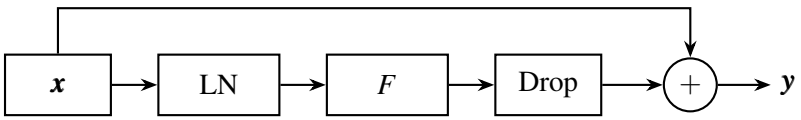
$$\frac{\partial \boldsymbol{y}_L}{\partial \boldsymbol{x}} = \prod_{l=1}^{L} \left(I + J_l\right) = I + \sum_{l} J_l + (\textit{wyrazy wyższych rzędów w } J). \tag{9.2}$$

Pomysł dowodu. Pochodna sumy to suma pochodnych, a pochodna $\boldsymbol{x}$ po $\boldsymbol{x}$ to macierz jednostkowa; dla stosu mnożymy jakobiany (reguła łańcuchowa).

Dowód. Z liniowości pochodnej $\partial(\boldsymbol{x} + F(\boldsymbol{x}))/\partial \boldsymbol{x} = \partial \boldsymbol{x}/\partial \boldsymbol{x} + \partial F/\partial \boldsymbol{x} = I + J$. Dla stosu reguła łańcuchowa daje iloczyn jakobianów kolejnych bloków. Rozwijając iloczyn $(I + J_L)\cdots(I + J_1)$ otrzymujemy I (wybór składnika I z każdego nawiasu), plus J_l (jeden nawias daje J), plus iloczyny dwóch i więcej J. Człon I nie zależy od F. To kończy dowód. ■

W zwykłym języku: nawet jeśli F ma bardzo małe pochodne, sygnał uczący przepływa przez „autostradę” I i nie znika. Dzięki temu można ułożyć wiele bloków bez ryzyka, że gradient wygaśnie po drodze.

Na konkretnych liczbach. Dla skalarnej $F(x) = 0{,}01x$ i $L = 50$ bloków: z połączeniem $\prod(1 + 0{,}01) = 1{,}01^{50} = 1{,}645$, bez niego $\prod 0{,}01 = 10^{-100}$. Gradient bez autostrady byłby praktycznie zerem.



Rysunek 9.3: Blok resztkowy typu „pre-norm” jak w warstwach Gen 6: wejście $\boldsymbol{x}$ jest normalizowane (LN), przechodzi przez F (konwolucja albo uwaga) i dropout, a następnie dodawane do niezmienionego $\boldsymbol{x}$ (górna ścieżka). Wynik: $\boldsymbol{y} = \boldsymbol{x} + \mathrm{Drop}(F(\mathrm{LN}(\boldsymbol{x})))$.

Definicja 9.10 (Dropout). W uczeniu *dropout* z prawdopodobieństwem ρ zeruje każdą współrzędną wektora, a pozostałe mnoży przez $\frac{1}{1-\rho}$. Przy wnioskowaniu nie robi nic.

Wniosek 9.11 (Dropout nie zmienia średniej). *Dla $\boldsymbol{x}$ ustalonego, $\mathbb{E}[\mathrm{Drop}(\boldsymbol{x})] = \boldsymbol{x}$.*

Dowód. Dla jednej współrzędnej x_i wynik wynosi 0 z prawdopodobieństwem ρ i $x_i/(1-\rho)$ z prawdopodobieństwem $1-\rho$. Stąd

$$\mathbb{E}[\mathrm{Drop}(x_i)] = \rho \cdot 0 + (1-\rho)\cdot \frac{x_i}{1-\rho} = x_i. \quad \text{(definicja wartości oczekiwanej)}$$

Skalowanie przez $\frac{1}{1-\rho}$ sprawia, że przy wnioskowaniu (bez dropoutu) liczby mają ten sam rząd wielkości co w uczeniu. Gen 6 używa $\rho = 0{,}1$. To kończy dowód. ■

Pułapka. LayerNorm i dropout zachowują się inaczej w uczeniu i wnioskowaniu (dropout) lub zależą od wymiaru (LayerNorm liczy po cechach jednego punktu, nie po paczce). Błąd typowy: zapomnieć wywołać `model.eval()` przed przewidywaniem; sieć wciąż losowo zeruje cechy i wyniki są inne przy każdym uruchomieniu. ♢

Podsumowanie

- Między warstwami liniowymi stawiamy nieliniowość GELU $= z\Phi(z)$.
- Konwolucja używa tych samych wag w każdym miejscu; liczba parametrów to $C_{\text{we}}C_{\text{wy}}k_t k_p + C_{\text{wy}}$ i nie zależy od długości sygnału (tw. 9.3); jest równoważna przesunięciom (tw. 9.4).
- Pole widzenia stosu konwolucji: $R = \sum d_i r_i$ (tw. 9.5); dla bloków Gen 6 $R = 8$ klatek.
- LayerNorm usuwa skalę i przesunięcie wektora cech (tw. 9.7).
- Połączenie resztkowe $\boldsymbol{x} + F(\boldsymbol{x})$ zachowuje gradient (tw. 9.9); dropout nie zmienia średniej (wn. 9.11).

Ćwiczenia

1. Policz konwolucję $x = (2,0,1,3)$ z jądrem $w = (1,2,1)$ (dla $j = -1,0,1$, $b = 0$) i dopełnieniem zerami.
2. Ile parametrów ma konwolucja 5×5 z 16 do 32 kanałów? A głębokościowa 5×5 na 32 kanałach?
3. Stos czterech konwolucji z jądrem 3 i dylatacjami $1, 2, 4, 8$. Jakie jest pole widzenia? Ile wynosiłoby bez dylatacji?
4. Policz $\mathrm{LN}(\boldsymbol{z})$ dla $\boldsymbol{z} = (4,4,8)$ ($\gamma = 1, \beta = 0, \varepsilon \to 0$).

Rozwiązania

1. $y[0] = 1\cdot 0 + 2\cdot 2 + 1\cdot 0 = 4$ (bo $x[-1] = 0$); $y[1] = 1\cdot 2 + 2\cdot 0 + 1\cdot 1 = 3$; $y[2] = 1\cdot 0 + 2\cdot 1 + 1\cdot 3 = 5$; $y[3] = 1\cdot 1 + 2\cdot 3 + 1\cdot 0 = 7$. Wynik $(4,3,5,7)$.
2. $16 \cdot 32 \cdot 25 + 32 = 12\,832$; głębokościowa: $32 \cdot 25 + 32 = 832$.
3. $R = 1 + 2 + 4 + 8 = 15$ klatek z każdej strony; bez dylatacji $R = 4$.
4. $\mu = 16/3 = 5{,}333$; $\sigma^2 = \frac{1}{3}\big(2 \cdot 1{,}778 + 7{,}111\big) = 3{,}556$, $\sigma = 1{,}886$. Wynik: $(-0{,}707;\ -0{,}707;\ 1{,}414)$.

10 Uwaga (attention)

10.1 Czemu konwolucja nie wystarcza?

Konwolucja patrzy na stały, mały sąsiad (rozdział 9). Tymczasem żeby ocenić, czy w danej klatce gra E3, sieć powinna sprawdzić, czy gra też E2 (oktawę niżej, której alikwoty zlewają się z E3) i czy ta sama nuta trwała w poprzednich klatkach. To są *dalekie* zależności, a ich siła zależy od treści: oktawa jest ważna zawsze, ale tylko wtedy, gdy dwie nuty rzeczywiście grają razem. Mechanizm, który wybiera, na co patrzeć, na podstawie treści, nazywamy *uwagą*.

Po tym rozdziale umiesz: (i) policzyć uwagę dla kilku elementów ręcznie, (ii) uzasadnić, że wynik jest średnią ważoną wartości, (iii) wyjaśnić, skąd się bierze dzielenie przez $\sqrt{d}$, (iv) policzyć liczbę parametrów warstwy uwagi i wskazać, jak nadać jej wiedzę o położeniu.

10.2 Uwaga pojedynczego zapytania

Każdy element sekwencji dostaje trzy wektory: *zapytanie* $\boldsymbol{q}$ („czego szukam"), *klucz* $\boldsymbol{k}$ („co oferuję") i *wartość* $\boldsymbol{v}$ („co przekazuję, gdy mnie wybierzesz"). Powstają z wektora cech $\boldsymbol{h}$ przez trzy macierze: $\boldsymbol{q} = W_Q\boldsymbol{h}$, $\boldsymbol{k} = W_K\boldsymbol{h}$, $\boldsymbol{v} = W_V\boldsymbol{h}$ (rozdział 4).

uwaga

Definicja 10.1 (Uwaga skalowana iloczynem skalarnym). Dla zapytania $\boldsymbol{q} \in \mathbb{R}^d$, kluczy $\boldsymbol{k}_1, \ldots, \boldsymbol{k}_n \in \mathbb{R}^d$ i wartości $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n \in \mathbb{R}^{d_v}$ oraz opcjonalnych *premii* $b_j \in \mathbb{R}$:

$$s_j = \frac{\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle}{\sqrt{d}} + b_j, \qquad \alpha_j = \operatorname{softmax}(s)_j, \qquad \operatorname{Attn}(\boldsymbol{q}) = \sum_{j=1}^{n} \alpha_j \boldsymbol{v}_j. \quad (10.1)$$

Liczby α_j nazywamy *wagami uwagi*.

Przykład 10.1 (Trzy elementy, policzone ręcznie). Niech $d = 2$, $\boldsymbol{q} = (1,0)$, klucze $\boldsymbol{k}_1 = (1,0)$, $\boldsymbol{k}_2 = (0,1)$, $\boldsymbol{k}_3 = (1,1)$, wartości $\boldsymbol{v}_1 = (1,0)$, $\boldsymbol{v}_2 = (0,1)$, $\boldsymbol{v}_3 = (2,2)$, premie $b = 0$. Wyniki $\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle = (1,0,1)$, dzielone przez $\sqrt{2}$: $s = (0{,}707;\, 0;\, 0{,}707)$. Wykładniki: $(2{,}028;\, 1;\, 2{,}028)$, suma 5,056, wagi $\alpha = (0{,}401;\, 0{,}198;\, 0{,}401)$. Wynik: $0{,}401 \cdot (1,0) + 0{,}198 \cdot (0,1) + 0{,}401 \cdot (2,2) = (1{,}203;\, 1{,}000)$. Zapytanie $(1,0)$ „pasuje" do kluczy 1 i 3 (oba mają pierwszą współrzędną 1), więc one dominują w wyniku. Gdyby klucz 3 dostał premię $b_3 = -1$, jego waga spadłaby do 0,198 i wynik zmieniłby się na $(0{,}933;\, 0{,}660)$.

Intuicja. Uwaga to miękkie wyszukiwanie w słowniku: zapytanie porównujemy ze wszystkimi kluczami (iloczyn skalarny = podobieństwo), zamieniamy podobieństwa na wagi (softmax) i zwracamy średnią wartości ważoną

tymi wagami. Zamiast jednego wyniku „dokładnie to hasło” dostajemy mieszankę wszystkich, z naciskiem na najlepiej pasujące. ♢

Twierdzenie 10.2 (Wynik uwagi to średnia ważona). *Wagi spełniają* $\alpha_j > 0$ *i* $\sum_j \alpha_j = 1$*, więc* $\mathrm{Attn}(\boldsymbol{q})$ *leży w otoczce wypukłej wartości* $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n$*: dla każdej współrzędnej* l*,* $\min_j v_{j,l} \le \mathrm{Attn}(\boldsymbol{q})_l \le \max_j v_{j,l}$.

Pomysł dowodu. Wagi są wynikiem softmaksa (tw. 8.3); średnia ważona dodatnimi wagami o sumie 1 nie wychodzi poza zakres wartości.

Dowód. Z tw. 8.3(a): $\alpha_j > 0$ i $\sum \alpha_j = 1$. Niech $m = \min_j v_{j,l}$, $M = \max_j v_{j,l}$.

$$\mathrm{Attn}(\boldsymbol{q})_l = \sum_j \alpha_j v_{j,l} \le \sum_j \alpha_j M = M \qquad (\alpha_j > 0,\ v_{j,l} \le M)$$

$$\mathrm{Attn}(\boldsymbol{q})_l \ge \sum_j \alpha_j m = m. \qquad \text{(analogicznie)}$$

Wynik leży więc między skrajnymi wartościami. Warstwa uwagi nie „wymyśla” nowych wartości spoza zakresu, tylko je miesza; to ona wybiera, w jakich proporcjach. To kończy dowód. ■

10.3 Dlaczego dzielimy przez $\sqrt{d}$

Twierdzenie 10.3 (Wariancja iloczynu skalarnego). *Jeśli współrzędne* q_i, k_i *są niezależnymi zmiennymi losowymi o średniej* 0 *i wariancji* 1*, to* $\mathbb{E}[\langle \boldsymbol{q}, \boldsymbol{k} \rangle] = 0$ *i* $\mathrm{Var}(\langle \boldsymbol{q}, \boldsymbol{k} \rangle) = d$*. Zatem* $\langle \boldsymbol{q}, \boldsymbol{k} \rangle / \sqrt{d}$ *ma wariancję* 1 *niezależnie od* d.

Pomysł dowodu. Iloczyn skalarny to suma d niezależnych składników $q_i k_i$, z których każdy ma średnią 0 i wariancję 1; wariancje niezależnych składników się dodają.

Dowód. Dla jednego składnika, z niezależności q_i i k_i:

$$\mathbb{E}[q_i k_i] = \mathbb{E}[q_i]\,\mathbb{E}[k_i] = 0, \qquad \text{(niezależność)}$$

$$\mathrm{Var}(q_i k_i) = \mathbb{E}[q_i^2 k_i^2] = \mathbb{E}[q_i^2]\,\mathbb{E}[k_i^2] = 1 \cdot 1 = 1. \qquad (\text{średnia 0, więc } \mathrm{Var} = \mathbb{E}[\cdot^2])$$

Składniki są niezależne, więc wariancja sumy to suma wariancji: $\mathrm{Var}\left(\sum_i q_i k_i\right) = d$. Dzielenie przez $\sqrt{d}$ dzieli wariancję przez d (stała wychodzi do kwadratu). To kończy dowód. ■

W zwykłym języku: im dłuższe wektory, tym większe losowe wyniki iloczynów. Duże wyniki wpychają softmax w nasycenie (jedna waga bliska 1, reszta ≈ 0), gdzie jego gradient zanika. Skalowanie utrzymuje wyniki w rozsądnym zakresie (rys. 10.1c: pomarańczowy rozrzut rośnie jak $\sqrt{d}$, niebieski, po skalowaniu, jest stały).

10.4 Uwaga dla całej sekwencji i premie położenia

Gdy każdy z n elementów jest też zapytaniem, wszystko zapisujemy macierzowo: $Q, K, V \in \mathbb{R}^{n \times d}$ (wiersze to wektory), $\mathrm{Attn}(Q,K,V) = \mathrm{softmax}\big(QK^\top/\sqrt{d} + B\big)V$, gdzie softmax działa na każdy wiersz, a $B \in \mathbb{R}^{n \times n}$ to macierz premii. Wynikiem jest nowy zestaw n wektorów.

Twierdzenie 10.4 (Bez premii uwaga nie zna kolejności). *Niech P będzie macierzą permutacji. Dla $B = 0$:* $\mathrm{Attn}(PQ, PK, PV) = P\,\mathrm{Attn}(Q, K, V)$.

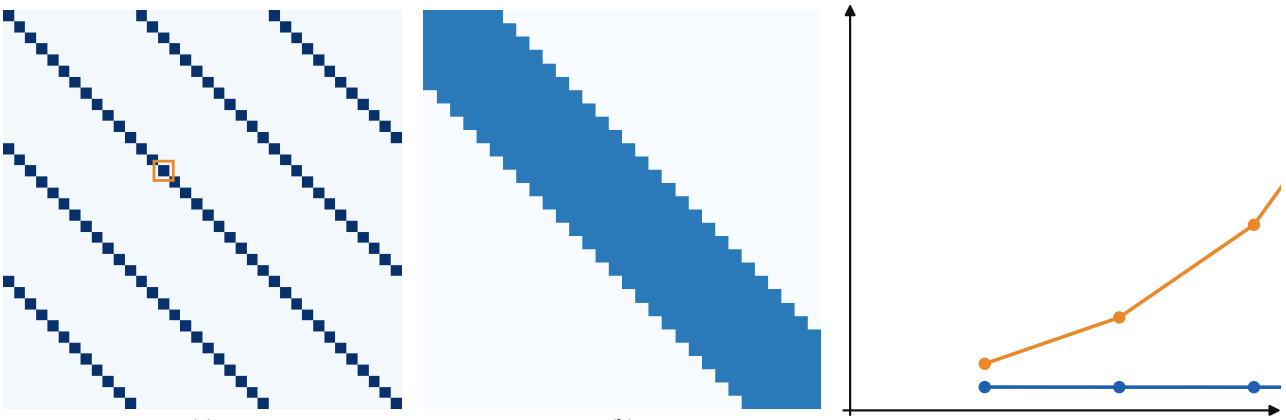
Pomysł dowodu. Permutacja wierszy Q, K permutuje wiersze i kolumny macierzy wyników w ten sam sposób; softmax po wierszach tego nie zauważa.

Dowód. $(PQ)(PK)^\top = PQK^\top P^\top$, więc macierz wyników S zamienia się w $PSP^\top$: wiersze i kolumny są przetasowane tak samo. Softmax liczony po wierszach przestawia kolumny wewnątrz wiersza bez zmiany wag, a P przestawia wiersze: $\mathrm{softmax}(PSP^\top) = P\,\mathrm{softmax}(S)\,P^\top$. Stąd

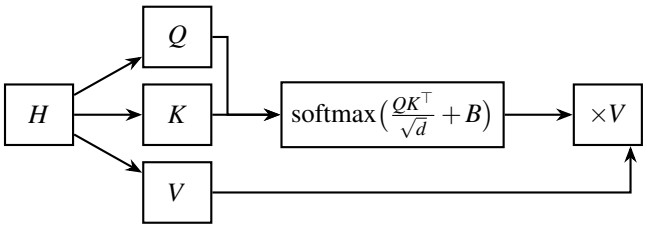
$$\begin{aligned}\mathrm{Attn}(PQ, PK, PV) &= P\,\mathrm{softmax}(S)\,P^\top PV && (P^\top P = I)\\ &= P\,\mathrm{Attn}(Q, K, V). && (\text{def.})\end{aligned}$$

Przetasowanie wejścia tylko przetasowuje wyjście. To kończy dowód. ■

W zwykłym języku: samo „co” nie mówi „gdzie”. Gdyby klatki wymieszać, uwaga nie zauważy. Dlatego dodajemy *premię zależną od odległości* b_{j-i} (wyuczoną liczbę dla każdej różnicy położeń): sieć może się nauczyć, że odległość 12 półtonów (oktawa) jest szczególnie ważna, albo że klatka sprzed 0,5 s ma inną wagę niż sąsiednia. Niektóre pary można też zablokować, ustawiając $b = -\infty$ (waga wtedy dokładnie 0): tak powstaje *okno* $|j - i| \le W$ (rys. 10.1b), które w Gen 6 ma $W = 43$ klatki (≈ 1 s) i kosztuje $O(n(2W+1))$ zamiast $O(n^2)$.



Rysunek 10.1: (a) Zabawka: 36 półtonów, a zapytanie i klucz to wskazanie klasy wysokości (i mod 12). Każdy wiersz macierzy wag α ma ciemne pola tylko dla tej samej klasy, czyli co 12 półtonów: wysokość 14 (pomarańczowa ramka) patrzy na 2, 14 i 26 — uwaga potrafi „zobaczyć” oktawy. (b) Maska okna $|t - u| \le 5$ dla 30 klatek: tylko pasmo wokół przekątnej ma niezerowe wagi. (c) Odchylenie standardowe $\langle \boldsymbol{q}, \boldsymbol{k} \rangle$ dla wymiarów $d = 4, 16, 64, 256$ (oś pozioma $\log_2 d$): bez skalowania (pomarańczowa) rośnie jak $\sqrt{d}$, po podzieleniu przez $\sqrt{d}$ (niebieska) jest równe 1. Obliczone z 10^5 losowych par.



Rysunek 10.2: Przepływ danych jednej głowicy uwagi. Wektory cech $H \in \mathbb{R}^{n \times D}$ są rzutowane na $Q, K, V \in \mathbb{R}^{n \times d_h}$; iloczyny $QK^\top \in \mathbb{R}^{n \times n}$ (wyniki dopasowania), dzielone przez $\sqrt{d}$ i powiększone o premie B, przechodzą przez softmax wiersz po wierszu; powstałe wagi mnożą V i dają wyjście $n \times d_h$.

10.5 Wiele głowic i liczba parametrów

Jedna uwaga potrafi śledzić jedną zależność naraz. *Wielogłowicowa* uwaga dzieli wektor D-wymiarowy na n_h części po $d_h = D/n_h$, w każdej liczy osobną uwagę (osobne W_Q, W_K, W_V i osobne premie), skleja wyniki i mnoży przez W_O. W Gen 6: $D = 64$, $n_h = 4$, $d_h = 16$.

Na konkretnych liczbach. Macierz $W_{QKV}\colon 64 \to 192$ (trzy macierze naraz) ma $64 \cdot 192 + 192 = 12\,480$ parametrów; $W_O\colon 64 \to 64$ ma $64 \cdot 64 + 64 = 4160$. Premie czasowe: $n_h(2W+1) = 4 \cdot 87 = 348$; premie między wysokościami: $n_h(2S-1) = 4 \cdot 105 = 420$ (dla $S = 53$). Uwaga w czasie ma więc $12\,480 + 4160 + 348 = 16\,988$ parametrów, a uwaga między wysokościami $12\,480 + 4160 + 420 = 17\,060$ — zgodnie z dodatkiem **??**.

Pułapka. Wagi uwagi (rys. 10.1a) bywają interpretowane jako „wyjaśnienie" decyzji modelu. To tylko część obrazu: po uwadze są jeszcze macierze W_O, normalizacja i kolejne warstwy, a każda głowica widzi inne części wektora. Wagi uwagi pokazują, skąd model brał informacje w jednym kroku, a nie dlaczego podjął decyzję. ♢

Podsumowanie

- Uwaga: $\mathrm{Attn}(\boldsymbol{q}) = \sum_j \mathrm{softmax}(\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle / \sqrt{d} + b_j)\, \boldsymbol{v}_j$.
- Wynik to średnia ważona wartości, więc nie wychodzi poza ich zakres (tw. 10.2).
- Dzielenie przez $\sqrt{d}$ utrzymuje wariancję wyników na 1 (tw. 10.3).
- Bez premii uwaga nie odróżnia kolejności (tw. 10.4); premia zależna od odległości daje jej wiedzę o położeniu i pozwala wyróżnić oktawę lub zablokować dalekie pary (okno).
- Wiele głowic = wiele zależności naraz; Gen 6: $n_h = 4$, $d_h = 16$.

Ćwiczenia

1. Dla $\boldsymbol{q} = (0,2)$, kluczy $(1,0), (0,1)$ i wartości $(5,0), (0,5)$ (z $d = 2$) policz wagi i wynik uwagi.
2. Pokaż, że dodanie tej samej stałej c do wszystkich premii b_j nie zmienia wag α_j.
3. Elementy mają $d = 100$ i współrzędne q_i, k_i o wariancji 1. Jakie odchylenie standardowe ma $\langle \boldsymbol{q}, \boldsymbol{k} \rangle$ bez skalowania, a jakie po skalowaniu?
4. Ile parametrów ma wielogłowicowa uwaga z $D = 128$, $n_h = 8$ (bez premii)?

Rozwiązania

1. $\langle \boldsymbol{q}, \boldsymbol{k}_j \rangle = (0,2)$, dzielone przez $\sqrt{2}$: $(0;\, 1{,}414)$, wykładniki $(1;\, 4{,}113)$, suma $5{,}113$, wagi $(0{,}196;\, 0{,}804)$. Wynik $0{,}196(5,0) + 0{,}804(0,5) = (0{,}978;\, 4{,}022)$.
2. Z tw. 8.3(b): $\mathrm{softmax}(s + c\mathbf{1}) = \mathrm{softmax}(s)$.

3. Bez skalowania $\sqrt{100} = 10$; po skalowaniu 1 (tw. 10.3).
4. W_{QKV}: $128 \cdot 384 + 384 = 49\,536$; W_O: $128 \cdot 128 + 128 = 16\,512$; razem 66 048 (liczba głowic nie zmienia liczby parametrów, tylko sposób ich podziału).

11 Optymalizacja: jak sieć się uczy

11.1 Od gradientu do działającego uczenia

W rozdziale 5 poznaliśmy spadek gradientu $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla L$. W praktyce potrzeba czterech poprawek: (i) gradient liczymy z *małej porcji* danych, nie ze wszystkich (SGD), (ii) dostosowujemy krok do każdego parametru osobno (Adam), (iii) dodajemy zanik wag, (iv) zmieniamy krok η w czasie (harmonogram). Ten rozdział uzasadnia każdy z tych kroków i podaje wartości użyte w Gen 6.

Po tym rozdziale umiesz: (i) wskazać największy bezpieczny krok uczenia dla paraboli, (ii) policzyć krok Adama, (iii) obliczyć wartość kroku w dowolnej chwili harmonogramu z rozgrzewką i kosinusem, (iv) uzasadnić przycinanie gradientu.

11.2 Kiedy spadek gradientu się zbiega?

Twierdzenie 11.1 (Kryterium stabilności). *Dla $L(\boldsymbol{x}) = \frac{1}{2}\sum_i \lambda_i x_i^2$ z $\lambda_i > 0$ spadek gradientu z krokiem η daje $x_i^{(k)} = (1-\eta\lambda_i)^k x_i^{(0)}$. Zbiega on do zera dla każdej współrzędnej wtedy i tylko wtedy, gdy $\eta < 2/\lambda_{\max}$. Najszybszy zbieżny wybór to $\eta^* = \dfrac{2}{\lambda_{\min}+\lambda_{\max}}$, z współczynnikiem $\rho = \dfrac{\lambda_{\max}-\lambda_{\min}}{\lambda_{\max}+\lambda_{\min}}$ na krok.*

Pomysł dowodu. Funkcja jest rozdzielona po współrzędnych, więc każda ewoluuje osobno jak ciąg geometryczny o ilorazie $1-\eta\lambda_i$; ciąg zbiega do zera, gdy $|1-\eta\lambda_i| < 1$.

Dowód. $\partial L/\partial x_i = \lambda_i x_i$, więc

$$\begin{aligned} x_i^{(k+1)} &= x_i^{(k)} - \eta\lambda_i x_i^{(k)} && \text{(def. 5.6)} \\ &= (1-\eta\lambda_i)\, x_i^{(k)}. && \text{(wyłączenie)} \end{aligned}$$

Z indukcji $x_i^{(k)} = (1-\eta\lambda_i)^k x_i^{(0)}$. Ciąg geometryczny zbiega do 0 dla dowolnej wartości początkowej wtedy i tylko wtedy, gdy $|1-\eta\lambda_i| < 1$, czyli $0 < \eta\lambda_i < 2$. Warunek dla wszystkich i jednocześnie to $\eta < 2/\lambda_{\max}$ (najostrzejszy). Tempo ogranicza współrzędna z największym $|1-\eta\lambda_i|$, czyli $\rho(\eta) = \max\big(|1-\eta\lambda_{\min}|, |1-\eta\lambda_{\max}|\big)$. Pierwszy argument maleje z η, drugi (dla $\eta > 1/\lambda_{\max}$) rośnie; przecinają się, gdy $1-\eta\lambda_{\min} = \eta\lambda_{\max} - 1$, czyli $\eta^* = 2/(\lambda_{\min}+\lambda_{\max})$, a wtedy $\rho = 1-\eta^*\lambda_{\min} = (\lambda_{\max}-\lambda_{\min})/(\lambda_{\max}+\lambda_{\min})$. To kończy dowód. ∎

W zwykłym języku: najbardziej „stromy” kierunek (największe λ) ogranicza krok dla całej doliny, a najbardziej płaski (najmniejsze λ) ogranicza

tempo. Im bardziej wydłużona dolina ($\lambda_{\max}/\lambda_{\min}$ duże), tym wolniej schodzimy.

Na konkretnych liczbach. Dolina z rozdziału 5: $\lambda = (1, 10)$. Granica kroku: $2/10 = 0{,}2$. Dla $\eta = 0{,}19$ współrzędna y mnoży się przez $1 - 1{,}9 = -0{,}9$ w każdym kroku: zbieżna, ale z drżeniem. Dla $\eta = 0{,}21$: $1 - 2{,}1 = -1{,}1$ — błąd rośnie 10% na krok i metoda się rozbiega. Najlepszy krok $\eta^* = 2/11 = 0{,}182$ daje $\rho = 9/11 = 0{,}818$: żeby zmniejszyć błąd 1000-krotnie, potrzeba $\ln 10^{-3} / \ln 0{,}818 \approx 34$ kroków (rys. 11.2a).

Intuicja. Wyobraź sobie kulkę w długim, wąskim korycie. Gradient w poprzek koryta jest ogromny, a wzdłuż niego malutki, więc zwykły spadek gradientu musi używać małego kroku (bezpiecznego dla ściany) i wolno posuwa się wzdłuż koryta. Adam dzieli ruch w każdej osi przez jej typową skalę gradientu, dzięki czemu obie osie robią krok podobnej wielkości *bez ręcznego dobierania η do skali każdego parametru*. Uczciwie trzeba dodać: na prostej paraboli z *idealnie* dobranym krokiem zwykły spadek gradientu jest lepszy (rys. 11.1); zaleta Adama ujawnia się w sieciach, gdzie skale gradientów różnią się między warstwami o wiele rzędów wielkości i jednego dobrego η nie da się wybrać. ♢

11.3 SGD i jego szum

Strata całego zbioru to średnia strat pojedynczych próbek: $L(\boldsymbol{\theta}) = \frac{1}{N}\sum_n \ell_n(\boldsymbol{\theta})$. Liczenie jej gradientu dla $N = 15\,600$ nagrań w każdym kroku byłoby za drogie, więc losujemy *paczkę* B i bierzemy $\hat{g} = \frac{1}{|B|}\sum_{n\in B}\nabla\ell_n$.

Twierdzenie 11.2 (Gradient z paczki jest nieobciążony). *Jeśli B składa się z $|B|$ próbek wylosowanych niezależnie i równomiernie z $\{1,\dots,N\}$, to* $\mathbb{E}[\hat{g}] = \nabla L(\boldsymbol{\theta})$.

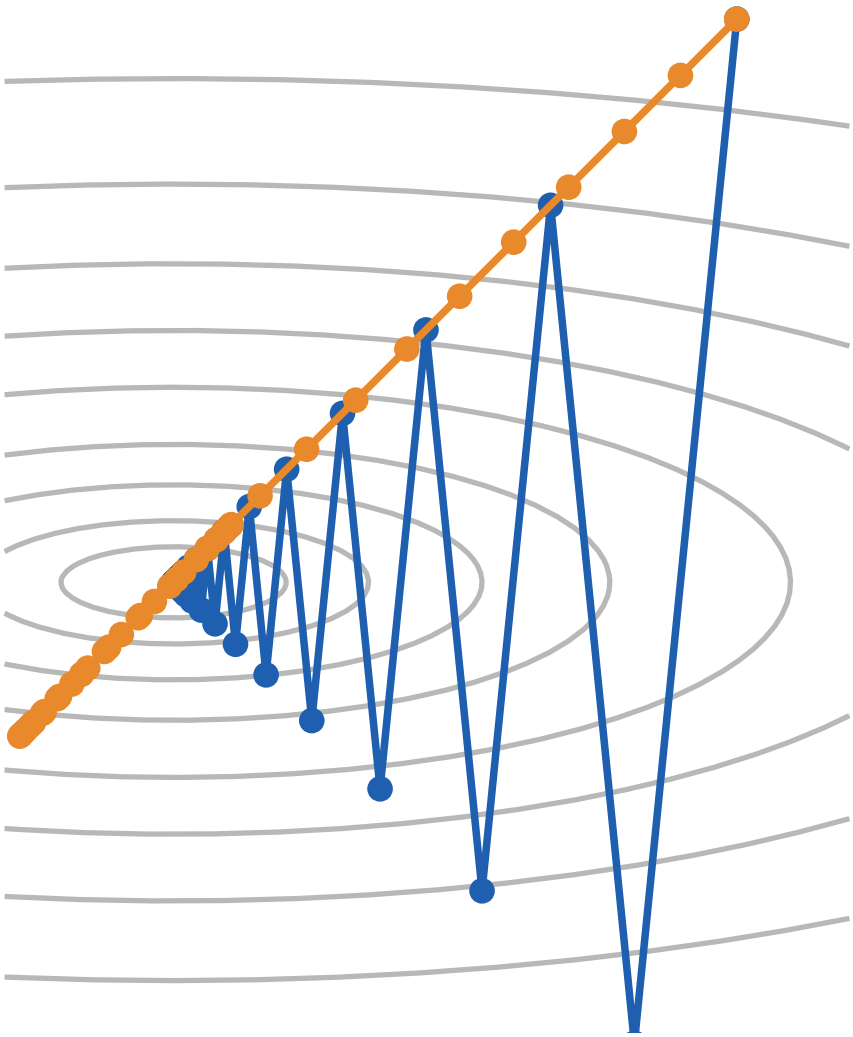
Pomysł dowodu. Każda próbka trafia do paczki z prawdopodobieństwem $\frac{1}{N}$; wartość oczekiwana średniej to średnia wartości oczekiwanych.

Dowód.

$$\begin{aligned}
\mathbb{E}[\hat{g}] &= \frac{1}{|B|}\sum_{j=1}^{|B|}\mathbb{E}\left[\nabla\ell_{n_j}\right] && \text{(liniowość } \mathbb{E}\text{)}\\
&= \frac{1}{|B|}\sum_{j=1}^{|B|}\sum_{n=1}^{N}\frac{1}{N}\nabla\ell_n && (n_j \text{ jednostajne})\\
&= \frac{1}{N}\sum_{n=1}^{N}\nabla\ell_n = \nabla L(\boldsymbol{\theta}). && (|B| \text{ jednakowych składników})
\end{aligned}$$

Gradient z paczki jest więc szumem wokół prawdziwego, ze średnią równą prawdziwemu; jego wariancja maleje jak $1/|B|$. To kończy dowód. ■

W Gen 6 paczka to 16 losowych wycinków po 192 klatki (4,4 s); wycinki są losowane z trzech źródeł z prawdopodobieństwami 0,5 (klasyka), 0,3 (GuitarSet) i 0,2 (środowiska).



Rysunek 11.1: Ta sama dolina $L = \frac{1}{2}(x^2 + 10y^2)$ co w rozdziale 5, start $(1,1)$, 40 kroków. Niebieska: spadek gradientu z optymalnym krokiem $2/11$ (strata końcowa $6 \cdot 10^{-7}$). Pomarańczowa: Adam z $\eta = 0{,}1$ (strata końcowa 0,056: długie kroki w obu osiach, ale potem drży wokół minimum). Szare warstwice to poziomy strat. Na tej prostej paraboli, przy idealnie dobranym kroku, wygrywa zwykły spadek gradientu. Obie ścieżki obliczone programem.

11.4 Adam i AdamW

W różnych częściach sieci gradienty mają bardzo różną skalę. *Adam* utrzymuje dla każdego parametru wygładzoną średnią gradientu m i wygładzoną średnią jego kwadratu v:

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2,$$

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \qquad \hat{v}_t = \frac{v_t}{1-\beta_2^t}, \qquad \theta_t = \theta_{t-1} - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} + \lambda \theta_{t-1} \right),$$

z $m_0 = v_0 = 0$, zwykle $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$. Człon $\lambda\theta$ to *zanik wag* (w AdamW dodawany osobno; Gen 6: $\lambda = 10^{-4}$), który delikatnie ściąga wagi do zera i ogranicza przeuczenie.

Twierdzenie 11.3 (Korekta obciążenia i niezmienniczość skali). *(a) Jeśli $g_t = g$ jest stałe, to $m_t = (1-\beta_1^t)g$, więc $\hat{m}_t = g$. (b) Jeśli pomnożymy wszystkie gradienty przez $c > 0$, to przy $\varepsilon \to 0$ krok Adama się nie zmienia.*

Pomysł dowodu. (a) Indukcja po t; (b) $\hat{m}$ rośnie c razy, a $\sqrt{\hat{v}}$ też c razy; czynnik się skraca.

Dowód. (a) Dla $t=1$: $m_1=(1-\beta_1)g=(1-\beta_1^1)g$. Jeśli $m_{t-1}=(1-\beta_1^{t-1})g$, to

$$\begin{aligned} m_t &= \beta_1(1-\beta_1^{t-1})g+(1-\beta_1)g && \text{(założenie indukcyjne)}\\ &= (\beta_1-\beta_1^t+1-\beta_1)g=(1-\beta_1^t)g. && \text{(redukcja)}\end{aligned}$$

Dzielenie przez $1-\beta_1^t$ daje $\hat{m}_t=g$. Bez korekty pierwsze kroki byłyby $1-\beta_1=10\%$ właściwej wartości. (b) $\hat{m}\mapsto c\hat{m}$ (liniowość), $\hat{v}\mapsto c^2\hat{v}$, $\sqrt{\hat{v}}\mapsto c\sqrt{\hat{v}}$, więc $\hat{m}/\sqrt{\hat{v}}$ się nie zmienia. To kończy dowód. ■

Przykład 11.1 (Pierwszy krok Adama). Dla $t=1$: $\hat{m}_1=g_1$ i $\hat{v}_1=g_1^2$, więc krok to $\eta g_1/|g_1|=\eta\,\mathrm{sgn}(g_1)$ ($\varepsilon\to 0$). Dla gradientów $(0{,}001;\ 100)$ oba parametry zmienią się o dokładnie $\eta=10^{-3}$. Zwykły SGD zmieniłby je o 10^{-6} i $0{,}1$, czyli o liczby różniące się pięć rzędów wielkości.

przycinanie gradientu

Definicja 11.4 (Przycinanie gradientu). Zamiast g używamy $g\cdot\min(1,\,c/\,\|g\|)$ (norma po wszystkich parametrach). Dla $\|g\|\le c$ nic się nie zmienia; dla większej normy kierunek zostaje, a długość spada do c.

Przykład 11.2. Dla $g=(3,4)$, $\|g\|=5$, $c=1$: $g\cdot\min(1,0{,}2)=(0{,}6;\,0{,}8)$, długość 1. Gen 6 przycina do $c=1$: pojedynczy dziwny wycinek nie wytrąci sieci z toru.

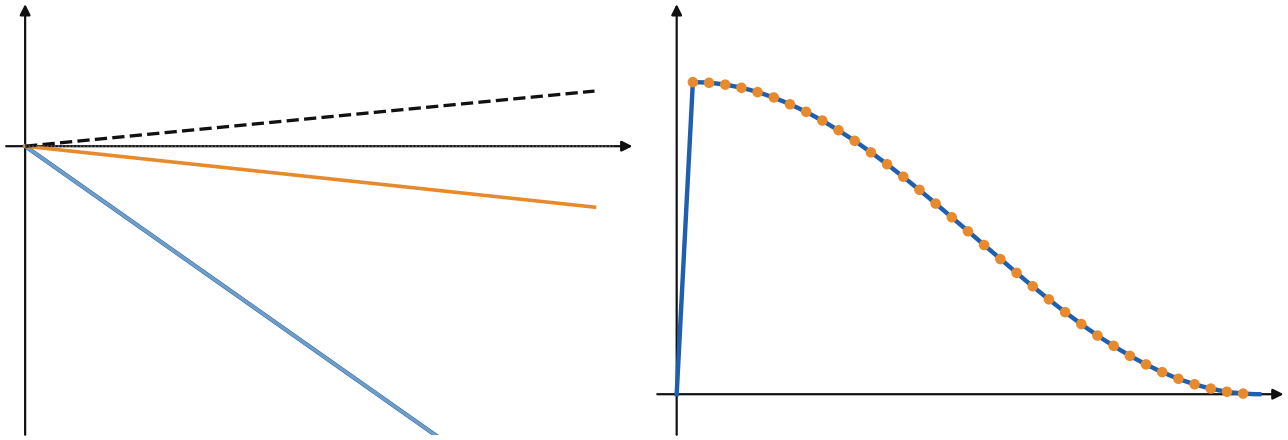
11.5 Harmonogram kroku

Na początku uczenia wagi są losowe, a Adam ma jeszcze niedokładne $\hat{v}$ — duży krok łatwo wszystko zepsuje; pod koniec chcemy kroku małego, by osiąść w dolinie. Stosujemy *rozgrzewkę* (liniowy wzrost od 0 do η_0 przez W kroków) i potem *spadek kosinusowy*:

$$\eta(t)=\begin{cases}\eta_0\,\dfrac{t}{W}, & t<W,\\[2mm] \eta_0\cdot\tfrac{1}{2}\bigl(1+\cos\pi q\bigr), \quad q=\dfrac{t-W}{T-W}, & t\ge W.\end{cases} \tag{11.1}$$

Na konkretnych liczbach. Sesja 1 Gen 6: $\eta_0=10^{-3}$, $W=1000$, $T=36\,000$ (36 epok po 1000 kroków). Dla $t=500$: $\eta=5\cdot10^{-4}$. Dla $t=15\,000$ ($q=0{,}4$): $\eta=10^{-3}\cdot\frac{1}{2}(1+\cos 0{,}4\pi)=6{,}55\cdot10^{-4}$, a dziennik uczenia zapisał na końcu epoki 14 wartość $6{,}55\cdot10^{-4}$. W połowie ($t=18\,500$, $q=0{,}5$): $5\cdot10^{-4}$. Na końcu $\eta\to 0$.

W Gen 6 uczenie przebiegło w trzech sesjach (w sumie 97 epok): sesja 1 z $\eta_0=10^{-3}$, sesja 3 (restart) z $4\cdot10^{-4}$, sesja 4 z $3\cdot10^{-4}$ i harmonogramem kosinusowym liczonym od *czasu*, a nie od liczby kroków (żeby skończyć dokładnie w limicie GPU).



(a) (b)

Rysunek 11.2: (a) Spadek gradientu dla $\lambda = 10$ ($\log_{10}|x|$ w kolejnych krokach): $\eta = 0{,}05$ (niebieska) i 0,15 (jasnoniebieska) zbiegają; $\eta = 0{,}19$ (pomarańczowa) zbiega z wolno gasnącym drżeniem; $\eta = 0{,}21 > 2/\lambda$ (czarna przerywana) rozbiega się. Szara kropkowana to poziom początkowy. (b) Harmonogram kroku z rozgrzewką i spadkiem kosinusowym (niebieska) oraz wartości zapisane w dzienniku prawdziwego uczenia Gen 6 po każdej epoce (pomarańczowe kropki): leżą dokładnie na krzywej.

Pułapka. Ten sam model bez rozgrzewki lub z za dużym η może się „rozjechać" w pierwszych setkach kroków i nigdy nie dojść do dobrego wyniku; objaw to strata, która nagle skacze do dużej wartości lub `NaN`. Warto zapisywać stan modelu po każdej epoce (Gen 6 tak robi) i umieć wznowić uczenie od zapisu. ♢

Podsumowanie

- Spadek gradientu na paraboli zbiega, gdy $\eta < 2/\lambda_{\max}$; tempo zależy od $\lambda_{\max}/\lambda_{\min}$ (tw. 11.1).
- Gradient z paczki jest nieobciążonym, zaszumionym oszacowaniem gradientu pełnego (tw. 11.2).
- Adam normuje krok przez $\sqrt{\hat{v}}$: ma niezmienniczą skalę, a korekta obciążenia daje $\hat{m} = g$ dla stałego gradientu (tw. 11.3). AdamW dodaje zanik wag $\lambda = 10^{-4}$.
- Przycinanie gradientu do normy 1 chroni przed pojedynczymi dziwnymi paczkami.
- Harmonogram: rozgrzewka 1000 kroków, potem kosinus do zera; dziennik uczenia Gen 6 zgadza się ze wzorem.

Ćwiczenia

1. Dla $\lambda = (2, 50)$ podaj granicę kroku i najlepszy krok η^* oraz współczynnik ρ.
2. Policz pierwszy krok AdamW dla $\theta = 0{,}5$, $g = -0{,}2$, $\eta = 10^{-3}$, $\lambda = 10^{-4}$ ($t = 1$, $\varepsilon \to 0$).
3. Oblicz $\eta(t)$ dla $\eta_0 = 3 \cdot 10^{-4}$, $W = 1000$, $T = 49\,000$, $t = 25\,000$.
4. Pokaż, że przycinanie gradientu do normy c nie zmienia jego kierunku.

Rozwiązania

1. Granica $2/50 = 0{,}04$; $\eta^* = 2/52 = 0{,}0385$; $\rho = 48/52 = 0{,}923$ (bardzo wolno: wydłużona dolina).
2. $\hat{m}/\sqrt{\hat{v}} = g/|g| = -1$, więc $\theta \leftarrow \theta - \eta\big(-1 + \lambda\theta\big) = 0{,}5 - 10^{-3}(-1 + 0{,}5 \cdot 10^{-4}) = 0{,}5 + 10^{-3} \cdot 0{,}99995 = 0{,}50099995$.
3. $q = (25\,000 - 1000)/48\,000 = 0{,}5$, więc $\eta = 3 \cdot 10^{-4} \cdot \frac{1}{2}(1+0) = 1{,}5 \cdot 10^{-4}$.
4. Nowy wektor to $s\,g$ z $s = \min(1, c/\,\|g\|) > 0$, czyli dodatnia wielokrotność g: kierunek $(g/\,\|g\|)$ pozostaje ten sam, zmienia się tylko długość.